LLM-BLM 実験 2

LLM が決算発表文から読み取る判断は、
発表への株価の反応を説明するか：事前登録したイベントの評価

実験の結果の報告書

2026 年 10 月 18 日

概要

前回の実験（『LLM-BLM 実験結果レポート』、H01〜H07）で、LLM に翌月のリターンを数値で予想させる構成は、入力の写しで価値がないと分かった。LLM を使う意味が残っていたのは、決算発表文から読み取った点数だけだった。今回は、その点数を「月次の断面」ではなく「決算発表 1 本ごとのイベント」として評価した。評価の手順と判定の基準は、株価の反応を計算する前に文書とコードで固定し（事前登録）、1 回だけ実行した。

主な結論

- **gpt-4o-mini の点数は、発表への株価の反応をはっきり説明する（支持）**。点数が 1 標準偏差高いと、発表をはさむ 2 取引日の超過リターンは +1.20% 高い（95% 区間 +0.95〜+1.45%、t 9.4）。同じ発表日の中で点数を入れ替えた対照 1,000 回では、実際を超えたものは 0 回だった。標本は 2023 年 11 月〜2026 年 8 月の 5,374 本で、gpt-4o-mini はこの期間の株価を知らない。
- **LLM を使わない方法の情報を、LLM の点数がほぼ含んでいる**。FinBERT、TF-IDF ＋リッジ、数値の驚き（SUE）は、それぞれ単独では反応を説明する。しかし LLM の点数と同時に入れると、文章の 3 つの方法の効果はほぼ 0 になった。LLM の効果は、FinBERT や TF-IDF の約 3 倍である。
- **ただし、取引には使えない**。反応は発表の 2 日のうちに出て、その後の 2〜21 日目のドリフトは有意でない（+0.10%、t 0.8）。点数を知ったときには、株価はすでに動いている。
- **先読みのない小さなモデル（ChronoGPT、1.55B）は、質問に答えさせる使い方ではほとんど読み取れない**。同じ標本で +0.04%（t 0.4）、2016〜2023 年の 14,204 本で +0.09%（Holm の補正の後 $p = 0.089$）。
- 関連の確認として、BLM の共分散のノイズ除去（Marcenko–Pastur）を比べた。制約のない最小分散では効くが、BLM の最適化（空売りなし、TE の上限）では今の Ledoit–Wolf のほうがわずかに良かった（付録 A）。

意味：LLM は、決算発表文から「市場がどう受け取るか」を、辞書や FinBERT より正確に読み取れる。これは LLM の読む力の確かな証拠だが、発表の後に取引する戦略や、月次の BLM のビューの価値にはならない。前回の H06（翌月のリターンは説明できない）と、今回の結果は矛盾しない。

目次

概要 1

第 1 章　前回の結果と、問いの立て直し 3
1.1　前回の実験から分かっていたこと . . . 3
1.2　方針と文献調査 . . . 3
1.3　今回の問い . . . 3

第 2 章　データ 4
2.1　決算発表文 . . . 4
2.2　発表の時刻と、反応の日 . . . 4
2.3　数値の驚き . . . 5

第 3 章　点数の付け方 6

第 4 章　評価の方法と事前登録 7
4.1　事前登録 . . . 7
4.2　主な検定 . . . 7

第 5 章　結果 8
5.1　主な検定 . . . 8
5.2　LLM を使わない方法との比較 . . . 8
5.3　反応の後：ドリフト . . . 9
5.4　副次の分析と頑健性 . . . 9

第 6 章　考察 11
6.1　LLM は何を読み取っているか . . . 11
6.2　取引と BLM にとっての意味 . . . 11
6.3　先読みのないモデル . . . 11

第 7 章　限界 12

第 8 章　次に行うこと 13

付録 A　共分散のノイズ除去（X01） 14

付録 B　再現の手順と記録 16

参考文献 17

第 1 章

前回の結果と、問いの立て直し

1.1　前回の実験から分かっていたこと

前回の 7 つの仮説の検証（2024 年 3 月〜2026 年 8 月の 30 か月）で、次のことが分かった。

- LLM の翌月のリターンの数値予想は、渡した月の値動きの写しだった（決定係数 0.81）。写しを除いた固有の IC は −0.004。
- 回答のばらつきは、誤差の大きさとしては使えない。BLM は、当たり具合で較正した Ω と TE の上限で設計どおりに動くが、成績は予想を並べ替えたビューと区別できなかった。
- 決算発表文（8-K の EX-99.1）を gpt-4o-mini に読ませた点数は、直近の値動きをなぞらず、業績の伸びに沿っていた。しかし翌月のリターンに対する月次の検定では、30 か月で有意にならなかった（H06）。

1.2　方針と文献調査

前回の結果を受けて、次に何をするかの方針を Claude・GPT・Gemini の 3 者に独立に書かせて比べ、さらに Gemini Deep Research を加えた 4 者で先行研究を調べた（**資料集/03_ 方針と文献調査/**）。3 者と文献が一致したのは、次の点である。

1. LLM に数値のリターンを予想させる構成はやめる。LLM は直近の値を外挿しすぎ、楽観に寄る（Chen ほか 2024）。
2. LLM の役割は、決算発表文から決まった形の判断（ガイダンスの変更、見通し、語調）を取り出すことに絞る。
3. 評価の単位を、月次の断面から決算発表ごとのイベントに移す。件数が増え、検出力が上がる。
4. LLM を使わない文章の分析（辞書、FinBERT、TF-IDF）と比べる。
5. 知識の期限より前の文章は、社名を伏せても記憶から復元されるので、gpt-4o-mini では確認に使えない（Lopez-Lira・Tang・Zhu 2025）。代わりに、年ごとに学習を区切って公開されている ChronoGPT（He ほか 2025）で読む。

文献からは、方針を変える発見もあった。決算発表文の内容は、翌朝の寄り付きで株価に完全に反映される（Wu ほか 2025）。そこで、主な目的変数を「発表の後のドリフト」ではなく「発表への反応」にし、ドリフトは副次の分析にした。

1.3　今回の問い

主な問い

LLM（gpt-4o-mini）が決算発表文から取り出した判断は、数値の驚き（SUE など）と、LLM を使わない文章の分析（辞書・FinBERT・TF-IDF）を超えて、発表への株価の反応を説明するか。

副次の問いは、(S1) 発表の後のドリフトも予測するか、(S2・S3) 先読みのない ChronoGPT でも同じことが言えるか、(S4) 語調・見通し・ガイダンスのどれが効くか、の 4 つである。

第 2 章

データ

2.1　決算発表文

SEC EDGAR から、S&P500 の構成銘柄（期間中に一度でも入った銘柄）の 8-K のうち、Item 2.02（決算の発表）を含むものを取得した。本文には、添付の EX-99.1（プレスリリース）を選んだ。

表2.1: 取得した決算発表と、評価に使った標本。

	件数	備考
取得した 8-K（2015-01〜2026-08）	28,447	本文が取れたもの 28,108
基本の標本	23,056	提出日に S&P500 の構成銘柄、本文が EX-99、同じ銘柄・同じ日の重複を除く
標本 A（主）	5,374	2023-11〜2026-08、gpt-4o-mini の点数あり、519 社、527 の発表日
標本 B（副）	14,204	2016-01〜2023-10、ChronoGPT の点数あり、514 社
株価が欠けて除いた発表	A：0、B：1,373	B は上場廃止などで株価が取れない銘柄

すべて新しい DB の表（`earnings_releases`、`release_scores` など）に入れた。前回の H06 の 6,209 本と 5,429 本の点数も、この表に移した（件数と費用 3.31 ドルが記録と一致することを確かめた）。

2.2　発表の時刻と、反応の日

EDGAR の受理時刻（UTC）をニューヨーク時間に直し、時間帯で反応の日（`event_date`、終値が初めて発表を織り込む取引日）を決めた。寄り前と場中の受理はその日、16 時以後の受理は次の取引日である。

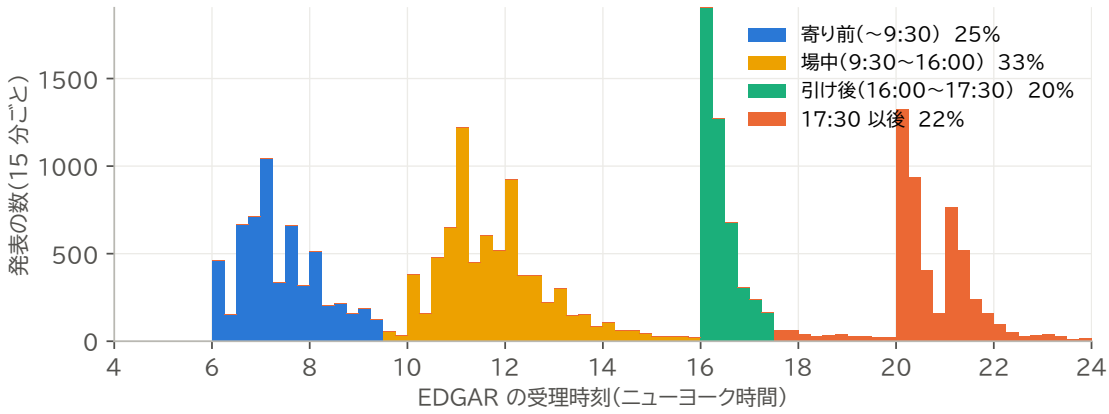


図2.1: EDGAR の受理時刻の分布（基本の標本 23,056 本）。山が 4 つあり、寄り前（6〜8 時）と場中（10〜13 時）、引け後（16 時台）と 17:30 以後（20〜21 時）が、それぞれ約 4 時間ずれて対になっている。

図 2.1 の 4 つの山は、多くの会社がプレスリリースを配信してから数時間後に 8-K を提出することを示し

ている。「場中」の受理（33%）の多くは寄り前に配信された発表で、その場合も反応の日は同じ日になる。「17:30 以後」（22%）の多くは引け後に配信された発表で、反応の日は翌日になる。どちらも、主な窓（反応の日の前日の終値から、反応の日の翌日の終値まで）は配信の後の値動きを含む。場中の受理を除いても結果は変わらなかった（第 5 章、R2）。

2.3　数値の驚き

アナリストの予想は持っていないので、数値の驚きは前年の同じ四半期との差で測った（季節のランダムウォーク）。

- **SUE**：希薄化後 EPS の前年同期との差を、過去 8 四半期の同じ差の標準偏差で割ったもの。過去は、発表の前に提出された四半期だけを使う。
- **売上の驚き**：売上の前年同期比から、過去 4 四半期の前年同期比の平均を引いたもの。

SUE が計算できなかったのは標本 A の 5.2%、売上の驚きは 3.3% である。欠けは 0 で埋め、欠けを示す変数を回帰に入れた。

第 3 章

点数の付け方

同じ発表文に、5 つの方法で点数を付けた。結果を見る前に作れるもの（1〜4）は、事前登録の前にすべて計算した。TF-IDF は株価の反応で学習するので、事前登録の後に作った。

表3.1: 点数の付け方。時間は合計（この PC の GPU、RTX 5050 Laptop 8GB）。

方法	中身	対象	費用・時間
gpt-4o-mini	H06 と同じ質問のまま。ガイダンスの変更・見通し・語調（−2〜+2）と、リスクの種類。温度 0。合成点数は語調＋見通し＋ガイダンス（記載なしは 0）	2023-11 以降	3.31 ドル（1.5 時間）
ChronoGPT	発表の前の年末までの文章だけで学習した版（1.55B）。ガイダンスと語調の選択肢の確率を、中身のない文章での確率で割って較正。先頭の 1,792 トークンだけ読む	全期間	0 円（8.3 時間）
辞書	Loughran–McDonald の語彙で、肯定語と否定語の差 ÷ 和。発表の年より後に辞書に加わった語は使わない	全期間	0 円（6 分）
FinBERT	金融の文章で学習した BERT。先頭の 200 文の、肯定の確率 − 否定の確率の平均	全期間	0 円（4.2 時間）
TF-IDF ＋リッジ	語彙 2 万語。四半期ごとに、その四半期の始まりより前に窓が閉じた発表の反応で学び直す	全期間	0 円（14 分）

gpt-4o-mini の点数は楽観に寄る。語調は 88% が前向き（+1 が 71%、+2 が 17%）、ガイダンスは 42% が引き上げ、10% が引き下げだった。発表文そのものが前向きに書かれるためで、回帰では標準化するので影響しない。点数どうしの順位相関は、LLM と FinBERT が 0.38、LLM と TF-IDF が 0.38、LLM と SUE が 0.28、LLM と ChronoGPT が 0.17 だった。

第 4 章

評価の方法と事前登録

4.1　事前登録

前回の実験で探索した期間を再び使うので、結果を見てから手順を選ぶ余地をなくす必要がある。そこで、株価の反応を一度も計算しないうちに、次のものを 1 つのコミット（`2df746e`）に固定して GitHub にプッシュし、その後に 1 回だけ実行した。

- 事前登録の文書（`experiments/E2_event_reaction/preregistration.md`）：標本、変数、検定、判定の基準、副次の分析、頑健性の確認、実装の細部
- 評価のコード（`run.py`）：作ったデータでだけテストしたもの
- 使う点数の番号と、その設定のハッシュ

4.2　主な検定

- **目的変数**：反応の日の前日の終値から、翌日の終値まで（2 取引日）の超過リターン。超過リターンは、銘柄の配当込みのリターン − 同じセクターの ETF のリターン。上下 1% で丸める。
- **主な説明変数**：gpt-4o-mini の合成点数（標準化）。
- **統制**：SUE、売上の驚き（丸め、欠けの印つき）、辞書・FinBERT・TF-IDF の点数（標準化）、発表前 21 日の超過リターン、時価総額の対数。セクターと年・四半期の固定効果。
- **標準誤差**：反応の日ごとにまとめる（同じ日の発表どうしの相関のため）。
- **置換の対照**：同じ反応の日の中で点数を入れ替え、1,000 回回帰し直す。
- **判定**：点数の係数が、t 検定と置換の両方で片側 $p < 0.05$ なら「支持」。

副次の分析（S1〜S4、6 つの回帰）は Holm で補正した。頑健性の確認（R1〜R7）は判定に使わない。

第 5 章

結果

5.1　主な検定

判定

支持。gpt-4o-mini の合成点数の係数は、1 標準偏差あたり +120bp（95% 区間 +95〜+145bp、$t = 9.41$、片側 $p = 8 \times 10^{-20}$）。置換の対照の片側 $p = 0.001$（1,000 回で実際を超えたのは 0 回で、出せる最小の値）。決定係数は、統制だけのモデルより 2.2 ポイント高い。

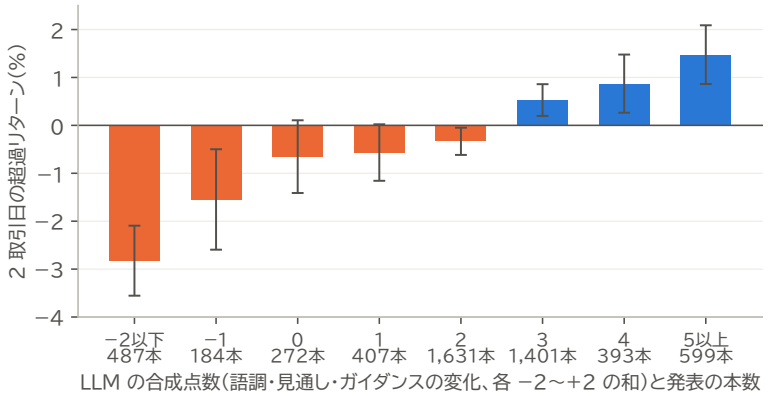


図5.1: LLM の合成点数の値ごとの、2 取引日の超過リターンの平均（標本 A、上下 1% で丸め、縦線は発表日でクラスタした 95% 区間）。本数の少ない両端（−5〜−2、5〜6）はまとめた。探索の図で、判定には使っていない。

合成点数の値ごとに並べると、反応の平均は −2 以下で −2.82%、−1 で −1.55%、0 で −0.65%、1 で −0.57%、2 で −0.33%、3 で +0.53%、4 で +0.87%、5 以上で +1.48% と、点数の順に並んだ（図 5.1）。両端の差は約 4.3 ポイントである。

図の作り直し（2026-10-28）

この図は初め、点数の 5 分位（同じ点数の発表を、ファイルの中の順で機械的に割り振ったもの）で描いていた（平均は −1.77%、−0.20%、−0.25%、+0.46%、+1.16%）。合成点数は整数で、2 が 1,631 本、3 が 1,401 本と同じ値が多いので、2 番目と 3 番目の 5 分位はほぼ同じ「点数 2」の発表を分け合い、真ん中が平らに見えていた。点数の値ごとの図に替えた。判定（回帰の係数）は変わらない。

5.2　LLM を使わない方法との比較

1 つずつ入れると、TF-IDF（+44bp、t 3.7）、FinBERT（+39bp、t 3.7）、SUE（+28bp、t 4.0）も反応を説明する。辞書は弱い（+10bp、t 1.1）。しかし LLM の点数と同時に入れると、文章の 3 つの方法の係数は 0 に近くなる（t 0.3、−0.4、0.4）。一方、LLM の係数は 1 つずつでも同時でも +120bp で変わらない（図 5.2）。**LLM の点数は、ほかの文章の方法が持つ情報をほぼ含み、さらにその約 3 倍の情報を持つ**。Siano（2025）の「LLM による決算発表文の測度は、辞書や LLM でない機械学習の 3 倍、発表の短い期間のリターンを説明する」と合う。

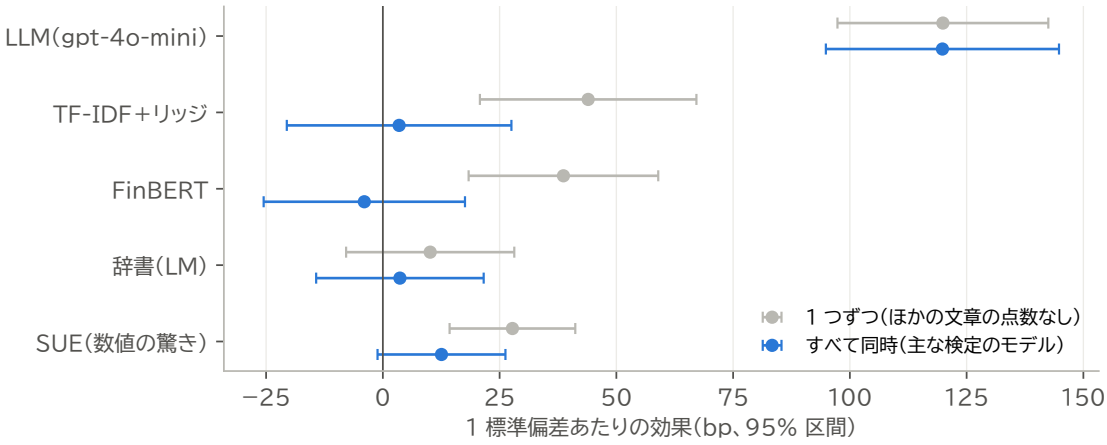


図5.2: 点数ごとの効果（1 標準偏差あたり、95% 区間）。灰色はほかの文章の点数を入れずに 1 つずつ（数値の驚きなどの統制は入れる）、青は主な検定のモデル（すべて同時）。探索の図。

5.3　反応の後：ドリフト

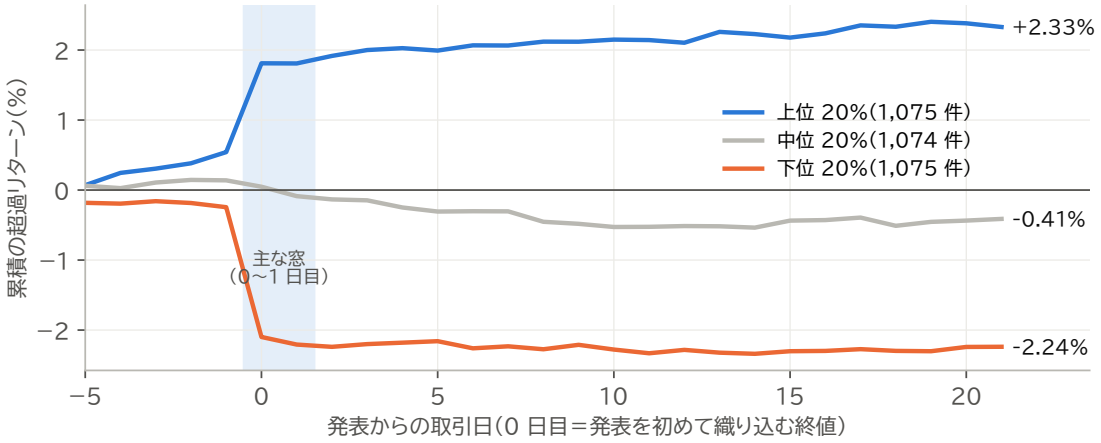


図5.3: LLM の合成点数の上位・中位・下位 20% の、累積の超過リターン（標本 A、丸めなし）。探索の図。

反応の大部分は 0 日目に出る（図 5.3）。上位 20% は 0〜1 日目で約 +1.3%、下位 20% は約 −2.0% 動き、その後はほぼ横ばいだった。上位は 21 日目までにさらに +0.5% ほど上がるが、統制を入れた回帰では、2〜21 日目のドリフトは有意でない（S1、+10bp、t 0.83、Holm の $p = 0.41$）。上位は発表の前（−5〜−1 日目）にも約 +0.5% 上がっている。8-K の提出が配信より 1 日以上遅れた発表では、反応が −1 日目に入るためと考えられる。窓を $[-1, +1]$ に広げても係数は同じ（+120bp）だった（R1）。

5.4　副次の分析と頑健性

- **語調・見通し・ガイダンスは、どれも単独で強く効く**（S4）。合成点数の効果は、3 つのどれか 1 つから来ているのではない。
- **頑健性**：窓を変えても（R1）、場中の受理を除いても（R2）、S&P500 との差にしても（R3）、丸めをなくしても・幅を変えても（R4・R5）、順位に直しても（R6）、t は 7.5〜9.6 の範囲に収まり、係数（単位の

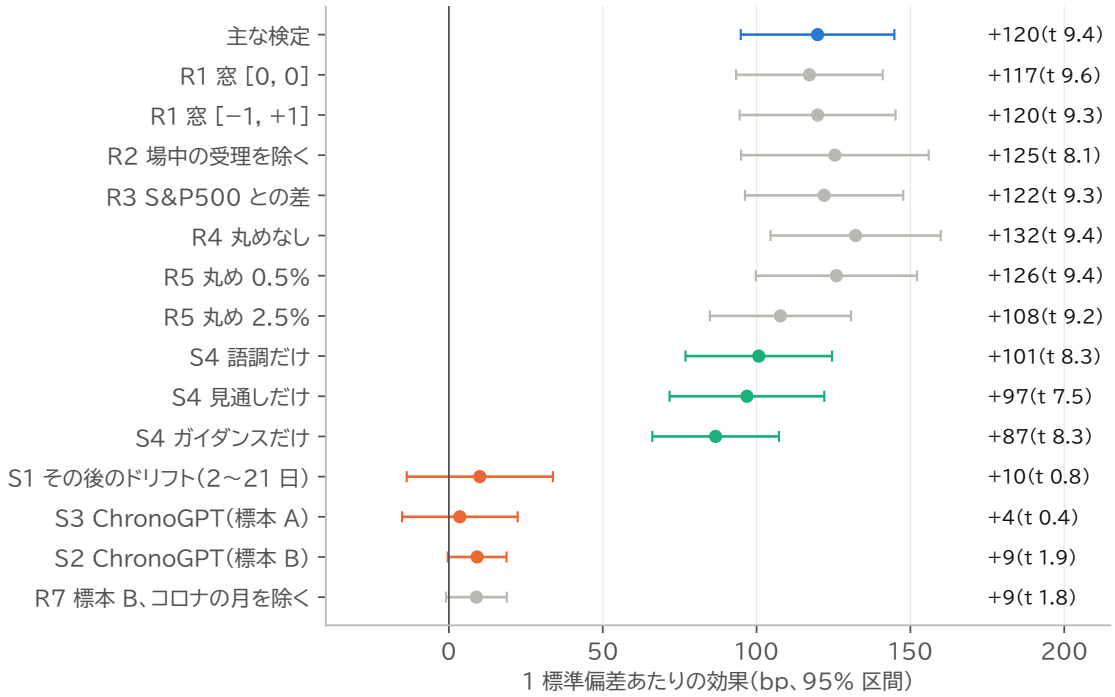


図5.4: 主な検定（青）、頑健性の確認（灰）、語調・見通し・ガイダンスの 1 つずつ（緑）、ドリフトと ChronoGPT（橙）の係数と 95% 区間。R6（順位の版）は単位が違うので省いた（t 7.5）。

表5.1: 副次の分析（Holm で 6 つを補正）。係数は 1 標準偏差あたりの bp。

	係数	t	Holm の p	件数
S1 発表の後のドリフト（2〜21 日目）	+10	0.83	0.41	5,374
S2 標本 B（2016〜2023）を ChronoGPT で	+9	1.89	0.089	14,204
S3 標本 A を ChronoGPT で	+4	0.37	0.41	5,374
S4 語調だけ	+101	8.29	3×10^{-15}	5,374
S4 見通しだけ	+97	7.55	4×10^{-13}	5,374
S4 ガイダンスだけ	+87	8.26	3×10^{-15}	5,374

違う R6 を除く）は +108〜+132bp だった（図 5.4）。結論は丸め方や窓の取り方に左右されない。

- **ChronoGPT**：標本 B で +9bp（補正の前の片側 $p = 0.03$、補正の後 0.089）、コロナの月を除いても +9bp（R7）。同じ標本 A では +4bp で、gpt-4o-mini の +120bp と大きな差がある。

第 6 章

考察

6.1　LLM は何を読み取っているか

gpt-4o-mini の点数は、FinBERT や TF-IDF の情報をほぼ含み、その約 3 倍の情報を持っていた。FinBERT は文ごとの語調の平均、TF-IDF は単語の出方しか見ない。LLM は文書全体から「ガイダンスを引き上げたか」「需要は強まっているか」といった判断を読める。この差が、反応の説明力の差に表れたと考えられる。

一方で、数値の驚きの統制は弱い。アナリストの予想がないので、SUE は前年同期との差でしか測れていない。発表文には「予想を上回った」「市場の予想を下回るガイダンス」といった記述があり、LLM はこれを読んで本当の驚きを捉えている可能性がある。その場合、効果の一部は「文章から数値の驚きを読む力」で、純粋な語調の情報ではない。どちらでも LLM の読む力の証拠であることは変わらないが、「数値を超える情報」と言い切るには、ガイダンスの数値などで統制を強める必要がある。

6.2　取引と BLM にとっての意味

反応は発表の 2 日のうちにほぼ出尽くした。この点数が手に入るのは発表文を読んだ後なので、それから売買しても、反応の大部分はすでに株価に入っている。前回の H06 で翌月のリターンを説明できなかったことと、今回の結果は矛盾しない。どちらも「発表の内容は速やかに株価に織り込まれる」ことを示している（Wu ほか 2025、Yu ほか 2026）。

BLM のビューは「これから先のリターンの見込み」なので、この点数をそのままビューにしても価値は生まれない。BLM に組み込むかどうかは、ドリフトの部分（S1）が十分に大きいと示されてからにすべきである。

6.3　先読みのないモデル

ChronoGPT は、先読みがないことを学習データの段階で保証できる唯一の比べる相手だが、質問に答えさせる使い方（選択肢の確率）では、ほとんど読み取れなかった。1.55B と小さく、先頭の 1,792 トークンしか読めず、指示の学習のデータも 2000 年より前の内容に限られている。He ほか（2025）は、このモデルの内部の数値（最後の層）を取り出し、その上に過去のデータで学習した回帰を置く使い方で、大きなモデルと同程度の成績を報告している。標本 B（2016〜2023）で「LLM の読む力」を確かめるには、この方法でやり直す必要がある。

第 7 章

限界

- **数値の驚きの統制が弱い**。アナリストの予想がなく、SUE は前年同期との差で測った。
- **主な標本は約 3 年**。gpt-4o-mini の知識の期限より後に限ったため（527 の発表日）。
- **発表の時刻**：EDGAR の受理時刻を使い、プレスリリースの配信時刻は持っていない。8-K の提出が配信より 1 日以上遅れた発表では、反応の一部が窓の外に出る。場中の受理を除いても、窓を広げても結果は変わらなかった。
- **生存者の偏り**：上場廃止などで株価が取れない銘柄は除いている（標本 B で 1,373 本）。
- **ChronoGPT の弱さ**が、モデルの弱さか、質問の形の弱さかは区別できない。
- **同じ期間の再利用**：標本 A は、前回の H06 で翌月のリターンについて一度見た期間である。発表への反応は一度も計算していなかったので、事前登録で手順を固定した。

第 8 章

次に行うこと

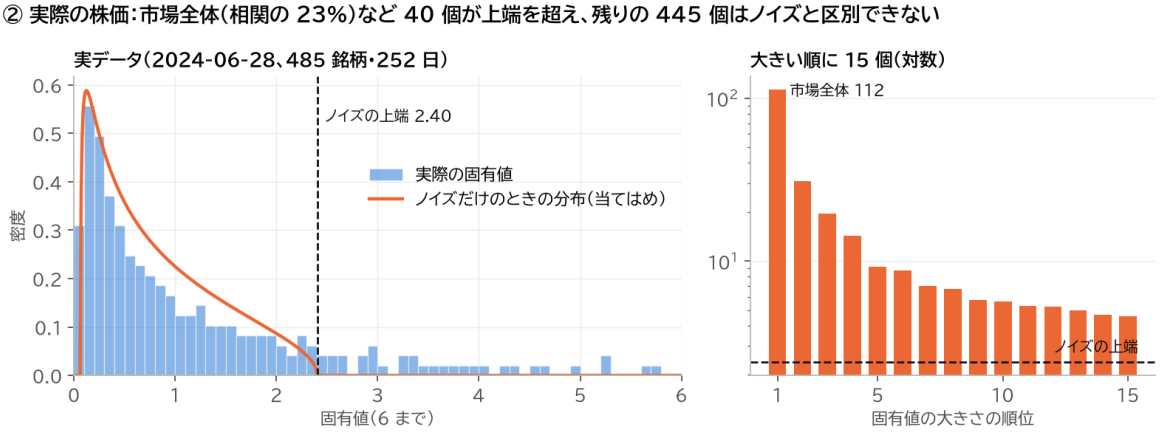
リポジトリの やること.md に一覧がある。効果が大きいと考える順に挙げる。

1. **ChronoGPT の内部の数値と回帰**（He ほか 2025 の方法）。標本 B で、先読みのない比べる相手を強い形で作り直す。GPU で数時間（借りれば 1 時間程度）。
2. **数値の驚きの統制を強める**。発表文のガイダンスの数値（売上・EPS の見通し）と前回の見通しの差を、数値の驚きとして加える。「LLM は数値以外も読んでいるか」を確かめる。
3. **配信の時刻の確認**。受理と配信のずれを数十本で照合し、窓の決め方を確かめる。
4. **超過リターンの基準を良くする**。Fama–French の日次の因子で、市場・規模・バリュー・モメンタムを除く。
5. **BLM への組み込みは保留**。ドリフトが十分に大きいと示されるまで行わない。

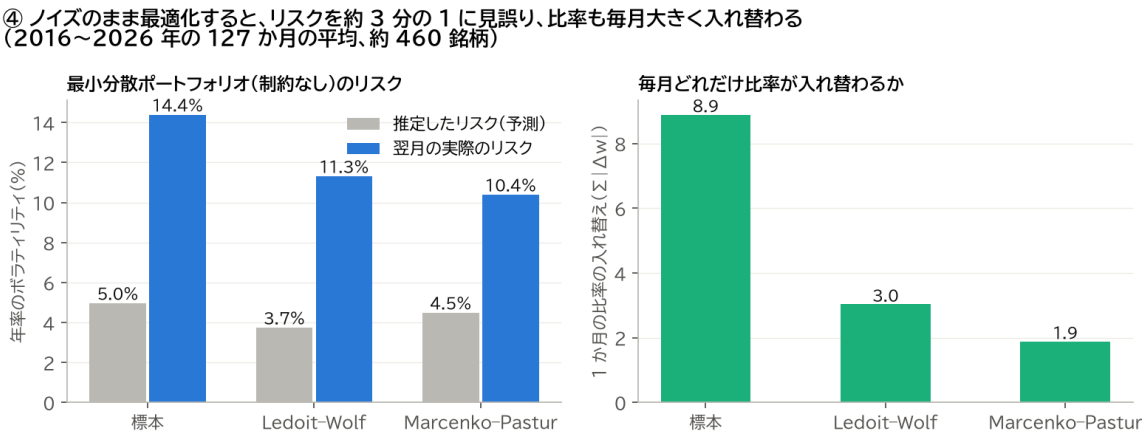
付録 A

共分散のノイズ除去（X01）

待ち時間に、BLM の共分散 Σ の推定を比べた（`experiments/X01_covariance_denoise/`）。LLM は使わない。2016〜2026 年の 127 か月の月末に、約 460 銘柄で比率を決め、翌月の値動きで答え合わせした。比べ方は計算の前に固定した。



図A.1: 2024 年 6 月末の S&P500 の相関行列の固有値。Marcenko–Pastur のノイズの上端（2.40）を超えるのは 40 個で、残りの 445 個はノイズと区別できない。



図A.2: 制約のない最小分散ポートフォリオ。そのままの標本共分散ではリスクを約 3 分の 1 に見誤り、比率も毎月大きく入れ替わる。

表A.1: 翌月の実際のリスク（年率）。

	標本	Ledoit–Wolf（今の BLM）	Marcenko–Pastur
制約のない最小分散：ボラティリティ	14.4%	11.3%	**10.4%**
空売りなしの最小分散：ボラティリティ	10.5%	**10.5%**	10.6%
BLM の最適化（TE の上限 3%）：実際の TE	4.8%	**4.5%**	4.7%

- 制約のない最適化では、ノイズ除去がはっきり効く（実際のリスク 11.3% → 10.4%、t −5.8）。
- 空売りの禁止や TE の上限があると、制約そのものがノイズによる大きな賭けを抑えるので、差はほとんど消える。BLM の最適化では Ledoit–Wolf がわずかに良かった（+0.14 ポイント、t 3）。**BLM の共分散は今のままでよい**。
- どの推定でも、実際の TE は上限 3% の約 1.5 倍になった。過去 1 年から推定した共分散は、翌月のリスクの変化を捉えきれない。BLM の結果を報告するときは、上限ではなく実際の TE を書く。

付録 B

再現の手順と記録

表B.1: ブランチ `feature/earnings-events` の主なコミット（すべて GitHub にプッシュ済み）。

コミット	内容
`f7d3bba`	設計（設計.md：ディレクトリ、表、時刻、点数、評価の順番）
`792766c`	実装（表、EDGAR の取得、時刻、数値の驚き、点数、統計）と H06 の移し替え
`d81b6fc`	ChronoGPT の点数付けの修正（GPU のメモリ）
`867ddbd`、`bc8c6d9`	X01（共分散のノイズ除去）と図
`2df746e`	**事前登録と評価のコード（反応を計算する前）**
`94e08f8`	E2 の結果

```
python run_events.py import-h06        # H06 の結果を DB へ
SEC_USER_AGENT="<名前> <メール>" \
  python run_events.py fetch --from 2015-01-01 --to 2023-10-31
python run_events.py surprise          # 数値の驚き
python run_events.py score dictionary  # finbert / chrono も同じ
python experiments/E2_event_reaction/run.py   # 事前登録の後に 1 回だけ
python 資料集/02_実験/実験2_決算発表文/作成スクリプト/figs.py   # この資料の図
```

費用は gpt-4o-mini の 3.31 ドル（前回の H06 のもの）だけで、今回の点数付けと評価はすべてこの PC で行った（GPU で約 13 時間）。

参考文献

- Chen, S., Green, T. C., Gulen, H., Zhou, D. (2024). What Does ChatGPT Make of Historical Stock Returns? arXiv:2409.11540.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Chronologically Consistent Large Language Models. arXiv:2502.21206.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Instruction Tuning Chronologically Consistent Language Models. arXiv:2510.11677.
- Huang, A. H., Wang, H., Yang, Y. (2023). FinBERT: A Large Language Model for Extracting Information from Financial Text. Contemporary Accounting Research 40(2).
- Jagannathan, R., Ma, T. (2003). Risk Reduction in Large Portfolios: Why Imposing the Wrong Constraints Helps. Journal of Finance 58(4).
- Kolari, J. W., Pynnönen, S. (2010). Event Study Testing with Cross-Sectional Correlation of Abnormal Returns. Review of Financial Studies 23(11).
- Lopez-Lira, A., Tang, Y., Zhu, M. (2025). The Memorization Problem: Can We Trust LLMs' Economic Forecasts? arXiv:2504.14765.
- López de Prado, M. (2020). Machine Learning for Asset Managers. Cambridge University Press.
- Loughran, T., McDonald, B. (2011). When Is a Liability Not a Liability? Journal of Finance 66(1).
- Siano, F. (2025). The News in Earnings Announcement Disclosures: Capturing Word Context Using LLM Methods. Management Science 71(11).
- Wu, Y., Akin, E. M., Martineau, C., Grégoire, V., Veneris, A. (2025). Extracting the Structure of Press Releases for Predicting Earnings Announcement Returns. arXiv:2509.24254.
- Yu, D., Liu, Z., Zhang, H., He, H. (2026). Fast Numbers, Slow Language: Bridging Quantitative and Qualitative Earnings Signals. arXiv:2606.29734.