LLM-BLM 実験 3

アナリスト予想との差を統制しても、
LLM の点数は決算発表への反応を説明するか

実験の結果の報告書

2026 年 10 月 18 日

概要

実験 2 で、gpt-4o-mini が決算発表文から読み取った点数は、発表をはさむ 2 取引日の株価の反応を強く説明した。ただし数値の驚きは「前年同期との差（SUE）」でしか統制しておらず、LLM が本文の「予想を上回った」という記述から本当の驚きを読んでいるだけではないか、という疑問が残っていた（総合報告書 2 で最大の限界とした点）。今回は、アナリスト予想（発表前のコンセンサス EPS）と実績の差を新たに統制に加えた。手順と判定の基準は、実験 2 と同じく、計算の前に文書とコードで固定した（事前登録）。

主な結論

- **予想との差を統制しても、LLM の点数の効果はほとんど縮まない（支持）**。1 標準偏差あたり +120bp が +116bp になっただけで、97% が残った（t 9.37、置換の対照で $p = 0.001$）。
- **予想との差そのものも効く**（+69bp、t 6.2）。データは確かに働いている。それでも LLM の効果は、予想との差の約 1.7 倍だった。
- **LLM は予想との差を少しは読んでいるが、主な情報は別にある**。予想を上回った発表の中でも、下回った発表の中でも、LLM の点数が高いほど反応が良い。
- **取引に使える価値は、やはりない**。発表の後 2〜21 日のドリフトは有意でない（+9bp、t 0.8）。

意味：LLM の読み取りは、EPS の予想との差という「数字の驚き」には還元できない。ガイダンスや見通しの書き方など、文章の中身を読んでいると考えられる。ただし、売上の予想とガイダンスの予想はまだ統制していない。

目次

概要 1

第 1 章　目的 3

第 2 章　データ 4
2.1　アナリスト予想 4
2.2　決算発表との照合 4
2.3　標本 4

第 3 章　方法と事前登録 5

第 4 章　結果 6
4.1　主な検定 6
4.2　予想を上回った発表と、下回った発表の中で 7
4.3　副次の分析と頑健性 7

第 5 章　考察と限界 9
5.1　LLM は何を読んでいるか 9
5.2　取引と BLM にとっての意味 9
5.3　限界 9

再現の手順 10

第 1 章

目的

実験 2 の主な結果は次のとおりだった。

- gpt-4o-mini の合成点数（語調＋見通し＋ガイダンスの変更）が 1 標準偏差高いと、発表をはさむ 2 取引日の超過リターンは +120bp 高い（t 9.41）。
- 辞書・FinBERT・TF-IDF・SUE を統制しても変わらず、効果は FinBERT や TF-IDF の約 3 倍。
- 発表の後のドリフトは有意でない。

残っていた疑問は、「LLM は、本文の『予想を上回った』『市場予想を下回る見通し』といった記述から、アナリスト予想との差（本当の驚き）を読んでいるだけではないか」である。SUE は前年同期との差なので、市場が何を期待していたかは表さない。もしこの疑問のとおりなら、予想との差を統制すると、LLM の効果は大きく縮むはずである。

問い

アナリスト予想との差を統制しても、gpt-4o-mini の合成点数は、発表への株価の反応を説明するか。

第 2 章

データ

2.1　アナリスト予想

Alpha Vantage の EARNINGS から、各四半期の発表前のコンセンサス EPS と実績 EPS、発表日、発表の時間帯（寄り前・引け後）を取得した（2016 年以降に決算発表がある 656 銘柄）。

- 1 銘柄 1 回の問い合わせで、過去の全四半期が返る（多くの銘柄で 1996 年から）。無料の枠（1 日 25 回）で取得した。
- 予想がなかった 77 銘柄のうち 73 銘柄は、買収や上場廃止で今はない会社で、株価がないため評価の標本には入っていない。残りの 4 銘柄（BRK-B、BF-B、BXP、DOC）は種類株や REIT である。
- 利用規約は個人の非商用の研究を認めているが、再許諾できない。予想の値そのものは Git に入れず、DB とキャッシュにだけ置いた。

2.2　決算発表との照合

発表の受理日（ニューヨーク時間）に最も近い報告日を持つ同じ銘柄の四半期を、前後 3 日以内で選んだ。全期間の 23,765 本では 95.0% が照合でき、そのうち 91% は同じ日だった。

表2.1: 実験 2 の時間帯の区分と、データ上の発表の時間帯（全期間）。

実験 2 の時間帯（受理時刻）	データ上の寄り前	データ上の引け後
場中（9:30〜16:00）	7,054	281
17:30 以後	540	5,275
引け後（16:00〜17:30）	188	4,160
寄り前（〜9:30）	4,964	106

「場中に受理された 8-K の多くは、寄り前に配信された発表」という実験 2 の推測が確かめられた。反応の日の決め方が誤るのは、場中に受理されたがデータ上は引け後の発表（281 本、約 1.2%）で、反応の日が 1 日早くなる。主な窓（2 取引日）はその翌日も含むので、影響は小さい。

2.3　標本

実験 2 の標本 A（2023 年 11 月〜2026 年 8 月、5,374 本、527 の発表日）をそのまま使った。そのうち 5,200 本（96.8%）に予想があった。予想を上回った発表が 4,086 本、一致が 229 本、下回りが 894 本である。**標本 A は、実験 2 で発表への反応を一度計算した期間の再利用である。**

第 3 章

方法と事前登録

事前登録の文書（`experiments/E3_analyst_surprise/preregistration.md`）と評価のコード（`run.py`）を、コミット `1f39810` に固定してから、1 回だけ実行した。評価のコードは、作ったデータで次の 2 つを見分けられることを確かめてある。

- LLM の点数が予想との差とは別の情報を持つ場合 → 統制の後も係数が残る。
- LLM の点数が予想との差をなぞっているだけの場合 → 統制で係数が消える。

表3.1: 主な検定の設計。

モデル M0	実験 2 の主な検定と同じ（目的変数、LLM の合成点数、統制、固定効果、丸め、標準化）
モデル M1（主）	M0 に、予想との差（(実績 − 予想) ÷ | 予想 |、上下 1% で丸めて標準化）と、照合できなかった印を加える
判定	M1 の LLM の係数が、t 検定（発表日ごとにまとめた標準誤差）と、同じ発表日の中での置換 1,000 回の両方で片側 $p < 0.05$ なら「支持」
副次（Holm）	S1 予想との差の係数、S2 発表の後のドリフト、S3 LLM の点数は予想との差を読んでいるか
頑健性	R1 上回り・下回りの印、R2 順位の版、R3 照合と時刻のずれを除く、R4 驚きを丸めない

第 4 章

結果

4.1　主な検定

判定

支持。M1 の LLM の合成点数の係数は、1 標準偏差あたり +116bp（95% 区間 +92〜+141bp、$t = 9.37$）。置換の対照の片側 $p = 0.001$。M0（+120bp）に対して 97% が残った。

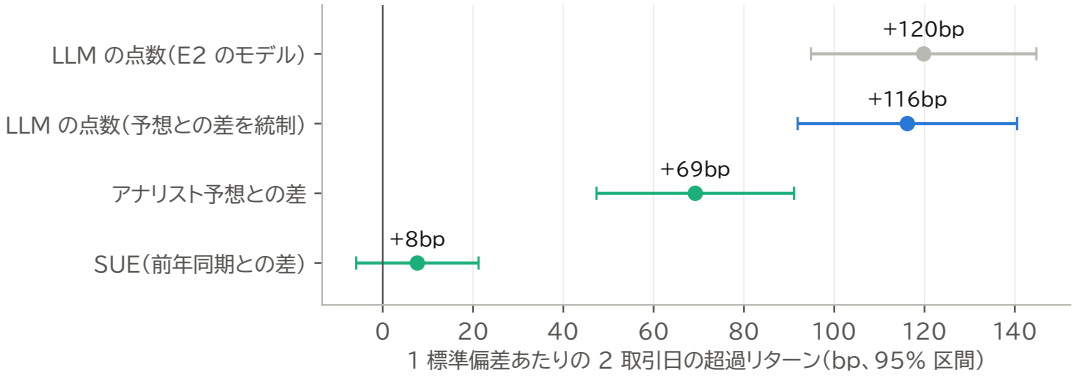


図4.1: LLM の点数の係数（予想との差を統制する前と後）と、主なモデルでの数値の驚きの係数（1 標準偏差あたり、95% 区間）。

予想との差そのものは +69bp（t 6.2）で、反応を確かに説明する（図 4.1）。一方、前年同期との差（SUE）は、予想との差を入れると +8bp（t 1.1）に縮んだ。市場が反応するのは「前年との差」ではなく「予想との差」であり、データはその点で筋が通っている。

4.2　予想を上回った発表と、下回った発表の中で

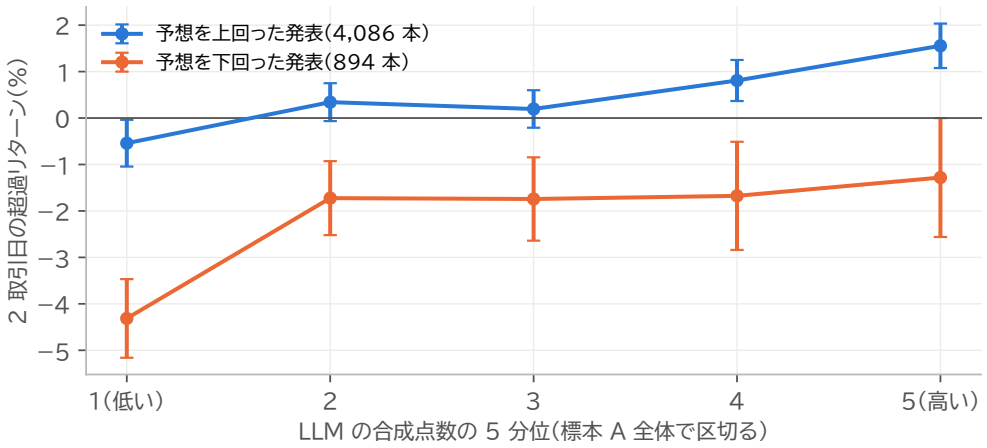


図4.2: LLM の合成点数の 5 分位ごとの、2 取引日の超過リターンの平均（予想を上回った発表と、下回った発表に分けて。上下 1% で丸め、縦線は 95% 区間)。探索の図で、判定には使っていない。

表4.1: LLM の合成点数の 5 分位ごとの、2 取引日の超過リターンの平均（%、探索)。

	1（低い）	2	3	4	5（高い）
予想を上回った発表（4,086 本）	−0.54	+0.34	+0.20	+0.81	+1.56
予想を下回った発表（894 本）	−4.31	−1.72	−1.74	−1.68	−1.28

予想を上回った発表の中でも、点数が高いほど反応が良く、最も低い 5 分位では上回ったのに平均で下げている（図 4.2)。予想を下回った発表では、点数が最も低い 5 分位だけが大きく下げた（−4.31%)。EPS は予想を下回り、しかも文章の中身（ガイダンスの引き下げ、見通しの悪化など）も悪い発表である。

4.3　副次の分析と頑健性

表4.2: 副次の分析（Holm で 3 つを補正)。

	係数	t	Holm の p
S1 予想との差の係数（M1）	+69bp	6.20	< 0.001
S2 発表の後のドリフト（2〜21 日目）	+9bp	0.77	0.22
S3 LLM の点数 → 予想との差	+1.4 ポイント	2.90	0.004

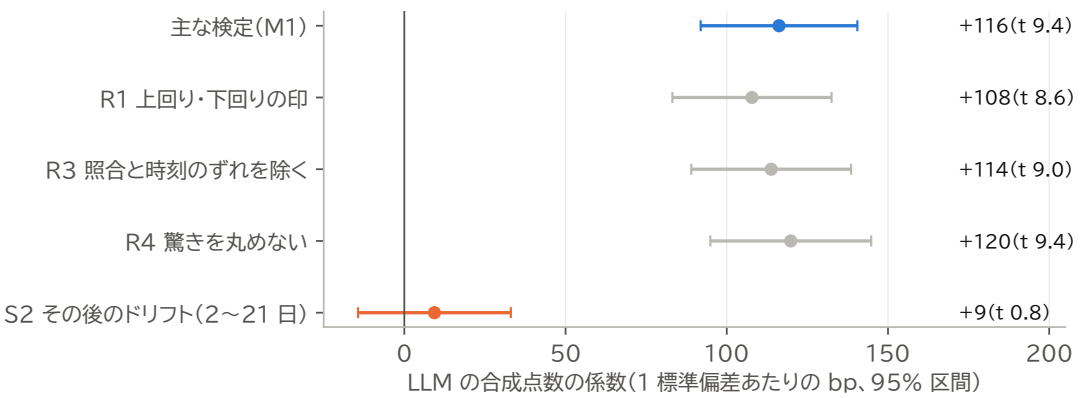


図4.3: LLM の合成点数の係数の頑健性。R2（順位の版）は単位が違うので省いた（t 6.43）。

- **S3**：LLM の点数が 1 標準偏差高い発表は、予想との差が平均 1.4 ポイント大きかった。LLM は予想との差を少しは読んでいるが、その部分は効果のごく一部である。
- **頑健性**：上回り・下回りの印にしても（R1、上回りの印は +266bp）、順位にしても（R2）、照合できなかった発表と時刻のずれを除いても（R3）、驚きを丸めなくても（R4）、LLM の係数は +108〜+120bp、t は 6.4〜9.4 だった（図 4.3）。R4 では、驚きの裾が長すぎて予想との差の係数が消えるが、LLM の係数は変わらない。

第 5 章

考察と限界

5.1　LLM は何を読んでいるか

実験 2 の後に残っていた「LLM は本当の驚き（EPS の予想との差）を文章から読んでいるだけ」という説明は、データで否定された。予想との差を統制しても係数は 97% 残り、予想を上回った発表の中でも下回った発表の中でも、点数は反応を説明した。LLM が読んでいるのは、EPS の数字の驚き以外の中身（ガイダンスの変更、需要や受注の見通し、経営陣の語調）と考えられる。実験 2 の項目ごとの分析で、語調・見通し・ガイダンスがどれも単独で効いたこととも合う。

5.2　取引と BLM にとっての意味

予想との差を統制しても、発表の後のドリフトは有意でなかった。LLM の読み取りが正確でも、その中身は 2 日のうちに株価に入る。BLM のビューにする価値がないという実験 2 の結論は変わらない。

5.3　限界

- **売上の予想とガイダンスの予想は統制していない**。無料で取れる予想は EPS だけだった。LLM の効果の一部は、売上の驚きや、会社の見通しと市場の期待の差を、文章から読んでいる可能性が残る。
- **予想との差の測り方**：÷ | 予想 | で測ったので、予想が 0 に近い発表で値が極端になる。丸めと順位の版で確かめた。株価で割る測り方は、EPS と株価の株式分割の扱いが揃わないので使わなかった。
- **予想のデータの元**（どの会社の集計か）は公開されていない。
- **標本 A は、実験 2 で一度見た期間**である。新しい統制を加えた検定として事前登録したが、確認の強さは、結果を見ていない標本での検定より一段弱い。

再現の手順

```
python run_events.py estimates                    # 予想（無料の枠は 1 日 25 銘柄）
python experiments/E2_event_reaction/run.py       # 実験 2 の panel.csv
python experiments/E3_analyst_surprise/run.py     # 事前登録の後に 1 回
cd 資料集/02_実験/実験3_アナリスト予想
python 作成スクリプト/figs.py                      # この資料の図
```

数値の出どころは experiments/E3_analyst_surprise/results/summary.json と findings.md。費用は 0 円（予想は無料の枠、計算はこの PC）。