LLM-BLM 実験 7・8

LLM の決算の読み取りを BLM に入れて、
月次と日次でポートフォリオを組む

実験の結果の報告書

2026 年 10 月 18 日

概要

実験 2〜4 で、gpt-4o-mini が決算発表文から読み取った点数は、発表後 2 取引日の反応を強く説明した。ただし 3 日目以降のドリフトはなかった。この報告書では、その点数を BLM の見通しに入れて、実際にポートフォリオを組んだ。

- **実験 7**：これまでの結果を全部入れた BLM を、月次で組んだ。
- **実験 8**：発表日の終値の時点で、LLM の情報がまだ株価に残っているかを調べ、日次の BLM も組んだ。

2 つの実験は、手順・判定の基準・コードを同じコミット（`55ef830`）に固定してから、1 回ずつ実行した（事前登録）。

主な結論

- **実験 7：月次の BLM は、時価総額を有意には上回らない（支持されない）**。費用の後で月 +0.10%（年約 +1.2%、$t = 1.22$）。31 か月の累積は +68.5% と +63.8%。実際の TE は 2.5% と約束の 3% 以内だった。
- 副次の分析では、LLM の点数を銘柄の間で入れ替えた BLM を、本物が月 +0.20% 上回った（$t = 2.30$）。弱い情報が月次でも残っているかもしれない。
- **実験 8：発表日の終値の後には、LLM の情報は残っていない（支持されない）**。翌日の超過リターンへの係数は +3.6bp（$t = 0.93$）。2 日の反応（+116bp）のほぼ全部が、発表日のうちに出ている。
- **日次の BLM は費用に負ける**。毎日の最適化で 1 日に 42% が入れ替わり、費用の後で年 −20% だった。

目次

概要 1

第 1 章　目的 3

第 2 章　実験 7：月次の BLM 4
2.1　設計 4
2.2　結果 4

第 3 章　実験 8：発表の翌日と日次の BLM 6
3.1　第 1 部：翌日の反応（判定） 6
3.2　第 2 部：日次の BLM（報告） 6

第 4 章　考察と限界 8
4.1　何が分かったか 8
4.2　限界 8

再現の手順 9

第 1 章

目的

これまでに分かったことを並べる。

- **見通しの中身**：gpt-4o-mini の点数は、決算発表への 2 日の反応を、数値の驚き・アナリスト予想・FinBERT（追加学習した版も含む）を超えて説明する（実験 2〜4）。ただし day 2〜21 のドリフトは +10bp で、有意でない。
- **見通しの不確かさ** Ω：LLM の 30 回の答えのばらつきは使えない（総合報告書 1）。
- **共分散と TE**：Ledoit–Wolf で十分。TE の上限は、過去 36 か月の「実際 ÷ 予測」の比で割ると守れる（補足実験 X01〜X03）。

問い

実験 7：これらを全部入れた BLM を月次で組むと、費用の後で時価総額を上回るか。
実験 8：発表日の終値の時点で、LLM の点数は、翌日の超過リターンを予測するか。

実験 7 の予想は、実行の前に事前登録に書いた。ドリフトがなかったので、上回らない見込みが高い。株価は発表日の寄り付きで跳ねるので、日次のデータで取引できるのは、早くても発表日の終値からである。実験 8 は、そこに情報が残っているかを見る。

第 2 章

実験 7：月次の BLM

2.1　設計

表2.1: 月次の BLM の設定（事前登録で固定）。

判断日	2024-01〜2026-07 の各月末（31 か月）。翌月末まで持つ。gpt-4o-mini の点数は 2023-11 以降の発表にしかないので、1 四半期分がそろう 2024-01 末から
銘柄	各月末の S&P500 の構成銘柄（平均 491）
事前分布	均衡リターン $\Pi = \delta \Sigma w_{\mathrm{mkt}}$（$\delta = 2.5$）
見通し	直近 92 日に反応が始まった決算発表がある銘柄（平均 454）。最新の発表の LLM の合成点数を正規スコア z にし、$q_i = \Pi_i + 0.05\,\sigma_i z_i$（Grinold の α）
Ω	He–Litterman：$\tau\,\mathrm{diag}(P\Sigma P')$、$\tau = 0.025$
共分散	直近 252 日の Ledoit–Wolf
最適化	TE の上限つきの BLM。上限は 3% ÷ 過去 36 か月の比（X03）で、平均 1.95%
取引費用	売買した額の 0.1%（片道）
比べる相手	時価総額のポートフォリオ（費用なし）
対照	点数を銘柄の間で入れ替えた同じ BLM（20 通り）

2.2　結果

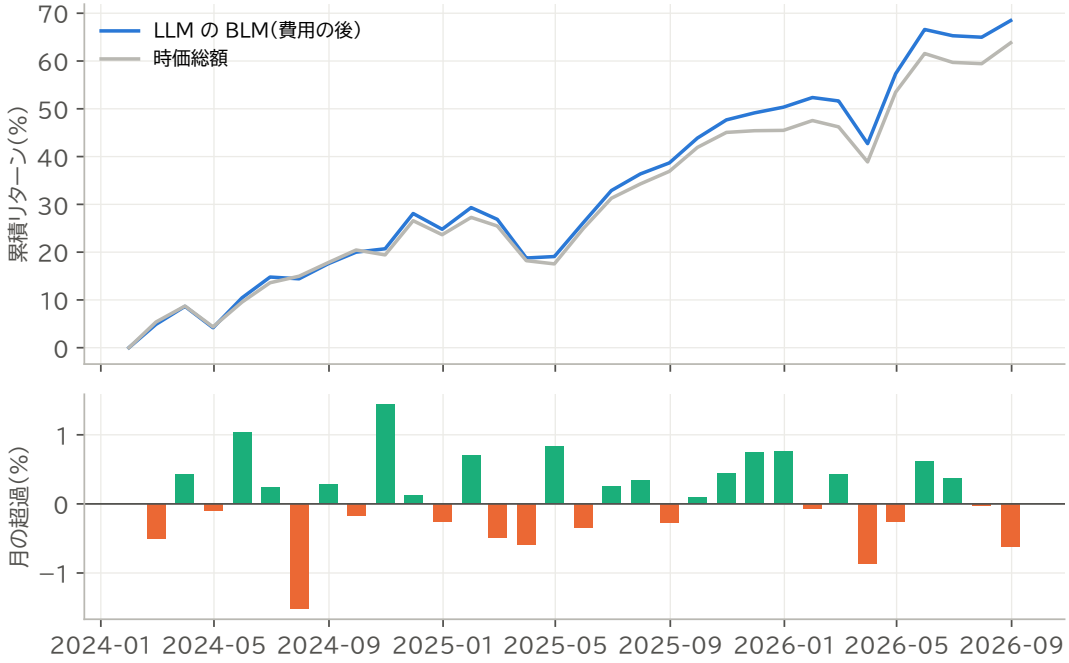


図2.1: 上：累積リターン（LLM の BLM は費用の後）。下：月ごとの超過リターン（緑はプラス、橙はマイナス）。

判定

支持されない。費用の後の超過リターンは月 +0.10%、Newey–West の $t = 1.22$（片側 $p = 0.12$）。

表2.2: 月次の BLM の成績（31 か月）。

超過リターン（費用の後、月）	+0.10%
超過リターン（費用の前、月）	+0.15%
情報比（年率、費用の後）	0.55
累積（BLM ／時価総額）	+68.5% ／ +63.8%
時価総額を上回った月	55%
回転率（月、片道）	25%
実際の TE（年率）	2.46%

- 向きはプラスだが、31 か月では有意でない。事前登録に書いたとおり、この期間で検出できるのは、年率の情報比が 2 を超える場合だけである。0.55 は「ない」とも「ある」とも言えない。
- **点数を入れ替えた対照との比較**（副次）：本物の LLM の BLM が、費用の前で月 +0.20% 上回った（$t = 2.30$）。対照は費用の後で月 −0.17% と、時価総額に負けた。比率を動かすこと自体は損だが、それを上回る分が点数の中身にあった、と読める。判定に使わない分析で、期間も短いので、仮説の段階にとどめる。
- **TE**：校正で上限が平均 1.95% になり、実際の TE は 2.46% と約束の内に収まった。X03 の校正は、LLM の見通しでも働いた。

第 3 章

実験 8：発表の翌日と日次の BLM

3.1　第 1 部：翌日の反応（判定）

実験 3 の標本 A（5,374 本）で、発表日（day 0）の終値から翌日（day 1）の終値までの超過リターンを、LLM の点数で回帰した。統制は実験 3 のモデル（実験 2 の統制＋アナリスト予想との差）に、day 0 の超過リターンを加えた。day 0 の終値で分かっている情報なので、LLM はそれを超える必要がある。

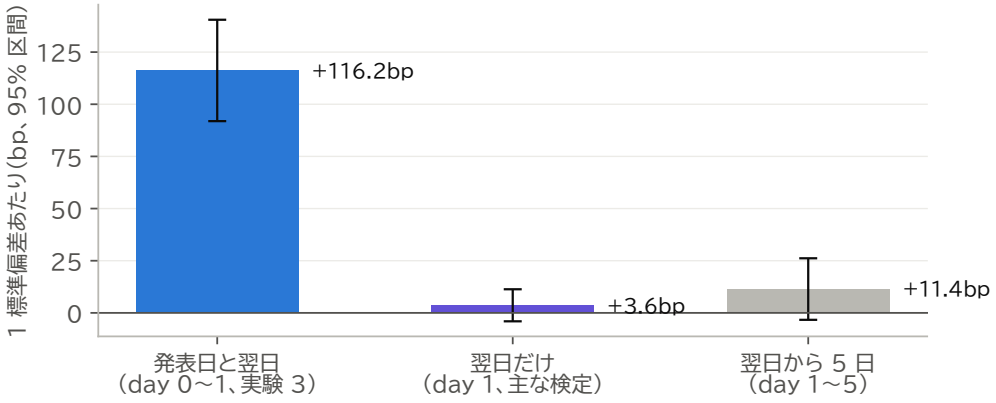


図3.1: LLM の合成点数の係数（1 標準偏差あたり、95% 区間）。左は実験 3 の主な結果（day 0〜1）。

判定

支持されない。翌日の係数は +3.6bp（95% 区間 −4.0〜+11.3、$t = 0.93$、置換の $p = 0.15$）。

表3.1: 翌日以降の反応への係数（1 標準偏差あたり）。

	係数	t	p（片側）
主な検定：day 1	+3.6bp	0.93	0.18
S1：day 1〜5	+11.4bp	1.52	0.065（Holm 0.13）
S2：day 1（day 0 の統制なし）	+3.4bp	0.87	0.19（Holm 0.19）

- 2 日の反応は 1 標準偏差あたり +116bp だった（実験 3）。翌日に残るのは、多く見ても +11bp（95% 区間の上限）で、反応のほとんどは発表日のうちに出る（図 3.1）。
- day 0 の反応そのものも、翌日を予測しなかった（−1.4bp、$t = -0.3$）。続きも戻りもない。

3.2　第 2 部：日次の BLM（報告）

毎日、その日が発表日の銘柄にだけ見通しを付け、その終値で BLM の比率を決めて、翌日の終値まで持った。見通しの作り方と Ω は実験 7 と同じで、点数はそれより前の日の全発表で標準化した。事前の TE は 3%、費用は片道 0.1%。期間は 2024-04-18〜2026-08-28 の 593 取引日（過去の発表が 500 本たまった日から）。

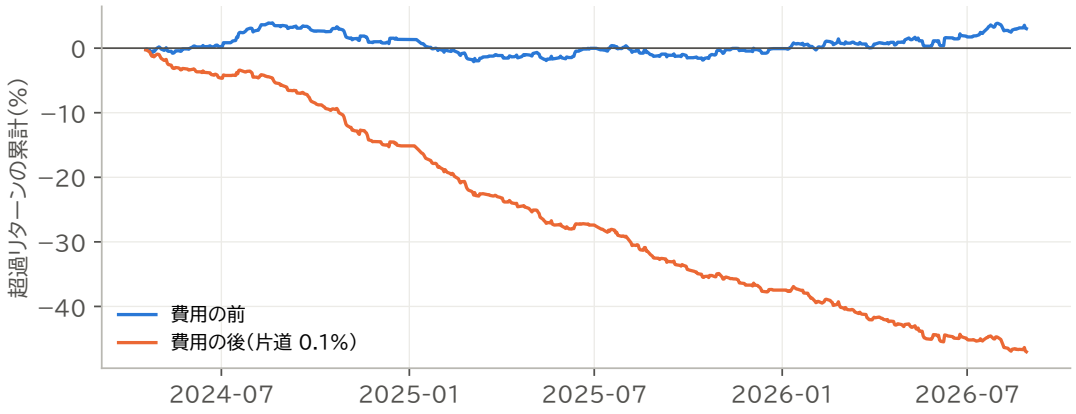


図3.2: 日次の BLM の、時価総額に対する超過リターンの累計。

表3.2: 日次の BLM の成績。

	LLM の BLM	点数を入れ替えた対照
超過リターン（費用の前、年率）	+1.3%	+2.0%
超過リターン（費用の後、年率）	−20.0%	−19.7%
日次の回転率（片道）	42%	43%
実際の TE	3.4%	3.2%

- 費用の前でも、LLM は対照を上回らない（差は −0.3bp ／日、$t = -0.3$）。第 1 部と合う。
- 毎日最適化をやり直すと、見通しのない銘柄も含めて比率全体が組み替わり、1 日に 42% が入れ替わった。片道 0.1% でも年 −20% になる（図 3.2）。日次で BLM を使うなら、売買を抑える仕組み（回転率の罰則、見通しのある銘柄だけを動かす）が欠かせない。
- 593 日のうち 32 日は、最適化の解の精度が低い可能性があった（ソルバーの警告）。費用の前の差が対照とほぼ同じなので、結論は変わらない。

第 4 章

考察と限界

4.1　何が分かったか

1. **LLM が決算発表から読み取る情報は、発表日のうちに株価に入る**。実験 2〜4 の「2 日で織り込まれる」は、実際には「発表日のうちに」だった。利益にするには、発表の直後（場中や時間外）に売買する必要があり、日次のデータでは検証できない。
2. **結果を全部入れた BLM は、約束の TE を守りながら、市場並みかやや上の成績だった**。月 +0.10% は有意でない。
3. **点数を入れ替えた対照には勝った**。月次でも弱い情報が残っているかもしれない。先読みのない ChronoGPT（実験 5）で 2016 年からの点数が作れれば、同じ BLM を約 10 年で確かめられる。
4. **日次の BLM は、設計の段階で売買を抑えないと成り立たない**。

4.2　限界

- **期間が短い**。実験 7 は 31 か月、実験 8 は約 2 年 4 か月。
- IC 0.05 は仮の値で、選び直していない。
- 時価総額の比率は浮動株で調整していない。上場をやめた銘柄は、その後 0% とした。
- 標本 A は、実験 2〜5 で一度見た期間である（翌日だけの反応は見ていなかった）。
- 日次の戦略は月ごとに並列で計算したため、月の最初の取引は時価総額の比率からの差で数えた。

再現の手順

```
python experiments/E2_event_reaction/run.py   # 実験 2 の panel.csv
python experiments/E7_monthly_blm/run.py      # 事前登録の後に 1 回（コミット 55ef830）
python experiments/E8_daily_blm/run.py        # 同上
cd 資料集/02_実験/実験7・8_月次と日次のBLM
python 作成スクリプト/figs.py                  # この資料の図
```

数値の出どころは、experiments/E7_monthly_blm/results/ と experiments/E8_daily_blm/results/ の summary.json、CSV、findings.md。費用は 0 円（CPU で約 15 分）。