# LLM-BLM 実験 7・8・9

LLM の決算の読み取りを BLM に入れて、
月次と日次でポートフォリオを組む

実験の結果の報告書

2026 年 10 月 18 日（実験 9 を 10 月 19 日に追加）

# 概要

実験 2〜4 で、gpt-4o-mini が決算発表文から読み取った点数は、発表後 2 取引日の反応を強く説明した。ただし 3 日目以降のドリフトはなかった。この報告書では、その点数を BLM の見通しに入れて、実際にポートフォリオを組んだ。

- **実験 7**：これまでの結果を全部入れた BLM を、月次で組んだ。
- **実験 8**：発表日の終値の時点で、LLM の情報がまだ株価に残っているかを調べ、日次の BLM も組んだ。
- **実験 9**：実験 7 の月次の BLM を、先読みのない ChronoGPT の予測（実験 5）を見通しにして、2017 年から約 10 年で確かめた。

実験 7・8 は同じコミット（`55ef830`）、実験 9 はコミット `0856fd0` に、手順・判定の基準・コードを固定してから、1 回ずつ実行した（事前登録）。

**主な結論**

- **実験 7：月次の BLM は、時価総額を有意には上回らない（支持されない）**。費用の後で月 +0.10%（年約 +1.2%、$t = 1.22$）。31 か月の累積は +68.5% と +63.8%。実際の TE は 2.5% と約束の 3% 以内だった。
- 副次の分析では、LLM の点数を銘柄の間で入れ替えた BLM を、本物が月 +0.20% 上回った（$t = 2.30$）。弱い情報が月次でも残っているかもしれない。
- **実験 8：発表日の終値の後には、LLM の情報は残っていない（支持されない）**。翌日の超過リターンへの係数は +3.6bp（$t = 0.93$）。2 日の反応（+116bp）のほぼ全部が、発表日のうちに出ている。
- **日次の BLM は費用に負ける**。毎日の最適化で 1 日に 42% が入れ替わり、費用の後で年 −20% だった。
- **実験 9：約 10 年でも、月次の BLM は市場とほぼ同じ（支持されない）**。費用の後で月 +0.003%（$t = 0.04$）。入れ替えた対照には月 +0.15%（$t = 1.78$）で、実験 7 と同じ向きだが有意でない。実験 7 の「やや上回る」は、31 か月の偶然の範囲だった可能性が高い。

# 目次

概要 1

第 1 章　目的 3

第 2 章　実験 7：月次の BLM 4
2.1　設計 . . . . . 4
2.2　結果 . . . . . 4

第 3 章　実験 8：発表の翌日と日次の BLM 6
3.1　第 1 部：翌日の反応（判定） . . . . . 6
3.2　第 2 部：日次の BLM（報告） . . . . . 6

第 4 章　実験 9：先読みのない見通しで、月次の BLM を約 10 年 8
4.1　設計 . . . . . 8
4.2　結果 . . . . . 8

第 5 章　考察と限界 10
5.1　何が分かったか . . . . . 10
5.2　限界 . . . . . 10

再現の手順 11

# 第 1 章

# 目的

これまでに分かったことを並べる。

- **見通しの中身**：gpt-4o-mini の点数は、決算発表への 2 日の反応を、数値の驚き・アナリスト予想・FinBERT（追加学習した版も含む）を超えて説明する（実験 2〜4）。ただし day 2〜21 のドリフトは +10bp で、有意でない。
- **見通しの不確かさ** Ω：LLM の 30 回の答えのばらつきは使えない（総合報告書 1）。
- **共分散と TE**：Ledoit–Wolf で十分。TE の上限は、過去 36 か月の「実際 ÷ 予測」の比で割ると守れる（補足実験 X01〜X03）。

**問い**

**実験 7**：これらを全部入れた BLM を月次で組むと、費用の後で時価総額を上回るか。
**実験 8**：発表日の終値の時点で、LLM の点数は、翌日の超過リターンを予測するか。

実験 7 の予想は、実行の前に事前登録に書いた。ドリフトがなかったので、上回らない見込みが高い。株価は発表日の寄り付きで跳ねるので、日次のデータで取引できるのは、早くても発表日の終値からである。実験 8 は、そこに情報が残っているかを見る。

第 2 章

# 実験 7：月次の BLM

## 2.1　設計

**表2.1:** 月次の BLM の設定（事前登録で固定）。

| | |
|---|---|
| 判断日 | 2024-01〜2026-07 の各月末（31 か月）。翌月末まで持つ。gpt-4o-mini の点数は 2023-11 以降の発表にしかないので、1 四半期分がそろう 2024-01 末から |
| 銘柄 | 各月末の S&P500 の構成銘柄（平均 491） |
| 事前分布 | 均衡リターン $\Pi = \delta \Sigma w_{\mathrm{mkt}}$（$\delta = 2.5$） |
| 見通し | 直近 92 日に反応が始まった決算発表がある銘柄（平均 454）。最新の発表の LLM の合成点数を正規スコア $z$ にし、$q_i = \Pi_i + 0.05\,\sigma_i z_i$（Grinold の $\alpha$） |
| $\Omega$ | He–Litterman：$\tau\,\mathrm{diag}(P\Sigma P')$、$\tau = 0.025$ |
| 共分散 | 直近 252 日の Ledoit–Wolf |
| 最適化 | TE の上限つきの BLM。上限は 3% ÷ 過去 36 か月の比（X03）で、平均 1.95% |
| 取引費用 | 売買した額の 0.1%（片道） |
| 比べる相手 | 時価総額のポートフォリオ（費用なし） |
| 対照 | 点数を銘柄の間で入れ替えた同じ BLM（20 通り） |

## 2.2　結果

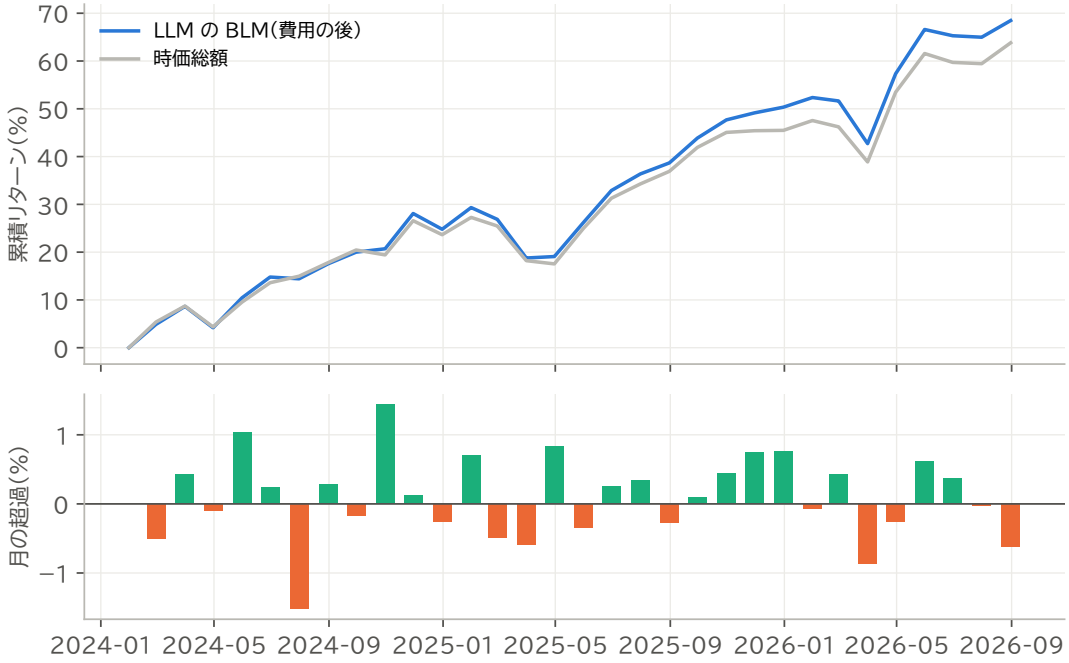



**図2.1:** 上：累積リターン（LLM の BLM は費用の後）。下：月ごとの超過リターン（緑はプラス、橙はマイナス）。

**判定**

**支持されない**。費用の後の超過リターンは月 $+0.10\%$、Newey–West の $t = 1.22$（片側 $p = 0.12$）。

**表2.2:** 月次の BLM の成績（31 か月）。

| | |
|---|---|
| 超過リターン（費用の後、月） | $+0.10\%$ |
| 超過リターン（費用の前、月） | $+0.15\%$ |
| 情報比（年率、費用の後） | 0.55 |
| 累積（BLM ／時価総額） | $+68.5\%$ ／ $+63.8\%$ |
| 時価総額を上回った月 | 55% |
| 回転率（月、片道） | 25% |
| 実際の TE（年率） | 2.46% |

- 向きはプラスだが、31 か月では有意でない。事前登録に書いたとおり、この期間で検出できるのは、年率の情報比が 2 を超える場合だけである。0.55 は「ない」とも「ある」とも言えない。
- **点数を入れ替えた対照との比較**（副次）：本物の LLM の BLM が、費用の前で月 $+0.20\%$ 上回った（$t = 2.30$）。対照は費用の後で月 $-0.17\%$ と、時価総額に負けた。比率を動かすこと自体は損だが、それを上回る分が点数の中身にあった、と読める。判定に使わない分析で、期間も短いので、仮説の段階にとどめる。
- **TE**：校正で上限が平均 1.95% になり、実際の TE は 2.46% と約束の内に収まった。X03 の校正は、LLM の見通しでも働いた。

第 3 章

# 実験 8：発表の翌日と日次の BLM

## 3.1　第 1 部：翌日の反応（判定）

実験 3 の標本 A（5,374 本）で、発表日（day 0）の終値から翌日（day 1）の終値までの超過リターンを、LLM の点数で回帰した。統制は実験 3 のモデル（実験 2 の統制＋アナリスト予想との差）に、day 0 の超過リターンを加えた。day 0 の終値で分かっている情報なので、LLM はそれを超える必要がある。

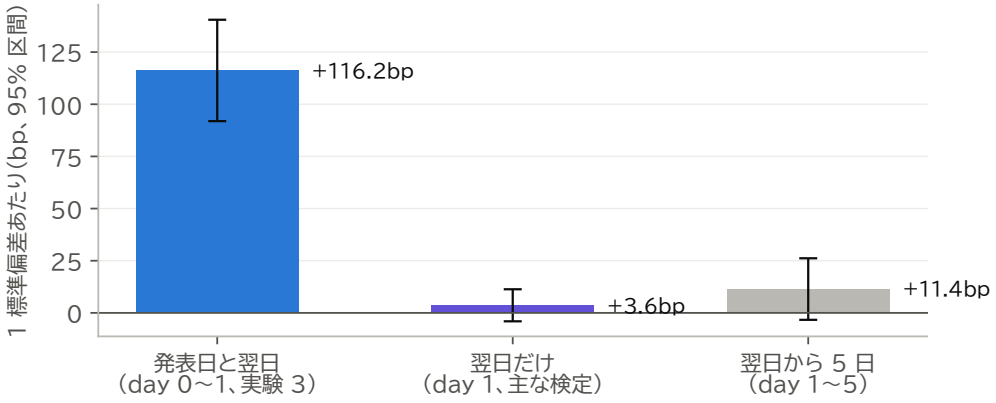



**図3.1:** LLM の合成点数の係数（1 標準偏差あたり、95% 区間）。左は実験 3 の主な結果（day 0〜1）。

**判定**

**支持されない**。翌日の係数は +3.6bp（95% 区間 −4.0〜+11.3、$t = 0.93$、置換の $p = 0.15$）。

**表3.1:** 翌日以降の反応への係数（1 標準偏差あたり）。

| | 係数 | $t$ | $p$（片側） |
|---|---|---|---|
| 主な検定：day 1 | +3.6bp | 0.93 | 0.18 |
| S1：day 1〜5 | +11.4bp | 1.52 | 0.065（Holm 0.13） |
| S2：day 1（day 0 の統制なし） | +3.4bp | 0.87 | 0.19（Holm 0.19） |

- 2 日の反応は 1 標準偏差あたり +116bp だった（実験 3）。翌日に残るのは、多く見ても +11bp（95% 区間の上限）で、反応のほとんどは発表日のうちに出る（図 3.1）。
- day 0 の反応そのものも、翌日を予測しなかった（−1.4bp、$t = -0.3$）。続きも戻りもない。

## 3.2　第 2 部：日次の BLM（報告）

毎日、その日が発表日の銘柄にだけ見通しを付け、その終値で BLM の比率を決めて、翌日の終値まで持った。見通しの作り方と Ω は実験 7 と同じで、点数はそれより前の日の全発表で標準化した。事前の TE は 3%、費用は片道 0.1%。期間は 2024-04-18〜2026-08-28 の 593 取引日（過去の発表が 500 本たまった日から）。

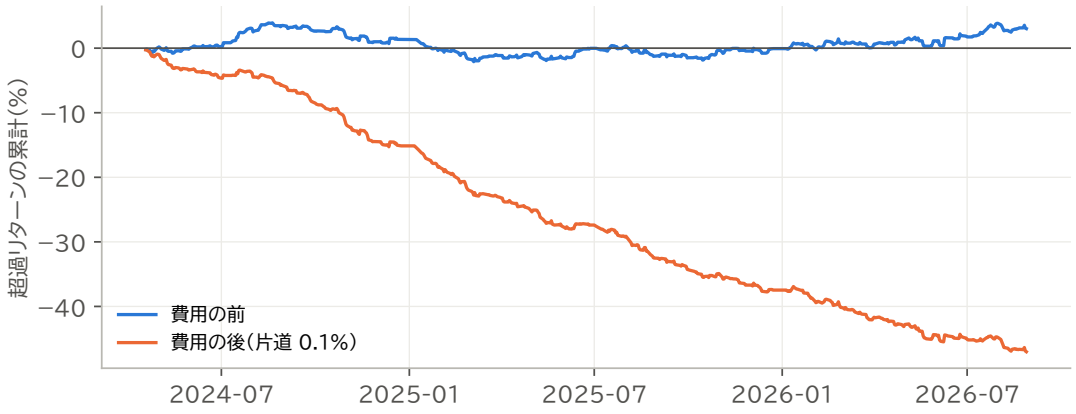



**図3.2:** 日次の BLM の、時価総額に対する超過リターンの累計。

**表3.2:** 日次の BLM の成績。

| | LLM の BLM | 点数を入れ替えた対照 |
|---|---|---|
| 超過リターン（費用の前、年率） | +1.3% | +2.0% |
| 超過リターン（費用の後、年率） | −20.0% | −19.7% |
| 日次の回転率（片道） | 42% | 43% |
| 実際の TE | 3.4% | 3.2% |

- 費用の前でも、LLM は対照を上回らない（差は −0.3bp ／日、$t = -0.3$）。第 1 部と合う。
- 毎日最適化をやり直すと、見通しのない銘柄も含めて比率全体が組み替わり、1 日に 42% が入れ替わった。片道 0.1% でも年 −20% になる（図 3.2）。日次で BLM を使うなら、売買を抑える仕組み（回転率の罰則、見通しのある銘柄だけを動かす）が欠かせない。
- 593 日のうち 32 日は、最適化の解の精度が低い可能性があった（ソルバーの警告）。費用の前の差が対照とほぼ同じなので、結論は変わらない。

第 4 章

# 実験 9：先読みのない見通しで、月次の BLM を約 10 年

## 4.1　設計

実験 7 は 31 か月しかなく、月 +0.10% が本物かどうか分からなかった。実験 5 で、先読みのない ChronoGPT の予測が 2016 年から作れたので、それを見通しにして同じ BLM を長い期間で回した。

- **見通し**：2023-10-31 までに提出された発表は、実験 5 のまとまり B（版 2015）の予測。それ以降はまとまり A（版 2022）の予測。版 2022 の、それより前の発表への予測は使わない。
- **TE の上限**：X03 の規則（X02 の過去 36 か月）は 2020 年より前に使えないので、この戦略自身の過去の月の「実際 ÷ 予測」で 3% を割った（12 か月たまるまでは 3%）。
- それ以外（見通しの作り方、Ω、共分散、費用、入れ替えた対照 20 通り）は実験 7 と同じ関数を使った。

**事前登録からのずれ（実装の誤り）**

事前登録では判断日を 2016-03〜2026-07（125 か月）としたが、主な実行は 2017-01〜2026-07 の 115 か月だった。判断日の一覧を借りた関数が、2017 年からしか日付を返さなかったためである。計画の変更ではなく、コードの誤りである。日付の部分だけを直し、125 か月でも 1 回だけ実行した（`results/corrected_dates/`）。結論は同じだった。判定は事前登録どおり主な実行で行う。

## 4.2　結果

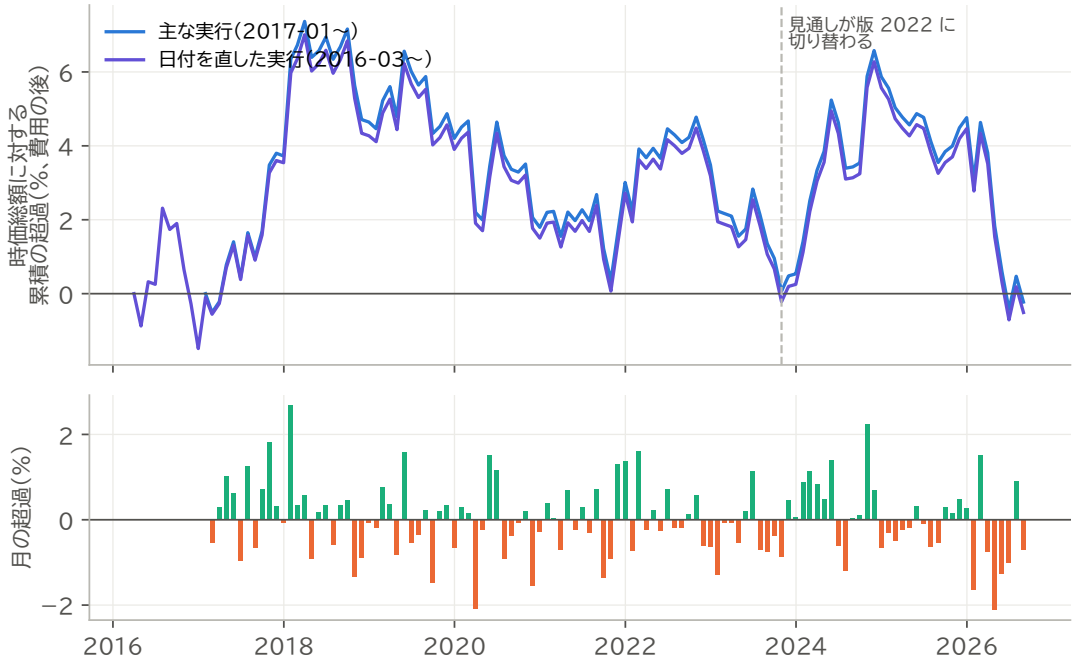



**図4.1:** 上：時価総額に対する累積の超過リターン（費用の後）。破線から見通しが版 2022 の予測に切り替わる。下：主な実行の月ごとの超過リターン。

**判定**

**支持されない**。費用の後の超過リターンは月 +0.003%、Newey–West の $t = 0.04$（片側 $p = 0.49$）。日付を直した 125 か月でも月 +0.002%（$t = 0.02$）。

**表4.1:** 実験 9 の成績。

| | 主な実行（115 か月） | 日付を直した実行（125 か月） |
|---|---|---|
| 超過リターン（費用の後、月） | +0.003%（$t$ 0.04） | +0.002%（$t$ 0.02） |
| 超過リターン（費用の前、月） | +0.06% | +0.06% |
| 累積（BLM ／時価総額） | +303.9% ／ +304.8% | +354.0% ／ +356.3% |
| 回転率（月、片道） | 30% | 30% |
| 入れ替えた対照との差（費用の前、月） | +0.15%（$t$ 1.78） | +0.14%（$t$ 1.75） |
| 実際の TE（目標 3%） | 3.04% | 3.04% |

- 約 10 年で、費用の後はほぼ 0。費用の前の月 +0.06%（年約 +0.7%）を、取引費用がちょうど打ち消している。2018 年初めまでに累積で約 +7% 上回ったが、その後は上下しながら 0 に戻った（図 4.1）。
- 入れ替えた対照には、月 +0.15% 上回った。実験 7（+0.20%、$t$ 2.30）と同じ向きで大きさも近いが、10 年では $t$ 1.8 で 5% には届かない。比率を動かすこと自体の損（対照は費用の後で月 −0.24%）を、予測の中身がほぼ埋め合わせて、市場並みに戻している。
- 見通しがすべて版 2015 の月（2017-01〜2023-09）でも、2023-10 以降の月でも、ほぼ 0 だった。2023-10 以降は実験 7 とほぼ同じ期間だが、見通しの源が違う（実験 7 は gpt-4o-mini）。
- 自分の過去で校正した TE の上限（平均 2.77%）で、実際の TE は 3.04% と約束どおりだった。

第 5 章

# 考察と限界

## 5.1　何が分かったか

1. **LLM が決算発表から読み取る情報は、発表日のうちに株価に入る**。実験 2〜4 の「2 日で織り込まれる」は、実際には「発表日のうちに」だった。利益にするには、発表の直後（場中や時間外）に売買する必要があり、日次のデータでは検証できない。
2. **結果を全部入れた BLM は、約束の TE を守りながら、市場並みかやや上の成績だった**。月 +0.10% は有意でない。
3. **点数を入れ替えた対照には勝った**。月次でも弱い情報が残っているかもしれない。約 10 年で確かめた実験 9 でも同じ向き（月 +0.15%、$t$ 1.78）だったが、有意ではなかった。
4. **日次の BLM は、設計の段階で売買を抑えないと成り立たない**。
5. **約 10 年で見ても、決算の読み取りを入れた月次の BLM は市場とほぼ同じだった（実験 9）**。予測の中身はランダムより良いが、費用を払うほどではない。実験 7 の「やや上回る」は、短い期間の偶然の範囲だった可能性が高い。

## 5.2　限界

- **期間が短い**。実験 7 は 31 か月、実験 8 は約 2 年 4 か月。実験 9 は約 10 年だが、見通しの予測は gpt-4o-mini の半分以下の強さ（実験 5）。
- IC 0.05 は仮の値で、選び直していない。
- 時価総額の比率は浮動株で調整していない。上場をやめた銘柄は、その後 0% とした。
- 標本 A は、実験 2〜5 で一度見た期間である（翌日だけの反応は見ていなかった）。
- 日次の戦略は月ごとに並列で計算したため、月の最初の取引は時価総額の比率からの差で数えた。

# 再現の手順

```
python experiments/E2_event_reaction/run.py   # 実験 2 の panel.csv
python experiments/E7_monthly_blm/run.py      # 事前登録の後に 1 回（コミット 55ef830）
python experiments/E8_daily_blm/run.py        # 同上
python experiments/E9_monthly_blm_long/run.py # 事前登録の後に 1 回（0856fd0）
cd 資料集/02_実験/実験7・8_月次と日次のBLM
python 作成スクリプト/figs.py                  # この資料の図
```

数値の出どころは、experiments/E7_monthly_blm/results/ と experiments/E8_daily_blm/results/ の summary.json、CSV、findings.md。費用は 0 円（CPU で約 15 分）。