LLM-BLM 実験 11

決算発表文の読ませ方とまとめ方の修正：
先読みのない LLM は、小技なしでも NLP を超えるか

実験の結果の報告書

2026 年 10 月 21 日

概要

LLM や NLP が決算発表文を読むとき、読める長さは限られている（ChronoGPT は約 7,000 字、gpt-4o-mini は先頭 15,000 字）。発表文の後半は、ばらけた表や免責事項が多い。そこで、文献調査で挙がった「少ない読む量で効果を上げる」修正 5 つを試した。

- 修正 1：表の切れ端と定型文を除く
- 修正 2：FinBERT の読む範囲を変える（先頭＋末尾、全文）
- 修正 3：会社ごとの点数をセクターにまとめる方法
- 修正 4：ChronoGPT の埋め込みの取り方（真ん中の層、最後のトークン）
- 修正 5：LLMLingua-2 で文章を圧縮する

開発用のモデル（先読みのない ChronoGPT と NLP）で修正を試し、残すかどうかは人ではなく事前に決めた規則が決めた。そのあと、まだ使っていない最終の期間で、gpt-4o-mini・ロジスティック回帰・反応で追加学習した BERT と並べて、1 回だけ比べた。

主な結論

- **修正はほとんど残らなかった**。表の切れ端や定型文を除いても、反応の説明力はほぼ変わらない（大事な記述はもともと先頭にある）。まとめ方も、今のやり方（直近の発表、時価総額加重）が最良だった。
- **それでも、先読みのない ChronoGPT は NLP を超えた（主な検定は支持）**。2020 年以降の 13,141 本で、数字の統制と辞書・FinBERT・TF-IDF を超えて、1 標準偏差あたり +34bp（t 4.8、置換の $p = 0.001$）。期間の切り方を変えた 3 通りすべてで支持。
- **探索：効いたのは埋め込みの取り方だった**。ChronoGPT の真ん中の層を使うと、開発の期間の説明力が約 1.6 倍になった（3 通りすべてで差の t 2 以上）。ただし、規則の順番のせいで本番の判定には入っていない。圧縮（修正 5）ははっきり悪くなった。
- **セクター単位の BLM では、どのモデルも効かなかった**。

目次

概要 1

第 1 章　目的と設計 3
1.1　問い . . . 3
1.2　期間の分け方 . . . 3
1.3　残すかどうかの規則 . . . 3
1.4　モデルと比べる相手 . . . 3

第 2 章　実行の記録 5

第 3 章　開発の結果 6
3.1　修正 1 は、ほとんど差がなかった . . . 6
3.2　探索：試されなかった修正 2・4・5 . . . 6

第 4 章　最後の比較 8
4.1　主な検定 . . . 8
4.2　会社ごとの比較 . . . 8
4.3　セクター単位 . . . 9

第 5 章　考察と限界 10
5.1　何が分かったか . . . 10
5.2　限界 . . . 10

再現の手順 11

第 1 章

目的と設計

1.1　問い

問い

主：修正後の先読みのない ChronoGPT は、数字の統制と、修正後の NLP 3 つ（辞書・FinBERT・TF-IDF）を超えて、決算発表への 2 取引日の反応を説明するか。
副：修正 1〜5 は、それぞれのモデルの説明力を上げるか。修正後のモデルは、gpt-4o-mini・ロジスティック回帰・反応で追加学習した BERT と並べるとどうか。セクター単位の BLM ではどうか。

1.2　期間の分け方

修正を何度も試した期間で最終の比較をすると、良く見える修正を選んだ分だけ結果が甘くなる。期間を開発と最終に分け、切り方を 3 通り用意した。

表1.1: 期間の切り方。主な結果は B。A と C は確認用。

切り方	開発	最終	最終の月数
B（主）	2016〜2019 年	2020-01〜2026-08	約 80 か月
A	2016〜2020 年	2021-01〜2026-08	約 68 か月
C	2016〜2022 年	2023-01〜2026-08	約 44 か月

C の開発の期間は A・B の最終の期間に重なる。そこで、修正を残すかどうかは人が選ばず、事前にコードで固定した規則が切り方ごとに機械的に決めた。

1.3　残すかどうかの規則

1. 修正前と比べて主な指標が良くなり、その差の t が 1 以上（会社ごと：同じ発表どうしで当てはまりの差を比べ、発表日ごとにまとめた標準誤差。セクターごと：月ごとの IC の差の Newey–West の t）。
2. 開発の期間の前半と後半のどちらでも悪くならない。
3. 順番：修正 1 →（修正 1 が残れば）修正 2・4・5 → 修正 3。

1.4　モデルと比べる相手

- **ChronoGPT**：全期間で版 2015（2015 年末までの文章で学習）に揃えた。2016 年以降には先読みがない。埋め込みの上に、四半期ごとに過去の発表だけで学習するリッジ回帰を置く（実験 5 と同じ）。
- **NLP**：辞書（Loughran–McDonald）、FinBERT（学習なし）、TF-IDF ＋リッジ（四半期ごとに学び直す）。
- **ロジスティック回帰**：数字の説明変数だけで、反応の符号を当てる。

- **BERT（追加学習）**：実験 4 の FinBERT の追加学習を、切り方ごとに開発の終わりまでの反応で学び直したもの。
- **gpt-4o-mini**：最後の比較だけに使う（開発では一度も使わない）。期間は 2023-11 以降。

TF-IDF は新しい言葉を覚え直し、FinBERT は 2019 年までの文章を知っている。ChronoGPT には不利な条件での比較である。

第 2 章

実行の記録

事前登録とコードを固定してから、点数付け・開発の判定・最後の比較をそれぞれ 1 回だけ行った。途中で起きたことを、すべて記録する。

事前登録の後に直したこと（どれも、どの点数の評価よりも前）

- **修正 5 を行った。**事前に決めた確認で、修正 1 の後でも見通しの語が ChronoGPT の読む範囲の外にある発表が 10.7%（基準 10% 以上）だったため。圧縮用のモデル（LLMLingua-2、MIT）とそのコードを、評価の前に追加した。
- **修正 1 の規則の穴を直した。**最初の規則は、定型文の語やメールアドレスを 1 つでも含む行を、行ごと捨てていた。要約がまるごと 1 行に詰まった発表では、大事な中身まで消えていた（1,500 本の抜き出しで約 15%）。開発の判定が別の理由（文章が空になる発表）で止まったときに見つけ、文単位で定型文だけを捨てる形に直して、点数を作り直した。直した後の確認で、消える「見通し」の語は、見出しだけの行・免責事項・説明会の案内の中のものだけだった。
- 直した後も文章が何も残らない 14 本（本文が見出しだけの発表）は、その修正の点数を「なし」として比較から除いた。

- 計算はすべてこの PC（RTX 5050）で行った（約 19 時間）。一度、借りた GPU（RunPod、RTX 4090）で回したが、結果をダウンロードする前に止めてしまい、消えたので使っていない。
- 修正 1 で除いた文字は平均 27%。
- 規則の判定で切り方 B では修正 1 が残らなかったので、事前に決めた条件どおり、gpt-4o-mini の付け直しは行わなかった（費用 0 円）。

第 3 章

開発の結果

3.1　修正 1 は、ほとんど差がなかった

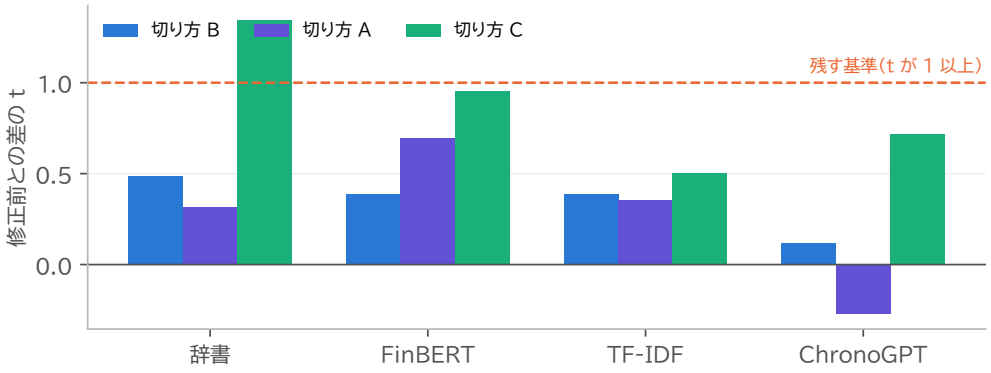


図3.1: 開発の期間での、修正 1（表の切れ端と定型文を除く）と修正前の差の t。破線が残す基準。

表3.1: 開発の判定で残った修正。

切り方	残った修正	まとめ方
B（主）	なし	今のまま（直近 92 日、時価総額加重）
A	なし	今のまま
C	辞書の修正 1 だけ（差の t 1.34）	今のまま

- 修正 1 の差は、どのモデルでも決定係数で ±0.0005 ポイント以内と、ほぼ 0 だった（図 3.1）。大事な記述（要約と見通し）は、もともと発表の先頭にある。
- 修正 3（まとめ方）：直近の発表を日数で弱める形も、単純平均も、今のやり方を超えなかった。単純平均は、どのモデル・切り方でも悪くなった（差の t はおおむね -1〜-3）。セクターの見通しは、セクターの値動きを決める大きな会社の読み取りで作るほうがよい。
- 修正 2・4・5 は、順番の規則（修正 1 が残ったときだけ試す）により、FinBERT と ChronoGPT では判定に進まなかった。

3.2　探索：試されなかった修正 2・4・5

順番の規則で判定に進まなかった修正を、事前登録とは別の探索として、修正前と直接比べた。

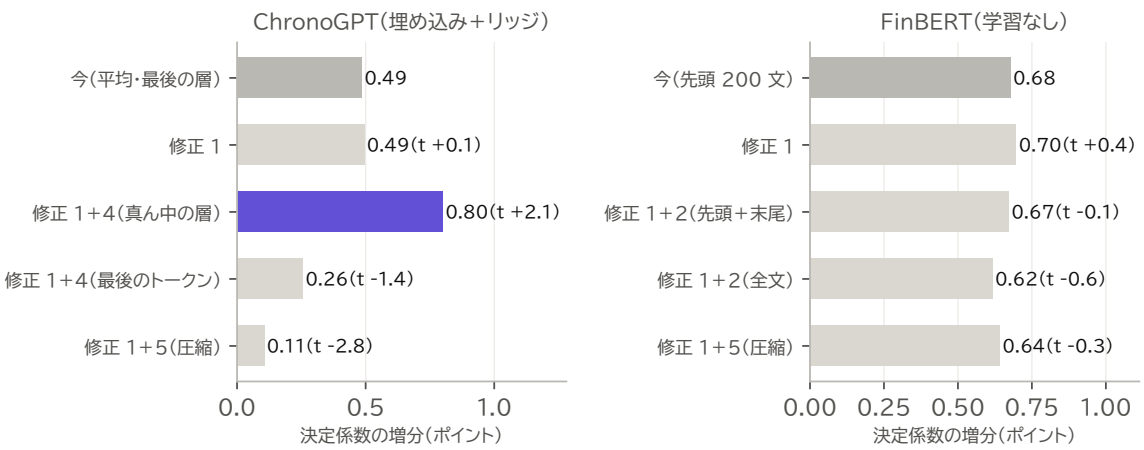


図3.2: 切り方 B の開発の期間で、数字の統制に加えたときの決定係数の増分。括弧は修正前との差の t。色の濃い棒が、規則の基準を満たすもの。探索の結果で、判定には使っていない。

- **ChronoGPT の真ん中の層（修正 4）が、はっきり良かった**。増分は 0.49 → 0.80 ポイント（約 1.6 倍）。3 つの切り方すべてで差の t が 2 以上（B 2.07、A 2.57、C 2.86）で、規則で試されていれば残っていた（図 3.2）。最後の層は次の単語を当てることに特化していて、真ん中の層のほうが文章の意味をよく持っている、という文献の指摘と合う。
- 最後のトークンは悪くなった（t −1.4〜−2.0）。
- **圧縮（修正 5）は、はっきり悪くなった**（ChronoGPT で t −2.8〜−4.3）。単語を間引いた崩れた文章を、ChronoGPT はうまく読めない。
- FinBERT の読む範囲の変更（修正 2）と圧縮は、どれも良くならなかった。

第 4 章

最後の比較

4.1　主な検定

判定

支持。切り方 B の最終の期間（2020-01〜2026-08、13,141 本）で、ChronoGPT の係数は 1 標準偏差あたり +34.3bp（95% 区間 +20.3〜+48.4、$t = 4.79$）、置換の片側 $p = 0.001$。統制は、数字の説明変数と、辞書・FinBERT・TF-IDF。

表4.1: 主な検定（修正が残らなかったので、ChronoGPT と NLP は修正前と同じ）。

切り方	本数	係数（bp）	t	置換の p	判定
B（主）	13,141	+34.3	4.79	0.001	支持
A	11,252	+38.1	4.88	0.001	支持
C	7,448	+37.0	3.51	0.001	支持
gpt-4o-mini の期間（参考）	5,706	+47.8	3.79	—	—

4.2　会社ごとの比較

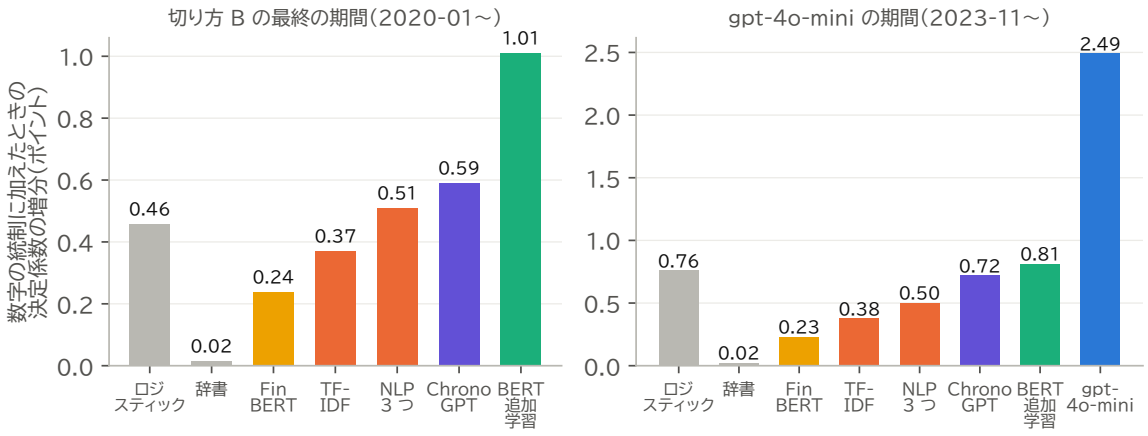


図4.1: 数字の統制に、それぞれを 1 つずつ加えたときの決定係数の増分。左：切り方 B の最終の期間。右：gpt-4o-mini の点数がある期間。

- ChronoGPT（+0.59 ポイント）は、NLP 3 つをまとめたもの（+0.51）より大きい。
- 反応で学習した BERT（+1.01）は ChronoGPT より大きい。学習なしの gpt-4o-mini は、短い期間で +2.49 と群を抜く（同じ期間で ChronoGPT は +0.72）。実験 4・5 と同じ並び。

ロジスティック回帰の作りの弱さ（探索で確かめた）

事前登録したロジスティック回帰は、外れ値に弱かった。アナリスト予想との差には −500% のような極端な値があり、標準化するとふつうの値が押しつぶされる。そのため、全体の予測の当たり具合（AUC 0.593）が、アナリスト予想との差 1 つだけ（0.612）より低くなり、文章の点数を足すと AUC がむしろ下がった。変数を学習期間の中での順位に直すと（探索）、土台の AUC は 0.611 になり、ChronoGPT を足すと +0.0026（95% 区間 +0.0005〜+0.0047）上がった。AUC の比較は、この版で読むのがよい。

4.3　セクター単位

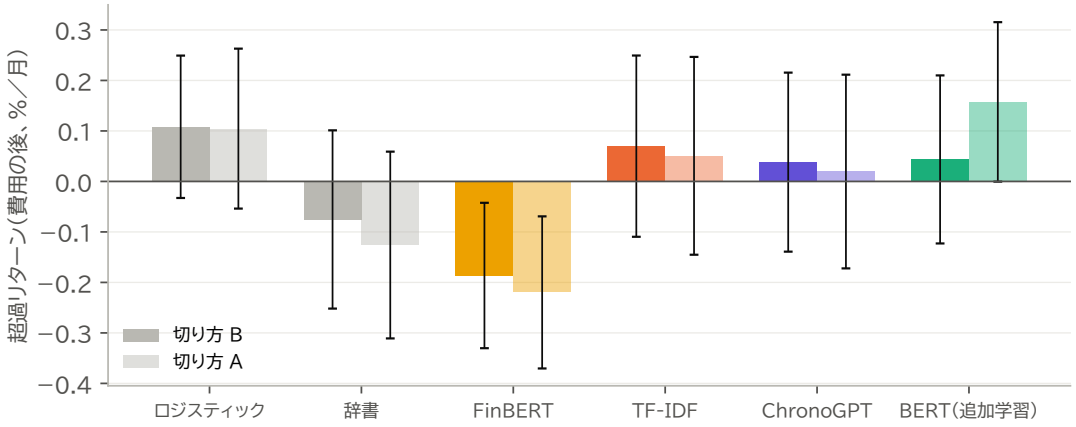


図4.2: セクター単位の BLM（11 セクター＋米国債、TE の上限 3%、片道 0.1% の費用）の、時価総額に対する月次の超過リターン（95% 区間）。濃い色が切り方 B、薄い色が A。

どのモデルも、費用の後で有意に時価総額を上回らなかった（図 4.2）。翌月のセクターのリターンとの順位相関（IC）も、ロジスティック回帰（+0.08、t 2.6）以外はほぼ 0 だった。学習なしの FinBERT は月 −0.19%（t −2.5）と悪かった。決算発表の情報は月次の見通しにはほとんど残らない、という実験 7〜9 の結論と同じである。

第 5 章

考察と限界

5.1　何が分かったか

1. **読ませ方の小技（不要な部分を除く、範囲を変える、圧縮する）は、ほとんど効かない**。決算発表の大事な記述は先頭にまとまっていて、今の読み方でも読めていた。圧縮はむしろ害になる。
2. **効く可能性があるのは、モデルの中のどこを取り出すか（真ん中の層）**。ただし探索の結果で、確かめるには新しい事前登録が要る。最終の期間はもう見たので、新しい確認では、まだ使っていない評価（たとえば翌年の発表）を用意する必要がある。
3. **先読みのない LLM は、小技なしでも NLP を超える情報を持つ**。5 年以上の期間で、3 通りの切り方すべてで支持された。
4. **それでも、反応で学習した BERT と、大きな LLM（gpt-4o-mini）には及ばない**。

5.2　限界

- 修正 1 の規則に穴があり、点数の評価の前に直した。
- 順番の規則のせいで、修正 2・4・5 は本番の判定に進まなかった。修正 1 の成否と、ほかの修正の成否を結び付けたのは設計の誤りだった。
- 事前登録したロジスティック回帰は外れ値に弱かった（順位の版は探索）。
- 開発の期間（2016〜2019 年）は、実験 2〜5 で反応を一度見た期間。
- gpt-4o-mini の期間は約 33 か月と短い。

再現の手順

```
python experiments/F_fixes/score.py stats dictionary finbert chrono_raw chrono
python experiments/F_fixes/score.py compress finbert5 chrono5
python experiments/F_fixes/develop.py      # 開発の判定（規則で機械的に）
python experiments/F_fixes/bert.py         # BERT の学び直し（切り方ごと）
python experiments/F_fixes/gpt.py          # 条件つき（今回は行わず）
python experiments/F_fixes/final.py        # 最後の比較（1 回だけ）
python experiments/F_fixes/explore_fixes245.py     # 探索
python experiments/F_fixes/explore_rank_logit.py   # 探索
```

数値の出どころは `experiments/F_fixes/results/` の JSON と `findings.md`、事前登録は `experiments/F_fixes/preregistration.md`。費用はこの PC の分は 0 円（RunPod で回して結果が消えた分に、数ドルかかった）。