LLM-BLM 実験 R1

新しい 1,000 社での S1〜S4 の再現と、
BLM が比べる相手を上回るかの検定

実験の報告書（事前登録した検定の結果）

2026 年 10 月 25 日

概要

小型株の実験 S1〜S4 は、同じ 1,000 社（元の標本）で行った。この実験 R1 では、元の標本に含まれない新しい 1,000 社で S1〜S4 を同じコード・同じ設定で 1 回ずつやり直し（再現）、あわせて、S4 の形の BLM が比べる相手（範囲の全社、浮動株時価総額で加重）を上回るかを、新しい主な検定（R-BLM）として事前登録して確かめた。

要点

- **4 つの主な検定のうち 3 つが再現した**。決算発表文の読み取りが発表後 2〜60 日のドリフトを予測すること（S1：+54.5bp/SD、$t = +2.22$、並べ替えの $p = 0.0080$）、発表後の変動率を予測すること（S2：+1.06%/SD、$t = +3.01$）、文章のリスクの点数で共分散を補正しても TE の見積もりは良くならないこと（S3）は、新しい標本でも同じだった。TE の校正（S4）は再現しなかった。
- **R-BLM は、事前登録の基準では支持された**（2017 年以降、比べる相手との差は年 +5.3%、95% 区間 [+1.1%, +12.2%]、片側 p <0.001）。ただし実現の TE は 10.0% で、約束の 3% の約 3 倍だった。
- **探索（結果を見た後の分析）で、その原因は株価データの誤りだとわかった**。2020-11-20 に、破産から再出発した会社（CHRD）の古い株と新しい株の価格を yfinance がつないでいて、1 日で約 +25,700% の、実際にはなかった値上がりが入っていた。この 1 日だけで、BLM と相手の差が +30% 開き、そのあと約 3 年、校正が TE の上限を下限の 1% に張り付かせた。
- **ありえない日々のリターン（+300% 超、−80% 未満）を除いて計算し直すと**、新しい標本でも校正は元の標本と同じように効いた（偏り g：校正なし 1.24 → 校正あり 1.08。元の標本は 1.26 → 1.04）。S4 の不成立は、この種のデータの誤りでほぼ説明できる。
- 誤りを除いた後の R-BLM の BLM は、新しい標本で実現の TE 3.2%、相手との差は年 +2.9%（95% 区間 [+1.0%, +4.8%]、片側 p <0.001）、元の標本で差は年 +3.0%（片側 p <0.001）だった。事前登録の値（年 +5.3%）の多くは誤りから来ていたが、誤りを除いても、両方の標本で相手を上回った。これは結果を見た後の分析なので、誤りを除く規則を先に決めて、別の期間で確かめ直す必要がある。
- 同じ種類のデータの誤りは元の標本にもあった。これからの小型株の計算では、株価の誤りを先に取り除く手順を、事前登録に入れる。

目次

概要 1

第 1 章　目的 3

第 2 章　事前登録と方法 4
2.1　新しい標本 4
2.2　実行 4
2.3　再現の判定 4
2.4　新しい主な検定（R-BLM） 4

第 3 章　再現の判定 5

第 4 章　新しい主な検定（R-BLM） 7

第 5 章　探索：TE が約束の約 3 倍になった理由 8
5.1　1 日の寄与 8
5.2　原因：破産から再出発した会社の株価のつなぎ 8
5.3　ありえないリターンを除いた計算 9

第 6 章　まとめ 11

第 7 章　限界 12

再現の手順 13

第 1 章

目的

S1〜S4 は、同じ 1,000 社（元の標本）で行った。S1 の検定自体は事前登録して 1 回だけ実行したが、S2〜S4 の設計は S1 の結果を見た後であり、BLM の推移が比べる相手を上回ったことは検定していなかった。そこで、次の 2 つを、元の標本に含まれない新しい 1,000 社で確かめた。

問い

1. S1〜S4 の主な検定の結果は、別の 1,000 社でも同じになるか（再現）。
2. S4 の形の BLM（ChronoGPT の見通し・株価で補正した共分散・TE の校正）は、比べる相手（範囲の全社、浮動株時価総額で加重）を上回るか（新しい主な検定）。

第 2 章

事前登録と方法

仮説・方法・判定の基準は `experiments/R1_replication/preregistration.md` に書き、コードと同じコミットで固定してから実行した。新しい標本の株価の反応・変動率・ポートフォリオは、それまで一度も計算していない。

2.1　新しい標本

元の標本を選んだのと同じ条件（小型株の範囲に一度でも入った会社のうち、いま上場して株価があり、2016 年以降の決算の 8-K が 4 件以上）を満たす 2,400 社から、元の 1,000 社を除いた 1,400 社のうち、1,000 社を乱数の種 1 で選んだ（元の標本との重なりは 0）。決算発表文・財務データ・驚き・点数（辞書、FinBERT、ChronoGPT、gpt-4o-mini）は、元の標本と同じコードで作った。

2015 年以降の発表は 38,601 件（元の標本は 38,054 件）、評価する発表（2020 年以降、範囲の中）は 16,164 件（元は 15,997 件）。

2.2　実行

S1〜S4 のコードを、データベース・点数の保存先・結果のフォルダだけを環境変数で切り替えて、元と同じ順・同じ設定・同じ乱数の種で 1 回ずつ実行した。

2.3　再現の判定

S1・S2・S4 の主な検定は、元と同じ基準で「支持」なら「再現した」。S3 の主な検定は、元の結果が「支持されない」だったので、再び「支持されない」なら「再現した（効果なし）」とした。

2.4　新しい主な検定（R-BLM）

2015 年末から四半期ごと、ChronoGPT ＋リッジの見通し、株価で補正した共分散（B）、TE の校正ありの BLM について、2017 年以降の日次の超過リターン（BLM − 比べる相手）の平均が正かを、円形のブロック・ブートストラップ（ブロック 63 日、2,000 回）で検定した（片側 $p < 0.05$ で「支持」）。

第 3 章

再現の判定

表3.1: S1〜S4 の主な検定：元の標本と新しい標本

実験	主な数字	元の標本	新しい標本	判定
S1：ドリフトの予測（ChronoGPT ＋リッジ → 2〜60 日の超過リターン）	係数（bp/SD）	+76.1	+54.5	**再現した**
	t	+3.20	+2.22	
	並べ替えの片側 p	0.0010	0.0080	
S2：変動率の予測（ChronoGPT ＋リッジ → 2〜60 日の変動率）	係数（%/SD）	+1.51	+1.06	**再現した**
	t	+4.01	+3.01	
	並べ替えの片側 p	0.0010	0.0200	
S3：文章のリスクの点数で共分散を補正（B → C）	偏り b（B）	1.220	3.552	**再現した**（効果なし）
	偏り b（C）	1.219	3.494	
	片側 p	0.201	0.287	
S4：TE の上限の校正（B → B ＋校正）	g（B）	1.22	3.72	**再現しなかった**
	g（B ＋校正）	1.05	3.32	
	実現の TE（B ＋校正）	3.2%	10.0%	
	片側 p	0.004	0.148	

評価した発表は、新しい標本で 16,164 件（元の標本は 15,997 件）、gpt-4o-mini の期間（2024 年以降）は 7,418 件。偏り b ＝ 日々の（BLM − 相手）÷ 事前の TE の 2 乗平均の平方根、g ＝ 日々の（BLM − 相手）÷（$3\%/\sqrt{252}$）の 2 乗平均の平方根（どちらも 1 なら見積もりどおり）。

結果

4 つのうち 3 つが再現した。

- **S1（ドリフト）**：係数は元の +76.1bp から +54.5bp に小さくなったが、t ＝ +2.22、並べ替えの p ＝ 0.0080 で、同じ基準を満たした。
- **S2（変動率）**：+1.06%/SD（t ＝ +3.01）。元より小さいが、同じ向きではっきりしている。
- **S3（文章による共分散の補正）**：元と同じく、補正しても偏りは変わらなかった（効果がないことが再現した）。
- **S4（TE の校正）**：再現しなかった。新しい標本では偏りが 3.72 と大きく（元は 1.22）、校正しても 3.32（実現の TE 10.0%）にしか下がらなかった。原因は 第 5 章の探索で調べた。

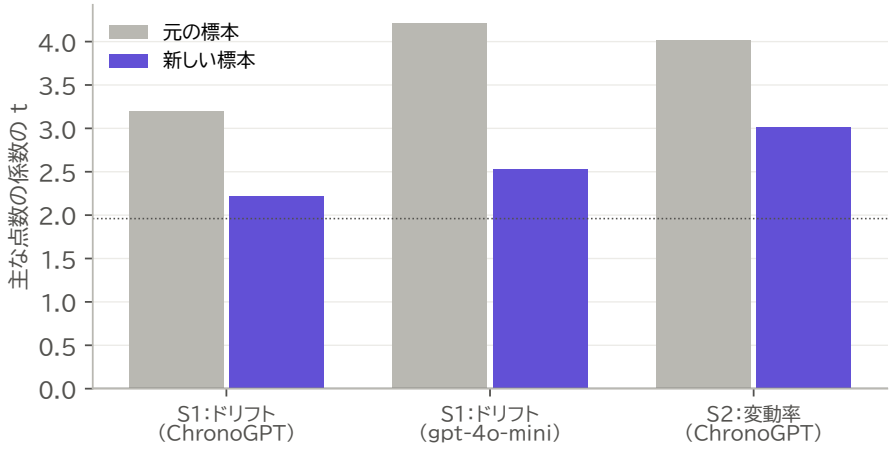


図3.1: 主な点数の係数の t。点線は 1.96。S1 の gpt-4o-mini は副次の検定（2024 年以降）。

gpt-4o-mini の読み取り（学習なし）も、新しい標本でドリフトを予測した（+83.9bp/SD、$t = +2.53$。元は +148.9bp、$t = +4.21$）。

S1 の副次の月次のポートフォリオ（点数の上位 5 分の 1 を浮動株時価総額で持つ、片道 0.3% の費用の後）は、元の標本で月 +0.16%（$t = +0.73$）、新しい標本で月 −1.43%（$t = -0.88$）で、どちらも比べる相手との差ははっきりしなかった。

第 4 章

新しい主な検定（R-BLM）

結果

事前登録の基準では**支持された**。2015 年末から四半期ごとの BLM（ChronoGPT ＋リッジ、共分散 B、TE の校正あり）の、2017 年以降 2,449 日の比べる相手との差は年 +5.3%（95% 区間 [+1.1%, +12.2%]、片側 p <0.001）、情報レシオ +0.53。
ただし実現の TE は 10.0% で、約束の 3% の約 3 倍だった。この差の多くは 1 日のデータの誤りから来ている（第 5 章）。

表4.1: BLM と比べる相手の差（年率、評価する日）。主な検定は 1 行目。ほかは副次（判定には使わない）。元の標本の列は、R1 の事前登録を書いた時点で一度計算していた探索の値

				元の標本（探索）			新しい標本		
始点	リバランス	見通し		相手との差	情報レシオ	片側 p	相手との差	情報レシオ	片側 p
2015 年末	四半期	ChronoGPT	**主**	+3.0%	+0.96	0.002	+5.3%	+0.53	<0.001
2015 年末	半年	ChronoGPT		+2.5%	+0.79	0.002	+2.3%	+0.71	0.011
2015 年末	1 年	ChronoGPT		+2.0%	+0.64	0.009	+1.1%	+0.32	0.153
2023 年末	四半期	ChronoGPT		+5.7%	+1.74	0.003	+2.7%	+0.91	0.065
2023 年末	半年	ChronoGPT		+4.2%	+1.14	0.061	+2.8%	+0.88	0.088
2023 年末	1 年	ChronoGPT		+1.2%	+0.32	0.266	+1.4%	+0.47	0.182
2023 年末	四半期	gpt-4o-mini		+2.2%	+0.62	0.195	+1.3%	+0.43	0.167

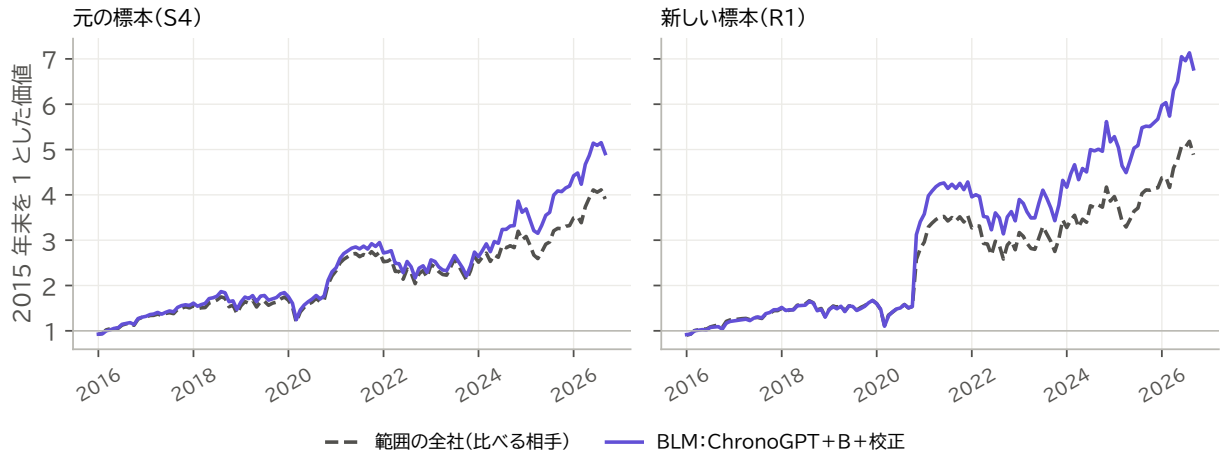


図4.1: 2015 年末を 1 とした推移（四半期ごと、ChronoGPT ＋リッジ、共分散 B、TE の校正あり）。新しい標本の 2020 年 11 月の跳ね上がりの多くは、比べる相手にも BLM にも入っている株価の誤り（第 5 章）。

最終の値は、元の標本で BLM 4.899・相手 3.906、新しい標本で BLM 6.764・相手 4.882。

第 5 章

探索：TE が約束の約 3 倍になった理由

この章は事前登録していない。R1 の結果を見た後に、新しい標本で実現の TE が大きかった理由を調べた（`experiments/R1_replication/explore.py`、結果は `results/explore_orig.json`・`explore_rep.json`）。ここの数字で、前の章の判定は変えない。

5.1　1 日の寄与

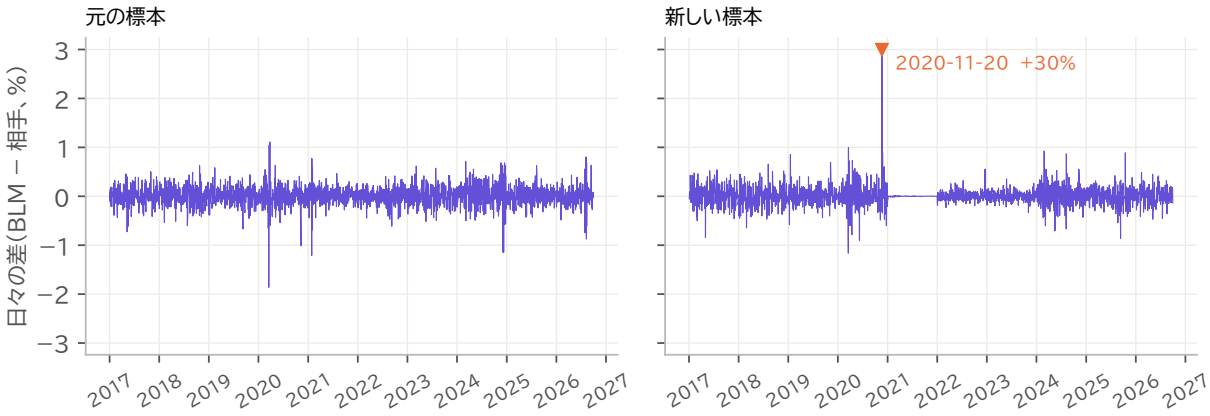


図5.1: 日々の差（BLM − 比べる相手、%）。2017 年以降、四半期ごと、共分散 B、TE の校正あり。±3% を超える日は端に印を付けた。

新しい標本では、2020-11-20 の 1 日に、BLM と相手の差が +30% 開いた。日々の差の 2 乗の合計のうち、いちばん大きい 5 日が占める割合は、新しい標本で 93%（元の標本は 9%）。この 5 日を除くと、偏り g は次のようになる。

表5.1: 偏り g（2017 年以降、四半期ごと）と、いちばん大きい 5 日を除いた値

	元の標本		新しい標本	
共分散	g	5 日を除く	g	5 日を除く
A（補正なし）	1.26	1.20	2.22	1.14
B（株価で補正）	1.22	1.17	3.72	1.11
B ＋校正	1.05	1.01	3.32	0.89

5 日を除くと、新しい標本の偏りは元の標本と同じくらいになり、校正すると 1 を下回った。

5.2　原因：破産から再出発した会社の株価のつなぎ

その日に大きく動いたのは CHRD（今の Chord Energy。2020 年当時は Oasis Petroleum）だった。Oasis は 2020 年に連邦破産法 11 条の手続きに入り、2020 年 11 月に新しい株で再出発した。古い株は取り消されて新し

い株が発行されたので、古い株を持っていた人の資産が 1 日で 250 倍になったわけではない。ところが yfinance は、古い株の最後の価格（0.12 ドル）に新しい株の最初の価格（31 ドル）をそのままつないでいて、調整後終値の日々のリターンは 2020-11-20 に約 +25,700% になっていた。

BLM はこの銘柄を相手より約 0.1% 多く持っていたので、この 1 日で差が大きく開いた。比べる相手も浮動株時価総額でこの銘柄を持っていたので、相手の価値も同じ日に跳ね上がった（図 4.1）。さらに、TE の校正は過去 756 日の偏りで上限を割るので、この 1 日が過去 756 日に入っていた 2020 年 12 月から 2023 年 9 月まで（12 回のリバランス、約 3 年）、上限は下限の 1% に張り付き、BLM の動きは小さくなった（図 5.1）。

同じような日は、両方の標本にあった。

表5.2: 標本の会社の日々のリターン（調整後終値、2015 年以降）のうち、ありえない大きさのもの

	元の標本	新しい標本
会社 × 日の数	2,953,000	2,953,000
+300% を超える日	30	38
+100% を超える日	171	203
−80% を下回る日	30	31

いちばん大きいもの：元の標本は AMPY（2016-10-24、+16,079%）、NFE（2026-08-04、+5,064%）、NFE（2026-08-07、+5,060%）、新しい標本は CHRD（2020-11-20、+25,733%）、DFTX（2019-12-27、+4,700%）、TPST（2023-10-11、+3,971%）。破産からの再出発のつなぎのほか、1 日で何十倍にもなって翌日に元へ戻る、価格の乱れもあった。

5.3　ありえないリターンを除いた計算

S4 の 2015 年末から四半期ごとのポートフォリオを、日々のリターンのうちしきい値を超えるものを欠け（S4 は欠けた価格を 0% と数える）として、計算し直した。しきい値は、計算する前に 3 通り決めた（主：+300% 超か −80% 未満）。そのままの計算は S4 の値と一致した（元の標本でも一致した）。

表5.3: ありえない日々のリターンを除いた計算（2017 年以降、四半期ごと、ChronoGPT ＋リッジ）。最終の値は 2015 年末を 1 とした 2026 年 9 月末の値

			B ＋校正（R-BLM の主なポートフォリオ）					A ＋校正	最終の値	
標本	日々のリターンの扱い	除いた数	g	実現の TE	相手との差	情報レシオ	片側 p	g	BLM	相手
元の標本	そのまま（S4 と同じ）	0	1.05	3.2%	+3.0%	+0.96	0.002	1.04	4.90	3.91
元の標本	+300%・−80% を除く（主）	60	1.04	3.1%	+3.0%	+0.97	<0.001	1.05	4.88	3.89
元の標本	+100%・−50% を除く	353	1.02	3.0%	+2.6%	+0.86	0.003	1.05	4.65	3.88
元の標本	+1000%・−90% を除く	30	1.03	3.1%	+2.6%	+0.83	0.004	1.05	5.04	4.17
新しい標本	そのまま（S4 と同じ）	0	3.32	10.0%	+5.3%	+0.53	<0.001	1.91	6.76	4.88
新しい標本	+300%・−80% を除く（主）	69	1.08	3.2%	+2.9%	+0.89	<0.001	1.08	4.19	3.52
新しい標本	+100%・−50% を除く	417	1.07	3.2%	+2.7%	+0.83	0.002	1.08	4.14	3.58
新しい標本	+1000%・−90% を除く	25	1.06	3.2%	+2.9%	+0.92	<0.001	1.07	4.25	3.53

探索の結果

- 主のしきい値で除くと（新しい標本で 69 個の会社 × 日）、新しい標本の B ＋校正の偏りは $g = 1.08$（実現の TE 3.2%）になり、約束の 3% に近づいた。比べる相手との差は年 +2.9%（95% 区間 [+1.0%,

+4.8%]、片側 p <0.001)、情報レシオ +0.89。

- 元の標本では、除いても結果はほとんど変わらなかった（差は年 +3.0%、片側 p <0.001、$g = 1.04$)。
- **誤りを除くと、新しい標本でも TE の校正は効いた**。偏り g は、校正なしの B で 1.24、B +校正で 1.08（元の標本は 1.26 → 1.04)。S4 が再現しなかったのは、主にこの種の誤りのためだった。
- 比べる相手の最終の値も、新しい標本ではそのままの 4.88 から 3.52 に下がった。2020 年 11 月の跳ね上がりの多くが誤りだったことを裏づける。
- つまり、R-BLM の年 +5.3% の多くは株価の誤りから来ていた。誤りを除いた後の値が、この BLM の成績の、より正直な見積もりである。ただし、これは結果を見た後の分析なので、別の標本か別の期間で、誤りを除く手順を先に決めて確かめ直す必要がある。
- ほかの 2 つのしきい値でも、結論は同じ向きだった（表 5.3)。最適化が解けなかったリバランスは、比べる相手の比率のままにした（S4 が解けないときと同じ扱い)。

第 6 章

まとめ

- **決算発表文の読み取りが、小型株の発表後のドリフトと変動率を予測することは、別の 1,000 社でも再現した**（S1・S2）。係数は元の標本より小さかった。
- **文章のリスクの点数で共分散を補正しても、TE の見積もりは良くならない**ことも再現した（S3）。
- **TE の校正（S4）と R-BLM は、株価データの誤り 1 日に大きく左右された**。事前登録の判定（S4 は再現しない、R-BLM は支持）はそのまま記録するが、どちらも誤りの影響を受けた結果である。
- **誤りを除くと（探索）**、TE の校正は両方の標本で効き（実現の TE 約 3%）、BLM は両方の標本で比べる相手を年約 3% 上回った（新しい標本 +2.9%、元の標本 +3.0%）。事前登録の値（年 +5.3%）の約半分は誤りによる上乗せだった。
- **これからの手順**：小型株の株価は、計算の前に、ありえない日々のリターン（破産からの再出発のつなぎ、1 日だけの乱れ）を取り除く。その規則を事前登録に書いてから、BLM の検定をやり直す。

第 7 章

限界

- **株価データの誤り**：yfinance の調整後終値には、破産から再出発した会社の古い株と新しい株のつなぎや、1 日だけの価格の乱れが残っている（第 5 章）。S1・S2 の回帰は目的変数を 1%・99% で切るので影響は小さいが、BLM の日々のリターンと TE は切らないので、大きく左右される。誤りを除いた計算は探索で、事前登録していない。
- **生存者バイアス**：新しい標本も、いま上場している会社だけである。元の標本と同じ選び方なので、同じ偏りを共有する。資産の水準は高く出ている。
- **同じ母集団**：新しい標本は、元の標本と同じ母集団（米国の小型株、2015〜2026 年）の残りの会社である。別の市場・別の期間での再現ではない。
- **費用と規模**：費用は片道 0.3% の一定とした。小型株で大きな資金を動かすと、インパクトでもっとかかる。

再現の手順

リポジトリの直下で（.venv の Python）：

1. python -m smallcap.replica（新しい標本のデータベースを作る）。
2. smallcap/start_replica.ps1、smallcap/start_replica_llm.ps1（決算発表文・財務データ・驚き・点数）。
3. experiments/R1_replication/start_analysis.ps1（S1〜S4 と R1 を、環境変数を切り替えて 1 回ずつ）。
4. 探索：python experiments/R1_replication/explore.py orig と ... explore.py rep（それぞれ約 30 分）。
5. 資料集/02_ 実験/実験 R1_ 新しい 1000 社での再現/作成スクリプト/ の values.py と figs.py、このフォルダで tectonic -X compile LLM-BLM_ 実験 R1.tex。