LLM-BLM 実験 S2

小型株で、決算発表文の読み取りは
発表後の変動率（リスク）を予測するか

実験の報告書（事前登録した検定の結果）

2026 年 10 月 24 日

概要

実験 S1 では、小型株で、決算発表文の読み取りが発表後のドリフト（リターンの向き）を予測した。この実験 S2 では、同じ 1,000 社の決算発表文で、読み取りが発表後の**変動率（リスク）**を、過去の変動率を超えて予測するかを、事前登録して 1 回だけ確かめた。

要点

- **主な検定は支持された**。ChronoGPT（2015 年版）のベクトルに、変動率の驚きを正解にしたリッジを当てた点数が 1 標準偏差高い発表は、発表の前の変動率・2 日の反応の大きさなどを統制した後、2〜60 取引日の変動率が +1.51% 高かった（$t = +4.01$、置換の片側 p 0.0010、発表 15,158 件）。2021 年以降では +2.17%（$t = +6.05$）。
- **ただし大きさは小さい**。決定係数の増分は 0.036 ポイントで、変動率の大部分は発表の前の変動率で説明される。
- **ほかの点数**：ChronoGPT の 26 層目、gpt-4o-mini の 14 項目＋リッジ、辞書の否定的な語も有意に正。辞書の不確実さの語、FinBERT の否定的な文は有意でなかった。2 日の反応の大きさは、辞書の否定的な語や gpt-4o-mini のリスクの印の数がよく予測した。
- **標本外の予測には役立たなかった**。四半期ごとに学習した単純な予測のモデルに点数を足すと、二乗誤差はわずかに大きくなった（比 1.0107、$t = -5.34$）。点数の情報は、同じ時期の銘柄どうしの相対的なリスクについてのもので、変動率の水準の予測には効かなかった。
- **次**：BLM の Ω や量の調整に、リスクの点数を相対的に使う（新しい事前登録の追記として）。

目次

概要 1

第 1 章　目的 3

第 2 章　事前登録 4

第 3 章　データと変数 5
3.1　標本 5
3.2　目的変数 5
3.3　統制 5
3.4　点数 5

第 4 章　主な検定 6

第 5 章　副次の検定と比較 7
5.1　ほかの点数 7
5.2　比較の表 7

第 6 章　標本外の予測 9

第 7 章　解釈 11
7.1　何が分かったか 11
7.2　BLM への使い道 11
7.3　注意すべき点 11

第 8 章　限界 12

再現の手順 13

第 1 章

目的

実験 S1 では、小型株で、ChronoGPT ＋リッジの決算発表文の読み取りが、発表後 2〜60 日のドリフト（リターンの向き）を予測した。しかし、規模で加重した月次のポートフォリオでは、有意な差にならなかった。

リターンの平均より、変動率（リスク）のほうが予測しやすい。変動率には強い持続性があり、過去の変動率でかなり説明できる。文章の不確実さや否定的な語が、その後の変動率と関係するという研究もある。そこで、次の問いを確かめた。

問い

決算発表文の読み取りは、過去の変動率と 2 日の反応の大きさを超えて、発表後 2〜60 取引日の変動率を予測するか。

予測できれば、BLM の見通しの不確かさ（Ω）や量の調整に使える。この実験では、その応用は検定しない。

第 2 章

事前登録

検定の仮説・データ・変数・方法・判定の基準は `experiments/S2_smallcap_risk/preregistration.md` に書き、実行するコード（`run.py`）と同じコミットで固定してから、1 回だけ実行した。実行に使ったコミットは `ecf16bb`（`results/summary.json` に記録）。

- **書いた時点で見ていたもの**：S1 のすべての結果（点数と符号つきの超過リターンの関係）。
- **見ていなかったもの**：どの銘柄の、どの期間の変動率も計算していなかった。点数と変動率、点数と反応の大きさ（絶対値）の関係も、一度も計算していなかった。
- **主な検定 P**：2020 年以降・範囲の中の発表で、`log_rv_2_60` を `chrono_risk` と統制・固定効果で回帰した係数が正か。
- **判定**：片側 t の $p < 0.05$、かつ、同じ反応日の中で点数を 1,000 回入れ替える置換の片側 $p < 0.05$ なら「支持」。
- **副次**（判定に使わない）：ほかの点数（2 つの族でそれぞれ Holm）、2 つの期間 $\times$ 4 つの目的変数の比較の表、標本外の予測の比較、2021 年以降と 2 日の反応の大きさを統制から外した頑健性。

第 3 章

データと変数

3.1　標本

S1 と同じ 1,000 社（今も上場している会社）の決算発表文。2015 年以降の発表は 38,054 件、評価する発表（2020 年以降、提出日に範囲の中）は 15,997 件、gpt-4o-mini の点数がそろう 2024 年以降の発表は 6,975 件。2015〜2019 年の発表は学習にだけ使った。

3.2　目的変数

反応日を day 0 として、調整後終値の日次の対数リターンから計算した（年率、$\sqrt{252}$ 倍）。

- 主：`log_rv_2_60`：2〜60 取引日目の変動率の対数（59 日のうち 40 日以上のリターンがあるもの）
- 副：`log_rv_2_21`（2〜21 日目）、`log_ivol_2_60`（IWM との日次の差の変動率、2〜60 日目）、`abs_r_0_1`（2 日の反応の大きさ |`abn_r_0_1`|）

係数は、点数が 1 標準偏差高いときの差で、対数の変動率では「%」（対数の差 × 100、ほぼ変動率の比の%）、反応の大きさでは「bp」で示す。

3.3　統制

発表の前の変動率（`log_rv_pre`：−60〜−1 日、`log_rv_long`：−252〜−61 日）、規模（`log_float`）、決算と売上の驚きの大きさ（|SUE|、| 売上の驚き |、欠けの印）、業種と年・四半期の固定効果。2 日の反応の大きさ（day 1 の終値で分かる）も統制に入れた（目的変数が反応の大きさのときは除く）。標準誤差は反応日ごとにまとめた。

3.4　点数

表3.1: 比べた点数（どれも「高いほどリスクが高い」向き。評価する標本の中で標準化）

列	中身	学習
`chrono_risk`	ChronoGPT 2015 年版、元の文章の最後の層の平均（S1 と同じベクトル）に、四半期ごとのリッジ（主）	変動率の驚き
`chrono_mid_risk`	ChronoGPT 2015 年版、掃除した文章の 26 層目の平均に、同じリッジ	変動率の驚き
`dict_uncertainty`	Loughran–McDonald の不確実さの語の割合	なし
`dict_negative`	Loughran–McDonald の否定的な語の割合	なし
`finbert_negative`	FinBERT の否定的な文の割合	なし
`gpt_flags`	gpt-4o-mini のリスクの印 10 個の数	なし
`gpt_risk`	gpt-4o-mini の 14 の項目に、同じリッジ	変動率の驚き

学習ありの点数の正解は「変動率の驚き」$\log(\mathrm{rv}_{2\sim60}/\mathrm{rv}_{\mathrm{pre}})$ で、その四半期が始まる前に 60 日の窓が閉じた発表だけで学習した。

第 4 章

主な検定

表4.1: 主な検定 P：2020 年以降・範囲の中の発表で、2〜60 取引日の変動率（対数）を `chrono_risk` と統制・固定効果で回帰した結果

点数が 1 標準偏差高いときの変動率の差	+1.51%
95% 信頼区間	[+0.77, +2.25]%
t（反応日ごとにまとめた標準誤差）	+4.01
片側 p	<0.001
置換（同じ反応日の中で 1,000 回）の片側 p	0.0010
発表の数（反応日の数）	15,158（1,384）
決定係数の増分	0.036 ポイント
判定	**支持**

結果

事前登録の判定の基準を両方とも満たし、仮説は**支持**された。ChronoGPT ＋リッジの点数が 1 標準偏差高い発表は、発表の前の変動率（2 つの期間）・2 日の反応の大きさ・規模・驚きの大きさ・業種と時期の固定効果を統制したうえで、その後 2〜60 取引日の変動率が +1.51% 高かった。1,000 回の置換のどれも、実際の係数を超えなかった。

- **大きさは小さい**：1 標準偏差で約 1.5%（変動率の比で、例えば年 50% が 50.8% になる程度）。決定係数の増分は 0.036 ポイントで、変動率のばらつきの大部分は、発表の前の変動率で説明される。
- **2021 年以降**：+2.17%（$t = +6.05$）。同じ向きで、より大きい。
- **2 日の反応の大きさを統制から外す**：+1.61%（$t = +4.25$）。ほとんど変わらない。点数の情報は、市場が 2 日で示した反応の大きさとは別のものである。

第 5 章

副次の検定と比較

5.1　ほかの点数

表5.1: 副次の検定：2〜60 日の変動率の回帰（係数は変動率の%。族ごとに Holm の補正）

期間	点数	係数	t	片側 p	Holm の p	発表の数
2020 年以降	ChronoGPT 26 層目＋リッジ	+1.64%	+5.42	<0.001	<0.001	15,140
2020 年以降	辞書：不確実さの語	+0.37%	+1.51	0.066	0.131	15,158
2020 年以降	辞書：否定的な語	+0.94%	+3.97	<0.001	<0.001	15,158
2020 年以降	FinBERT：否定的な文	+0.26%	+1.10	0.135	0.135	15,143
2024 年以降	gpt-4o-mini：リスクの印の数	+0.56%	+1.85	0.033	0.033	6,236
2024 年以降	gpt-4o-mini：14 項目＋リッジ	+1.41%	+4.21	<0.001	<0.001	6,236
2024 年以降	ChronoGPT ＋リッジ（主）	+1.70%	+3.06	0.001	0.002	6,236

- **ChronoGPT の 26 層目**（掃除した文章）は、主のモデルと同じくらい強く、Holm の補正の後も有意だった。
- **学習なしの点数**：辞書の否定的な語の割合は有意に正（+0.94%、$t = +3.97$）だった。辞書の不確実さの語と、FinBERT の否定的な文の割合は、有意でなかった。「不確実さ」の語が変動率を予測するという直感とは違う結果である。
- **gpt-4o-mini の期間**（2024 年以降）：14 の項目に重みを学習したもの（+1.41%、$t = +4.21$）と、ChronoGPT ＋リッジ（+1.70%、$t = +3.06$）が強く、リスクの印の数（学習なし）は弱かった（+0.56%、$t = +1.85$。Holm の補正の後も 5% で有意）。

5.2　比較の表

表5.2: 2020 年以降：係数と、括弧の中は t

点数 単位	変動率 2〜60 日 %	変動率 2〜21 日 %	固有の変動率 2〜60 日 %	2 日の反応の大きさ bp
ChronoGPT ＋リッジ（主）	+1.51 (+4.01)	+1.09 (+2.54)	+1.57 (+3.90)	+21.9 (+2.55)
ChronoGPT 26 層目＋リッジ	+1.64 (+5.42)	+0.97 (+2.74)	+1.94 (+6.06)	+19.9 (+2.80)
辞書：不確実さの語	+0.37 (+1.51)	+0.14 (+0.45)	+0.43 (+1.61)	−16.5 (−2.64)
辞書：否定的な語	+0.94 (+3.97)	+0.75 (+2.63)	+0.80 (+2.93)	+34.5 (+5.15)
FinBERT：否定的な文	+0.26 (+1.10)	+0.57 (+1.99)	+0.34 (+1.29)	+4.6 (+0.75)
発表の数（最大）	15,158	15,834	15,158	15,870

表5.3: 2024 年以降（gpt-4o-mini の点数がそろう発表）：係数と、括弧の中は t

点数 単位	変動率 2〜60 日 %	変動率 2〜21 日 %	固有の変動率 2〜60 日 %	2 日の反応の大きさ bp
ChronoGPT ＋リッジ（主）	+1.70 (+3.06)	+1.01 (+1.79)	+1.53 (+2.56)	+18.0 (+1.23)
ChronoGPT 26 層目＋リッジ	+2.02 (+4.60)	+1.17 (+2.42)	+2.04 (+4.20)	+9.6 (+0.71)
辞書：不確実さの語	+0.33 (+0.93)	+0.73 (+1.70)	+0.51 (+1.33)	−5.9 (−0.60)
辞書：否定的な語	+0.47 (+1.34)	−0.01 (−0.03)	+0.30 (+0.71)	+42.1 (+3.80)
FinBERT：否定的な文	+0.80 (+2.37)	+0.60 (+1.57)	+0.50 (+1.40)	+25.5 (+2.43)
gpt-4o-mini：リスクの印の数	+0.56 (+1.85)	+0.38 (+1.04)	+0.31 (+1.00)	+39.1 (+3.80)
gpt-4o-mini：14 項目＋リッジ	+1.41 (+4.21)	+1.58 (+4.06)	+1.02 (+2.89)	+16.4 (+1.42)
発表の数（最大）	6,236	6,912	6,236	6,948

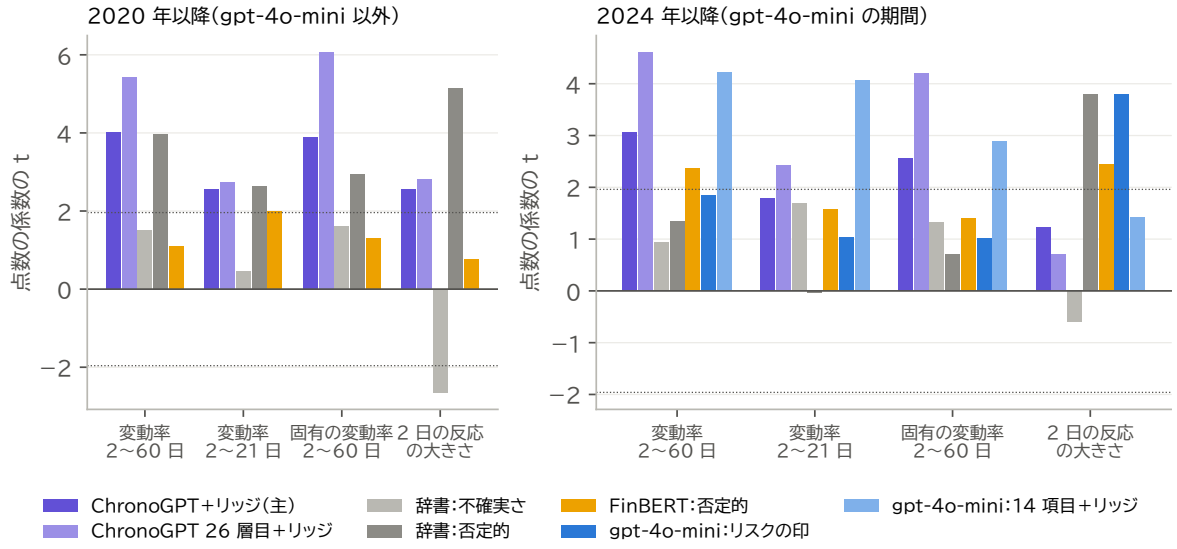


図5.1: 点数の係数の t。点線は ±1.96。

- 学習ありの点数（ChronoGPT の 2 つ、gpt-4o-mini の 14 項目）は、2〜60 日・2〜21 日・固有の変動率のどれでも正だった。
- **2 日の反応の大きさ**は、学習なしの点数のほうがよく説明した。辞書の否定的な語、gpt-4o-mini のリスクの印の数、FinBERT の否定的な文（2024 年以降）は、反応が大きくなることを予測した。一方、辞書の不確実さの語は、2020 年以降では反応が**小さい**ことと関係した。悪い知らせを多く含む発表ほど、株価が大きく動く。

第 6 章

標本外の予測

事前登録の副次の 4：2020 年以降の各四半期について、その四半期の前に 60 日の窓が閉じた発表だけで最小二乗を学習し、2〜60 日の変動率（対数）を予測した。基準のモデル（発表の前の変動率、規模、2 日の反応の大きさ、驚きの大きさ）と、それに ChronoGPT ＋リッジの点数を足したモデルを比べた。

表6.1: 標本外の予測の比較（発表 15,158 件）

標本外の決定係数（基準のモデル）	47.60%
標本外の決定係数（基準＋点数）	47.04%
差	−0.56 ポイント
二乗誤差の比（＋点数 ÷ 基準）	1.0107
損失の差（基準 − ＋点数）の平均の t	−5.34

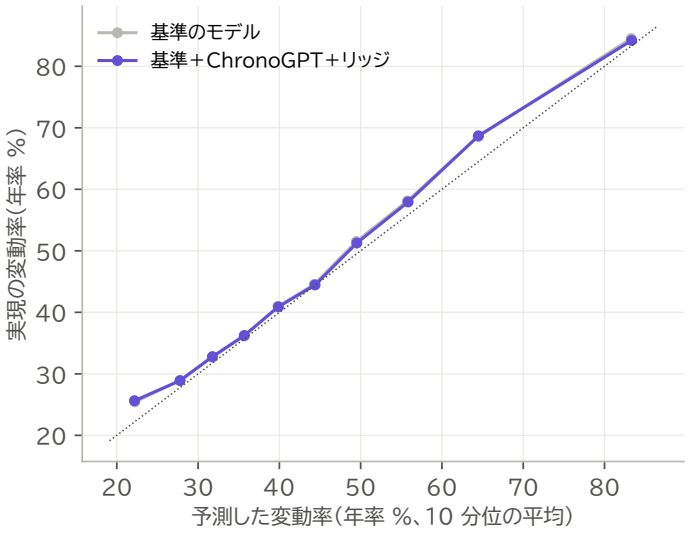


図6.1: 予測した変動率と実現の変動率（予測の 10 分位ごとの平均）。2 本の線はほぼ重なる。点線は予測＝実現。

結果

発表の前の変動率などの基準のモデルだけで、標本外の決定係数は 47.60% あった。そこに点数を足すと、予測は**わずかに悪くなった**（二乗誤差の比 1.0107、$t = -5.34$）。回帰の検定（第 4 章）で見えた情報は、この単純な水準の予測では役に立たなかった。

年ごとの内訳（実行の後に加えた記述）

表6.2: 標本外の予測の二乗誤差の年ごとの平均（事前登録にない記述）

年	発表の数	二乗誤差（基準）	二乗誤差（＋点数）	比	平均の誤差（基準）
2020	2,006	0.5105	0.5072	0.994	+0.261
2021	2,035	0.0889	0.0993	1.118	−0.104
2022	2,044	0.0755	0.0751	0.995	+0.085
2023	2,225	0.0832	0.0852	1.023	−0.026
2024	2,583	0.0777	0.0782	1.007	+0.019
2025	2,788	0.1005	0.1018	1.012	+0.017
2026	1,477	0.0855	0.0854	0.998	+0.064

悪化は主に 2021 年に生じ、ほかの年はほぼ同じだった。2020 年は、新型コロナの急落で市場全体の変動率が予想より大きく、どちらのモデルも大きく外した（平均の誤差が大きい）。この予測のモデルは、時期の固定効果を持たないので、市場全体の変動率の水準の変化をそのまま誤差として受ける。

第 7 章

解釈

7.1　何が分かったか

1. **決算発表文の読み取りは、その後の変動率を予測した**。過去の変動率と 2 日の反応の大きさを統制しても残り、置換の検定でも偶然では説明できない。2021 年以降ではより強い。
2. **ただし大きさは小さい**。1 標準偏差で変動率が約 1.5% 高くなる程度で、変動率のばらつきの大部分は、発表の前の変動率で説明される（ヘッジファンドの報告書の第 8 章：変動率は持続性が強い）。
3. **学習ありの読み取りが効いた**。ChronoGPT のベクトルや gpt-4o-mini の 14 の項目に、変動率の驚きを正解にして重みを学習したものが強く、学習なしの点数では、辞書の否定的な語だけが効いた。
4. **水準の予測には役立たなかった**。四半期ごとに学習した単純な予測のモデルでは、点数を足すと予測がわずかに悪くなった。回帰の検定は同じ時期の銘柄どうしを比べる（時期の固定効果）のに対し、予測のモデルは水準を当てる必要があり、市場全体の変動率の変化に誤差の大部分が支配される。また、点数は四半期ごとに学習し直すリッジの出力なので、その尺度が時期によって変わる可能性がある。

7.2　BLM への使い道

点数の情報は「同じ時期の銘柄どうしの相対的なリスク」についてのものである。BLM に使うなら、変動率の水準を置き換えるのではなく、次のような相対的な使い方が筋がよい（次の事前登録の追記の候補）。

- 見通しの不確かさ Ω を、リスクの点数の順位に応じて銘柄ごとに大きく・小さくする。
- 共分散の対角（固有の分散）を、点数の順位で少しだけ補正する。
- 発表の後、リスクの点数の高い銘柄の量を抑える。

7.3　注意すべき点

- 標本は今も上場している会社だけで、変動率の高い時期に消えた会社が抜けている可能性がある。
- 変動率は日次の終値で測った。日中のデータがあれば、より正確に測れる。
- gpt-4o-mini の期間は短い。
- 1 回の実行の結果である。

第 8 章

限界

- **生き残った会社だけ**：上場をやめた会社は、変動率の高い時期に消えやすいので、高い変動率の発表が欠けている可能性がある。
- **日次の終値だけ**：日中のデータはないので、実現の変動率は日次の終値で測った。
- **gpt-4o-mini の期間**は短く、`gpt_risk` は 60 日の窓が閉じるまで学習できないので、さらに短い。
- **応用は未検定**：予測した変動率を BLM の Ω や量の調整に使う効果は、この実験では確かめていない。
- **1 回の結果**：事前登録の通り 1 回だけ実行した。

再現の手順

リポジトリの直下で（.venv の Python）：

1. データと点数：S1 と同じ（smallcap.build、smallcap.score）。
2. 検定：python experiments/S2_smallcap_risk/run.py（結果は results/。2 回目は summary.json があると止まる）。
3. この報告書の数値・表と図：資料集/02_ 実験/実験 S2_ 小型株のリスク予測/作成スクリプト/ の values.py と figs.py。
4. コンパイル：このフォルダで tectonic -X compile LLM-BLM_ 実験 S2.tex。