LLM-BLM 小型株のデータ

母集団の作り方、生存者バイアスの見積もり、
決算発表文と株価の取得

データの報告書

2026 年 10 月 23 日

概要

S&P500 では、LLM の決算発表文の読み取りは発表の当日に株価に入りきり、翌日以降には残っていなかった（実験 2・8）。追加した参考文献（Hong・Stein 1999、Akbas ほか 2017、Lan ほか）によれば、株価の反応の遅れは注目されていない銘柄に集中する。そこで、**注目の低い小型株**で同じことを確かめるためのデータを作った。この報告書は、データの作り方と、その偏りの見積もりだけを扱う。**株価の反応と点数の関係は、まだ一度も計算していない**（事前登録の前）。

要点

- **母集団**：SEC の XBRL から、2015〜2025 年の各年について、米国の提出企業の浮動株時価総額を取り、各年の 1,001〜3,000 位を小型株とした（浮動株時価総額でおおむね 9,000 万〜40 億ドル。Russell 2000 に近い）。後で消えた会社も含めて、一度でも入った会社は 4,921 社。
- **生存者バイアス**：無料で取れる株価（yfinance）は、いま上場している会社だけ。小型株の会社・年のうち **32%** は株価が取れない（2015 年は 52%、2025 年は 6%）。
- **消えた理由**：消えた 1,826 社のうち **79% が買収**、15% が倒産。買収された会社は、消える前の 1 年の動きが残った会社とほぼ同じ（浮動株時価総額の中央値 +2% と +4%）。倒産した会社は −22% と、すでに大きく下がっていた。
- **集めたデータ**：条件を満たす 2,400 社から 1,000 社を無作為に選び、2015〜2026 年の決算発表文（8-K の EX-99.1）**38,390 本**（99.0% が取れた）と、株価、株式数を取った。
- **次**：株価の反応を使わない点数付け（辞書、FinBERT、ChronoGPT の埋め込み）を、この PC の GPU で始めた。反応を使う分析は、事前登録の後に行う。

目次

概要 1

第 1 章　目的 3
1.1　これまでの結果 3
1.2　なぜ小型株か 3

第 2 章　母集団の作り方 4
2.1　浮動株時価総額で並べる 4
2.2　その時点で知られていたか 4

第 3 章　生存者バイアス 5
3.1　どれだけ欠けるか 5
3.2　なぜ消えたか 5
3.3　消える前の動き 6
3.4　偏りの向き 7

第 4 章　集めたデータ 8
4.1　会社の選び方 8
4.2　決算発表文 8
4.3　株価と株式数 9
4.4　置き場所 9

第 5 章　次にすること 10
5.1　点数付け（実行中） 10
5.2　事前登録で決めること 10

第 6 章　限界 11

再現の手順 12

第 1 章

目的

1.1　これまでの結果

- 実験 2〜5・11：LLM の決算発表文の点数は、発表をはさむ 2 取引日の株価の反応を強く説明した（gpt-4o-mini で 1 標準偏差あたり +120bp、先読みのない ChronoGPT でも +34bp）。
- 実験 2・3・8：その後のドリフト（2〜21 日）と翌日には、有意な残りがなかった。月次・日次の BLM は時価総額加重を上回らなかった（実験 7〜9）。

1.2　なぜ小型株か

文献	この研究への含み
Hong・Stein（1999, Journal of Finance）	情報が投資家の間にゆっくり広がると、短期では反応が足りず（モメンタム）、長期では行き過ぎて戻る。広がりの遅い銘柄ほど、反応の遅れが大きい（理論）
Akbas・Markov・Subasi・Weisbrod（2017, SSRN 2860521）	アナリスト予想の処理が遅れるほど、発表時の反応は小さく、その後のドリフトは大きい。非効率は注目されていない銘柄に集中する
Lan・Xie・Mi・Zhang（SSRN 4589824）	投資家の注目が、発表後のドリフトを強める（中国市場、査読前のプレプリント）

S&P500 は世界で最も注目されている銘柄である。小型株は、アナリストも投資家の注目も少ない。LLM が人の代わりに文章を読む価値は、小型株のほうが大きいはずである。

第 2 章

母集団の作り方

2.1　浮動株時価総額で並べる

Russell 2000 は、米国の上場株を時価総額で並べた 1,001〜3,000 位である。その過去の構成銘柄は無料では手に入らない。そこで、SEC に提出された財務諸表の表紙に載る**浮動株時価総額**（`dei:EntityPublicFloat`）を使って、同じ考え方の範囲を自分で作った。

- SEC の XBRL の frames（1 回の呼び出しで、全提出企業のある時点の値が取れる API）から、2015〜2025 年の各年の値を取った。浮動株時価総額は決算期の第 2 四半期の末に測るので、年ごとに 4 つの四半期を合わせ、会社・年ごとに 1 つにした。
- 使わない値：100 万ドル未満（9,406 件。休眠会社など）、4 兆ドル超（100 件。桁を誤った報告）、その会社のほかの年の中央値から 200 倍以上ずれる値（389 件）。
- 所在地が米国の会社だけを並べ、各年の 1,001〜3,000 位を「小型株の範囲」とした。

この作り方では、**後で上場をやめた会社も、その年の母集団に入る**。SEC の提出は、上場をやめるまで続くからである。

表2.1: 各年の範囲の境目（浮動株時価総額、百万ドル）。

年	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
米国の提出企業	4,846	4,619	4,520	4,483	4,338	4,470	5,114	5,024	4,629	4,416	4,283
1,000 位	2,552	2,269	2,637	2,907	2,800	2,559	4,100	3,200	3,368	3,623	3,935
3,000 位	124	87	99	117	91	106	275	186	115	99	98

2.2　その時点で知られていたか

浮動株時価総額は、測った日（第 2 四半期の末）の数か月後に、年次報告書（10-K）で公表される。12 月決算の会社なら、6 月末に測り、翌年 3 月までに公表する。そこで、**測った日の 9 か月後から使える**とする。各判断日の範囲は、そのときに使える最新の値で決める。

第 3 章

生存者バイアス

3.1　どれだけ欠けるか

無料の株価（yfinance）は、いま上場している会社のものしかない。上場廃止の会社の株価を持つ EODHD は、無料プランでは直近 1 年しか返さない（2026-10-23 に確認）。そこで、**いま株価が取れる会社だけ**でデータを作り、欠ける分の大きさを見積もった。

範囲に入った会社・年のうち、その年か翌年に決算の 8-K（Item 2.02）を出した 20,282 件を対象にした。いまのティッカーで、その期間の株価が取れるものを「残った」、取れないものを「消えた」とした。

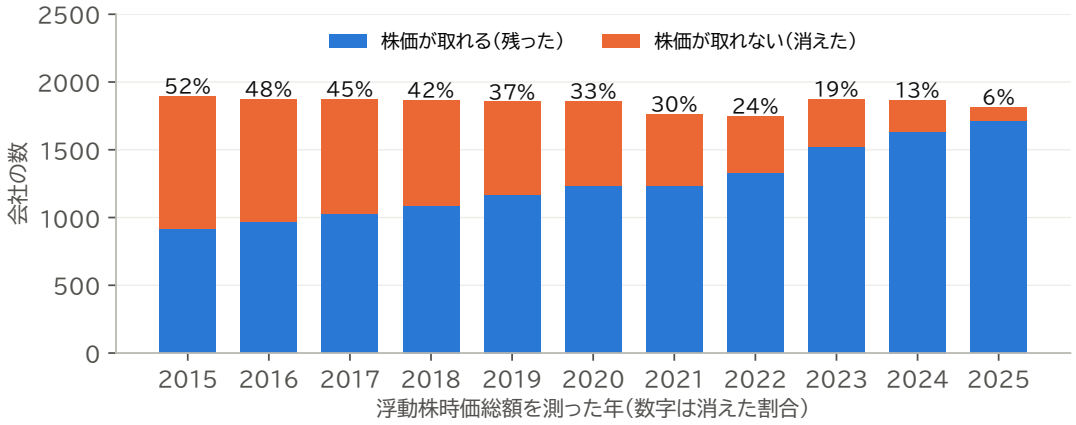


図3.1: 小型株の範囲に入った会社（決算の 8-K を出したもの）のうち、株価が取れる会社と取れない会社。

全体で **31.7%**（6,431 件）が欠ける（図 3.1）。古い年ほど多く、2015 年は 51.5%、2020 年は 33.4%、2025 年は 5.5% である。2015 年の小型株は、半分がもう株価を取れない。

3.2　なぜ消えたか

消えた 1,826 社について、EDGAR の届け出から理由を機械的に決めた（上から順に当てはめる）。

- 倒産：8-K の Item 1.03（倒産・管財人）
- 買収：合併の委任状（DEFM14A など）、公開買付けへの意見表明（SC 14D9）、8-K の Item 5.01（支配権の移動）
- 上場廃止・登録廃止：Form 25、Form 15
- まだ提出している：2026 年にも提出がある（別の市場、名前の変更）

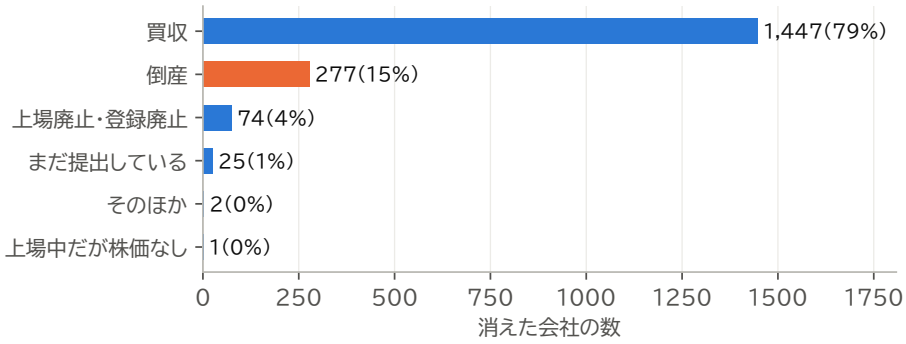


図3.2: 消えた会社の理由。

小型株が消える主な理由は**買収**（79%）で、倒産は 15% だった（図 3.2）。小型株には地方銀行や医薬品・バイオの会社が多く、どちらも合併や買収の多い業種である。

3.3　消える前の動き

消えた会社の株価は取れないので、代わりに、範囲に入った最後の年の、前の年からの浮動株時価総額の変化を見た（株価に株式の数を掛けたものなので、株価の動きの目安になる。ただし株式の発行でも増える）。

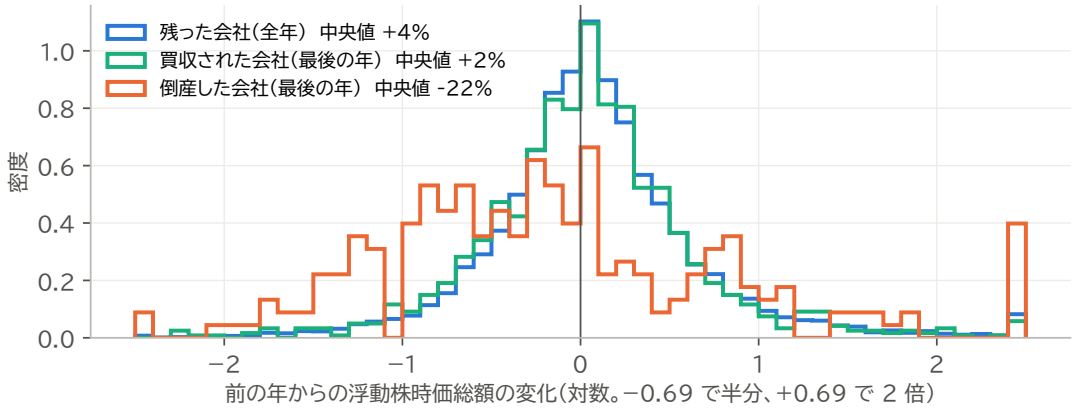


図3.3: 前の年からの浮動株時価総額の変化。

表3.1: 前の年からの浮動株時価総額の変化。

	件数	中央値	4 割以上減った割合
残った会社（全年）	12,030	+4.1%	11.5%
買収された会社（最後の年）	1,205	+2.3%	13.9%
倒産した会社（最後の年）	226	**−22.0%**	**38.5%**
上場廃止・登録廃止（最後の年）	61	+9.4%	13.1%

3.4　偏りの向き

LLM の点数を使う戦略は、「点数の高い会社を多く、点数の低い会社を少なく持つ」形になる。比べる相手は、同じ会社の集合で作った時価総額加重である。

1. **倒産（15%）は、こちらに不利な向き**。倒産した会社は消える前から大きく下がっていた。悪い内容の発表をした会社が抜けるので、点数の低い会社の成績が実際より良く見え、戦略と時価総額加重の差は実際より**小さく**出る。勝てた場合には、その結果は控えめな見積もりになる。
2. **買収（79%）は、向きが読めない**。買収されるときには上乗せで株価が上がるが、その上昇もデータから消える。点数の高い会社と低い会社のどちらが買収されやすいかで、向きが変わる。買収された会社は、消える前の動きが残った会社とほぼ同じだった（表 3.1）。
3. **欠けの多い年は、別の市場を見ている**。2015〜2018 年は半分前後が欠ける。結論は「生き残った小型株の中で」と書く必要がある。

実験のときに決めておくこと

- 欠けの少ない 2021 年以降だけの結果も、主な結果と並べて報告する。
- 時価総額加重は、同じ会社の集合で作る。実際に買える Russell 2000 の ETF（IWM）は生存者バイアスがないので、参考として並べるだけにする。
- 買収で消えた会社が、点数でどちらに偏るかは、消えた会社の決算発表文も読めば確かめられる（反応は見ない）。今回は株価の取れる会社だけを集めたので、次の段階の候補とする。

第 4 章

集めたデータ

4.1　会社の選び方

次の条件をすべて満たす 2,400 社から、1,000 社を無作為に選んだ（乱数の種 0）。

- 2015〜2025 年のどこかで、小型株の範囲に入った。
- いま Nasdaq・NYSE・NYSE American に上場していて、yfinance で株価が取れる。
- 2016 年以降に、決算の 8-K（Item 2.02）を 4 本以上出している。

選んだ会社の業種は、医薬品（80 社）、州法銀行（54 社）、バイオ（45 社）、ソフトウェア（43 社）、REIT（42 社）が多い。各年に小型株の範囲に入っている社数は、2015 年の 387 社から 2025 年の 718 社まで（図 4.1）。古い年ほど少ないのは、前の章の欠けのためである。

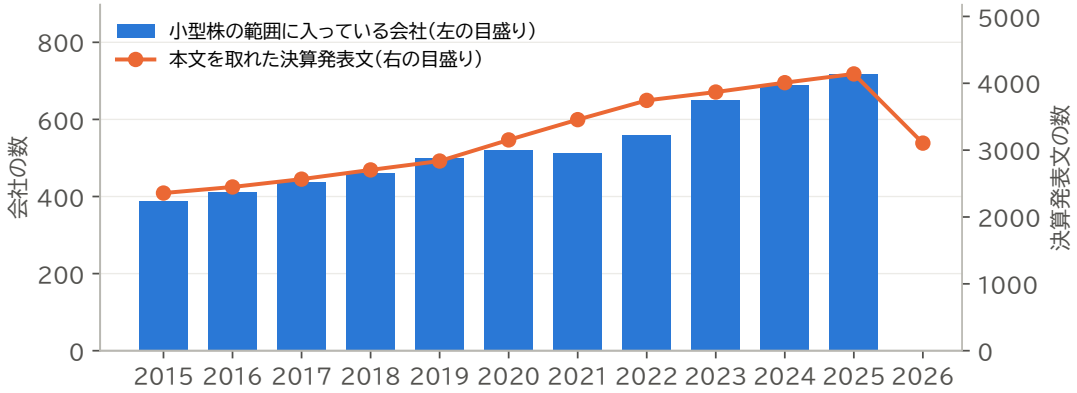


図4.1: 選んだ 1,000 社のうち、各年に小型株の範囲に入っている会社の数と、本文を取れた決算発表文の数。

4.2　決算発表文

S&P500 と同じ取り方（実験 2 の `events/edgar.py`）で、8-K の Item 2.02 に付く EX-99.1 の本文を取った。取得は約 3 時間（SEC の求めに従い、毎秒 8 回以下）。

表4.1: 決算発表文の取得（2015-01-01〜2026-09-30 に提出されたもの）。

決算の 8-K（Item 2.02）	38,800 本（999 社）
届け出を読めた	38,794 本（6 本は SEC の索引が読めなかった）
本文を取れた	**38,390 本**（99.0%）
うち、先頭に EX-99.1（または EX-99）と書かれていた	99.6%
本文の長さ（中央値）	24,129 字
反応の日（day 0）が決まった	99.99%
本文が 4 本以上ある会社	998 社

- 本文の選び方：ファイル名が EX-99.1 に当たるもの 29,991 本、最も大きい添付書類 6,202 本、EX-99.2 などから EX-99.1 に差し替えたもの 723 本。1,305 本は、S&P500 の取得のときにすでに保存していた本文だった（S&P500 に入っていた時期のある会社）。添付書類がなかった届け出は 404 本。
- 年ごとの本数は、2015 年の 2,358 本から 2025 年の 4,140 本まで増える（2026 年は 9 月までで 3,105 本）。古い年ほど少ないのは、選んだ会社の中で、その年に上場していた会社が少ないためである。

表4.2: 届け出が受理された時間帯（ニューヨーク時間）。S&P500 は実験 2 の設計のときの 6,209 本。

時間帯	小型株	S&P500
寄り前（9:30 より前）	14.7%	23.4%
場中（9:30〜16:00）	21.4%	31.0%
引け後（16:00〜17:30）	22.3%	19.7%
17:30 以後	**41.5%**	25.9%

小型株は、17:30 より後に受理される届け出が多い（表 4.2）。発表文の配信より 8-K の提出が遅れると、反応の日が 1 日ずれうる。S&P500 と同じく、反応の窓を 2 取引日にとって吸収する。

4.3 株価と株式数

- 株価：範囲に一度でも入り、いま上場している 2,617 社と、指数・ETF（^GSPC、IWM、IJR、SPY、セクター ETF 11 本）。2,632 銘柄のうち 2,627 銘柄が取れた。2014-12 から 2026-09 まで。
- 発行済株式数：XBRL の frames の `dei:EntityCommonStockSharesOutstanding`（四半期ごと、211,112 件）。時価総額は、株式の分割を合わせてから計算する（ポートフォリオを組む段階で行う）。

4.4 置き場所

すべて `data/smallcap.sqlite`（本体の DB と同じ表の形と、`sc_` で始まる表）。本体の DB は変えていない。本文は `data/cache/edgar/`、どちらも Git には入れない。

第 5 章

次にすること

5.1　点数付け（実行中）

株価の反応を使わない点数付けを、この PC の GPU で始めた（`smallcap/score.py`）。

- 辞書（Loughran–McDonald）と、学習なしの FinBERT：S&P500 と同じ設定。
- ChronoGPT（版 2015）の埋め込み：元の文章の最後の層の平均（実験 5 のベクトル）と、掃除した文章の 3 種類（最後の層の平均、最後のトークン、26 層目の平均）。26 層目は、実験 11 の探索で強かったもの。

gpt-4o-mini は、方針どおり最後の比較まで使わない。

5.2　事前登録で決めること

1. 主な問い：小型株で、LLM（ChronoGPT）の点数は、発表後 2〜60 日の超過リターンを説明するか（2 日の反応を統制したうえで）。
2. 各判断日の小型株の範囲（使える最新の浮動株時価総額で決める）。
3. 超過リターンの基準（IWM、またはセクター ETF）。
4. 統制：数値の驚き、発表前のリターン、規模、モメンタム、業種と四半期。
5. ポートフォリオ：月次の BLM と、同じ会社の集合の時価総額加重。費用は片道 0.3〜0.5%（小型株の売買の値段の差は大きい）。
6. 欠けの少ない 2021 年以降だけの結果も並べる。

第 6 章

限界

- 生き残った会社だけのデータである（第 3 章）。
- 消えた理由は届け出の種類から機械的に決めた。合併の委任状を出したが成立しなかった会社や、倒産から立ち直った会社の扱いは粗い。
- 浮動株時価総額の変化は株価の動きの代わりで、株式の発行（バイオ企業に多い）でも増える。
- 浮動株時価総額は、創業者などの持ち分を除いた値で、Russell 2000 の時価総額とは違う。並べる相手も、上場していない提出企業を含む。
- 小型株の中でも、選んだ 1,000 社は 2,400 社の一部である。

再現の手順

```
python -m smallcap.build population
python -m smallcap.build submissions
python -m smallcap.build shares
python -m smallcap.build prices
python -m smallcap.bias
python -m smallcap.build select --n 1000
python -m smallcap.build releases
python 資料集/02_実験/小型株のデータ/作成スクリプト/figs.py
powershell -ExecutionPolicy Bypass -File smallcap\start_score.ps1
```

SEC の手順には SEC_USER_AGENT(名前と連絡先。.env に置き、表示しない)が要る。設計は 設計 _ 小型株.md、偏りの数値は smallcap/results/bias.json と findings.md、この報告書の数値は 図/numbers.json。