LLM-BLM 補足実験 X05

見通しの大きさ（α）を変えると、BLM のポートフォリオは変わるか

実験の結果の報告書（探索）

2026 年 10 月 19 日

概要

実験 7・9 の月次の BLM では、LLM などの点数を、期待リターンの上乗せ $\alpha = \mathrm{IC} \times \sigma \times z$ に直して見通しにした。このとき σ に日次のボラティリティを使い、1 か月持つ前提との単位の調整をしていなかった。期間に合った大きさより $\sqrt{21} \approx 4.6$ 倍大きい。そこで、α に倍率 k を掛けて、6 つの点数（LLM 2 つ、NLP 4 つ）でポートフォリオを計算し直した。実験 7・9 の結果を見た後の分析なので、事前登録はしていない（探索）。すべての組み合わせを報告する。

主な結論

- $k \geq 0.03$ **では、どの点数でも、ポートフォリオと成績がまったく同じだった**。TE（時価総額からのずれ）の上限が毎月効いていて、そのときは α の大きさが比率に影響しないためである。期間に合った大きさ（$k = 1/\sqrt{21} \approx 0.22$）も、この範囲に入る。
- α **の単位の誤りは、実験 7・9 の結論に影響しない**。比率は、見通しの向き（どの銘柄を上・下に見るか）と TE の上限だけで決まっていた。
- **LLM と NLP を比べると、月次の成績で有意にプラスの点数はない**。反応を一番よく説明した gpt-4o-mini（月 +0.10%）より、単語の出方の TF-IDF（+0.17%）のほうが高かったが、どれも有意でない。

目次

概要 1

第 1 章　きっかけ：α の単位 3

第 2 章　方法 4

第 3 章　結果 5
3.1　α の大きさは、ほとんど効かない 5
3.2　なぜ同じになるか 5
3.3　LLM と NLP の比較 6

第 4 章　まとめと限界 7

再現の手順 8

第 1 章

きっかけ：α の単位

Grinold の式では、見通しの上乗せ α を、予測する期間のボラティリティで作る。

$$\alpha_{月} = \mathrm{IC} \times \sigma_{月} \times z, \qquad \sigma_{月} = \sigma_{日}\sqrt{21}$$

共分散を日次で扱うなら、α も日次の単位に直す。

$$\alpha_{日} = \frac{\alpha_{月}}{21} = \frac{\mathrm{IC} \times \sigma_{日} \times z}{\sqrt{21}}$$

実験 7・9 は $\alpha_{日} = \mathrm{IC} \times \sigma_{日} \times z$ としていて、$\sqrt{21}$ で割っていなかった。α が大きすぎると、BLM の見通しが強く効きすぎ、結果を歪めたおそれがある。これを確かめる。

第 2 章

方法

実験 7・9 と同じ BLM（見通しの選び方、He–Litterman の Ω、Ledoit–Wolf の共分散、片道 0.1% の費用、TE の上限）で、α に倍率 k を掛けて計算し直した。

表2.1: 比べたもの。

倍率 k	0.001、0.003、0.01、0.03、0.1、$1/\sqrt{21}$（≈ 0.218、期間に合った大きさ）、0.5、1（実験 7・9）、2
期間 A	2024-01〜2026-07 の 31 か月（実験 7 と同じ日付と TE の上限）。点数：gpt-4o-mini、ChronoGPT のリッジ（実験 5）、辞書、FinBERT（学習なし）、TF-IDF ＋リッジ、FinBERT の追加学習（実験 4）
期間 L	2016-03〜2026-07 の 125 か月（実験 9 と同じ日付と TE の上限）。点数：ChronoGPT のリッジ、辞書、FinBERT、TF-IDF ＋リッジ（2016 年から点数があるもの）

$k = 1$ は、実験 7（gpt-4o-mini：月 +0.10%、t 1.22）と実験 9（ChronoGPT：月 +0.002%）をそのまま再現した。k の 0.001〜0.03 は、0.1〜2 で結果がすべて同じだと分かった後に、どこで変わり始めるかを見るために足した。

第 3 章

結果

3.1　α の大きさは、ほとんど効かない

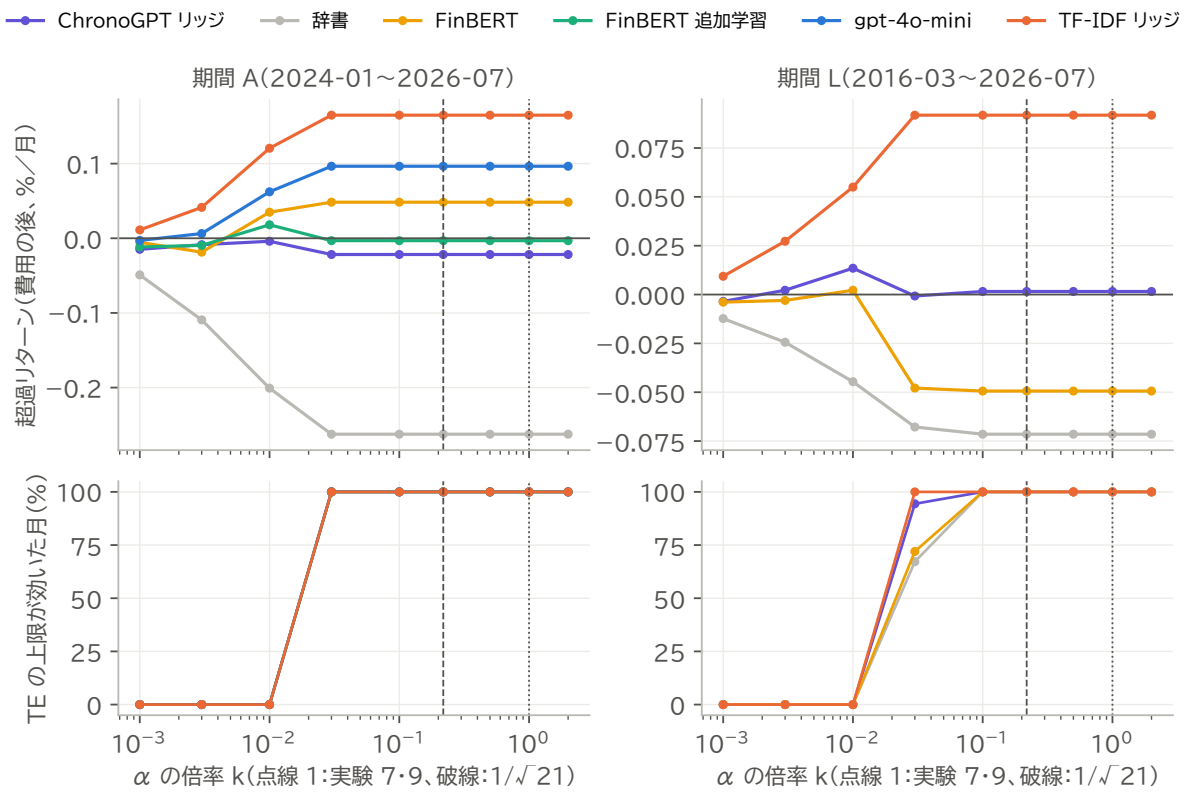


図3.1: 上：費用の後の月次の超過リターン。下：TE の上限が効いた月の割合。横軸は倍率 k（対数）。点線は実験 7・9（$k = 1$）、破線は期間に合った大きさ（$k = 1/\sqrt{21}$）。

- $k \geq 0.03$（期間 L の一部は $k \geq 0.1$）では、TE の上限が毎月効き、どの点数でも成績が 1 桁も違わず同じだった（図 3.1 の右側の平らな線）。
- $k \leq 0.01$ では上限が効かなくなり、時価総額からのずれはほぼ k に比例して小さくなる。gpt-4o-mini の事前の TE は、$k = 0.01$ で 1.47%、$k = 0.001$ で 0.22%（上限は 1.95%）。成績も 0 に近づく。

3.2　なぜ同じになるか

時価総額の比率を w_m、そこからのずれを x とする。均衡リターンは $\Pi = \delta \Sigma w_m$ なので、最適化の目的の Π の部分は打ち消し合い、

$$\max_x \; k\, a'x - \frac{\delta}{2} x'\Sigma x \quad （ただし $x'\Sigma x \leq \mathrm{TE}^2$、空売りなし）$$

になる（a は見通しの向き）。上限が効いているときは $x'\Sigma x = \mathrm{TE}^2$ で一定なので、答えは「$a'x$ を最大にする x」で決まり、k によらない。上限が効かなくなる境目は $k \approx 0.02$ で、期間に合った大きさ（0.218）はそ

の 10 倍以上大きい。

判定

α の単位の誤りは、実験 7・9 の結論に影響しない。この BLM では、比率は見通しの向きと TE の上限だけで決まる。α の大きさより、TE の上限の決め方（補足実験 X03）のほうが成績を左右する。

3.3　LLM と NLP の比較

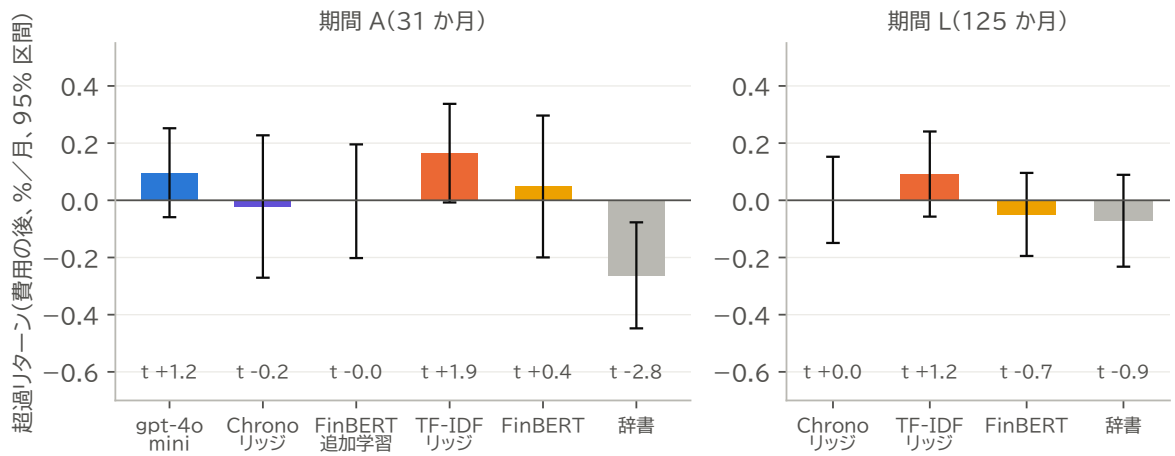


図3.2: TE の上限が効く倍率（どの $k \geq 0.03$ でも同じ）での、費用の後の月次の超過リターン（95% 区間）と Newey–West の t。

表3.1: 費用の後の月次の超過リターン（対時価総額）。

点数	期間 A（31 か月）	期間 L（125 か月）
gpt-4o-mini	+0.10%（t 1.2）	—
ChronoGPT のリッジ	−0.02%（t −0.2）	+0.00%（t 0.0）
FinBERT の追加学習	−0.00%（t −0.0）	—
TF-IDF ＋リッジ	+0.17%（t 1.9）	+0.09%（t 1.2）
FinBERT（学習なし）	+0.05%（t 0.4）	−0.05%（t −0.7）
辞書	−0.26%（t −2.8）	−0.07%（t −0.9）

- 費用の後で有意にプラスの点数はない。10 通りを比べているので、$|t|$ 2 前後は偶然でも出うる。辞書の期間 A の −2.8 も、10 通りの補正（Holm）をすると有意でない。
- **反応の説明力と、月次の成績の並びは一致しない。**発表への 2 日の反応を一番よく説明したのは gpt-4o-mini だった（実験 3〜5、10）。月次の BLM では、単語の出方の TF-IDF のほうが、どちらの期間でも高かった（有意でない）。月末の時点では決算の情報の大部分がもう株価に入っている（実験 8）ので、残りは小さく、どの点数でもほぼ雑音と考えられる（図 3.2）。

第 4 章

まとめと限界

1. 実験 7・9 の「月次の BLM は市場とほぼ同じ」は、α の大きさの設定のせいではない。
2. この BLM では TE の上限がほぼ常に効くので、見通しの大きさではなく向きだけが比率を決める。実務でも、TE の上限を置く BLM では同じことが起きる。
3. 決算の点数は、LLM でも NLP でも、月次では効かない。

限界：実験 7・9 の結果を見た後の分析で、事前登録はしていない。期間 A は 31 か月しかない。倍率の 0.001〜0.03 は、1 回目の結果を見て足した。

再現の手順

```
python experiments/X05_alpha_scale/run.py          # k = 0.1 .. 2
python experiments/X05_alpha_scale/run.py small    # k = 0.001 .. 0.03
cd 資料集/02_実験/補足実験_ の大きさ
python 作成スクリプト/figs.py                       # この資料の図
```

数値の出どころは experiments/X05_alpha_scale/results/ の summary.csv、small/summary.csv、findings.md。費用は 0 円（CPU で約 40 分）。