LLM-BLM：文献調査と次の設計方針

7 つの仮説の結果を踏まえ、何を問い、どう確かめるか

情報工学工房　LLM-BLM

2026 年 10 月 17 日

この文書の要点

1. これまでの実験（H01〜H07）で、LLM に翌月のリターンを数値で答えさせる構成は、統計を超える価値を示せなかった。予想の 81% は、渡した月の値動きの写しだった。
2. 方針を、Claude・GPT・Gemini の 3 者に独立に書かせ、比べた。文献調査は、Gemini Deep Research を加えた 4 者で行い、挙げられた文献を機械的に照合した。
3. 新しい問いは「LLM が決算発表文から取り出した判断は、数値と、LLM を使わない文章の分析を超える情報を持つか」。BLM は、検証を通った信号を安全に比率に変える部分として使う。
4. 文献から、方針を 4 点変える。
   - 発表文の内容は寄り付きで株価に反映されるので、主な目的変数を「発表への反応」にする。
   - プロンプトに下流の目的（株価の予測）を書かない。
   - 2015〜2023 年の文章は、匿名化ではなく、年ごとに学習を区切った LLM（ChronoGPT）で読む。
   - 取り下げられた論文の引用を直す。
5. 主な検定は、手順を固定した前向きの検証（2026 年 10 月以降の決算発表）にする。

目次

1 これまでの結果 2

2 方法：3 者の方針と 4 者の文献調査 2

3 文献調査の結果 3
- 3.1 4 者が一致したこと . . . 3
- 3.2 方針を変える発見 . . . 3
- 3.3 意見が分かれた点と、文献からの判断 . . . 4

4 研究の問い 4

5 新しいアーキテクチャ 5

6 評価の枠組み 5

7 ChronoGPT の環境と最初の確認 6

8 次の実験（優先順） 7

9 やらないこと 7

10 リスクと未解決の問い 7

11 スケジュール 8

主な参考文献 8

1 これまでの結果

S&P500 の銘柄で、gpt-4o-mini の予想を Black–Litterman モデル（BLM）のビューに入れたとき、追加の価値があるかを 7 つの仮説で確かめた（評価は 2024 年 3 月〜2026 年 8 月の 30 か月。gpt-4o-mini の知識の期限 2023 年 10 月より後）。

仮説	確かめたこと	結果
H01	元論文の計算の再現	式は一致した。BLM が LLM の予想を中央値 99.9% 採用し、均衡はほぼ使われない。元論文の最適化（SLSQP）は、入力のわずかな違いで解が変わり、再現できない
H02	統計の基準との比較	LLM の予想は、渡した月の値動きの写し（決定係数 0.81）。写しを除いた固有の IC は −0.004（95% 区間 −0.036〜+0.027）
H03	相対ビュー	高ベータへの傾きは消えない。原因は、銘柄の間のなぞり
H04	Ω の較正	過去の当たり具合で較正すると、BLM は設計どおりに動く。ただし成績（年率 +0.53%）は、並べ替えたビューと区別できない（片側 $p = 0.104$。セクターの中での並べ替えでは $p = 0.38$）。回答のばらつきは、大きさとしては確信が強すぎる（外れの 2 乗の約 8 分の 1）。一方で、外れやすさの順番の手がかりにはなる（偏順位相関 +0.17）
H05	文章だけを渡す	なぞりは消える（+0.77→+0.05）。ただし予測力は不十分（セクターの IC +0.06、t 0.72）
H06	決算発表文の点数	5,429 本。IC +0.033（Newey–West の t 2.32、探索的）。数値を統制すると有意でない（Fama–MacBeth の t 0.97）
H07	成績のフィードバック	予想は改善しない（IC の差 +0.011）。一律に強気に寄った（楽観の偏りが日次 +0.12%→+0.29%）

評価が 30 か月だけなので、IC 0.07 未満の効果は検出できない。API の費用は合計約 6.7 ドルだった。

2 方法：3 者の方針と 4 者の文献調査

- **方針**：同じ依頼と資料（実験結果レポート、ビューとリスクの要点）を、Claude、GPT（gpt-5.6）、Gemini（gemini-3.1-pro）に渡し、独立に書かせた。見出しを揃え、比べやすくした。Claude は、他の回答を読む前に書き終えた。
- **文献調査**：同じ依頼で、上の 3 者に Gemini Deep Research を加えた 4 者が、ウェブ検索で調べた。テーマは 8 つ（LLM の数値の予想、先読み、決算発表文、イベントスタディ、不確実性、BLM、評価の確かさ、フィードバック）。
- **照合**：挙がった文献を、arXiv・OpenAlex・Crossref で機械的に照合した（`LLM/refcheck.py`）。arXiv の番号は、題名と著者まで突き合わせた。照合で見つからないものは、検索で個別に確かめた。

依頼の文書の誤り

文献調査の依頼で、H04 のばらつきの結果を「大きさにも順番にも合わない」と誤って書いた。正しくは「大きさには使えないが、順番の手がかりにはなる」である。GPT は添付のレポートから正しく読んだが、Gemini と Deep Research は誤った文を前提に書いている。依頼の文書には訂正を注記した。

照合で ok でも、主張の中身までは保証されない。この文書で使う主張は、要旨か本文で確かめたものに限った。

表1: 文献調査の条件と、照合の結果

	文献	検索	照合で見つかった誤り
Claude	36	約 35 回	なし（H04 の読み違いを照合の段階で修正）
GPT	38	14 回	著者の取り違え 2 件。最も役に立ち、方針を変えた発見の多くはここから
Gemini	15	8 語	別の論文の番号 1、著者の誤り 1（DOI は自分で「推定」と書いた）、見つからない 1、著者が Anonymous 3
Deep Research	17	36 回	著者の取り違え 4、題名の取り違え 2、主張の出どころの誤り、要旨にない数値。統計の解説サイトなど、学術でない根拠

3　文献調査の結果

3.1　4 者が一致したこと

1. **LLM に数値のリターンを答えさせる構成はやめる**。LLM のリターンの予想は、直近の成績を外挿しすぎ、楽観に寄る。プロンプトでは消しにくい（Chen, Green, Gulen, Zhou 2024）。H02 の「写し」はこの現象そのものである。
2. **知識の期限より前の文章は、匿名化しても確認用にはならない**。LLM は期限より前の経済の数値を記憶から再現する。社名や日付を伏せても、文脈から復元される（Lopez-Lira, Tang, Zhu 2025）。
3. **前向きの検証を、主な検定にする**。
4. **LLM を使わない対照は、Loughran–McDonald の辞書、TF-IDF の正則化回帰、FinBERT の 3 つにする**。FinBERT は辞書を大きく上回る（Huang, Wang, Yang 2023）。
5. **イベントの時刻の監査は必須である**。発表が同じ日に集まると、超過リターンの弱い相関でも、検定は大きく過大に棄却する（Kolari, Pynnönen 2010）。悪いニュースは、引け後や忙しい日に出やすい（deHaan, Shevlin, Thornock 2015）。

3.2　方針を変える発見

1. **決算発表文の内容は、寄り付きで株価に完全に反映される**。
   - 2005〜2023 年の 13.8 万本の決算発表文で、文章は利益の驚きと同じくらい情報を持つ。FinBERT が最も強い。そして、株価は寄り付きの時点で発表文の内容を完全に反映する（Wu ほか 2025）。
   - 遅れて効くのは、決算説明会の語調である（Yu ほか 2026）。決算説明会の書き起こしは、EDGAR から無料では取れない。
   - LLM による決算発表文の測度は、発表の短い期間のリターンの変動を、辞書や LLM でない機械学習の約 3 倍説明する（Siano 2025）。

   ⇒ 主な目的変数を「翌日以降のドリフト」から「**発表への反応**」に移す。
2. **LLM に下流の目的を教えると、測定が偏る**。
   - 「株価の予測に使う」と伝えると、語調などの中間の点数が目的に沿って偏る。その「改善」は、知識の期限より前にだけ現れる（Cao, Jiang, Xu 2026、NBER WP 35142）。
   - H06 のプロンプトは目的を書いていない。ただし「株価の動きについて知っていることを使わない」という一文があり、株価との関係をほのめかしている。

   ⇒ 凍結の前に、プロンプトを株価に触れない言い方に変える。
3. **年ごとに学習を区切った LLM が、重みつきで公開されている**。

- ChronoGPT-Instruct は、1999〜2024 年の各年末までの文章だけで学習している。1.55B パラメータ、文脈 1,792 トークン、MIT ライセンスである（He, Lv, Manela, Wu 2025）。
- ほかに、DatedGPT（1.3B、2013〜2024 年）と、Kelly ほかの 4B までの月ごとのモデルがある。
- 先読みを測る検定もある。日付だけを示して想起させ、当たりとの交互作用を見る（Gao, Jiang, Yan 2025）。

⇒ 2015〜2023 年は、匿名化ではなく ChronoGPT で読む（この PC に環境を作った）。

4. **取り下げられた論文がある。**
   - Kim, Muhn, Nikolaev（2024）「Financial Statement Analysis with LLMs」は、2025 年 2 月に arXiv で取り下げられた。共著者が、データと分析の不整合を見つけたためである。
   - プロジェクトの資料 4 つが、これを成功例として引いている。

   ⇒ 引用を直す。

3.3　意見が分かれた点と、文献からの判断

論点	意見	判断
2015〜2023 年の文章	前回、Gemini は「匿名化して主に使う」とし、GPT は「使わない」とした。今回は 4 者とも「確認用にはしない」	時点を区切ったモデルで読み、「汚染のない下限」として報告する。gpt-4o-mini の汚染は、LAP の検定で診断する
意味のある最小の効果	GPT は追加の rank IC 0.01 ＋経済効果、Gemini は IC 0.03、Deep Research は 0.05、Claude は検出力の実験で決める	文献に共通の値はない。合成信号の検出力の実験で決め、GPT の基準を候補にする
BLM	GPT は副次の評価に下げる。他は残す（Deep Research は Factor BLM でベータを中立化）	残す。役割は「弱い信号での損と回転を抑える」。単純な順位の戦略と、同じ TE で比べる
回答のばらつき	GPT は二段階（大きさは誤差で、比率は順位で）が上限とする	数値の予想をやめるので、使わない。H04 の結果は、元論文の前提への検証として報告する

4　研究の問い

主な問い

LLM が決算発表文から取り出した判断（語調、見通し、ガイダンスの変更）は、数値の驚き（SUE など）と、LLM を使わない文章の分析（辞書、TF-IDF、FinBERT）を超える情報を持つか。

副次の問いは次の 4 つ。

1. その情報は、寄り付きより後（取引できる時点）にも残るか。
2. 先読みのない時点を区切ったモデルでも、同じ方向の情報が取れるか。
3. 較正した BLM は、当たらない信号を自動で使わず、当たる信号だけを使うか（合成信号で測る）。
4. LLM の数値の予想が写しになること、ばらつきが大きさに使えないこと、フィードバックで楽観に寄ることを、元論文の前提の検証としてまとめる。

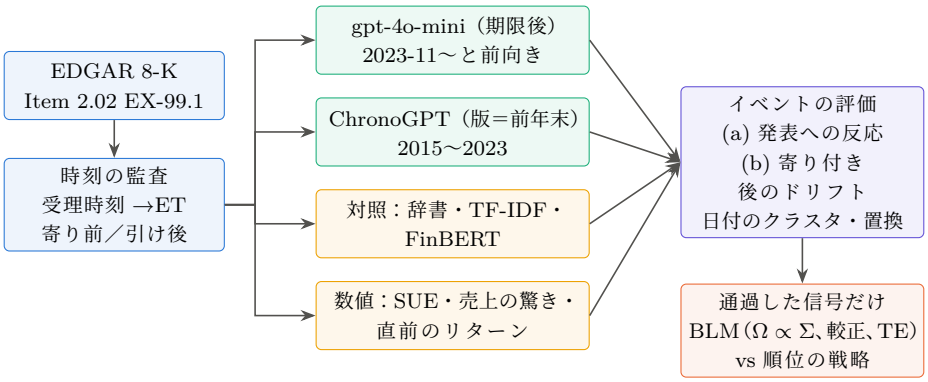


図1: 新しい構成。LLM は文章の点数を取り出す役だけを担い、価値の判定はイベントの評価で行う。

5　新しいアーキテクチャ

捨てるもの	LLM の数値の予想、回答のばらつきの Ω、予想役へのフィードバック、月次レポートの分析、SLSQP、新しいモデル（gpt-5.x・gemini-3.x）による予想
残すもの	$\Omega \propto \Sigma$ と過去の当たり具合での較正（採用率＝縮めた傾き）、能動ベータ 0 と TE の上限、Clarabel による最適化、置換の対照、Holm の補正
足すもの	発表の時刻の監査、イベントの評価、非 LLM の 3 つの対照、ChronoGPT による期限前の点数、LAP の検定、前向きの凍結の記録、合成信号による検出力の測定

LLM の役割

- **させること**：決算発表文だけを読み、決まった形の点数（ガイダンスの変更、見通し、語調、リスクの種類）を返す。
- **させないこと**
  - 数値の予想
  - 自信の申告
  - 下流の目的（株価の予測）の説明
  - 成績のフィードバック
  - 知識の期限より前の文章を、gpt-4o-mini で読むこと
- **使わない選択肢**：辞書・TF-IDF・FinBERT と同じ物差しで比べる。超えなければ、以後の文章の信号は安い方法で作る。

6　評価の枠組み

- **目的変数**
  - 主は (a) 発表への反応。引け後の発表なら、翌日の寄り付きまでを含む。
  - 副は (b) 寄り付きより後 1・5・20 取引日の、市場とセクターを調整した超過リターン。
- **時刻**
  - EDGAR の受理時刻を ET に直す。寄り前の発表はその日、引け後の発表は翌取引日を最初の取引日にする。
  - 17 時 30 分 ET より後の受理は、翌営業日の扱いになるので、個別に確かめる。

- **統制**：SUE、売上の驚き、直前のリターン、規模、ベータ、セクター。
- **検定**：日付ごとのクラスタリング（または Kolari–Pynnönen）、同じ日・同じ業種での置換の対照、Holm の補正。
- **未来の情報の混入の防ぎ方**
  - 期限より前は、時点を区切ったモデルだけで読む。
  - 期限より後は gpt-4o-mini。
  - 確認は、2026 年 10 月以降の前向きの記録で行う。
- **検出力**：既知の強さの合成信号を、実際のイベントの日付の構造に入れて測る。意味のある最小の効果は、その結果で決める。
- **前向きの検証**
  - 目的変数、点数、統制、除外の規則、窓、判定の基準、プロンプトとコードのハッシュを凍結する。
  - 2027 年 2 月まで結果を開けない。

7　ChronoGPT の環境と最初の確認

この PC に、ChronoGPT-Instruct の環境を作った（`工房/LLM/chrono/`）。2015〜2023 年の判断日と、その後の比較に使う 2014〜2024 年末の 11 の版を取得する（2026 年 10 月 17 日に取得中。以下の確認は 2022 年末の版で行った）。

- **重み**：元は fp32（7.4GB）で 8GB の GPU に載らないため、bf16（3.7GB）にして保存した。元のファイルの SHA-256 は、公開されている値と一致した。
- **速さとメモリ**：選択肢の確率で点数を付けると、1 本あたり 0.1〜0.3 秒、GPU のメモリは最大約 5.2GB。
- **知識**：2022 年の版でも、今の米国大統領を「Bill Clinton」と答えた。指示の学習のデータが 2000 年より前の内容に限られているためで、知識を問う使い方には向かない。
- **ゼロショットの点数**
  - モデルの癖が強い。較正しないと、良い発表でも悪い発表でも、ガイダンスを「lower」と 9 割以上で答えた。
  - 中身のない文章で測った癖で割る「文脈による較正」で、大きく改善した（下の表）。

較正後の確率（2022 年の版）	良い発表の例	悪い発表の例
ガイダンス：raise ／ lower ／ keep	0.79 ／ 0.17 ／ 0.04	0.33 ／ 0.54 ／ 0.13
語調：positive 系／ negative 系	0.79 ／ 0.20	0.31 ／ 0.66

「据え置き」や中間の文章は、まだ区別できない。研究では、He ほか（2025）と同じように、最後の層の埋め込み（1,536 次元）の上に、判断日より前のイベントだけで学習した回帰を置く。ゼロショットの点数は、補助に使う。

8　次の実験（優先順）

実験	方法と成功の基準	次の判断	費用・時間
P0 前向きの記録	手順を凍結し、毎週 EDGAR の新しい発表文を取得して点数化。プロンプトから株価への言及を除く	2027 年 2 月に一度だけ開ける	数ドル、今週着手
E1 時刻の監査	5,429 件の受理時刻と取引日を確定。時刻の不明なものは主な分析から外す	以後のすべての前提	0 円、1 週間
E2 イベントの評価	既存の点数で (a) 反応と (b) ドリフトを評価。数値を統制して、係数と区間を求める	(a) で残らなければ文章の線を縮小	0 円、1 週間
E3 非 LLM の対照	辞書・TF-IDF・FinBERT を同じイベントに。LLM が 3 つを統制して残るか	超えなければ安い方法へ	0 円、1〜2 週間
E4　検出力と BLM	2016〜2026 年に合成信号を入れ、検出に要る件数と、較正した BLM の採用率を測る	最小の効果と規模を決める	0 円、1〜2 週間
E5 期限前の延長	ChronoGPT（前年末の版）で 2015〜2023 年の発表文を点数化。2023 年以降で gpt-4o-mini と一致度を比べる。LAP の検定で gpt-4o-mini の汚染を診断	使えれば標本が約 4 倍	0 円（GPU）、2〜3 週間
E6 BLM への組み込み	E2〜E5 で残った信号だけ。順位の戦略・等リスクと、同じ TE とコストで比べる	改善しなければ BLM を外す	0 円、1〜2 週間

9　やらないこと

- 数値の予想のプロンプトの工夫、新しいモデルによる予想。外挿と先読みの問題は、工夫で消えない。
- 予想役へのフィードバック。H07 で、一律に強気に寄った。
- 成績を見て τ・TE・Ω を選ぶこと。過剰適合になる。
- 2015〜2023 年の文章を、gpt-4o-mini と匿名化で読むこと。記憶を除けない。
- 月次レポートの分析。米国の銘柄やセクターにほとんど触れていない。

10　リスクと未解決の問い

- 前向きの検証の標本は、2026 年 10 月〜2027 年 1 月の決算シーズンの約 1,000 件にとどまる。区間で報告し、「有意でない」を「効果がない」と読まない。
- ChronoGPT は文脈が 1,792 トークンと短く、読む力も弱い。決算発表文は、見出しと冒頭の要約か、段落ごとの点数で扱う。
- 寄り付きで反映されるなら、取引できる価値はゼロに近い。その場合も「LLM は情報を正しく取り出すが、取引できる価値はない」が結論になる。
- Liang（2026）の「期限の前と後の誤差の差」など、独立に確かめられなかった文献は、根拠に使わない。

11　スケジュール

時期	作業	終わりの判断点
10 月後半	P0 の凍結と記録の開始、E1 の時刻の監査、引用の修正	主な目的変数と判定の基準を凍結したか
11 月	E2・E3、並行して E4	文章の点数が数値と対照を超えるか。超えなければ縮小
12 月	E5（ChronoGPT による延長）、LAP の検定	期限前の点数が期限後と同じ方向か
1〜2 月	E6（信号が残った場合）、前向きの記録を締める	BLM を残すか
2〜3 月	前向きの検証を開け、最終報告	凍結した基準で一度だけ判定

決めること

1. 前向きの記録を今すぐ始めるか。主な目的変数を「発表への反応」にするか。
2. 取り下げられた論文の引用を、LLM-BLM の資料 4 つで直すか。

主な参考文献

- Cao, S., Jiang, W., Xu, H. (2026). Seeing the Goal, Missing the Truth: Human Accountability for AI Bias. NBER WP 35142; arXiv:2602.09504.
- Chen, S., Green, T. C., Gulen, H., Zhou, D. (2024). What Does ChatGPT Make of Historical Stock Returns? arXiv:2409.11540.
- deHaan, E., Shevlin, T., Thornock, J. (2015). Market (in)attention and the strategic scheduling and timing of earnings announcements. J. Accounting and Economics 60. doi:10.1016/j.jacceco.2015.03.003.
- Gao, Z., Jiang, W., Yan, Y. (2025). Detecting Lookahead Bias in LLM Forecasts. arXiv:2512.23847.
- Glasserman, P., Lin, C. (2024). Assessing Look-Ahead Bias in Stock Return Predictions Generated by GPT Sentiment Analysis. J. Financial Data Science 6(1); arXiv:2309.17322.
- Harvey, C. R., Liu, Y., Zhu, H. (2016). …and the Cross-Section of Expected Returns. Review of Financial Studies 29(1). doi:10.1093/rfs/hhv059.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Chronologically Consistent Large Language Models. arXiv:2502.21206.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Instruction Tuning Chronologically Consistent Language Models. arXiv:2510.11677.
- Huang, A. H., Wang, H., Yang, Y. (2023). FinBERT: A Large Language Model for Extracting Information from Financial Text. Contemporary Accounting Research 40(2). doi:10.1111/1911-3846.12832.
- Kelly, B., Malamud, S., Schwab, J., Xu, T. A. (2026). Scaling Point-in-Time Language Models. arXiv:2607.11889.
- Kim, A. G., Muhn, M., Nikolaev, V. V. (2024). Financial Statement Analysis with Large Language Models. arXiv:2407.17866（2025 年 2 月に取り下げ）.
- Kolari, J. W., Pynnönen, S. (2010). Event Study Testing with Cross-Sectional Correlation of Abnormal Returns. Review of Financial Studies 23(11). doi:10.1093/rfs/hhq072.
- Lee, Y., Kim, Y., Kim, S., Lee, Y. (2025). LLM-Enhanced Black-Litterman Portfolio Optimization. CIKM 2025; arXiv:2504.14345.
- Lopez-Lira, A., Tang, Y., Zhu, M. (2025). The Memorization Problem: Can We Trust LLMs' Economic Forecasts? arXiv:2504.14765.
- Loughran, T., McDonald, B. (2011). When Is a Liability Not a Liability? J. Finance 66(1). doi:10.1111/j.1540-6261.2010.01625.x.
- McLean, R. D., Pontiff, J. (2016). Does Academic Research Destroy Stock Return Predictability? J. Finance 71(1). doi:10.1111/jofi.12365.
- Meursault, V., Liang, P. J., Routledge, B. R., Scanlon, M. M. (2023). PEAD.txt: Post-Earnings-Announcement Drift Using Text. JFQA 58(6). doi:10.1017/S0022109022001181.

- Siano, F. (2025). The News in Earnings Announcement Disclosures: Capturing Word Context Using LLM Methods. Management Science 71(11). doi:10.1287/mnsc.2024.05417.
- Wu, Y., Akin, E. M., Martineau, C., Grégoire, V., Veneris, A. (2025). Extracting the Structure of Press Releases for Predicting Earnings Announcement Returns. arXiv:2509.24254.
- Yan, Y., Tang, R., Gao, Z., Jiang, W., Lu, Y. (2026). DatedGPT: Preventing Lookahead Bias in Large Language Models with Time-Aware Pretraining. arXiv:2603.11838.
- Yu, D., Liu, Z., Zhang, H., He, H. (2026). Fast Numbers, Slow Language: Bridging Quantitative and Qualitative Earnings Signals. arXiv:2606.29734.