平均分散から Black-Litterman へ

He と Litterman（1999）に沿った解説と、本プロジェクト（LLM-BLM）の計算

勉強用資料

2026 年 10 月

目次

この資料について 3

第 1 章 平均分散最適化 5
1.1 ポートフォリオのリターンとリスク 5
1.2 リターンとリスクの釣り合い：効用の最大化 6
1.3 全額を投資する場合 7
1.4 平均分散最適化の弱点 8

第 2 章 市場の均衡リターン 10
2.1 考え方：市場の比率から期待リターンを逆算する 10
2.2 G7 の例：入力 10
2.3 G7 の例：均衡リターンを計算する 11
2.4 CAPM との関係とリスク回避度 δ 11
2.5 均衡リターンを最適化に入れると、市場の比率に戻る 12
2.6 均衡から少しずらすだけで、比率は大きく動く 13

第 3 章 ビューの表し方 15
3.1 絶対的なビューと相対的なビュー 15
3.2 行列 P とベクトル Q 15
3.3 均衡が示すビューの値 16
3.4 ビューの不確かさ Ω 16
3.5 τ の意味 17

第 4 章 ベイズで混ぜる：Black-Litterman の公式 18
4.1 2 段の確率モデル 18
4.2 1 資産・1 ビューの場合 18
4.3 一般の場合の導出 19
4.4 もう 1 つの形：更新形 20
4.5 更新形の読み方：ビューの驚きが、相関を通じて広がる 21
4.6 事後の不確かさと、予測の共分散 22
4.7 極端な場合 23

第 5 章 He と Litterman の主結果：最適ポートフォリオの形 24
5.1 制約のない最適化 24
5.2 主結果：市場ポートフォリオとビューのポートフォリオの和 24
5.3 4 つの性質 25
5.4 例 1：ドイツとほかのヨーロッパ 26
5.5 例 2：カナダとアメリカのビューを足す 27
5.6 例 3：ビューを強気にする 28
5.7 例 4：ビューへの自信を下げる 28
5.8 例 5：重みが 0 になるビュー 29
5.9 この章のまとめ 30

第 6 章 実際に使うときの論点 31
6.1 制約を付ける 31

6.2 $\Sigma + M$ か Σ か 32
6.3 τ の役割 32
6.4 単位をそろえる 33
6.5 共分散の推定 33

第 7 章 本プロジェクトの計算 34
7.1 計算の流れ 34
7.2 He と Litterman の記号とコードの対応 35
7.3 $P = I$ のときの式 35
7.4 5 銘柄で計算する 36
7.5 全銘柄では 41
7.6 He と Litterman の設定との違い 42
7.7 元の実装との違い 43

第 8 章 まとめ 45

付録 A 行列の公式 46
A.1 ベクトルでの微分 46
A.2 平方完成 46
A.3 Woodbury の公式 46
A.4 正規分布の条件付き分布 46
A.5 制約付きの最適化の条件 47

付録 B 本プロジェクトのコード 47
参考文献 49

この資料について

この資料は、本プロジェクト（LLM-BLM）の比率の計算（`blm/`）が何をしているかを、平均分散最適化から順に、式と具体的な数字で追うためのものである。

骨組みには、He と Litterman の論文 *The Intuition Behind Black-Litterman Model Portfolios*（1999 年、Goldman Sachs Investment Management Research）を使う。Black-Litterman モデル（以下 BL）の原論文（Black and Litterman 1992）は、結果の数字を中心に書かれていて、式の導き方や、出てくる比率がなぜその形になるのかの説明は少ない。He と Litterman は、BL で得られる最適ポートフォリオが

「市場ポートフォリオ」＋「ビューを表すポートフォリオの重み付きの和」

という形で書けることを示し、G7 の株式市場の例で、ビューの強さや自信の度合いが比率にどう効くかを 1 つずつ確かめた。この資料も同じ順に進み、同じデータで計算をやり直す。

構成

章	内容
第 1 章	平均分散最適化。2 資産の例で、比率の公式と、その弱点を見る
第 2 章	市場の均衡リターン（逆最適化）。G7 の例で計算する
第 3 章	ビュー（投資家の見方）を P、Q、Ω で表す
第 4 章	均衡とビューをベイズの考え方で混ぜる。BL の公式を導き、G7 の例を手で計算する
第 5 章	He と Litterman の主結果。最適ポートフォリオの形と、その 4 つの性質
第 6 章	実際に使うときの論点（制約、τ の意味、単位、共分散の推定）
第 7 章	本プロジェクトの計算。5 銘柄の実データで、コードと同じ計算を 1 段ずつ追う
第 8 章	まとめ
付録	行列の公式、本プロジェクトのコード、参考文献

前提として、行列の積と逆行列、正規分布、偏微分を使う。使う公式は付録 A にまとめた。

数字の出どころ

本文と表の数字は、すべて同じフォルダの `BLM 解説 _ 計算.py` で計算し、自動で差し込んでいる（手で写した数字はない）。

- **G7 の例**：入力（相関、標準偏差、時価総額の比率）は He と Litterman の表 1 の値（もとは Black and Litterman 1992 の値）を使った。この入力から均衡リターンを計算し直すと、論文の表 1 の値と小数 1 桁まで一致する（表 2.3）。それ以降の例の数字は、この資料で計算し直したものである。論文の表とは、丸め方の違いで最後の桁がずれることがある。
- **本プロジェクトの例**：`data/blm.sqlite` の株価と、LLM の回答（LLM の実行番号 1、gpt-4o-

mini、1 銘柄につき 30 回答）を使った。判断日は 2025-01-31 である。

記号

記号	大きさ	意味
N		資産（銘柄）の数
K		ビューの数
r	N	資産のリターン（確率変数）
μ	N	期待リターン。断りがなければ、無リスク金利を引いた超過リターン
Σ	$N \times N$	リターンの共分散行列
w	N	投資比率
δ	スカラー	リスク回避度
w_{eq}	N	市場の比率（時価総額の比率）
Π	N	均衡リターン $\Pi = \delta \Sigma w_{\mathrm{eq}}$
τ	スカラー	均衡リターンの不確かさの大きさ
P	$K \times N$	ビューの行列。k 行目 p_k がビュー k のポートフォリオ
Q	K	ビューの値
Ω	$K \times K$	ビューの不確かさ（共分散）。ふつうは対角行列
$\bar{\mu}$	N	BL の事後の期待リターン
M	$N \times N$	事後の期待リターンの不確かさ（共分散）
$\Sigma_p = \Sigma + M$	$N \times N$	予測に使う共分散
$\Lambda = (\lambda_k)$	K	ビューのポートフォリオに付く重み
$\mathbf{1}$	N	成分がすべて 1 のベクトル
$x^\top$		転置

ベクトルはすべて縦ベクトルとする。たとえば $w^\top \mu = \sum_i w_i \mu_i$ である。

第 1 章

平均分散最適化

BL は、平均分散最適化の「入力の作り方」を変える方法である。そこでまず、平均分散最適化そのものと、その弱点を確認する。

1.1　ポートフォリオのリターンとリスク

N 個の資産のリターンを並べたベクトルを r とし、その期待値を $\mu = E[r]$、共分散行列を $\Sigma = \mathrm{Cov}(r)$ とする。Σ の (i,j) 成分は資産 i と j のリターンの共分散 $\sigma_{ij} = \rho_{ij}\sigma_i\sigma_j$ で、対角成分は各資産の分散 σ_i^2 である。

資産 i に比率 w_i を投資したポートフォリオのリターンは $r_p = \sum_i w_i r_i = w^\top r$ で、その期待値と分散は

$$E[r_p] = \sum_i w_i \mu_i = w^\top \mu, \tag{1.1}$$

$$\mathrm{Var}(r_p) = \sum_i \sum_j w_i w_j \sigma_{ij} = w^\top \Sigma w \tag{1.2}$$

となる。分散の式は、$\mathrm{Var}(\sum_i w_i r_i) = \sum_i \sum_j w_i w_j \mathrm{Cov}(r_i, r_j)$ を行列で書いたものである。

計算例 1.1：2 資産のポートフォリオ

資産 A は期待リターン 6%、標準偏差 20%、資産 B は期待リターン 2%、標準偏差 10%、相関は $\rho = 0.3$ とする（年率）。共分散は $\sigma_{AB} = 0.3 \times 0.20 \times 0.10 = 0.0060$ なので

$$\mu = \begin{pmatrix} 0.06 \\ 0.02 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} 0.04 & 0.0060 \\ 0.0060 & 0.01 \end{pmatrix}.$$

半分ずつ持つ $w = (0.5,\, 0.5)^\top$ では、期待リターンは $0.5 \times 6\% + 0.5 \times 2\% = 4.0\%$、分散は

$$w^\top \Sigma w = \underbrace{0.5^2 \times 0.04}_{0.0100} + \underbrace{0.5^2 \times 0.01}_{0.0025} + \underbrace{2 \times 0.5 \times 0.5 \times 0.006}_{0.0030} = 0.0155$$

で、標準偏差は $\sqrt{0.0155} = 12.45\%$ である。

標準偏差の単純な平均は $(20\% + 10\%)/2 = 15\%$ だが、ポートフォリオの標準偏差はそれより小さい。相関が 1 より小さいと、一方が下がるときにもう一方が下がらないことがあり、ぶれが打ち消し合うからである。相関を変えたときの値を表 1.1に示す。期待リターンは相関によらず同じで、リスクだけが変わる。これが分散投資の効果である。

この資料では、断りがなければ μ は無リスク金利を上回る分（超過リターン）を表す。無リスク資産（短期国債など）にお金を置けば、確実に無リスク金利が得られる。比率の合計 $\mathbf{1}^\top w$ が 1 より小さいときは残りを無リスク資産に置き、1 より大きいときはその分を無リスク金利で借りていると考える。

表1.1: 2 資産を半分ずつ持つポートフォリオの、相関とリスク。

相関 ρ	期待リターン	分散	標準偏差
1.0	4.0%	0.0225	15.00%
0.5	4.0%	0.0175	13.23%
0.3	4.0%	0.0155	12.45%
0.0	4.0%	0.0125	11.18%
−0.5	4.0%	0.0075	8.66%
−1.0	4.0%	0.0025	5.00%

1.2 リターンとリスクの釣り合い：効用の最大化

期待リターンは高いほどよく、分散は小さいほどよい。この 2 つを 1 つの数にまとめるため、次の量（効用）を最大にする比率を求める。

$$U(w) = w^\top \mu - \frac{\delta}{2} w^\top \Sigma w \tag{1.3}$$

$\delta > 0$ はリスク回避度で、分散 1 単位をリターンに換算するといくらの損になるかを決める。δ が大きいほど、リスクを嫌う投資家である。

1.2.1 1 資産の場合

資産が 1 つで、残りを無リスク資産に置く場合、$U(w) = w\mu - \frac{\delta}{2} w^2 \sigma^2$ である。w で微分して 0 とおくと

$$\frac{dU}{dw} = \mu - \delta w \sigma^2 = 0 \quad \Longrightarrow \quad w^* = \frac{\mu}{\delta \sigma^2} \tag{1.4}$$

となる。期待リターンが高いほど多く持ち、分散が大きいほど、またリスクを嫌うほど少なく持つ。資産 A だけなら、$\delta = 2.5$ として $w^* = 0.06/(2.5 \times 0.04) = 0.60$、つまり 60% を A に、40% を無リスク資産に置くのが最適である。

1.2.2 N 資産の場合

ベクトルで微分すると、$\partial(w^\top \mu)/\partial w = \mu$、$\partial(w^\top \Sigma w)/\partial w = 2\Sigma w$ なので（付録 A）、

$$\frac{\partial U}{\partial w} = \mu - \delta \Sigma w = 0 \quad \Longrightarrow \quad w^* = (\delta \Sigma)^{-1} \mu \tag{1.5}$$

となる。式 (1.4) の $\mu/(\delta\sigma^2)$ を、そのまま行列にした形である。Σ は正定値なので、U は上に凸で、この点が最大になる。

計算例 1.2：2 資産の最適比率（制約なし）

計算例 1.1 の 2 資産で、$\delta = 2.5$ とする。2×2 行列の逆行列は

$$\Sigma^{-1} = \frac{1}{\sigma_A^2 \sigma_B^2 - \sigma_{AB}^2} \begin{pmatrix} \sigma_B^2 & -\sigma_{AB} \\ -\sigma_{AB} & \sigma_A^2 \end{pmatrix}$$

で、行列式は $0.04 \times 0.01 - 0.006^2 = 0.000364$ だから

$$\Sigma^{-1} = \begin{pmatrix} 27.47 & -16.48 \\ -16.48 & 109.89 \end{pmatrix},$$

$$\Sigma^{-1}\mu = \begin{pmatrix} 27.47 \times 0.06 + (-16.48) \times 0.02 \\ (-16.48) \times 0.06 + 109.89 \times 0.02 \end{pmatrix} = \begin{pmatrix} 1.3187 \\ 1.2088 \end{pmatrix}.$$

これを $\delta = 2.5$ で割ると $w^* = (0.5275,\ 0.4835)^\top$ になる。A に 52.7%、B に 48.4% で、合計は 1.0110 なので、足りない 1.1% を無リスク金利で借りることになる。

1.3　全額を投資する場合

無リスク資産を使わず、比率の合計を 1 にする（全額をこれらの資産に投資する）場合は、条件 $\mathbf{1}^\top w = 1$ を付けて最大化する。ラグランジュ乗数 γ を使って

$$L(w, \gamma) = w^\top \mu - \frac{\delta}{2} w^\top \Sigma w - \gamma(\mathbf{1}^\top w - 1)$$

を w で微分して 0 とおくと $\mu - \delta \Sigma w - \gamma \mathbf{1} = 0$、つまり

$$w^* = \frac{1}{\delta} \Sigma^{-1}(\mu - \gamma \mathbf{1}) \tag{1.6}$$

である。γ は、条件 $\mathbf{1}^\top w^* = 1$ から

$$\gamma = \frac{\mathbf{1}^\top \Sigma^{-1} \mu - \delta}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \tag{1.7}$$

と決まる。式 (1.6) は、式 (1.5) の μ を、全資産から同じ γ を引いた $\mu - \gamma \mathbf{1}$ に置き換えた形である。γ は「全額を投資する」という条件のために、すべての資産に一律にかかる基準のリターンだと読める。

計算例 1.3：2 資産の最適比率（全額投資）

計算例 1.2 の Σ^{-1} から、$\mathbf{1}^\top \Sigma^{-1} \mu = 1.3187 + 1.2088 = 2.5275$、$\mathbf{1}^\top \Sigma^{-1} \mathbf{1} = 27.47 + 2 \times (-16.48) + 109.89 = 104.40$ なので

$$\gamma = \frac{2.5275 - 2.5}{104.40} = 0.00026 \ (\approx 0.03\%).$$

式 (1.6) に入れると、A が 52.6%、B が 47.4% になる。制約なしの解がもともと合計 1 に近かったので、ほとんど変わらない。

ここで、A の期待リターンを 6% から 7% に 1% だけ上げてみる。同じ計算をやり直すと、A が 63.2%、B が 36.8% になる。期待リターンの 1% の違いで、比率が 10% 以上動く。

1.4　平均分散最適化の弱点

式 (1.5) は単純で、理論としては申し分ない。しかし実際に使うと、次の問題が起きることがよく知られている。

1.4.1　期待リターンは推定できない

共分散は、日次のデータを使えば比較的精度よく推定できる。一方、期待リターンの推定は非常に難しい。年率の標準偏差 σ の資産の平均リターンを T 年分のデータで推定すると、その標準誤差は $\sigma/\sqrt{T}$ である（日次で測っても、期間の長さ T 年が同じなら精度はほぼ変わらない）。

表1.2: 期待リターンの推定の精度（年率の標準偏差 20% の資産）。

データの長さ T	平均の標準誤差 $\sigma/\sqrt{T}$	95% の範囲（真の平均 6% のとき）
1 年	20.0%	−33.2% 〜45.2%
5 年	8.9%	−11.5% 〜23.5%
10 年	6.3%	−6.4% 〜18.4%
30 年	3.7%	−1.2% 〜13.2%
100 年	2.0%	2.1% 〜9.9%

表 1.2 のとおり、10 年分のデータがあっても、95% の範囲は ±12% 以上ある。期待リターン 6% の資産について、約 −6% から約 +18% のどれが本当か区別できない。

本プロジェクトの規模でも確かめておく。判断日 2025-01-31 の 487 銘柄で、日次リターンの標準偏差の中央値は 1.63% である。1 か月 (21 取引日) の平均リターンの標準誤差は $1.63\%/\sqrt{21} = 0.356\%$ になる。一方、後で計算する均衡リターンの中央値は 1 日 0.0102% で、標準誤差のほうが 30 倍以上大きい。1 か月分の値動きから期待リターンを読み取るのは、統計的にはほとんど不可能である。

1.4.2　入力に敏感で、極端な比率になる

計算例 1.3 で見たように、最適な比率は期待リターンの小さな違いで大きく動く。資産が多く、互いに似た動きをする資産（相関の高い資産）があると、この性質はさらに強くなる。似た 2 つの資産の期待リターンにわずかな差があると、最適化は「高いほうを買い、低いほうを売る」組み合わせを、ほぼリスクのない儲けとみなして大量に持とうとする。具体的な例は 2.6 節で G7 のデータを使って見る。

1.4.3　推定の誤差を最大化する

期待リターンの推定値には誤差がある。最適化は推定値が高い資産を多く持つので、結果として「たまたま高く推定された資産」を選んで多く持つことになる。Michaud（1989）は、平均分散最適化が「誤差の最大化」になりやすいと指摘した。本プロジェクトの総合報告書でも、過去 1 年の平均リターンをそのまま使った平均分散最適化は、過去 1 年で最も上がった数銘柄に比率が集中した。

1.4.4　出発点がない

結局、問題の根は「μ を何にすればよいか分からない」ことにある。μ を全資産で同じ値にしても、比率は等金額にも時価総額の比率にもならず、やはり極端な比率になる（2.6 節）。何も特別な見方がないときに、どの μ を使えば「妥当な比率」が出てくるのか。BL の第 1 の答えが、次の章の均衡リターンである。

第 2 章

市場の均衡リターン

2.1　考え方：市場の比率から期待リターンを逆算する

すべての投資家が同じ μ と Σ を信じて平均分散最適化を行うなら、全員が同じリスク資産の組み合わせを持つ。市場全体はその合計なので、市場で実際に観察される時価総額の比率 w_{eq} が、平均的な投資家の最適な比率になっているはずである。これは CAPM（資本資産価格モデル）の考え方である。

それなら、式 (1.5) を逆にたどればよい。w_{eq} が最適になるような期待リターンは

$$w_{\mathrm{eq}} = (\delta\Sigma)^{-1}\Pi \quad \Longleftrightarrow \quad \Pi = \delta\,\Sigma\,w_{\mathrm{eq}} \tag{2.1}$$

である。Π を均衡リターン（市場が織り込んでいる期待リターン）と呼び、この計算を逆最適化と呼ぶ。Π は超過リターンである。

式 (2.1) は、共分散と時価総額という「観察できるもの」だけから期待リターンを作る。過去の平均リターンのような、推定の難しい量を使わない。そして、Π を最適化に入れれば、必ず市場の比率 w_{eq} が返ってくる。これが BL の出発点（事前の見方）になる。

2.2　G7 の例：入力

He と Litterman は、G7 の 7 か国の株式市場（ドル建て）を例に使った。表 2.1 がリターンの相関、表 2.3 が標準偏差と時価総額の比率である。

表2.1: G7 の株式市場のリターンの相関（He と Litterman の表 1）。

	AUS	CAN	FRA	GER	JPN	UK	USA
オーストラリア	1.000	0.488	0.478	0.515	0.439	0.512	0.491
カナダ	0.488	1.000	0.664	0.655	0.310	0.608	0.779
フランス	0.478	0.664	1.000	0.861	0.355	0.783	0.668
ドイツ	0.515	0.655	0.861	1.000	0.354	0.777	0.653
日本	0.439	0.310	0.355	0.354	1.000	0.405	0.306
イギリス	0.512	0.608	0.783	0.777	0.405	1.000	0.652
アメリカ	0.491	0.779	0.668	0.653	0.306	0.652	1.000

共分散は $\Sigma_{ij} = \rho_{ij}\sigma_i\sigma_j$ で作る。たとえばドイツの分散は $0.271^2 = 0.07344$ である。

2.3　G7 の例：均衡リターンを計算する

$\delta = 2.5$ として、式 (2.1) を計算する。ドイツの成分は

$$\Pi_{\mathrm{GER}} = \delta \sum_j \Sigma_{\mathrm{GER},j}\, w_{\mathrm{eq},j} = \delta \sum_j \rho_{\mathrm{GER},j}\, \sigma_{\mathrm{GER}}\, \sigma_j\, w_{\mathrm{eq},j}$$

で、各項は表 2.2のとおりである。

表2.2: ドイツの均衡リターンの計算。最後の列を足して $\delta = 2.5$ を掛ける。

国 j	$\rho_{\mathrm{GER},j}$	σ_j (%)	$\Sigma_{\mathrm{GER},j}$	$w_{\mathrm{eq},j}$ (%)	$\Sigma_{\mathrm{GER},j}\, w_{\mathrm{eq},j}$
オーストラリア	0.515	16.0	0.02233	1.6	0.000357
カナダ	0.655	20.3	0.03603	2.2	0.000793
フランス	0.861	24.8	0.05787	5.2	0.003009
ドイツ	1.000	27.1	0.07344	5.5	0.004039
日本	0.354	21.0	0.02015	11.6	0.002337
イギリス	0.777	20.0	0.04211	12.4	0.005222
アメリカ	0.653	18.7	0.03309	61.5	0.020352
合計 $(\Sigma w_{\mathrm{eq}})_{\mathrm{GER}}$					0.036109

合計は 0.036109 なので、$\Pi_{\mathrm{GER}} = 2.5 \times 0.036109 = 0.09027$、つまり年率 9.03% である。ドイツの比率は 5.5% しかないが、最も大きい寄与はアメリカ（比率 61.5%）との共分散から来ている。均衡リターンは「その資産が市場全体のリスクにどれだけ寄与しているか」で決まる。7 か国すべての結果を表 2.3に示す。論文の表 1 の値と、小数 1 桁で一致する。

表2.3: G7 の標準偏差、時価総額の比率、均衡リターン（年率、$\delta = 2.5$）。

国	標準偏差 σ_i (%)	時価総額比率 $w_{\mathrm{eq},i}$ (%)	Π_i 再計算 (%)	Π_i 論文 (%)
オーストラリア	16.0	1.6	3.94	3.9
カナダ	20.3	2.2	6.92	6.9
フランス	24.8	5.2	8.36	8.4
ドイツ	27.1	5.5	9.03	9.0
日本	21.0	11.6	4.30	4.3
イギリス	20.0	12.4	6.77	6.8
アメリカ	18.7	61.5	7.56	7.6

2.4　CAPM との関係とリスク回避度 δ

Σw_{eq} の i 番目の成分は、資産 i のリターンと市場ポートフォリオのリターン $r_m = w_{\mathrm{eq}}^{\top} r$ の共分散 $\mathrm{Cov}(r_i, r_m)$ である。したがって式 (2.1) は $\Pi_i = \delta\, \mathrm{Cov}(r_i, r_m)$ と書ける。両辺に $w_{\mathrm{eq},i}$ を掛けて

足すと、市場ポートフォリオの期待超過リターンは

$$\Pi_m = w_{\text{eq}}^\top \Pi = \delta\, w_{\text{eq}}^\top \Sigma w_{\text{eq}} = \delta\, \sigma_m^2 \quad \Longrightarrow \quad \delta = \frac{\Pi_m}{\sigma_m^2} \tag{2.2}$$

となる。これを使って δ を消すと

$$\Pi_i = \frac{\mathrm{Cov}(r_i, r_m)}{\sigma_m^2}\,\Pi_m = \beta_i\,\Pi_m \tag{2.3}$$

で、CAPM の式そのものになる。逆最適化は、CAPM の期待リターンを行列で書いたものだと分かる。

計算例 2.1：G7 の市場ポートフォリオ

$\sigma_m^2 = w_{\text{eq}}^\top \Sigma w_{\text{eq}} = 0.02854$（標準偏差 16.89%）、$\Pi_m = w_{\text{eq}}^\top \Pi = 7.13\%$ である。$\Pi_m/\sigma_m^2 = 2.500$ となり、使った δ に戻る。市場のシャープレシオ（リスク 1 単位あたりの超過リターン）は $\Pi_m/\sigma_m = 0.422$ である。各国のベータと $\beta_i\Pi_m$ を表 2.4に示す。$\beta_i\Pi_m$ は Π_i に一致する。

表2.4: G7 のベータと、CAPM の式で計算した期待超過リターン。

国	β_i	$\beta_i\,\Pi_m$ (%)	Π_i (%)
オーストラリア	0.552	3.94	3.94
カナダ	0.969	6.92	6.92
フランス	1.172	8.36	8.36
ドイツ	1.265	9.03	9.03
日本	0.603	4.30	4.30
イギリス	0.949	6.77	6.77
アメリカ	1.060	7.56	7.56

式 (2.2) は、δ の決め方も教えてくれる。市場のシャープレシオ $S_m = \Pi_m/\sigma_m$ を使えば $\delta = S_m/\sigma_m$ である。たとえば市場の超過リターンが年率 6%、標準偏差が 16% なら $\delta = 0.06/0.16^2 \approx 2.3$ になる。He と Litterman は $\delta = 2.5$ を使っており、本プロジェクトも同じ値を使う。

δ は日次でも年率でも同じ値

リターンが日ごとに独立なら、期待リターンも分散も期間の長さに比例する。年率を日次に直すと Π_m も σ_m^2 も 1/252 倍になるので、式 (2.2) の比 $\delta = \Pi_m/\sigma_m^2$ は変わらない。本プロジェクトが日次のデータで $\delta = 2.5$ を使えるのは、このためである。標準偏差（$\sqrt{\ }$ が付く）を使うシャープレシオは、期間によって値が変わることに注意する。

2.5　均衡リターンを最適化に入れると、市場の比率に戻る

式 (2.1) の作り方から、$\mu = \Pi$ として式 (1.5) を解けば $w^* = w_{\text{eq}}$ になる。$\mathbf{1}^\top w_{\text{eq}} = 1$ なので、全額投資の式 (1.6) でも $\gamma = 0$ となり、やはり w_{eq} になる。

図 2.1 は、Π を期待リターンとしたときの効率的フロンティア（同じ期待リターンのなかで分散が最小になる組み合わせの集まり）である。原点（無リスク資産）から引いた直線が、空売りありのフロンティアに接する点が、シャープレシオが最大のポートフォリオ（接点ポートフォリオ）である。Π を使うと、それがちょうど市場ポートフォリオになる。

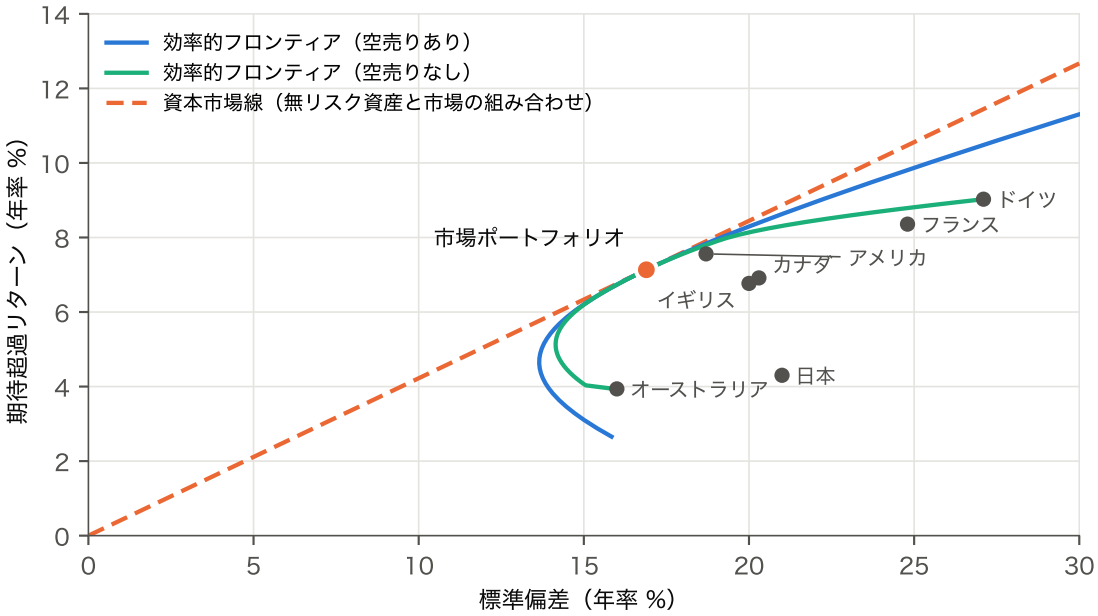


図2.1: G7 で Π を期待リターンとしたときの効率的フロンティア。点は各国、オレンジの点は市場ポートフォリオ。

2.6　均衡から少しずらすだけで、比率は大きく動く

均衡リターンは「何も特別な見方がないとき」の出発点として申し分ない。では、自分の見方を入れるために μ を少しだけ変えるとどうなるか。表 2.5 は、全額投資の式 (1.6) で、μ を変えたときの比率である。

表2.5: G7 で μ を変えたときの、全額投資の最適比率（%）。

国	均衡 Π	ドイツだけ +1%	ドイツ +1%、フランス −1%	全部 7%
オーストラリア	1.6	0.7	−0.8	47.5
カナダ	2.2	0.0	3.5	10.2
フランス	5.2	−10.8	−41.1	−1.1
ドイツ	5.5	29.1	45.1	−22.3
日本	11.6	12.7	13.3	18.6
イギリス	12.4	6.2	15.2	22.4
アメリカ	61.5	62.0	64.9	24.8
比率の絶対値の合計	100.0	121.6	183.9	146.8

- **ドイツだけ** $+1\%$：ドイツの比率は 5.5% から 29.1% に増え、フランスは -10.8%（空売り）になる。ドイツとフランスの相関は 0.861 と高いので、最適化は「ドイツを買い、フランスを売る」組み合わせを、リスクの小さい儲けとみなす。イギリスも 12.4% から 6.2% に減る。ドイツの見方を変えただけなのに、ほかの国の比率が動く。
- **ドイツ** $+1\%$**、フランス** -1%：ドイツは 45.1%、フランスは -41.1% になる。見方としては小さな違いだが、極端な比率になる。
- **全部 7%**：「どの国も同じ」と見たつもりでも、比率は オーストラリアの 47.5% から ドイツの -22.3% まで散らばる。期待リターンを同じにすると、分散が小さく、ほかと相関の低い資産が有利になるからである。

ここから分かることは 2 つある。第 1 に、μ を直接いじるのは危ない。どの資産の μ を変えても、相関を通してほかの資産の比率まで動く。第 2 に、見方を入れたいなら、「何についての見方か」と「どれくらい自信があるか」を分けて指定し、均衡からのずれをその分だけにとどめる仕組みがほしい。それが次の 2 章で見る BL の仕組みである。

第 3 章

ビューの表し方

BL では、投資家の見方（ビュー）を、次の 3 つに分けて書く。

1. どの資産の組み合わせについての見方か（行列 P）
2. その組み合わせの期待リターンはいくらだと思うか（ベクトル Q）
3. その見方はどれくらい確かか（行列 Ω）

3.1　絶対的なビューと相対的なビュー

ビューには 2 つの形がある。

- **絶対的なビュー**：「日本株の期待超過リターンは年 6%」のように、1 つの資産の値を言うもの。
- **相対的なビュー**：「ドイツ株はフランス株より年 2% 高い」のように、資産どうしの差を言うもの。

運用の現場の見方は「どちらが勝つか」の形が多く、相対的なビューで書くほうが自然なことが多い。He と Litterman の例は、すべて相対的なビューである。本プロジェクトは、全銘柄について絶対的なビューを置く（第 7 章）。

3.2　行列 P とベクトル Q

K 個のビューを、まとめて次のように書く。

$$P\mu = Q + \varepsilon \tag{3.1}$$

P の k 行目 p_k は、ビュー k が対象にする「ポートフォリオ」（各資産の重み）である。$p_k\mu$ はそのポートフォリオの期待リターンで、Q_k はそれについての投資家の予想値である。ε は予想の誤差で、次の節で扱う。

- 絶対的なビューの行は、その資産のところだけ 1 で、ほかは 0 である。
- 相対的なビューの行は、買う側の重みの合計が 1、売る側の重みの合計が -1 で、行の合計は 0 になる。

計算例 3.1：He と Litterman のビュー

ビュー 1：ドイツの株式は、ほかのヨーロッパ（フランスとイギリス）を年 5% 上回る。
「ほかのヨーロッパ」は、時価総額の比率で重み付けする。フランスは $5.2/(5.2+12.4) = 0.2955$、イギリスは $12.4/(5.2+12.4) = 0.7045$ である。
ビュー 2：カナダの株式は、アメリカの株式を年 3% 上回る。

国の順番を（オーストラリア、カナダ、フランス、ドイツ、日本、イギリス、アメリカ）とすると

$$P = \begin{pmatrix} 0 & 0 & -0.2955 & 1 & 0 & -0.7045 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & -1 \end{pmatrix}, \qquad Q = \begin{pmatrix} 0.05 \\ 0.03 \end{pmatrix}.$$

どちらの行も合計は 0 である。

3.3　均衡が示すビューの値

ビューのポートフォリオ p_k についても、均衡が示す期待リターン $p_k\Pi$ を計算できる。これと Q_k を比べると、そのビューが均衡に比べてどれだけ強気かが分かる。

計算例 3.2：均衡が示すビューの値

ビュー 1 では

$$p_1\Pi = 9.03\% - 0.2955 \times 8.36\% - 0.7045 \times 6.77\% = 1.79\%$$

である。市場は、ドイツがほかのヨーロッパを年 1.79% 上回ると見ている。投資家の $Q_1 = 5\%$ は、それより 3.21% 強気である。

ビュー 2 では $p_2\Pi = 6.92\% - 7.56\% = -0.64\%$ で、市場はカナダがアメリカを下回ると見ている。$Q_2 = 3\%$ は 3.64% 強気である。

後で見るとおり、BL で効くのは Q の値そのものではなく、均衡との差 $Q - P\Pi$ である。$Q = P\Pi$ のビューは、期待リターンについて新しい情報を何も持たない。

3.4　ビューの不確かさ Ω

式 (3.1) の誤差 ε は、平均 0、共分散 Ω の正規分布に従うとする。

$$\varepsilon \sim \mathcal{N}(0,\ \Omega) \tag{3.2}$$

ふつうは、ビューどうしの誤差は独立だとして、Ω を対角行列 $\mathrm{diag}(\omega_1, \ldots, \omega_K)$ にする。ω_k が小さいほど、ビュー k に自信があることを表す。

ω_k をどう決めるかは、BL を使ううえで最も悩ましい点である。He と Litterman は、次のように置いた。

$$\omega_k = p_k \left(\tau\Sigma\right) p_k^{\top} \tag{3.3}$$

右辺は、事前の見方（次の章の $\mu \sim \mathcal{N}(\Pi, \tau\Sigma)$）のもとでの $p_k\mu$ の分散である。つまり、「ビューの値の不確かさは、均衡がそのポートフォリオについて持つ不確かさと同じ」とする置き方である。次の章で見るとおり、こうするとビューと均衡が同じ重みで混ざる。

計算例 3.3：ビュー 1 の不確かさ

ビュー 1 のポートフォリオの分散は $p_1\Sigma p_1^{\top} = 0.02130$（標準偏差 14.6%）である。$\tau = 0.05$ とすると

$$\omega_1 = 0.05 \times 0.02130 = 0.001065$$

で、標準偏差は $\sqrt{0.001065} = 3.26\%$ である。ビュー 1 は「ドイツはほかのヨーロッパを $5\% \pm 3.26\%$ 上回る」と言っていることになる。同じように、ビュー 2 は $\omega_2 = 0.000852$ である。

ほかの決め方には、次のものがある。

決め方	内容
均衡に合わせる (He と Litterman)	式 (3.3)。ビューと均衡を同じ重みで扱う
自信の度合いから逆算する(Idzorek)	ビューごとに「何% 自信があるか」を決め、それに合う ω_k を逆算する
過去の当たり具合から決める	過去の予想が実際にどれだけ外れたか（予測誤差の分散）を使う
回答のばらつきを使う（本プロジェクト）	LLM に同じ質問を 30 回行い、回答の分散を ω_k にする

3.5 τ の意味

次の章では、真の期待リターン μ を確率変数とみなし、その事前の分布を $\mathcal{N}(\Pi, \tau\Sigma)$ とする。ここに出てくる 2 つの共分散を区別しておく。

- Σ：リターン r そのもののぶれ。来年の株価が上がるか下がるか。
- $\tau\Sigma$：期待リターン μ についての不確かさ。平均的にはどれくらい上がるはずか、を私たちがどれだけ知らないか。

平均を T 個の独立な観測から推定すれば、その推定値の共分散は Σ/T である。この見方では $\tau \approx 1/T$ で、$\tau = 0.05$ は 20 年分、$\tau = 0.025$ は 40 年分の年次データで平均を推定したのと同じ確かさに当たる。実際には 0.01〜0.05 程度の値がよく使われる。He と Litterman は $\tau = 0.05$、本プロジェクトの元論文と本プロジェクトは $\tau = 0.025$ である。

たとえば $\tau = 0.05$ のとき、ドイツの期待リターンの事前の標準偏差は $\sqrt{0.05} \times 27.1\% = 6.06\%$ である。事前の見方は「ドイツの期待リターンは $9.03\% \pm 6.06\%$」となる。

第 4 章

ベイズで混ぜる：Black-Litterman の公式

4.1　2 段の確率モデル

BL は、真の期待リターン μ を分からない量として扱い、次のモデルを考える。

$$r \mid \mu \sim \mathcal{N}(\mu,\ \Sigma) \qquad \text{リターンは、期待リターンのまわりにぶれる} \tag{4.1}$$

$$\mu \sim \mathcal{N}(\Pi,\ \tau\Sigma) \qquad \text{事前の見方：期待リターンは均衡のまわりにある} \tag{4.2}$$

$$Q \mid \mu \sim \mathcal{N}(P\mu,\ \Omega) \qquad \text{ビュー：} P\mu \text{ についての誤差のある予想} \tag{4.3}$$

式 (4.3) は、式 (3.1) を書き直したものである。Q を「$P\mu$ を誤差つきで観測したデータ」とみなし、ベイズの定理で μ の分布を更新する。Black と Litterman の原論文は、この組み合わせを Theil の混合推定（標本の情報と事前の情報をまとめて推定する方法）として説明していた。ベイズの事前分布と事後分布として読む説明は、その後に広まった（Satchell and Scowcroft 2000 など）。どちらで読んでも、得られる式は同じである。

4.2　1 資産・1 ビューの場合

まず、資産が 1 つで、その期待リターンについて絶対的なビューを 1 つ持つ場合を考える。事前は $\mu \sim \mathcal{N}(\Pi, \tau\sigma^2)$、ビューは $Q \mid \mu \sim \mathcal{N}(\mu, \omega)$ である。ベイズの定理から、事後の密度は事前の密度と尤度の積に比例する。

$$p(\mu \mid Q) \propto \exp\!\left(-\frac{(\mu-\Pi)^2}{2\tau\sigma^2}\right)\exp\!\left(-\frac{(Q-\mu)^2}{2\omega}\right)$$

指数の部分を μ について整理する（平方完成）。

$$-\frac{1}{2}\left[\left(\frac{1}{\tau\sigma^2}+\frac{1}{\omega}\right)\mu^2 - 2\left(\frac{\Pi}{\tau\sigma^2}+\frac{Q}{\omega}\right)\mu\right] + \text{定数} = -\frac{1}{2}\cdot\frac{(\mu-\bar{\mu})^2}{v} + \text{定数}$$

ここで

$$\frac{1}{v} = \frac{1}{\tau\sigma^2}+\frac{1}{\omega}, \qquad \bar{\mu} = v\left(\frac{\Pi}{\tau\sigma^2}+\frac{Q}{\omega}\right) \tag{4.4}$$

である。事後の分布も正規分布 $\mathcal{N}(\bar{\mu}, v)$ になる。分散の逆数を精度と呼ぶと、式 (4.4) は次のように読める。

- 事後の精度は、事前の精度とビューの精度の和である。情報が増えるので、事後の分散はどちらよりも小さい。
- 事後の平均は、Π と Q を、それぞれの精度で重み付けした平均である。

事後の平均は、さらに次の形に書き直せる。

$$\bar{\mu} = \Pi + k\,(Q-\Pi), \qquad k = \frac{\tau\sigma^2}{\tau\sigma^2+\omega} \tag{4.5}$$

k は、均衡から見たビューの「驚き」$Q - \Pi$ のうち、何割を受け入れるかを表す。この資料では k を**採用率**と呼ぶ。採用率は 2 つの不確かさの比 $\omega/(\tau\sigma^2)$ だけで決まる（図 4.2）。

計算例 4.1：1 資産の更新

$\Pi = 5\%$、$\sigma = 20\%$、$\tau = 0.05$ とする。事前の分散は $\tau\sigma^2 = 0.05 \times 0.04 = 0.002$（標準偏差 4.47%）である。ビューは $Q = 10\%$ とする。

He と Litterman の置き方では $\omega = \tau\sigma^2 = 0.002$ なので、$k = 0.002/(0.002 + 0.002) = 0.5$、$\bar{\mu} = 5\% + 0.5 \times (10\% - 5\%) = 7.50\%$ である。事後の分散は $1/(1/0.002 + 1/0.002) = 0.001$ で、標準偏差は 3.16% に減る（図 4.1）。ω を変えたときの結果を表 4.1に示す。

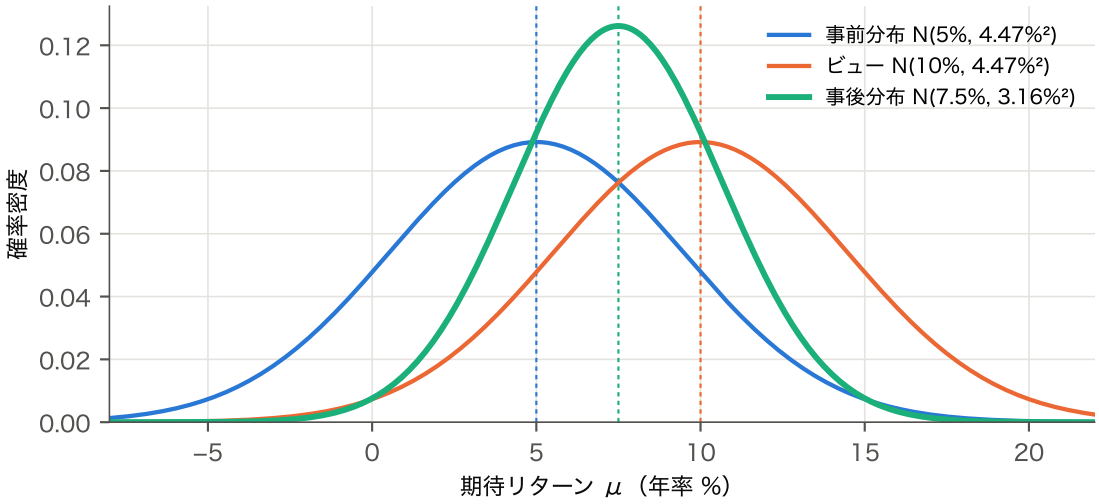


図4.1: 計算例 4.1 の事前分布、ビュー、事後分布。事後分布は 2 つの間にあり、幅が狭い。

表4.1: ビューの不確かさ ω と事後の期待リターン（$\Pi = 5\%$、$Q = 10\%$、$\tau\sigma^2 = 0.002$）。

ビューの不確かさ	ω	採用率 k	事後の平均	事後の標準偏差
$\omega = \tau\sigma^2/4$（強い自信）	0.0005	0.80	9.00%	2.00%
$\omega = \tau\sigma^2$	0.0020	0.50	7.50%	3.16%
$\omega = 4\tau\sigma^2$（弱い自信）	0.0080	0.20	6.00%	4.00%
$\omega \to \infty$（ビューなし）	∞	0.00	5.00%	4.47%
$\omega \to 0$（完全な自信）	0.0000	1.00	10.00%	0.00%

4.3　一般の場合の導出

N 資産・K ビューの場合も、やることは同じである。事後の密度の対数は、定数を除いて

$$\log p(\mu \mid Q) = -\frac{1}{2}(\mu - \Pi)^\top (\tau\Sigma)^{-1}(\mu - \Pi) - \frac{1}{2}(Q - P\mu)^\top \Omega^{-1}(Q - P\mu) + \text{定数}$$

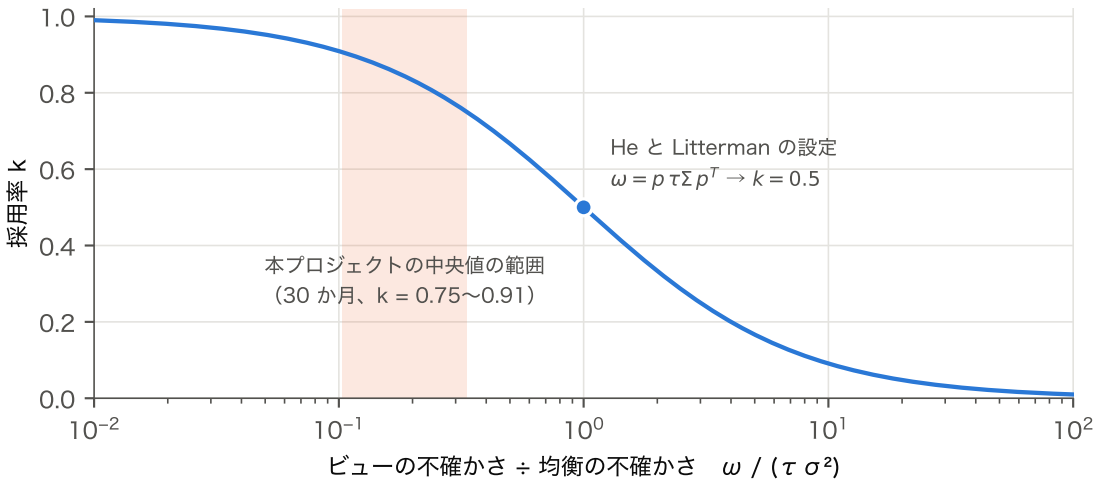


図4.2: 採用率 k と、2 つの不確かさの比 $\omega/(\tau\sigma^2)$ の関係。He と Litterman の置き方は $k = 0.5$。網かけは、本プロジェクトの 30 か月の判断日それぞれで、全銘柄の比の中央値を取ったときの範囲（第 7 章）。

である。μ の 2 次の項と 1 次の項を集めると

$$= -\frac{1}{2}\left[\mu^\top H\mu - 2\mu^\top h\right] + \text{定数}, \qquad H = (\tau\Sigma)^{-1} + P^\top\Omega^{-1}P, \quad h = (\tau\Sigma)^{-1}\Pi + P^\top\Omega^{-1}Q$$

となる。H は対称なので、平方完成すると $-\frac{1}{2}(\mu - H^{-1}h)^\top H(\mu - H^{-1}h) + \text{定数}$ である。したがって、事後の分布は

$$\mu \mid Q \sim \mathcal{N}(\bar{\mu},\ M), \qquad \bar{\mu} = H^{-1}h, \quad M = H^{-1} \tag{4.6}$$

で、書き下すと次の BL の公式になる。

Black-Litterman の公式（情報形）

$$\bar{\mu} = \left[(\tau\Sigma)^{-1} + P^\top\Omega^{-1}P\right]^{-1}\left[(\tau\Sigma)^{-1}\Pi + P^\top\Omega^{-1}Q\right] \tag{4.7}$$

$$M = \left[(\tau\Sigma)^{-1} + P^\top\Omega^{-1}P\right]^{-1} \tag{4.8}$$

1 資産のときと同じく、事後の精度 H は事前の精度 $(\tau\Sigma)^{-1}$ とビューの精度 $P^\top\Omega^{-1}P$ の和で、事後の平均はそれぞれの精度で重み付けした平均である。

4.4　もう 1 つの形：更新形

式 (4.7) は、$N \times N$ の逆行列を 3 回使う。Ω の逆行列も要るので、ビューの不確かさが 0（完全な自信）のときは使えない。同じ式は、次の形にも書ける。

Black-Litterman の公式（更新形）

$$\bar{\mu} = \Pi + \tau\Sigma P^\top\left(P\tau\Sigma P^\top + \Omega\right)^{-1}(Q - P\Pi) \tag{4.9}$$

$$M = \tau\Sigma - \tau\Sigma P^\top\left(P\tau\Sigma P^\top + \Omega\right)^{-1}P\tau\Sigma \tag{4.10}$$

逆行列は $K \times K$ の 1 つだけで、Ω が特異でもかまわない。式 (4.5) の 1 資産の形を、そのまま行列にしたものになっている。

■同じであることの確かめ　$A = \tau\Sigma$、$G = PAP^\top + \Omega$ とおく。Woodbury の公式（付録 A）から

$$M = (A^{-1} + P^\top \Omega^{-1} P)^{-1} = A - AP^\top G^{-1} PA$$

で、式 (4.10) が出る。これを $h = A^{-1}\Pi + P^\top \Omega^{-1} Q$ に掛けると

$$\bar{\mu} = Mh = \Pi + AP^\top \Omega^{-1} Q - AP^\top G^{-1} P\Pi - AP^\top G^{-1}(PAP^\top)\Omega^{-1} Q$$

である。最後の項で $PAP^\top = G - \Omega$ を使うと、$AP^\top G^{-1}(G-\Omega)\Omega^{-1}Q = AP^\top\Omega^{-1}Q - AP^\top G^{-1}Q$ なので、

$$\bar{\mu} = \Pi - AP^\top G^{-1} P\Pi + AP^\top G^{-1} Q = \Pi + AP^\top G^{-1}(Q - P\Pi)$$

となり、式 (4.9) が出る。付録 A では、(μ, Q) の同時分布から条件付き分布を求める、別の導き方も示す。

本プロジェクトのコードとの対応

本プロジェクトの `blm/black_litterman.py` には、2 つの関数がある。`posterior_returns` は更新形 (4.9)、`posterior_returns_original` は元の実装と同じ情報形 (4.7)（逆行列の代わりに疑似逆行列）で計算する。数学的には同じだが、Ω に 0 が含まれるときに結果が変わる（7.7.1 節）。

4.5　更新形の読み方：ビューの驚きが、相関を通じて広がる

式 (4.9) を、ビューが 1 つ（$K = 1$、$P = p$）の場合に書くと

$$\bar{\mu} = \Pi + g\,(Q - p\Pi), \qquad g = \frac{\tau\Sigma p^\top}{p\tau\Sigma p^\top + \omega} \tag{4.11}$$

である。$Q - p\Pi$ は「ビューが均衡に比べてどれだけ強気か」（驚き）、g はその驚きを各資産に配る係数である。g の i 番目の成分は、$\tau\,\mathrm{Cov}(r_i,\ p\,r)$、つまり資産 i とビューのポートフォリオの共分散に比例する。ビューに出てこない資産も、ビューのポートフォリオと相関があれば、期待リターンが動く。

計算例 4.2：G7 の例 1 を手で計算する

ビュー 1 だけを持つ場合（$\tau = 0.05$、$\omega_1 = p_1\tau\Sigma p_1^\top$）を計算する。

手順 1（驚き）：計算例 3.2 から $p_1\Pi = 1.79\%$、$Q_1 - p_1\Pi = 3.21\%$。

手順 2（分母）：$p_1\tau\Sigma p_1^\top = 0.001065$、$\omega_1 = 0.001065$ なので、分母は 2×0.001065。

手順 3（配る係数）：$\tau\Sigma p_1^\top$ を計算し、分母で割る（表 4.2）。

手順 4（足す）：$\bar{\mu}_i = \Pi_i + g_i \times 3.21\%$。

確かめ：ビューのポートフォリオの事後の値は $p_1\bar{\mu} = p_1\Pi + \dfrac{p_1\tau\Sigma p_1^\top}{p_1\tau\Sigma p_1^\top + \omega_1}(Q_1 - p_1\Pi) = 1.79\% + 0.5 \times 3.21\% = 3.39\%$ で、均衡の 1.79% とビューの 5% のちょうど中間になる。式 (3.3) の置き方では、採用率が 0.5 になるからである。

表4.2: 例 1 の事後の期待リターンの計算（年率）。g_i は式 (4.11) の係数。

国	$(\tau\Sigma p^\top)_i \times 10^4$	g_i	$g_i\,(Q - p\Pi)$ (%)	Π_i (%)	$\bar{\mu}_i$ (%)
オーストラリア	2.592	0.1217	0.39	3.94	4.33
カナダ	4.383	0.2058	0.66	6.92	7.58
フランス	6.166	0.2895	0.93	8.36	9.29
ドイツ	13.337	0.6262	2.01	9.03	11.04
日本	1.350	0.0634	0.20	4.30	4.51
イギリス	1.229	0.0577	0.19	6.77	6.95
アメリカ	3.379	0.1587	0.51	7.56	8.07

表 4.2 を見ると、ドイツだけでなく、7 か国すべての期待リターンが上がっている。ドイツはどの国とも正の相関を持つので、「ドイツが思ったより強い」という情報は、ほかの国にも少しずつ良い知らせになる。フランスとイギリスも上がるのは、ドイツとの相関が高いからである。ただし、上がり方はドイツより小さいので、ドイツとほかのヨーロッパの差は広がる。

4.6 事後の不確かさと、予測の共分散

事後の共分散 M は、ビューを知った後の μ の不確かさである。ビューがなければ $M = \tau\Sigma$ で、ビューがあると式 (4.10) の第 2 項の分だけ小さくなる。

最適化で使うのは、μ ではなく、来期のリターン r の予測の分布である。式 (4.1) から $r = \mu + e$ ($e \sim \mathcal{N}(0, \Sigma)$、$\mu$ と独立）と書けるので

$$r \mid Q \sim \mathcal{N}(\bar{\mu},\ \Sigma + M) = \mathcal{N}(\bar{\mu},\ \Sigma_p) \tag{4.12}$$

である。リターンのぶれ Σ に、期待リターンが分からないことによるぶれ M が加わる。ビューがないときは $\Sigma_p = (1 + \tau)\Sigma$ である。

表4.3: 例 1 の不確かさ（標準偏差、年率%）。ビューで μ の不確かさは減るが、$\Sigma + M$ に対しては小さな違いである。

国	事前 $\sqrt{(\tau\Sigma)_{ii}}$	事後 $\sqrt{M_{ii}}$	$\sqrt{\Sigma_{ii}}$	$\sqrt{(\Sigma + M)_{ii}}$
オーストラリア	3.58	3.53	16.00	16.39
カナダ	4.54	4.44	20.30	20.78
フランス	5.55	5.38	24.80	25.38
ドイツ	6.06	5.33	27.10	27.62
日本	4.70	4.69	21.00	21.52
イギリス	4.47	4.46	20.00	20.49
アメリカ	4.18	4.12	18.70	19.15

表 4.3 では、ドイツの期待リターンの不確かさが、ビューによって事前の 0.879 倍に減っている。一方、リターンそのもののぶれ Σ に比べると M は小さく、$\Sigma + M$ は Σ とほとんど変わらない。

4.7　極端な場合

式 (4.9) で、いくつかの極端な場合を確かめておく。

- **ビューがない**：$\bar{\mu} = \Pi$、$M = \tau\Sigma$。
- **ビューに自信がない**（$\Omega \to \infty$）：$(P\tau\Sigma P^\top + \Omega)^{-1} \to 0$ なので $\bar{\mu} \to \Pi$。ビューは無視される。
- **ビューに完全な自信がある**（$\Omega \to 0$）：$\bar{\mu} = \Pi + \tau\Sigma P^\top (P\tau\Sigma P^\top)^{-1}(Q - P\Pi)$。左から P を掛けると $P\bar{\mu} = Q$ で、ビューがそのまま成り立つ。ビューに出てこない方向は、均衡からの「最小の変更」で調整される。
- **ビューが均衡と同じ**（$Q = P\Pi$）：$\bar{\mu} = \Pi$。期待リターンは変わらない。ただし M は小さくなる。
- **τ と Ω を同じ倍率で変える**：$\tau\Sigma$ と Ω を両方 c 倍しても、式 (4.9) の $\bar{\mu}$ は変わらない。$\bar{\mu}$ を決めるのは 2 つの比である（6.3 節）。

第 5 章

He と Litterman の主結果：最適ポートフォリオの形

前の章で、ビューを入れた期待リターン $\bar{\mu}$ が求まった。He と Litterman の論文の中心は、それを最適化に入れたときに、どんな比率が出てくるかの分析である。

5.1　制約のない最適化

予測の分布 (4.12) を使い、式 (1.3) の効用を最大にする。制約を付けなければ、式 (1.5) と同じく

$$w^* = (\delta\Sigma_p)^{-1}\bar{\mu}, \qquad \Sigma_p = \Sigma + M \tag{5.1}$$

である。

■ビューがないとき　$\bar{\mu} = \Pi = \delta\Sigma w_{\text{eq}}$、$\Sigma_p = (1+\tau)\Sigma$ なので

$$w^* = \frac{1}{\delta(1+\tau)}\Sigma^{-1}\,\delta\Sigma w_{\text{eq}} = \frac{w_{\text{eq}}}{1+\tau} \tag{5.2}$$

となる。ビューがなければ、市場の比率をそのまま $1/(1+\tau)$ 倍に縮めたものを持つ。期待リターンが分からない分だけリスクが大きく見えるので、少しだけリスク資産を減らし、残りを無リスク資産に置く。$\tau = 0.05$ なら $1/1.05 = 95.2\%$ である。

5.2　主結果：市場ポートフォリオとビューのポートフォリオの和

He と Litterman の結果

制約のない BL の最適比率は

$$w^* = \frac{1}{1+\tau}\left(w_{\text{eq}} + P^\top\Lambda\right) \tag{5.3}$$

と書ける。Λ は K 次元のベクトルで、

$$\Lambda = \frac{\tau\Omega^{-1}Q}{\delta} - \frac{A^{-1}P\Sigma w_{\text{eq}}}{1+\tau} - \frac{A^{-1}P\Sigma P^\top}{1+\tau}\cdot\frac{\tau\Omega^{-1}Q}{\delta}, \qquad A = \frac{\Omega}{\tau} + \frac{P\Sigma P^\top}{1+\tau} \tag{5.4}$$

である。

$P^\top\Lambda = \sum_k \lambda_k\, p_k^\top$ は、ビューのポートフォリオ p_k を重み λ_k で足したものである。つまり、BL の最適比率は「市場の比率」に「ビューのポートフォリオ」を足し、全体を $1/(1+\tau)$ 倍したものになる。**ビューに出てこない資産の比率は、市場の比率（の $1/(1+\tau)$ 倍）から動かない**。第 2 章で見た平均分散最適化の、どこを変えても全部が動く性質とは、対照的である。

5.2.1　Λ を整理する

式 (5.4) の 3 つの項は、まとめると簡単になる。$(1+\tau)A = (1+\tau)\Omega/\tau + P\Sigma P^\top$ だから

$$\frac{P\Sigma P^\top}{1+\tau}\cdot\tau\Omega^{-1} = \left(A - \frac{\Omega}{\tau}\right)\tau\Omega^{-1} = A\tau\Omega^{-1} - I$$

である。これを第 3 項に使うと、第 1 項と打ち消し合って $A^{-1}Q/\delta$ が残る。第 2 項は $P\Sigma w_{\mathrm{eq}} = P\Pi/\delta$ と書けるので、

$$\Lambda = \frac{1}{\delta}A^{-1}\left(Q - \frac{P\Pi}{1+\tau}\right), \qquad A = \frac{\Omega}{\tau} + \frac{P\Sigma P^\top}{1+\tau} \tag{5.5}$$

となる。この資料の計算では、2 つの形が一致することを数値でも確かめている。

5.2.2　導き方

式 (5.3) と式 (5.5) が式 (5.1) と一致することを確かめる。示すべきことは

$$\delta\Sigma_p\,\frac{w_{\mathrm{eq}} + P^\top\Lambda}{1+\tau} = \bar{\mu}$$

である。$G = P\tau\Sigma P^\top + \Omega$ とおくと、式 (4.10) から

$$\Sigma_p = \Sigma + M = (1+\tau)\Sigma - \tau\Sigma P^\top G^{-1}P\tau\Sigma.$$

市場の部分：$\delta\Sigma w_{\mathrm{eq}} = \Pi$ を使うと

$$\delta\Sigma_p w_{\mathrm{eq}} = (1+\tau)\Pi - \tau\Sigma P^\top G^{-1}\,\tau P\Pi.$$

ビューの部分：

$$\delta\Sigma_p P^\top\Lambda = \delta\,\tau\Sigma P^\top\left[\frac{1+\tau}{\tau}I - G^{-1}\tau P\Sigma P^\top\right]\Lambda.$$

$\tau P\Sigma P^\top = G - \Omega$ だから、かっこの中は

$$\frac{1+\tau}{\tau}I - I + G^{-1}\Omega = G^{-1}\left(\frac{G}{\tau} + \Omega\right) = G^{-1}\left(P\Sigma P^\top + \frac{1+\tau}{\tau}\Omega\right) = (1+\tau)\,G^{-1}A$$

となる。よって $\delta\Sigma_p P^\top\Lambda = (1+\tau)\,\tau\Sigma P^\top G^{-1}\,\delta A\Lambda$ である。

合わせる：2 つを足して $1+\tau$ で割ると

$$\delta\Sigma_p\,\frac{w_{\mathrm{eq}} + P^\top\Lambda}{1+\tau} = \Pi + \tau\Sigma P^\top G^{-1}\left(\delta A\Lambda - \frac{\tau P\Pi}{1+\tau}\right).$$

これが式 (4.9) の $\bar{\mu} = \Pi + \tau\Sigma P^\top G^{-1}(Q - P\Pi)$ に等しくなる条件は

$$\delta A\Lambda - \frac{\tau P\Pi}{1+\tau} = Q - P\Pi \quad\Longleftrightarrow\quad \delta A\Lambda = Q - \frac{P\Pi}{1+\tau}$$

で、これは式 (5.5) そのものである。 □

5.3　4 つの性質

He と Litterman は、この形から BL の比率の性質を読み取っている。要約すると次の 4 つである。

BL の最適比率の性質（He と Litterman）

1. 制約のない最適比率は、市場の比率に、ビューを表すポートフォリオの重み付きの和を足したもの（を $1/(1+\tau)$ 倍したもの）である。
2. ビューのポートフォリオの重み λ_k は、そのビューが「均衡とほかのビューから示される値」より強気なら正になる。
3. ビューを強気にするほど、重み λ_k は大きくなる。
4. ビューへの自信が強いほど（ω_k が小さいほど）、重みの大きさ $|\lambda_k|$ は大きくなる。

ビューが 1 つのときは、式 (5.5) がスカラーの式になるので、性質 2〜4 がすぐに確かめられる。

$$\lambda = \frac{Q - p\Pi/(1+\tau)}{\delta\left(\omega/\tau + p\Sigma p^\top/(1+\tau)\right)} \tag{5.6}$$

- 分母は正なので、$\lambda > 0$ となるのは $Q > p\Pi/(1+\tau)$ のときである（性質 2）。
- λ は Q について増加する（性質 3）。
- ω が小さいほど分母が小さくなり、$|\lambda|$ は大きくなる（性質 4）。

境目が $p\Pi$ ではなく $p\Pi/(1+\tau)$ になっているのは、式 (5.3) で市場の比率そのものが $1/(1+\tau)$ 倍されているためである。$Q = p\Pi$（期待リターンは何も変えないビュー）でも、そのビューによって $p\mu$ の不確かさが減るので、そのポートフォリオを少しだけ多く持つ。例 1 では、$Q_1 = p_1\Pi$ のとき $\lambda_1 = 0.0082$ で、ほぼ 0 である。

ビューが複数あるときは、A^{-1} がビューどうしの関係を調整する。A の非対角成分 $p_j\Sigma p_k^\top/(1+\tau)$ は、ビューのポートフォリオどうしの共分散である。似たポートフォリオのビューが 2 つあれば、一方のビューの情報は他方のビューの重みにも影響する。性質 2 の「ほかのビューから示される値」は、このことを指している。

ビューがすべて相対的なビュー（$P\mathbf{1} = 0$）なら、$\mathbf{1}^\top P^\top \Lambda = 0$ なので、比率の合計は $\mathbf{1}^\top w^* = 1/(1+\tau)$ のまま変わらない。相対的なビューは、リスク資産全体の量を変えずに、中身の配分だけを変える。

5.4　例 1：ドイツとほかのヨーロッパ

ビュー 1 だけを持つ場合の結果を表 5.1に示す。

計算例 5.1：λ_1 を手で計算する

式 (5.6) に入れる。

$$\frac{\omega_1}{\tau} = \frac{0.001065}{0.05} = 0.02130, \qquad \frac{p_1\Sigma p_1^\top}{1+\tau} = \frac{0.02130}{1.05} = 0.02028, \qquad A = 0.04158,$$

$$Q_1 - \frac{p_1\Pi}{1+\tau} = 5\% - \frac{1.79\%}{1.05} = 3.30\%, \qquad \lambda_1 = \frac{3.30\%}{2.5 \times 0.04158} = 0.317.$$

比率の変化は $w^* - w_{\text{eq}}/(1+\tau) = \lambda_1 p_1^\top/(1+\tau)$ で、ドイツが $+0.302 = +30.2\%$、フランスが $0.302 \times (-0.2955) = -8.9\%$、イギリスが $0.302 \times (-0.7045) = -21.3\%$ である。表 5.1 の最後の列と一致する。

表5.1: 例 1：ドイツがほかのヨーロッパを 5% 上回る（年率%、$\tau = 0.05$、$\delta = 2.5$)。

国	P_1	Π	$\bar{\mu}$	w_{eq}	w^*	$w^* - \frac{w_{\text{eq}}}{1+\tau}$
オーストラリア	0	3.9	4.3	1.6	1.5	0.0
カナダ	0	6.9	7.6	2.2	2.1	0.0
フランス	−29.5	8.4	9.3	5.2	−4.0	−8.9
ドイツ	100.0	9.0	11.0	5.5	35.4	30.2
日本	0	4.3	4.5	11.6	11.0	0.0
イギリス	−70.5	6.8	7.0	12.4	−9.5	−21.3
アメリカ	0	7.6	8.1	61.5	58.6	0.0

表 5.1 で注目すべき点は 2 つある。

第 1 に、期待リターン $\bar{\mu}$ は 7 か国すべてで変わったのに、比率が $w_{\text{eq}}/(1+\tau)$ から動いたのは、ビューに出てくるドイツ、フランス、イギリスの 3 か国だけである。ほかの国の期待リターンの上昇は、ドイツとの相関から「当然そうなるはずの分」で、比率を変える理由にはならない。平均分散最適化に $\bar{\mu}$ を入れて比率がおかしくならないのは、$\bar{\mu}$ が Σ と整合するように作られているからである。

第 2 に、比率の変化は「ドイツを買い、ほかのヨーロッパを時価総額の比で売る」ビューのポートフォリオの形をしている。投資家は、自分のビューがそのまま比率に表れるので、結果を説明しやすい。He と Litterman が「直観的」と呼んだのは、この性質である。

5.5 例 2：カナダとアメリカのビューを足す

ビュー 2（カナダがアメリカを 3% 上回る）を足した結果を表 5.2と図 5.1に示す。

表5.2: 例 2：ビュー 1 とビュー 2（年率%)。

国	P_1	P_2	Π	$\bar{\mu}$	w_{eq}	w^*	$w^* - \frac{w_{\text{eq}}}{1+\tau}$
オーストラリア	0	0	3.9	4.4	1.6	1.5	0.0
カナダ	0	100.0	6.9	8.7	2.2	41.9	39.8
フランス	−29.5	0	8.4	9.5	5.2	−3.4	−8.4
ドイツ	100.0	0	9.0	11.2	5.5	33.6	28.4
日本	0	0	4.3	4.6	11.6	11.0	0.0
イギリス	−70.5	0	6.8	7.0	12.4	−8.2	−20.0
アメリカ	0	−100.0	7.6	7.5	61.5	18.8	−39.8

重みは $\lambda_1 = 0.298$、$\lambda_2 = 0.418$ である。カナダは 41.9%、アメリカは 18.8% になる。ビュー 2 の驚き（3.64%）はビュー 1（3.21%）と同じくらいだが、ビュー 2 のポートフォリオは分散が小さい（$\omega_2 < \omega_1$）ので、重みが大きい。

λ_1 は、例 1 の 0.317 から 0.298 に少し下がっている。2 つのビューのポートフォリオの相関は 0.105 で、わずかに正である。ビュー 2 の情報の一部は、ビュー 1 の方向にも効くので、その分だけ

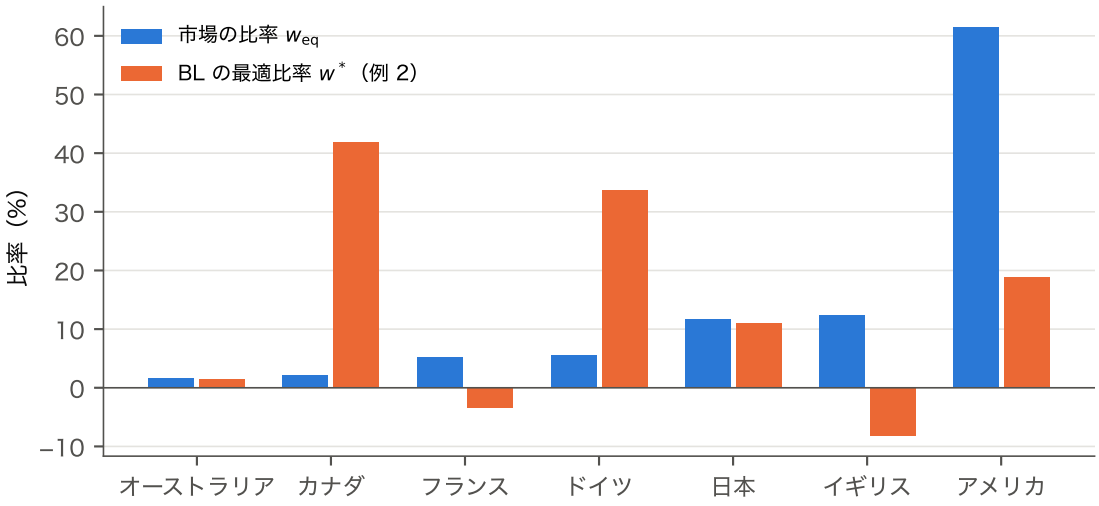


図5.1: 例 2 の市場の比率と BL の最適比率。動くのはビューに出てくる 5 か国だけ。

ビュー 1 に頼る必要が減る。比率の合計は、例 1 と同じ 95.2%（$= 1/1.05$）である。どちらも相対的なビューだからである。

5.6　例 3：ビューを強気にする

ビュー 2 を 3% から 4% に強めると（表 5.3）、λ_2 は 0.418 から 0.538 に増える（性質 3）。λ_1 は 0.298 から 0.292 に、わずかに動く。

表5.3: 例 3：ビュー 2 を 4% に強めたとき（年率%）。

国	P_1	P_2	Π	$\bar{\mu}$	w_{eq}	w^*	$w^* - \frac{w_{\mathrm{eq}}}{1+\tau}$
オーストラリア	0	0	3.9	4.4	1.6	1.5	0.0
カナダ	0	100.0	6.9	9.1	2.2	53.3	51.3
フランス	−29.5	0	8.4	9.5	5.2	−3.3	−8.2
ドイツ	100.0	0	9.0	11.3	5.5	33.1	27.8
日本	0	0	4.3	4.6	11.6	11.0	0.0
イギリス	−70.5	0	6.8	7.0	12.4	−7.8	−19.6
アメリカ	0	−100.0	7.6	7.3	61.5	7.3	−51.3

5.7　例 4：ビューへの自信を下げる

例 3 から、ビュー 1 の不確かさ ω_1 を 2 倍にする（表 5.4）。λ_1 は 0.292 から 0.193 に下がる（性質 4）。ビュー 1 の事後の値 $p_1\bar{\mu}$ も 3.53% から 3.04% に下がり、均衡の値（1.79%）に近づく。

表5.4: 例 4：例 3 で、ビュー 1 の ω_1 を 2 倍にしたとき（年率%）。

国	P_1	P_2	Π	$\bar{\mu}$	w_{eq}	w^*	$w^* - \frac{w_{\mathrm{eq}}}{1+\tau}$
オーストラリア	0	0	3.9	4.3	1.6	1.5	0.0
カナダ	0	100.0	6.9	8.9	2.2	53.9	51.8
フランス	−29.5	0	8.4	9.3	5.2	−0.5	−5.4
ドイツ	100.0	0	9.0	10.6	5.5	23.6	18.4
日本	0	0	4.3	4.6	11.6	11.0	0.0
イギリス	−70.5	0	6.8	6.9	12.4	−1.1	−13.0
アメリカ	0	−100.0	7.6	7.2	61.5	6.8	−51.8

5.8 例 5：重みが 0 になるビュー

最後に、ビュー 1 を 5% のまま、ビュー 2 の重みがちょうど 0 になる Q_2 を求める。式 (5.5) は Q について 1 次式なので、$\lambda_2 = 0$ は Q_2 の 1 次方程式になり、解は $Q_2 = -0.46\%$ である（表 5.5）。このときカナダとアメリカの比率は、市場の比率の $1/(1+\tau)$ 倍のままになる。

表5.5: 例 5：ビュー 2 の重みが 0 になる Q_2（年率%）。

国	P_1	P_2	Π	$\bar{\mu}$	w_{eq}	w^*	$w^* - \frac{w_{\mathrm{eq}}}{1+\tau}$
オーストラリア	0	0	3.9	4.3	1.6	1.5	0.0
カナダ	0	100.0	6.9	7.6	2.2	2.1	0.0
フランス	−29.5	0	8.4	9.3	5.2	−4.0	−8.9
ドイツ	100.0	0	9.0	11.0	5.5	35.4	30.2
日本	0	0	4.3	4.5	11.6	11.0	0.0
イギリス	−70.5	0	6.8	7.0	12.4	−9.5	−21.3
アメリカ	0	−100.0	7.6	8.1	61.5	58.6	0.0

この値は、均衡の値 $p_2\Pi = -0.64\%$ でも、$p_2\Pi/(1+\tau) = -0.61\%$ でもない。ビュー 1 があるために、境目が少しずれている。ビューが 2 つのとき、$\lambda_2 = 0$ の条件は A^{-1} の形から

$$Q_2 = \frac{p_2\Pi}{1+\tau} + \frac{A_{21}}{A_{11}}\left(Q_1 - \frac{p_1\Pi}{1+\tau}\right)$$

と書ける（$A_{21} = p_2\Sigma p_1^\top/(1+\tau)$）。ビュー 1 の驚きのうち、ビュー 2 のポートフォリオと共分散を持つ分だけ、ビュー 2 の「当然の値」がずれる。性質 2 の「均衡とほかのビューから示される値」とは、この値のことである。

図 5.2 は、Q_2 と ω_2 を連続的に変えたときの λ_2 である。λ_2 は Q_2 について直線的に増え（性質 3）、例 5 の値で 0 を横切る（性質 2）。ω_2 が小さい（自信が強い）ほど、傾きが急になる（性質 4）。

表5.6: 例 2〜5 の比較。λ_k は式 (5.3) の重み。

	Q_1	Q_2	ω_1	λ_1	λ_2
例 2（基準）	5.00%	3.00%	1.06×10^{-3}	0.298	0.418
例 3（カナダを 4% に）	5.00%	4.00%	1.06×10^{-3}	0.292	0.538
例 4（例 3 ＋ドイツの ω を 2 倍）	5.00%	4.00%	2.13×10^{-3}	0.193	0.544
例 5（$\lambda_2 = 0$ になる Q_2）	5.00%	−0.46%	1.06×10^{-3}	0.317	0.000

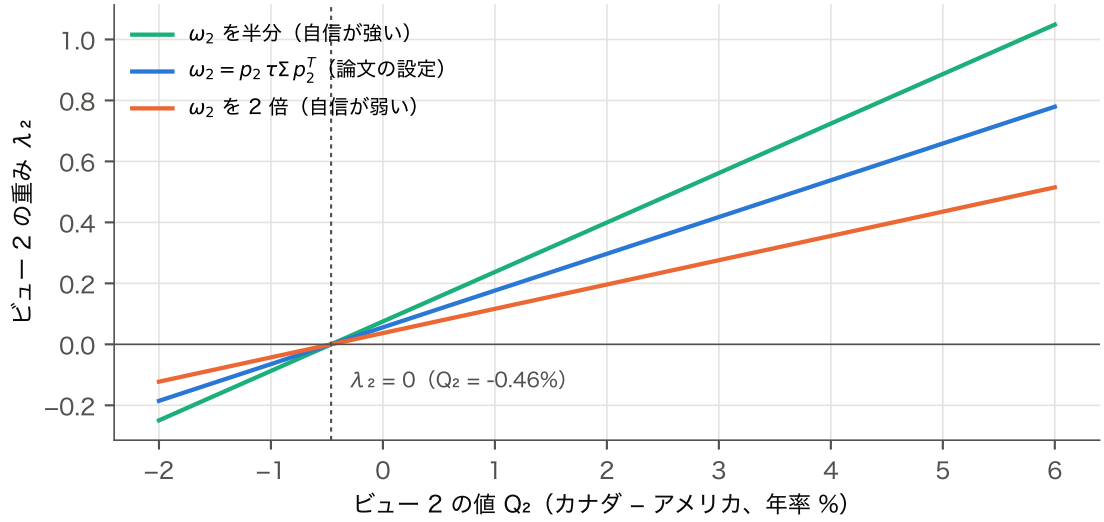


図5.2: ビュー 2 の重み λ_2 と、ビュー 2 の値 Q_2、不確かさ ω_2 の関係（ビュー 1 は 5% で固定）。

5.9 この章のまとめ

要点

- BL の最適比率は $w^* = (w_{\text{eq}} + P^\top \Lambda)/(1+\tau)$ で、「市場の比率」＋「ビューのポートフォリオ」である。ビューに出てこない資産は動かない。
- 重みは $\Lambda = (\delta A)^{-1}(Q - P\Pi/(1+\tau))$。ビューの驚きに比例し、不確かさ（$\Omega/\tau$）とビューのポートフォリオのリスク（$P\Sigma P^\top$）で割られる。
- 驚き $Q - P\Pi$ が同じでも、自信が弱い、またはリスクの大きいポートフォリオについてのビューは、小さな重みしか持たない。
- この形は、制約のない最適化のときだけ成り立つ。空売りの禁止などの制約を付けると、比率は数値計算でしか求まらない（第 6 章）。

第 6 章

実際に使うときの論点

He と Litterman の結果は、制約のない最適化と、年率のきれいな入力を前提にしている。本プロジェクトのような実際の計算では、いくつかの点で前提が変わる。この章では、その論点を G7 の例で確かめる。

6.1　制約を付ける

実際の運用では、比率の合計を 1 にし、空売りを禁止することが多い。最適化は

$$\max_{w} \; w^{\top}\bar{\mu} - \frac{\delta}{2} w^{\top}\Sigma_p w \qquad \text{条件：} \; \mathbf{1}^{\top} w = 1,\; w \geq 0 \tag{6.1}$$

になる。目的関数が 2 次式で、条件が 1 次式なので、二次計画問題と呼ばれる。式 (5.3) のような公式はなく、数値計算で解く。

表6.1: 例 2 のビューで、最適化の条件を変えたときの比率（%）。

国	w_{eq}	制約なし $\Sigma+M$	制約なし Σ	合計 1	合計 1・空売りなし
オーストラリア	1.6	1.5	1.6	3.8	2.6
カナダ	2.2	41.9	43.3	42.3	41.7
フランス	5.2	−3.4	−3.1	−3.5	0.0
ドイツ	5.5	33.6	33.7	32.5	27.5
日本	11.6	11.0	11.6	11.9	10.7
イギリス	12.4	−8.2	−7.5	−7.1	0.0
アメリカ	61.5	18.8	20.4	20.0	17.4
合計	100.0	95.2	100.0	100.0	100.0

表 6.1 の列は、左から、市場の比率、制約なし（$\Sigma + M$ を使う、He と Litterman の形)、制約なし（Σ を使う)、合計 1 のみ、合計 1 と空売りなし、である。空売りを禁止すると、フランスとイギリスは 0 になる。ドイツを買う資金を、フランスとイギリスの売りでまかなえなくなるので、ドイツの比率も 27.5% に下がる。カナダ（41.7%）とアメリカ（17.4%）は、制約なしとほぼ同じである。

制約を付けると、「ビューに出てこない資産は動かない」という性質は厳密には成り立たない。日本やオーストラリアの比率も、条件を満たすために少し動く。それでも、ビューの向きと強さが比率に表れるという大筋は変わらない。

6.2　$\Sigma + M$ か Σ か

He と Litterman は、最適化に予測の共分散 $\Sigma_p = \Sigma + M$ を使う。一方、多くの実装（本プロジェクトを含む）は、最適化に Σ をそのまま使う。Σ を使うと、制約のない比率は

$$w = (\delta\Sigma)^{-1}\bar{\mu} = w_{\mathrm{eq}} + \frac{\tau}{\delta} P^{\top}\left(P\tau\Sigma P^{\top} + \Omega\right)^{-1}(Q - P\Pi) \tag{6.2}$$

となる（式 (4.9) に $(\delta\Sigma)^{-1}$ を掛けて、$(\delta\Sigma)^{-1}\Pi = w_{\mathrm{eq}}$ を使う）。こちらも「市場の比率＋ビューのポートフォリオ」の形で、市場の部分が $1/(1+\tau)$ 倍されない。重みが 0 になる境目は、ちょうど $Q = P\Pi$ である。

表 6.1 のとおり、2 つの違いは主に全体の大きさ（$1/(1+\tau)$）で、中身の配分はほとんど変わらない。合計 1・空売りなしの条件では、Σ を使った場合との差は最大でも 2.26% だった。τ が小さければ M は Σ に比べて小さいので、どちらを使っても結果は近い。

6.3　τ の役割

4.4 節の最後で見たように、事後の期待リターン $\bar{\mu}$ は、$\tau\Sigma$ と Ω の比だけで決まる。そのため、τ の効き方は Ω の決め方によって大きく変わる。

■Ω を τ に比例させる場合（He と Litterman）　式 (3.3) では $\Omega = \tau\,\mathrm{diag}(P\Sigma P^{\top})$ なので、τ は $\bar{\mu}$ の式から消える。表 6.2 のとおり、τ を 0.01 から 1 まで変えても $\bar{\mu}$ はまったく変わらず、τ は Σ_p を通じて比率の全体の大きさ（合計 $1/(1+\tau)$）だけを変える。

表6.2: 例 2 で τ を変えたとき（$\Omega = \mathrm{diag}(P\tau\Sigma P^{\top})$、年率%）。

τ	$\bar{\mu}_{\mathrm{GER}}$	$\bar{\mu}_{\mathrm{CAN}}$	$\bar{\mu}_{\mathrm{USA}}$	w^*_{GER}	w^*_{CAN}	$\sum w^*$
0.010	11.21	8.73	7.48	33.7	43.0	99.0
0.025	11.21	8.73	7.48	33.7	42.6	97.6
0.050	11.21	8.73	7.48	33.6	41.9	95.2
0.250	11.21	8.73	7.48	32.7	37.0	80.0
1.000	11.21	8.73	7.48	27.7	26.1	50.0

■Ω を固定する場合（本プロジェクト）　Ω を τ と無関係に決めると、τ はビューの採用率を直接決める。表 6.3 は、例 2 の Ω（$\tau = 0.05$ で決めたもの）を固定して τ だけを変えた結果である。ビュー 1 の採用率は 0.17 から 0.83 まで動く。

本プロジェクトでは、Ω は LLM の回答の分散で、τ とは関係なく決まる。そのため $\tau = 0.025$ という値は、「LLM の予想をどれだけ信じるか」を直接決める係数になっている。元論文の第 2 版が、検証用の期間で τ を選び直しているのは、このためだと考えられる。

表6.3: 例 2 の Ω を固定して τ だけを変えたとき（年率%）。

τ	ビュー 1 だけのときの採用率	$p_1\bar{\mu}$	$\bar{\mu}_{\mathrm{GER}}$	$\bar{\mu}_{\mathrm{CAN}}$
0.010	0.167	2.38	9.79	7.54
0.025	0.333	2.95	10.51	8.14
0.050	0.500	3.50	11.21	8.73
0.250	0.833	4.52	12.52	9.85

6.4 単位をそろえる

BL の式は、どの単位で書いても成り立つ。ただし、すべての量を同じ単位にそろえる必要がある。

量	He と Litterman の例	本プロジェクト
Σ	年率のリターンの共分散	日次リターンの共分散
Π	年率の超過リターン	1 日あたりの超過リターン
Q	年率の超過リターン	LLM が答えた平均日次リターン − 1 日あたりの無リスク金利
Ω	年率のリターンの 2 乗の単位	日次リターンの回答の分散
δ	単位なし（2.5）	単位なし（2.5）。日次でも年率でも同じ値（第 2 章）
τ	単位なし（0.05）	単位なし（0.025）

単位がずれると、計算は動いても結果は意味を失う。本プロジェクトの元の実装では、日次のリターンから年率の金利 0.02 をそのまま引いていた（7.7 節）。

6.5 共分散の推定

BL は Σ を 3 か所で使う。均衡リターン（$\Pi = \delta\Sigma w_{\mathrm{eq}}$）、事後の期待リターン（$\tau\Sigma$）、最適化である。G7 の例は 7 資産で、長い期間のデータから Σ を推定できる。しかし S&P500 の約 500 銘柄では、事情が違う。

T 日分の日次リターンから作った $N \times N$ の標本共分散行列 S の階数は、高々 $T-1$ である。$T \le N$ なら S は特異で、逆行列がない。1 年分（252 日）でも 500 銘柄には足りない。逆行列がない行列で最適化すると、「分散が 0 に見える組み合わせ」に比率が流れ込む。

Ledoit と Wolf（2004）の縮小推定は、標本共分散を単純な形の行列 F に寄せる。

$$\hat{\Sigma} = (1-\alpha)\,S + \alpha\,F, \qquad F = \frac{\mathrm{tr}(S)}{N}\,I \tag{6.3}$$

F は、全銘柄の分散を平均値にそろえ、共分散を 0 にした行列である。寄せる強さ α は、真の共分散からの誤差（フロベニウスノルムの 2 乗の期待値）が最小になるように、データから決める。$\alpha > 0$ なら $\hat{\Sigma}$ は必ず正定値になる。本プロジェクトは scikit-learn の `LedoitWolf` をこの設定で使っている。判断日 2025-01-31 の 487 銘柄・252 日では、$\alpha = 0.118$ だった。

第 7 章

本プロジェクトの計算

この章では、本プロジェクトの BL の戦略（`blm/strategies.py` の `black_litterman`）が、ここまでの式のどれをどう使っているかを確かめ、実際のデータで 1 段ずつ計算する。

7.1　計算の流れ

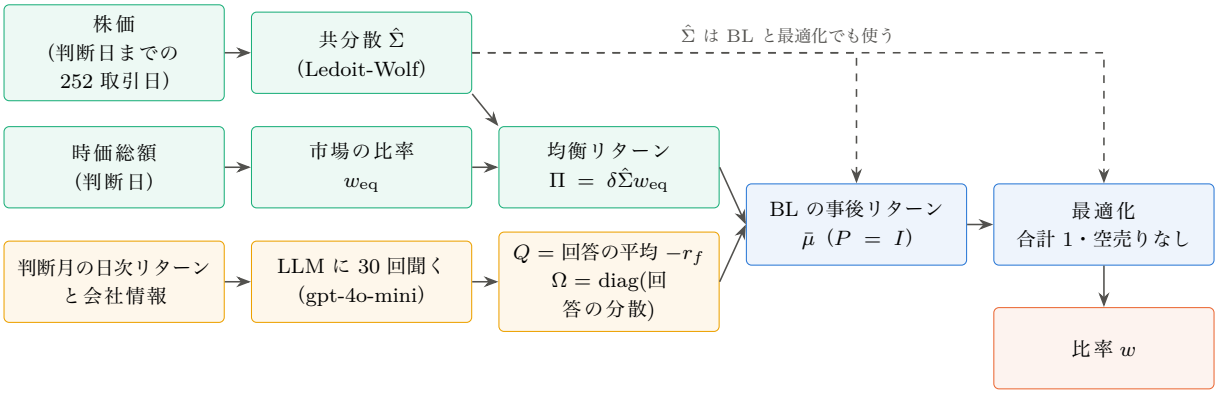


図7.1: 本プロジェクトの BL の計算。緑は市場のデータ、黄は LLM、青は計算、橙は出力。

時間の決まりは次のとおりである。判断日は t 月の最後の取引日で、使うのはその日までの情報だけである。LLM には t 月の日次リターン（前月末の終値から計算した約 20 日分）と会社情報（ティッカー、社名、GICS のセクターとサブ業種）を渡し、$t+1$ 月の平均日次リターンを答えさせる。比率は判断日の終値で買い、$t+1$ 月の最後の取引日まで持つとして評価する。

7.2 He と Litterman の記号とコードの対応

記号	本プロジェクトでの中身	コード
Σ	判断日までの 252 取引日の日次リターンを Ledoit-Wolf で縮小推定	`shrunk_covariance(inputs.returns)`
w_{eq}	判断日の時価総額の比率（対象の銘柄の中で合計 1）	`inputs.market_weights`
δ	2.5（`BLM_RISK_AVERSION`）	`config.RISK_AVERSION`
Π	$\delta\hat{\Sigma}w_{\text{eq}}$（1 日あたりの超過リターン）	`implied_returns(...)`
P	単位行列 I（全銘柄に絶対的なビュー）	式の中で省略
Q	30 回答の平均 − 1 日あたりの無リスク金利	`inputs.view_mean - inputs.risk_free_daily`
Ω	30 回答の分散（母分散）を並べた対角行列	`np.diag(view_variance)`
τ	0.025（`BLM_TAU`）	`config.TAU`
$\bar{\mu}$	更新形 (4.9) で $P = I$	`posterior_returns(...)`
最適化	式 (6.1) で、Σ_p の代わりに $\hat{\Sigma}$	`optimize(...)`（CVXPY と Clarabel）

無リスク金利 r_f は、判断日の 3 か月物米国債の利回り（`^IRX`）を 100 で割り、252 で割って 1 日あたりにしたものである。LLM はリターンそのものを答えるので、r_f を引いて超過リターンにそろえる。

対象の銘柄は、判断日に指数に在籍し、LLM の回答と時価総額があり、252 日のうち半分以上の日に株価がある銘柄である。上場前の日のリターンは、その日のほかの銘柄の平均で埋めている。

7.3 $P = I$ のときの式

全銘柄に絶対的なビューを 1 つずつ置くので、$P = I$（$K = N$）である。更新形 (4.9) は

$$\bar{\mu} = \Pi + \tau\Sigma\,(\tau\Sigma + \Omega)^{-1}\,(Q - \Pi) \tag{7.1}$$

になる。これが `posterior_returns` の中身である（リスト B.2）。

もし Σ が対角行列（銘柄どうしが無相関）なら、式 (7.1) は銘柄ごとに分かれて

$$\bar{\mu}_i = \Pi_i + k_i\,(Q_i - \Pi_i), \qquad k_i = \frac{\tau\sigma_i^2}{\tau\sigma_i^2 + \omega_i} \tag{7.2}$$

となり、1 資産の式 (4.5) と同じになる。実際には相関があるので、銘柄 i の $\bar{\mu}_i$ には、ほかの銘柄のビューの驚き $Q_j - \Pi_j$ も入ってくる。それでも k_i は「その銘柄のビューがどれくらい採用されるか」のよい目安になる。この資料では k_i を「目安の採用率」と呼ぶ。

He と Litterman の形 (5.3) は、$P = I$ なら $w^* = (w_{\text{eq}} + \Lambda)/(1 + \tau)$ で、各銘柄がそれぞれ 1 つのビューのポートフォリオになる。Λ_i は、銘柄 i を市場の比率からどれだけ増やすか（減らすか）を表す。本プロジェクトのように最適化で Σ を使う場合は、式 (6.2) から

$$w = w_{\text{eq}} + \frac{\tau}{\delta}\,(\tau\Sigma + \Omega)^{-1}\,(Q - \Pi) \tag{7.3}$$

である（制約がない場合）。

7.4　5 銘柄で計算する

実際の計算は約 490 銘柄で行うが、それでは途中の数字を追えない。ここでは、判断日 2025-01-31 に、Apple (AAPL)、NVIDIA (NVDA)、JPMorgan Chase (JPM)、Exxon Mobil (XOM)、Johnson & Johnson（JNJ）の 5 銘柄だけを対象にして、同じ計算を行う。データとコードは本番と同じで、対象の銘柄だけが違う。LLM は 2025 年 1 月の日次リターン（20 日分）を見て、2 月の平均日次リターンを答えている。

7.4.1　手順 1：過去 1 年のリターン

判断日までの 252 取引日の日次リターンの平均と標準偏差、相関を表 7.1と表 7.2に示す。

表7.1: 5 銘柄の過去 252 取引日の日次リターン。年率は平均を 252 倍、標準偏差を $\sqrt{252}$ 倍したもの。

銘柄	会社	日次の平均 (%)	日次の標準偏差 (%)	年率の平均 (%)	年率の標準偏差 (%)
AAPL	Apple	0.103	1.47	25.9	23.3
NVDA	NVIDIA	0.322	3.58	81.1	56.8
JPM	JPMorgan Chase	0.185	1.49	46.7	23.6
XOM	Exxon Mobil	0.028	1.21	7.1	19.2
JNJ	Johnson & Johnson	0.001	1.02	0.2	16.2

表7.2: 5 銘柄の日次リターンの相関。

	AAPL	NVDA	JPM	XOM	JNJ
AAPL	1.00	0.22	0.02	0.00	-0.07
NVDA	0.22	1.00	0.08	-0.11	-0.42
JPM	0.02	0.08	1.00	0.31	0.20
XOM	0.00	-0.11	0.31	1.00	0.22
JNJ	-0.07	-0.42	0.20	0.22	1.00

過去 1 年の平均をそのまま期待リターンにすると、NVDA の年率 81% のような値になる。これを平均分散最適化に入れるのが、本プロジェクトの「平均分散（過去 1 年)」の戦略で、1.4 節の弱点がそのまま出る。

7.4.2　手順 2：共分散の縮小推定

5 銘柄・252 日なら標本共分散でも逆行列はあるが、本番と同じく Ledoit-Wolf を使う。この 5 銘柄では、寄せる強さは $\alpha = 0.048$、寄せる先の分散（5 銘柄の分散の平均）は 3.921×10^{-4} だった。表 7.3 のとおり、分散は平均に向かって少し寄り（NVDA は下がり、ほかは上がる)、共分散は $1 - \alpha$ 倍に縮む。

表7.3: 標本共分散と Ledoit-Wolf の推定（日次、$\times 10^4$）。

銘柄 i	標本 S_{ii}	LW $\hat{\Sigma}_{ii}$	標本 $S_{i,\mathrm{AAPL}}$	LW $\hat{\Sigma}_{i,\mathrm{AAPL}}$
AAPL	2.151	2.236	2.151	2.236
NVDA	12.750	12.324	1.130	1.076
JPM	2.202	2.285	0.033	0.031
XOM	1.461	1.580	0.004	0.004
JNJ	1.038	1.177	−0.101	−0.096

scikit-learn の `LedoitWolf` は、標本共分散を $T-1$ ではなく T で割って作る（最尤推定）。そのため表 7.3の「標本」は、pandas の `cov()` の値とわずかに違う。

7.4.3　手順 3：市場の比率と均衡リターン

5 銘柄の時価総額の比率を、合計 1 になるように直し、$\Pi = 2.5\,\hat{\Sigma} w_{\mathrm{eq}}$ を計算する（表 7.4）。

表7.4: 5 銘柄の市場の比率と均衡リターン（1 日あたり）。β_i は 5 銘柄の市場に対するベータ。

銘柄	指数の中の比率 (%)	5 銘柄の中の比率 w_i (%)	$(\hat{\Sigma}w)_i \times 10^4$	β_i	Π_i (%/日)
AAPL	6.68	44.2	1.379	0.57	0.0345
NVDA	5.50	36.4	4.906	2.04	0.1227
JPM	1.39	9.2	0.420	0.17	0.0105
XOM	0.87	5.8	−0.016	−0.01	−0.0004
JNJ	0.68	4.5	−0.482	−0.20	−0.0120

計算例 7.1：AAPL の均衡リターン

$(\hat{\Sigma} w_{\mathrm{eq}})_{\mathrm{AAPL}} = \sum_j \hat{\Sigma}_{\mathrm{AAPL},j}\, w_j = 1.379 \times 10^{-4}$ なので

$$\Pi_{\mathrm{AAPL}} = 2.5 \times 1.379 \times 10^{-4} = 0.0345\%\text{(1 日あたり)}.$$

5 銘柄の市場の分散は $\sigma_m^2 = 2.411 \times 10^{-4}$ で、$\Pi_m = 2.5\sigma_m^2 = 0.0603\%$ ／日である。単純に年率に直すと、期待超過リターン 15.2%、標準偏差 24.6% になる。

JNJ の均衡リターンは -0.0120% と負である。この 5 銘柄だけの「市場」は AAPL と NVDA が 8 割を占め、JNJ は NVDA と負の相関（-0.42）を持つので、ベータが負（-0.20）になる。市場の値動きを打ち消す側の資産は、それだけでリスクを減らす価値があるので、低い期待リターンでも持たれる、という理屈である。均衡リターンは、対象にする銘柄の集まりによって変わる。

7.4.4　手順 4：LLM の回答からビューを作る

LLM には、同じ質問を 1 回のリクエストで 30 回分答えさせる（temperature 1.0）。AAPL の 30 個の回答を表 7.5に示す。

表7.5: AAPL についての 30 個の回答（翌月の平均日次リターン、%）。

1–10	−0.375	−0.571	−0.185	−0.066	−0.535	−0.273	−0.321	−0.326	−0.239	−0.405
11–20	−0.166	−0.245	−0.320	−0.220	−0.110	−0.221	−0.247	−0.290	−0.286	−0.111
21–30	−0.133	−0.475	−0.342	−0.267	−0.130	−0.271	−0.438	−0.248	−0.551	−0.373

30 個の平均は −0.291%、標準偏差は 0.130% である。LLM に渡した 1 月の日次リターンの平均は −0.278% で、回答の平均はこれに近い。5 銘柄の集計を表 7.6に示す。

表7.6: 5 銘柄の回答の集計（1 日あたり）。「1 月の平均」は LLM に渡した日次リターンの平均。

銘柄	回答数	1 月の平均 (%)	回答の平均 (%)	回答の標準偏差 (%)	最小 (%)	最大 (%)	分散 $\times 10^6$
AAPL	30	−0.278	−0.291	0.130	−0.571	−0.066	1.689
NVDA	30	−0.413	0.330	0.142	0.054	0.631	2.009
JPM	30	0.576	0.546	0.103	0.406	0.797	1.058
XOM	30	−0.026	−0.091	0.167	−0.496	0.189	2.782
JNJ	30	0.265	0.228	0.090	0.099	0.395	0.815

AAPL、JPM、JNJ の回答の平均は 1 月の平均に近い。総合報告書の分析でも、予想は入力した月の平均リターンにおおむね沿っていた（全銘柄での相関は 30 か月の平均で 0.89）。ただし NVDA は、1 月の平均が負なのに回答の平均は正で、例外もある。

ビューは

$$Q_i = (\text{回答の平均})_i - r_f, \qquad \omega_i = (\text{回答の分散})_i$$

である。この判断日の無リスク金利は 1 日 0.0166%（年率 4.19%）なので、たとえば $Q_{\mathrm{AAPL}} = -0.291\% - 0.0166\% = -0.3079\%$、$\omega_{\mathrm{AAPL}} = (0.130\%)^2 = 1.689 \times 10^{-6}$ である。分散は 30 で割る母分散で、データベースのビュー `llm_view_stats` が計算している。

7.4.5　手順 5：2 つの不確かさを比べる

ビューがどれくらい採用されるかは、ω_i と $\tau\hat{\Sigma}_{ii}$ の比で決まる（式 (7.2)）。表 7.7 のとおり、5 銘柄の目安の採用率は 0.59〜0.94 で、He と Litterman の 0.5 よりずっと大きい。LLM の回答のばらつきは、均衡の不確かさ（$\tau = 0.025$）よりも小さいので、ビューのほうが信頼される。

NVDA は値動きが大きい（$\hat{\Sigma}_{ii}$ が大きい）ので、均衡の不確かさ $\tau\hat{\Sigma}_{ii}$ も大きく、採用率が最も高い。値動きの大きい銘柄ほど、均衡リターンは当てにならないとみなされ、ビューに寄る。

表7.7: 均衡の不確かさとビューの不確かさ（1 日あたりの 2 乗、$\times 10^6$）。

銘柄	$\tau\hat{\Sigma}_{ii} \times 10^6$	$\omega_i \times 10^6$	$\omega_i/(\tau\hat{\Sigma}_{ii})$	目安の採用率 k_i
AAPL	5.590	1.689	0.302	0.768
NVDA	30.809	2.009	0.065	0.939
JPM	5.714	1.058	0.185	0.844
XOM	3.950	2.782	0.704	0.587
JNJ	2.943	0.815	0.277	0.783

7.4.6　手順 6：事後の期待リターン

式 (7.1) で計算した結果を表 7.8と図 7.2に示す。「動いた割合」は $(\bar{\mu}_i - \Pi_i)/(Q_i - \Pi_i)$ である。更新形（本プロジェクトの関数）と情報形（元の実装の関数）の結果の差は、最大で 1.4×10^{-18} だった。

表7.8: 5 銘柄の均衡リターン、ビュー、事後の期待リターン（% ／日）。

銘柄	Π_i	Q_i	$Q_i - \Pi_i$	$\bar{\mu}_i$	$\bar{\mu}_i - \Pi_i$	動いた割合
AAPL	0.0345	−0.3079	−0.3423	−0.2224	−0.2568	0.750
NVDA	0.1227	0.3132	0.1906	0.2870	0.1644	0.862
JPM	0.0105	0.5294	0.5189	0.4496	0.4391	0.846
XOM	−0.0004	−0.1077	−0.1073	−0.0126	−0.0122	0.113
JNJ	−0.0120	0.2113	0.2234	0.1623	0.1743	0.780

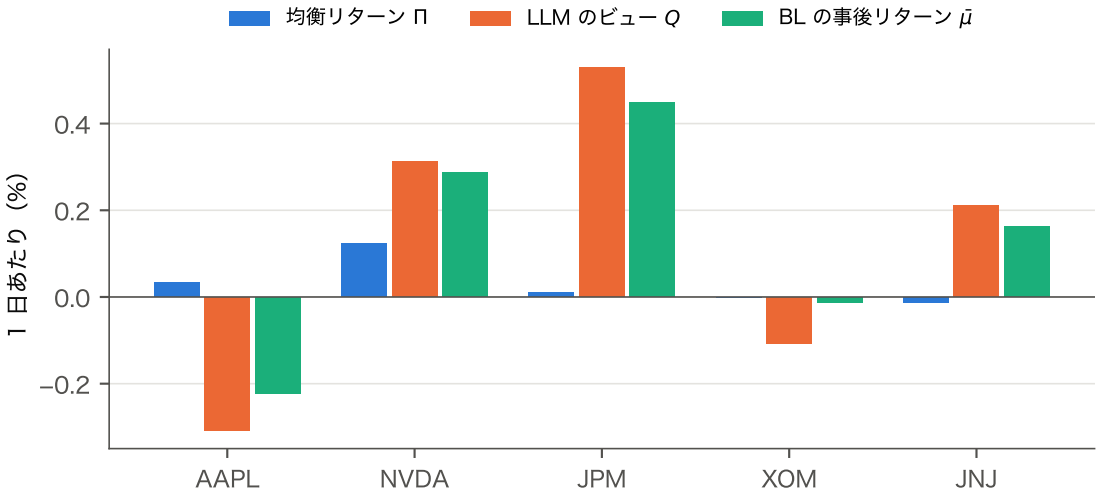


図7.2: 5 銘柄の均衡リターン Π、LLM のビュー Q、事後の期待リターン $\bar{\mu}$（1 日あたり）。

計算例 7.2：AAPL の事後の期待リターン（目安）

相関を無視した式 (7.2) で計算すると、$\tau\hat{\Sigma}_{ii} = 5.590\times10^{-6}$、$\omega_i = 1.689\times10^{-6}$ から $k = 0.768$、

$$\bar{\mu}_{\mathrm{AAPL}} \approx 0.0345\% + 0.768 \times (-0.3423\%) = -0.2284\%$$

である。行列の式 (7.1) の値は -0.2224% で、目安とほぼ同じになる。

目安と大きく違うのは XOM である。目安の採用率は 0.587 なのに、実際に動いた割合は 0.113 しかない。XOM 自身のビューは弱気（$Q = -0.1077\%$）だが、XOM と正の相関を持つ JPM（相関 0.31）と JNJ のビューが強気なので、その情報が相関を通じて XOM の期待リターンを押し上げ、自身の弱気のビューを打ち消している。4.4 節で見た「驚きが相関を通じて広がる」働きが、ここでも起きている。

7.4.7　手順 7：比率

最後に、$\bar{\mu}$ を最適化に入れる。結果を表 7.9に示す。

表7.9: 5 銘柄の比率（%）。「BL 制約なし」は式 (7.3)、「合計 1・空売りなし」が本プロジェクトの計算。

銘柄	市場 w	BL 制約なし	BL 合計 1	BL 合計 1・空売りなし	平均分散（過去 1 年）
AAPL	44.2	−462.1	−580.8	0.0	0.0
NVDA	36.4	166.9	116.5	0.0	53.2
JPM	9.2	763.6	713.3	100.0	46.8
XOM	5.8	−336.2	−475.0	0.0	0.0
JNJ	4.5	606.4	326.0	0.0	0.0
合計	100.0	738.8	100.0	100.0	100.0

まず確かめとして、$\bar{\mu}$ の代わりに Π を入れると、比率は市場の比率に戻る（差は最大 2.6×10^{-8}）。

ところが $\bar{\mu}$ を入れると、本プロジェクトの計算（合計 1・空売りなし）は JPM に 100.0% を入れる。制約のない比率は、合計が 739% で、AAPL と XOM を大きく空売りし、JPM と JNJ を何倍も買う。市場の比率を少し調整する、という BL 本来の形にはなっていない。

理由は、期待リターンの差がリスクに比べて大きすぎることである。最適な比率では、持つ銘柄について $\bar{\mu}_i - \delta(\hat{\Sigma}w)_i$（リターンからリスクの罰則を引いた、比率を少し増やしたときの得）が等しく、持たない銘柄ではそれ以下になる（ラグランジュの条件。付録 A）。JPM だけを持つ点で計算すると表 7.10になる。

リスクの罰則 $\delta(\hat{\Sigma}w)_i$ は、最も大きい JPM でも 1 日 0.0571% しかない。一方、$\bar{\mu}$ の銘柄間の差は 1 日 0.1〜0.7% ある。罰則が小さすぎて分散する理由がなく、$\bar{\mu}$ の最も高い銘柄に全額が入る。

He と Litterman の形 (5.3) で見ても、同じことが分かる（表 7.11）。G7 の例ではビューの重みは 0.3 前後だったが、ここでは AAPL が −5.15、JPM が 7.70 で、市場の比率の何倍もの売り買いをビューが求めている。AAPL の驚き $Q - \Pi = -0.3423\%$ ／日は、単純に 252 倍すると年率 −86%、JPM は年率 +131% に当たる。年率で数% の差を言う He と Litterman のビューとは、大きさの

表7.10: JPM に全額を入れた点での、比率を少し増やしたときの得（% ／日）。

銘柄	$\bar{\mu}_i$	$\delta(\hat{\Sigma}w)_i$	$\bar{\mu}_i - \delta(\hat{\Sigma}w)_i$
AAPL	−0.2224	0.0008	−0.2232
NVDA	0.2870	0.0105	0.2765
JPM	0.4496	0.0571	0.3925
XOM	−0.0126	0.0133	−0.0258
JNJ	0.1623	0.0072	0.1550

桁が違う。

表7.11: He と Litterman の形で見た 5 銘柄の比率（制約なし、$\Sigma_p = \hat{\Sigma} + M$）。

銘柄	w_{eq}	$w^* = (\delta(\hat{\Sigma} + M))^{-1}\bar{\mu}$	$\Lambda_i = (1+\tau)w_i^* - w_{\text{eq},i}$
AAPL	44.2	−459.3	−5.149
NVDA	36.4	166.3	1.341
JPM	9.2	760.3	7.701
XOM	5.8	−331.8	−3.459
JNJ	4.5	602.6	6.132

7.5 全銘柄では

同じ判断日の本番の計算（487 銘柄）でも、様子は同じである。

- 縮小推定の強さは $\alpha = 0.118$ だった。
- $\omega_i/(\tau\hat{\Sigma}_{ii})$ の中央値は 0.215（四分位 0.135〜0.324）、目安の採用率の中央値は 0.823（四分位 0.755〜0.881）である（図 7.3）。実際に動いた割合の中央値は 0.939 で、目安より大きい。
- 事後の期待リターンと Q の相関は 0.956、Π との相関は 0.347 である。$\bar{\mu}$ はほとんど LLM のビューで決まっている。
- 均衡リターンの中央値は 1 日 0.0102%（銘柄間の標準偏差 0.0081%）、ビューの中央値は 1 日 0.229%（同 0.291%）で、ビューのばらつきは均衡の 30 倍以上ある。
- 比率は 2 銘柄に集中し、実質的な銘柄数（$1/\sum_i w_i^2$）は 1.63 である。市場の比率は 53.2 である。

表 7.12 のとおり、比率を持つのは、事後の期待リターンが最も高い 2 銘柄（VST と CEG）だけである。どちらも、LLM が 1 日 1.6〜1.7% という予想を出した銘柄である。VST の $Q = 1.65\%$ ／日は、21 日の複利で 1 か月に 41% の上昇に当たる。この計算は、データベースに保存されている本番の比率と一致する（差は最大 0.000%）。

30 か月の判断日それぞれで、全銘柄の $\omega_i/(\tau\hat{\Sigma}_{ii})$ の中央値を取ると 0.10〜0.33、目安の採用率の中央値は 0.75〜0.91 だった（図 4.2 の網かけ）。どの月でも、LLM のビューは He と Litterman の設定より強く採用されている。

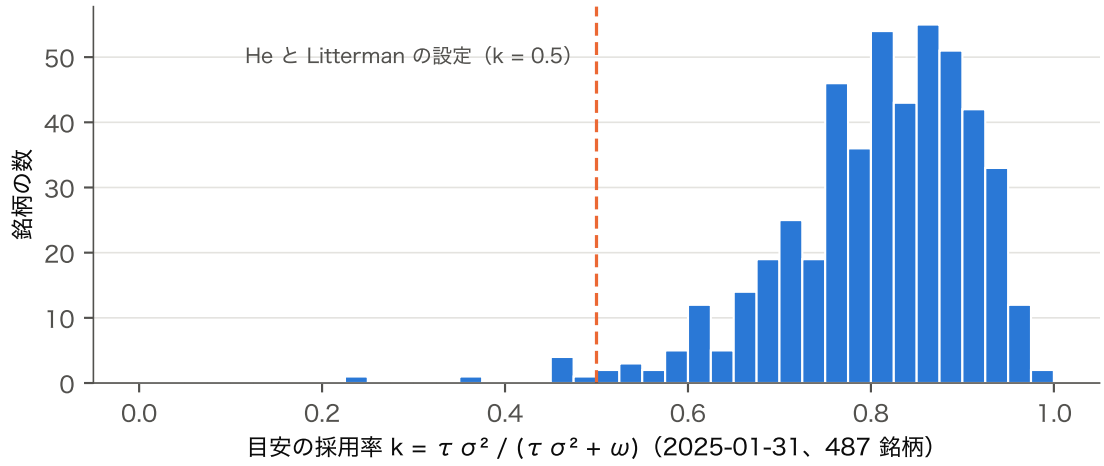


図7.3: 全銘柄の目安の採用率 k_i の分布（判断日 2025-01-31）。

表7.12: 事後の期待リターンが高い 6 銘柄（判断日 2025-01-31、全銘柄の計算）。

銘柄	BL の比率 (%)	市場の比率 (%)	Π_i (%/日)	Q_i (%/日)	$\bar{\mu}_i$ (%/日)	k_i
VST	73.9	0.11	0.035	1.647	1.305	0.679
CEG	26.1	0.17	0.024	1.721	1.236	0.565
GEV	0.0	0.19	0.030	1.234	0.935	0.546
NRG	0.0	0.04	0.019	0.841	0.862	0.549
CVS	0.0	0.13	0.006	0.860	0.858	0.799
TPL	0.0	0.06	0.017	1.028	0.756	0.683

7.6 He と Litterman の設定との違い

項目	He と Litterman	本プロジェクト
ビュー	少数（1〜3 個）。相対的	全銘柄（約 490 個）。絶対的（$P = I$）
ビューの大きさ	均衡との差が年率で数%	均衡との差が 1 日 0.1%（年率で約 25%）を超える銘柄が 90%
Ω	$\mathrm{diag}(P\tau\Sigma P^\top)$。採用率 0.5	回答の分散。採用率の中央値は 0.75〜0.91
τ	0.05（$\bar{\mu}$ には効かない）	0.025（採用率を直接決める）
Σ	与えられた年率の共分散	252 日の日次リターンを縮小推定
最適化の共分散	$\Sigma + M$	$\hat{\Sigma}$
制約	なし	合計 1・空売りなし
単位	年率	日次

He と Litterman の「市場の比率を、ビューの分だけ動かす」という直観は、ビューの驚き $Q - P\Pi$ が、ビューのポートフォリオのリスクに比べて小さいときに成り立つ。本プロジェクトの計算は、式

としては同じ BL だが、ビューが大きく、強く信じられているために、平均分散最適化の弱点 (1.4 節) がそのまま出ている。式 (5.5) で言えば、$Q - P\Pi$ が大きく、Ω/τ が小さいので、Λ が非常に大きくなる。

改善の方向は、この式から読み取れる。$Q - \Pi$ を小さくする（予想を当たり具合に合わせて縮める)、Ω を大きくする（回答のばらつきではなく、予測の外れ方から決める)、τ を小さくする、比率のずれに上限を付ける、のいずれかである。どれを選ぶかは総合報告書の「次に決めること」で検討しており、この資料では立ち入らない。

7.7　元の実装との違い

本プロジェクトには、元論文の公式実装と同じ計算を再現した戦略 `black_litterman_original` もある。ここまでの式から見ると、違いは次のとおりである。

	元の実装	本プロジェクト
共分散	判断月の約 20 日分の標本共分散	252 日分の縮小推定
事前の期待リターン	$\beta_i \times \mathrm{mean}(R_m - 0.02)$。日次のリターンから年率の金利を引く	$\Pi = \delta\hat{\Sigma}w_{\mathrm{eq}}$
ビュー	Q = 回答の平均（金利を引かない）	Q = 回答の平均 $-r_f$
事後の式	情報形 (4.7)、疑似逆行列	更新形 (4.9)
最適化	$w^\top\Sigma w - 0.1\, w^\top\bar{\mu}$ を SciPy（SLSQP、標準の設定）で最小化	$w^\top\bar{\mu} - \frac{\delta}{2}w^\top\hat{\Sigma}w$ を二次計画の解法で最大化

元の実装の目的関数は、0.1 で割って符号を変えると $w^\top\bar{\mu} - 10\, w^\top\Sigma w$ の最大化と同じで、$\delta/2 = 10$、つまり $\delta = 20$ の平均分散最適化である。同じ 5 銘柄で元の実装の計算を行った結果を表 7.13に示す。

表7.13: 元の実装の計算（5 銘柄、% ／日)。最後の 2 列は比率（%)。

銘柄	β_i	Π_i^{orig}	Q_i	$\bar{\mu}_i$	$\omega_i/(\tau S_{ii})$	動いた割合	比率 (元の解法)	比率 (最後まで解く)
AAPL	0.38	−0.829	−0.291	−0.373	0.1825	0.8482	20.0	0.0
NVDA	2.34	−5.163	0.330	0.190	0.0279	0.9746	20.0	0.0
JPM	0.12	−0.274	0.546	0.304	0.4974	0.7044	20.0	100.0
XOM	−0.11	0.240	−0.091	0.116	0.6378	0.3758	20.0	0.0
JNJ	−0.47	1.036	0.228	0.195	0.1433	1.0413	20.0	0.0

- **事前の期待リターン**：1 月の 5 銘柄の市場の平均リターンは 1 日 −0.210% で、ここから 0.02 (年率 2% のつもりの値) を引くと −2.210% になる。AAPL の事前の期待リターンは 1 日 −0.829% で、「毎日 1% 近く下がる」という出発点である。
- **採用率**：共分散が約 20 日分の標本共分散なので、ビューへの寄り方も変わる。XOM を除けば、事後の値は Q の側に大きく寄っている。
- **最適化**：SciPy の解法は 1 回の反復で「成功」と報告して止まり、比率は出発点（全銘柄 20%）のままだった。目的関数の値は 2.7×10^{-5} で、JPM だけを持つ点の -2.2×10^{-4} のほうがず

っと良い。目的関数の値が 10^{-5}〜10^{-4} 程度と小さいため、標準の止める基準ではすぐに収束したと判定されたと考えられる。同じ目的関数を最後まで解くと、JPM に 100.0% になる。

7.7.1 Ω に 0 があるときの違い

情報形は Ω^{-1} を使う。元の実装は、逆行列の代わりに疑似逆行列（`numpy.linalg.pinv`）を使うので、$\omega_i = 0$（30 個の回答がすべて同じ）の銘柄があっても計算は止まらない。しかし疑似逆行列では、0 の逆数は 0 として扱われる。これは「精度 0」、つまり**不確かさが無限大**という意味になり、本来の「完全な自信」と正反対になる。

2 銘柄で確かめる。$\Pi = (0.03\%, 0.03\%)$、$Q = (0.2\%, 0.2\%)$、$\omega = (10^{-6},\ 0)$、日次の分散 4×10^{-4}、共分散 10^{-4}、$\tau = 0.025$ とする。更新形では、$\omega_B = 0$ の銘柄 B は $\bar{\mu}_B = 0.2000\%$ で、ビューがそのまま成り立つ。疑似逆行列を使う情報形では $\bar{\mu}_B = 0.0686\%$ で、B 自身のビューは無視され、A のビューから相関を通じて少し動いただけになる。

本プロジェクトのデータでは、回答の分散の最小値は 3.6×10^{-8} で、0 になった銘柄はなかった。ただし temperature を下げると回答がそろいやすくなるので、注意が必要である。

第 8 章

まとめ

式の流れ

1. 平均分散最適化：$w^* = (\delta\Sigma)^{-1}\mu$。$\mu$ に敏感で、μ の推定は難しい。
2. 均衡リターン：$\Pi = \delta\Sigma w_{\text{eq}}$。これを入れると市場の比率に戻る。CAPM の $\beta_i\Pi_m$ と同じ。
3. 事前の見方：$\mu \sim \mathcal{N}(\Pi, \tau\Sigma)$。
4. ビュー：$P\mu = Q + \varepsilon$、$\varepsilon \sim \mathcal{N}(0, \Omega)$。
5. 事後の期待リターン：$\bar{\mu} = \Pi + \tau\Sigma P^\top (P\tau\Sigma P^\top + \Omega)^{-1}(Q - P\Pi)$。
6. 最適比率（制約なし）：$w^* = (\delta\Sigma_p)^{-1}\bar{\mu} = (w_{\text{eq}} + P^\top\Lambda)/(1+\tau)$、$\Lambda = (\delta A)^{-1}(Q - P\Pi/(1+\tau))$。

He と Litterman から分かること

- BL の比率は「市場の比率」＋「ビューのポートフォリオ」で、ビューに出てこない資産は動かない。
- ビューの重みは、驚き $Q - P\Pi$ に比例し、自信（Ω の小ささ）とともに大きくなる。
- ビューの値ではなく、均衡との差が効く。τ と Ω は比だけが効く。

本プロジェクトの計算について分かること

- コードは、He と Litterman の BL の式を $P = I$ で使い、Σ_p の代わりに $\hat{\Sigma}$ で、合計 1・空売りなしの最適化をしている。式としては正しい。
- ビューの採用率は、回答のばらつき ω_i と $\tau\hat{\Sigma}_{ii}$ の比で決まり、中央値で 0.75〜0.91 と、He と Litterman の 0.5 より高い。
- ビューの大きさ（均衡との差）が、リスクに比べて桁違いに大きい。そのため、最適化は事後の期待リターンが最も高い 1〜2 銘柄に集中する。
- 元の実装は、単位の誤り、20 日分の共分散、途中で止まる最適化が重なって、結果が分散して見えていた。

コードを読むときの確認事項

- Π、Q、Ω、Σ の単位（日次か年率か、超過リターンか）はそろっているか。Q から無リスク金利を引いているか。
- Ω は $\tau\Sigma$ の対角成分と比べてどれくらいか（採用率）。
- Π を最適化に入れたとき、市場の比率に戻るか。最適化は最後まで解けているか。
- 比率は、ビューの向きに沿って市場の比率から動いているか。極端な集中になっていないか。

付録 A

行列の公式

A.1　ベクトルでの微分

a を定数ベクトル、B を定数の対称行列とすると

$$\frac{\partial}{\partial x}(a^\top x) = a, \qquad \frac{\partial}{\partial x}(x^\top B x) = 2Bx.$$

成分で書くと、$x^\top Bx = \sum_i \sum_j B_{ij} x_i x_j$ を x_k で微分して $\sum_j B_{kj} x_j + \sum_i B_{ik} x_i = 2(Bx)_k$ である。式 (1.5) の導出に使った。

A.2　平方完成

H を対称な正定値行列とすると

$$x^\top Hx - 2x^\top h = (x - H^{-1}h)^\top H(x - H^{-1}h) - h^\top H^{-1} h.$$

右辺を展開すれば確かめられる。$\exp(-\frac{1}{2}(x^\top Hx - 2x^\top h))$ に比例する密度は、平均 $H^{-1}h$、共分散 H^{-1} の正規分布である。BL の情報形 (4.7) の導出に使った。

A.3　Woodbury の公式

A（$N \times N$）と Ω（$K \times K$）が正則で、$G = PAP^\top + \Omega$ も正則なら

$$(A^{-1} + P^\top \Omega^{-1} P)^{-1} = A - AP^\top G^{-1} PA.$$

■確かめ　左辺の逆行列に右辺を掛けると

$$\begin{aligned}(A^{-1} + P^\top \Omega^{-1} P)(A - AP^\top G^{-1} PA) &= I - P^\top G^{-1} PA + P^\top \Omega^{-1} PA \\ &\quad - P^\top \Omega^{-1} (PAP^\top) G^{-1} PA \\ &= I + P^\top \left[-G^{-1} + \Omega^{-1} - \Omega^{-1}(G - \Omega) G^{-1} \right] PA \\ &= I + P^\top \left[-G^{-1} + \Omega^{-1} - \Omega^{-1} + G^{-1} \right] PA = I.\end{aligned}$$

左辺は $N \times N$ の逆行列だが、右辺は $K \times K$ の逆行列 G^{-1} しか使わない。ビューの数 K が資産の数 N より少ないときに計算が楽になる。式 (4.9) の導出に使った。

A.4　正規分布の条件付き分布

(x, y) が同時に正規分布に従い

$$\begin{pmatrix} x \\ y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} m_x \\ m_y \end{pmatrix}, \begin{pmatrix} S_{xx} & S_{xy} \\ S_{yx} & S_{yy} \end{pmatrix} \right)$$

なら、y を知った後の x の分布は

$$x \mid y \sim \mathcal{N}\left(m_x + S_{xy}S_{yy}^{-1}(y - m_y),\quad S_{xx} - S_{xy}S_{yy}^{-1}S_{yx}\right)$$

である。

■BL の公式の別の導き方　$x = \mu$、$y = Q = P\mu + \varepsilon$ とおく。$\mu \sim \mathcal{N}(\Pi, \tau\Sigma)$ と $\varepsilon \sim \mathcal{N}(0, \Omega)$ が独立なら

$$m_x = \Pi,\quad m_y = P\Pi,\quad S_{xx} = \tau\Sigma,\quad S_{xy} = \mathrm{Cov}(\mu, P\mu + \varepsilon) = \tau\Sigma P^{\top},\quad S_{yy} = P\tau\Sigma P^{\top} + \Omega$$

で、上の公式に入れると、更新形 (4.9) と (4.10) がそのまま出てくる。「ビューの値 Q が、均衡から予想される値 $P\Pi$ からずれた分を、μ と Q の共分散に応じて μ に反映する」という読み方ができる。カルマンフィルタの更新と同じ形である。

A.5　制約付きの最適化の条件

合計 1・空売りなしの最適化 (6.1) で、目的関数の勾配を $g = \bar{\mu} - \delta\Sigma w$ とする。w が最適であるための条件（KKT 条件）は、ある数 γ について

$$g_i = \gamma \quad (w_i > 0), \qquad g_i \le \gamma \quad (w_i = 0)$$

が成り立つことである。比率を持つ銘柄では、比率を少し増やしたときの得 g_i がそろっていて、持たない銘柄では、それより小さい。もし $g_j > \gamma$ の銘柄があれば、ほかの銘柄から少し移すと目的関数が増えるので、最適ではない。表 7.10 はこの条件を確かめたものである。

付録 B

本プロジェクトのコード

この資料で扱った計算の、本プロジェクトのコードを載せる（2026 年 10 月時点）。

リスト B.1: 均衡リターン（blm/equilibrium.py の一部）

```
def implied_returns(covariance, market_weights, risk_aversion):
    """Excess returns that make the market-cap weights optimal: pi = delta x Sigma x w_market.
     """
    return risk_aversion * covariance @ market_weights
```

リスト B.2: BL の事後の期待リターン（blm/black_litterman.py）

```
def posterior_returns(prior, covariance, view_mean, view_variance, tau):
    """prior + tau Sigma (tau Sigma + Omega)^-1 (Q - prior), with Omega = diag(view_variance).
     """
    tau_sigma = tau * covariance.values
    omega = np.diag(view_variance.values)
```

```
    adjustment = tau_sigma @ np.linalg.solve(tau_sigma + omega, (view_mean - prior).values)
    return prior + pd.Series(adjustment, index=prior.index)


def posterior_returns_original(prior, covariance, view_mean, view_variance, tau):
    """The same posterior written as in the original implementation (pseudo-inverses)."""
    inv_tau_sigma = np.linalg.pinv(tau * covariance.values)
    inv_omega = np.linalg.pinv(np.diag(view_variance.values))
    m = np.linalg.pinv(inv_tau_sigma + inv_omega)
    return pd.Series(m @ (inv_tau_sigma @ prior.values + inv_omega @ view_mean.values), index=
     prior.index)
```

`posterior_returns` は式 (7.1)（更新形で $P = I$）、`posterior_returns_original` は式 (4.7)（情報形で $P = I$）である。`np.linalg.solve(A, b)` は $A^{-1}b$ を、逆行列を作らずに計算する。

リスト B.3: 最適化（`blm/optimizer.py` の一部）

```
OBJECTIVE_SCALE = 1e4

def optimize(expected_returns, covariance, risk_aversion):
    """Maximize  w.mu - risk_aversion / 2 x w.Sigma.w   subject to  sum(w) = 1, w >= 0."""
    w = cp.Variable(len(expected_returns))
    objective = expected_returns.values @ w - risk_aversion / 2 * cp.quad_form(w, cp.psd_wrap(
     covariance.values))
    problem = cp.Problem(cp.Maximize(OBJECTIVE_SCALE * objective), [cp.sum(w) == 1, w >= 0])
    problem.solve(solver=cp.CLARABEL)
    if problem.status != cp.OPTIMAL:
        raise RuntimeError(f"optimization failed: {problem.status}")
    weights = np.clip(w.value, 0, None)
    return pd.Series(weights / weights.sum(), index=expected_returns.index)
```

日次のリターンは 10^{-3}、分散は 10^{-4} 程度と小さいので、目的関数を 10^4 倍して、解法の許容誤差に比べて十分大きくしている。元の実装の最適化が途中で止まった問題（7.7 節）への対処でもある。

リスト B.4: BL の戦略（`blm/strategies.py` の一部）

```
def black_litterman(inputs):
    """Market equilibrium corrected by the LLM views."""
    covariance = shrunk_covariance(inputs.returns)
    prior = implied_returns(covariance, inputs.market_weights, config.RISK_AVERSION)
    views = inputs.view_mean - inputs.risk_free_daily      # the LLM predicts returns, the prior
      is in excess returns
    expected = posterior_returns(prior, covariance, views, inputs.view_variance, config.TAU)
    return optimize(expected, covariance, config.RISK_AVERSION)
```

リスト B.5: 回答の平均と分散（`marketdb/db/schema.sql` のビュー `llm_view_stats`）

```
CREATE VIEW IF NOT EXISTS llm_view_stats AS
SELECT run_id, as_of_date, symbol,
       COUNT(expected_return) AS n_answers,
       AVG(expected_return)   AS mean_return,
       AVG(expected_return * expected_return) - AVG(expected_return) * AVG(expected_return) AS
     variance
FROM llm_views
GROUP BY run_id, as_of_date, symbol;
```

この資料の作り直し方

数値、表、図は BLM 解説 _ 計算.py がデータベースから計算し、BLM 解説 _ 生成/ に書き出す。リポジトリの直下で次を実行する。

```
.venv/bin/python 資料集/勉強用/BLM解説_計算.py
cd 資料集/勉強用 && tectonic BLM解説.tex
```

判断日（DATE）や 5 銘柄（T5）を変えれば、別の月・別の銘柄で同じ計算を見られる。本文の文章は数字に合わせて書いているので、変えた場合は文章との食い違いに注意する。

参考文献

- Black, F. and R. Litterman (1992). Global Portfolio Optimization. *Financial Analysts Journal*, 48(5), 28–43.
- He, G. and R. Litterman (1999). The Intuition Behind Black-Litterman Model Portfolios. *Investment Management Research*, Goldman Sachs & Co. (SSRN 334304)
- Idzorek, T. (2005). A Step-by-Step Guide to the Black-Litterman Model: Incorporating User-Specified Confidence Levels. Working paper.
- Ledoit, O. and M. Wolf (2004). A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Lee, Y. et al. (2025). Integrating LLM-Generated Views into Mean-Variance Optimization Using the Black-Litterman Model. arXiv:2504.14345.（本プロジェクトの元論文）
- Markowitz, H. (1952). Portfolio Selection. *Journal of Finance*, 7(1), 77–91.
- Michaud, R. (1989). The Markowitz Optimization Enigma: Is 'Optimized' Optimal? *Financial Analysts Journal*, 45(1), 31–42.
- Satchell, S. and A. Scowcroft (2000). A Demystification of the Black-Litterman Model: Managing Quantitative and Traditional Portfolio Construction. *Journal of Asset Management*, 1(2), 138–150.
- Theil, H. and A. S. Goldberger (1961). On Pure and Mixed Statistical Estimation in Economics. *International Economic Review*, 2(1), 65–78.
- Walters, J. (2014). The Black-Litterman Model in Detail. SSRN 1314585.
- 本プロジェクト：資料集/報告書/LLM-BLM_ 総合報告書.pdf