LLM-BLM 実験仮説

既存の資料と実装の調査にもとづく改善仮説と、その検証の計画

実験の設計書（実験の前に作成）

2026 年 10 月 16 日

目次

この資料について 2

第 1 章 既存の研究で分かっていること 4
1.1 総合報告書の主な結果 4
1.2 BLM ビューとリスクのコツの主な結果 4
1.3 まだ確かめられていないこと 5

第 2 章 現行のアーキテクチャ 6
2.1 データの流れ 6
2.2 処理ごとの確認 6
2.3 仮説の検証のために変える場所 7

第 3 章 数式と、整合性を確かめる項目 8
3.1 標準の式 8
3.2 単位 8
3.3 確かめる項目 8

第 4 章 仮説の全体像 9
4.1 仮説の一覧 9
4.2 実験の順番と、その理由 9
4.3 ブランチの作り方 10

第 5 章 共通の評価方法 11
5.1 期間と時点 11
5.2 対象の銘柄 11
5.3 予想の当たり具合の指標 11
5.4 BL の挙動の指標 12
5.5 ポートフォリオの指標 12
5.6 ポートフォリオの作り方（H03 以降で共通） 12
5.7 事前登録の範囲 13
5.8 未来の情報が混ざらないことの確認 13
5.9 統計的な判断の決まり 13

第 6 章 H01：現行の計算の再現と整合性の確認 14

第 7 章 H02：LLM の数値予想と統計モデル 15

第 8 章 H03：ビューの形（q と P） 17

第 9 章 H04：Ω の設計と信頼度の較正 18

第 10 章 H05：市場とセクターを、文章だけ・数字だけで聞く 20

第 11 章 H06：決算発表文から LLM が取り出す情報 21

第 12 章 H07：フィードバックの LLM 23

第 13 章 リスクと限界 25

この資料について

本書は、LLM-BLM プロジェクトについて、既存の資料・コード・実験結果を調べたうえで立てた改善仮説と、その検証の計画をまとめたものである。**実験を始める前に書き、Git に記録してから実験に入る。**評価の指標と、仮説を支持する・しないの条件は、結果を見る前にここで決めておく。結果を見てから都合のよい指標を選ぶことを防ぐためである。

研究の目的は、LLM を使うこと自体を正当化することではない。**LLM が、既存の Black-Litterman モデル（BL）や単純な統計の方法に対して、本当に追加の価値を生むか**を確かめることである。

書き分け

本書では、次の 3 つを囲みの色で区別する。

資料で確認した事実（緑）

既存の資料・コード・データで、この設計書を書く前に確かめたこと。出典（資料の章や、コードのファイル）を添える。

新しく立てる仮説（紫）

本書で新しく提案し、実験で確かめる主張。

実験前の予想（黄）

結果について、実験の前に持っている見込み。外れても、そのまま記録する。

設計のレビュー

最初の版を、2 つの LLM（OpenAI の gpt-5.5、Google の gemini-3.1-pro-preview）に読ませ、問題点を挙げさせた。指摘を自分で確かめ、次の点を直した。H02〜H04 が既存のデータの再分析であることの明記、判断日の翌取引日に売買する感度分析、H07 の銘柄の選び方（後の在籍を条件にしない）、「有意でない＝効果なし」としない判定（意味のある最小の効果を IC 0.03 に決める）、$b_t = 0$ の扱い、順位ビューを同じ BL の式で比べる形への変更、H02 の主な検定を残差の IC に変更（多重共線性）、置換を 200 回に増やす、決算発表文の HTML を取り除く、H05 のなぞりの判定を検定に変更。指摘のうち「仮説ごとに補正せず単独で評価すべき」は採らず、補正の前と後の両方を書くことにした。

調べた資料

資料	読んだ範囲
『LLM-BLM 総合報告書』（報告書/LLM-BLM_ 総合報告書.pdf、原稿は 資料いろいろ/LLM-BLM_ 総合報告書.tex）	本文と付録（プロンプトの全文、月別の数値）を通読した。依頼文の「総合報告書 (2).pdf」に当たるファイルは見つからず、この版を使った
『BLM ビューとリスクのコツ』(LLM-BLM ビューとリスクのコツ/)	τ、Ω、当たり具合、積み上がり、ビューの形、TE、本プロジェクトへの当てはめ、質問の設計、コツの一覧の章を通読した。ほかの章は要点の囲みと表を読んだ。計算スクリプトの E、E2 節（Ω の比較）を読んだ
『BLM 解説』(勉強用/)	構成と式の記法を確認した
実験のスクリプト（LLM-BLM_ 実験/）	実験 D〜G のスクリプトと結果のファイルを確認した
コード（blm/、llm/、marketdb/、run_*.py）	すべて読んだ
データベース (data/blm_2015.sqlite)	テーブル、LLM の実行、比率の計算の記録を確認した

第 1 章

既存の研究で分かっていること

1.1　総合報告書の主な結果

総合報告書（2026 年 10 月 13 日版）で報告されていること

- 元論文の計算では、BL が均衡から LLM の予想へ動かす割合（採用率）は中央値で 99.87%（最小 99.75%）。均衡リターンをすべて 0 にしても比率は平均 92% 重なる（第 III 部、問題 1）。
- LLM の予想と、渡した月の平均リターンの相関は平均 0.89（最小 0.80、最大 0.95）。回帰の傾きは 0.77（第 6 章）。
- 予想と翌月の実際のリターンの順位相関は 30 か月の平均で +0.05。プラスの月は 14 か月（第 6 章、付録の月別の表）。
- 回答の分散 ÷ 実際の予測誤差の目安は中央値で 0.05〜0.15（問題 3）。
- 元の最適化（SciPy の SLSQP、標準の設定）は、改善できる幅の 95% で止まり、実質 9.9 銘柄。同じ式を二次計画の解法で最後まで解くと 4.2 銘柄（問題 4）。
- 均衡リターンの計算で、日次のリターンから年率の金利 0.02 をそのまま引いている。ただし採用率が 99.9% なので結果にはほぼ効かない（問題 5）。
- 共分散は判断月の約 20 日分の標本共分散で、約 488 銘柄に対して階数が足りない（問題 6）。
- 直した計算（逆最適化の均衡、252 日の Ledoit–Wolf、Clarabel で最後まで解く）では、比率が実質 1.7 銘柄に集中する（第 7 章）。
- 入力を要約した指標に変える（実験 D）、比率を明言する（E）、3 ターンにする・5 段階で答えさせる（F）、銘柄の数字を渡さずリスクの種類ごとに聞く（G）のどれでも、答えは渡した数字の中の直近の値動きに沿った。
- 結果へのフィードバックを行う LLM は「未着手」である（第 1 章の現在の状態の表）。**コードにも実装はない**。

1.2　BLM ビューとリスクのコツの主な結果

ビューとリスクのコツ（2026 年 10 月）で報告されていること

- Ω を τ に比例させると、事後の期待リターンから τ は消える。Ω を外から決めると、τ は採用率を直接決める係数になる。τ でトラッキングエラー（TE）を合わせると、「どれだけずれてよいか」と「ビューをどれだけ信じるか」を混ぜてしまう。Ω は当たり具合で、TE は最適化の制約で決めるのがよい（第 4、18 章）。
- 市場版の BL で $\omega = \sigma^2(1/\mathrm{IC}^2 - 1)$ と置くと、Grinold の式 $\alpha = \mathrm{IC} \cdot \sigma \cdot z$ と一致し、採用率は IC^2 になる（第 8 章）。
- ビューが多いのに Ω を対角にすると、外れの共通部分が無視され、確信が積み上がる。本プロジェクトの LLM の外れの共通相関は約 0.21、全体の水準の予想と実際の相関は -0.43（第 8b 章）。
- LLM の当たり具合：順位相関の平均 +0.052（t 値 1.51）、月ごとに平均を引いてまとめた傾き

+0.074、回答の分散は実際の外れの 2 乗の中央値の 0.124 倍（第 19 章）。

- Ω を 7 通りに変えた 30 か月の計算（第 19 章の表）：回答の分散では採用率 91.3%・実質 1.7 銘柄・TE 50.9%。傾きで較正し Σ に比例させると採用率 5.6%・実質 17.6 銘柄・TE 26.0%。さらに事前の TE を 3% 以内にすると実質 41.3 銘柄・実績の TE 5.3%・IR −0.02。**どの方法も、超過リターンの t 値の絶対値は 0.6 未満**だった。
- 2015 年からの銘柄の指標の IC（S&P500 の構成銘柄、129〜139 か月）は、どれも絶対値 0.03 未満で、t 値の絶対値は 1.2 未満（第 13 章）。
- 30 か月では、IC 0.05 程度の予想の価値は確かめられない。t 値 2 で確かめるには約 55 か月が要る（第 8 章）。

1.3　まだ確かめられていないこと

資料が「次に行うこと」に挙げ、まだ行われていないものを並べる。

未検証の課題	出典
文章だけを渡したとき、LLM の答えは月によって変わるか。数字に沿っていないか	総合報告書第 V 部の総合考察、次に行うこと 1
統計モデル（回帰）を比べる相手として作り、LLM が何を足しているかを示す	総合報告書第 10 章、次に行うこと 4
銘柄ごとの文章の情報源（決算の説明の文章など）を公表日つきで手に入れる	総合報告書次に行うこと 5
結果へのフィードバックを行う LLM	総合報告書第 1 章、次に行うこと 7
較正の傾き b を、推定の誤差に応じて 0 に寄せて使う	ビューとリスクのコツ第 8 章（「簡単のため縮めずに使った」）
売買のコストを入れた比較	両資料の限界の節
較正の仕組みを `blm/` に組み込む	ビューとリスクのコツ第 19 章の提案

第 2 章

現行のアーキテクチャ

2.1　データの流れ

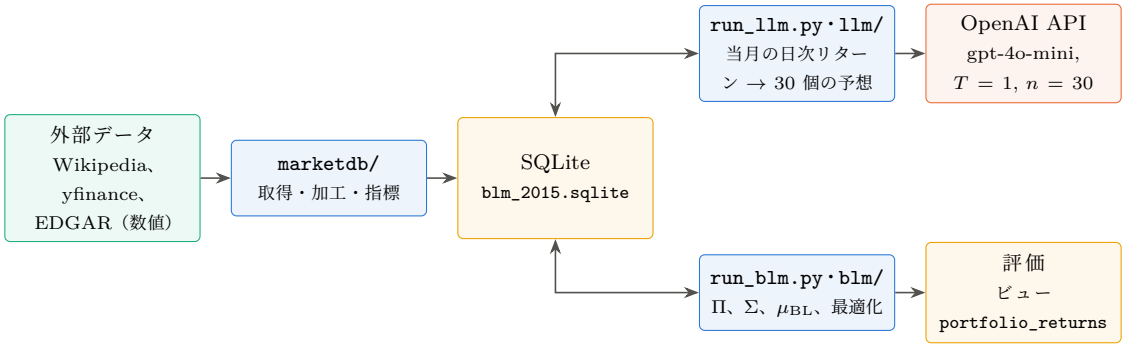


図2.1: 現行のデータの流れ。`llm/` と `blm/` はデータベースを通してだけつながる。結果へのフィードバックを行う LLM はない。

2.2　処理ごとの確認

処理	現行の実装（コードで確認）
1. データの取得元	構成銘柄と業種は Wikipedia、株価と株式数と指数は yfinance、財務諸表は EDGAR の XBRL（`marketdb/sources/`）。期間は 2014-01-02〜2026-09-30（株価）。銘柄の指標は 2015-02〜2026-09 の 140 か月（`stock_metrics`）
2. LLM への入力	ティッカー、社名、セクター、サブ業種、判断月の日次リターンの列（約 20 個、小数）。日付は渡さない（`llm/prompts.py`、`llm/context.py`）
3. LLM の出力	翌月の平均日次リターン（小数）を 1 銘柄 30 個。構造化出力で `{"expected_return": 数値}`。文章や信頼度は出させない（`llm/client.py`）。実行 1 は gpt-4o-mini-2024-07-18、温度 1.0、判断日 2024-03-28〜2026-08-31 の 30 か月、のべ 14,688 件
4. q、P、Ω への変換	q = 30 個の平均 − 日次の無リスク金利、$P = I$（全銘柄の絶対ビュー）、$\Omega = \mathrm{diag}$(30 個の母分散)（`blm/strategies.py`、ビュー `llm_view_stats`）
5. Π、Σ、τ	Σ は過去 252 取引日の日次リターンの Ledoit–Wolf 推定（`blm/covariance.py`）。$\Pi = \delta \Sigma w_{\mathrm{mkt}}$、$\delta = 2.5$（`blm/equilibrium.py`）。$\tau = 0.025$。$w_{\mathrm{mkt}}$ は判断日の時価総額（終値 × 発行済み株式数、浮動株の調整なし）
6. 事後と最適化	$\mu_{\mathrm{BL}} = \Pi + \tau\Sigma(\tau\Sigma+\Omega)^{-1}(q-\Pi)$（`blm/black_litterman.py`）。$\max_w w^\top \mu_{\mathrm{BL}} - \frac{\delta}{2} w^\top \Sigma w$、$\mathbf{1}^\top w = 1$、$w \geq 0$ を CVXPY と Clarabel で解く。最適でなければ例外を出す（`blm/optimizer.py`）。TE の制約、売買のコストはない

処理	現行の実装（コードで確認）
7. バックテスト	判断日の終値で買い、翌月の最後の取引日まで持つ。配当込みの調整後終値で計算（ビュー `portfolio_returns`）。比べる相手は時価総額加重。指標は `blm/evaluation.py`
8. DB への保存	LLM の実行条件（`llm_runs`：モデル、システムプロンプト、温度、回答数）、全回答（`llm_views`）、比率の実行条件（`portfolio_runs`：係数を JSON で）と比率（`portfolio_weights`）。予想と実現値の対応は、判断日と銘柄で株価に結合して作る。**ユーザープロンプトの型と、使った入力のまとまりは保存されていない**
9. フィードバックの LLM	**実装されていない**。総合報告書の計画（段階 2）では「数字で要因を分解し、その結果と当時のレポートを LLM に渡して説明させる」とされている

2.3 仮説の検証のために変える場所

変える要素	変える場所
ビューの形（q、P）	`blm/black_litterman.py` に、一般の P と行列の Ω を受け取る関数を足す
Ω の決め方と較正	較正の関数を `blm/calibration.py` に足す（判断日より前のデータだけを使う）
TE の制約、売買のコスト	`blm/optimizer.py` に TE つきの最適化を足す。コストは評価の側で引く
LLM への質問	`experiments/` の下に実験ごとのスクリプトを置く。回答と条件は実験のフォルダに保存し、既存の DB には書き込まない
統計モデルの対照	`stock_metrics` を読む実験のスクリプト

既存の `.env` の決まり（コードに既定値を置かない）を崩さないため、新しい関数は設定を読まない純粋な関数にし、係数は実験のスクリプトの中で定める。既存の関数と `run_*.py` の動きは変えない。

第 3 章

数式と、整合性を確かめる項目

3.1　標準の式

均衡の期待超過リターン（逆最適化）と、BL の事後の期待リターンは次のとおりである。

$$\Pi = \delta \, \Sigma \, w_{\mathrm{mkt}} \tag{3.1}$$

$$\mu_{\mathrm{BL}} = \left[(\tau\Sigma)^{-1} + P^{\top}\Omega^{-1}P\right]^{-1}\left[(\tau\Sigma)^{-1}\Pi + P^{\top}\Omega^{-1}q\right] \tag{3.2}$$

$$= \Pi + \tau\Sigma P^{\top}\left(P\tau\Sigma P^{\top} + \Omega\right)^{-1}(q - P\Pi) \tag{3.3}$$

N を銘柄数、K をビューの数とすると、Σ は $N \times N$、P は $K \times N$、q は K 次元、Ω は $K \times K$ である。現行の実装は $P = I$（$K = N$）で、式 (3.3) の形を `numpy.linalg.solve` で解いている。

3.2　単位

現行の「直した計算」では、Σ は日次リターンの共分散、Π は日次の超過リターン、q は「翌月の平均日次リターン − 日次の無リスク金利」、Ω は「30 個の回答の分散」で、平均日次リターンの分散である。Π と q と $\tau\Sigma$ はどれも「日次の平均リターン」の単位で、そろっている。

ただし、Ω が表すのは「回答のぶれ」であり、「平均日次リターンの予想の外れ」ではない。この点は計算の誤りではなく、研究の論点（仮説 H04）として扱う。

3.3　確かめる項目

1. **次元**：P が一般の形（相対ビュー、$K < N$）でも式 (3.2) と式 (3.3) が一致すること。
2. **ビューがないとき**：Π をそのまま最適化に入れると、比率が w_{mkt} に戻ること（30 か月すべて）。
3. **Ω の作り方**：ビュー `llm_view_stats` の分散が、30 個の回答の母分散と一致すること。
4. **逆行列の安定性**：$\tau\Sigma + \Omega$ の条件数と、`solve` の残差。
5. **採用率**：銘柄ごとの $(\mu_{\mathrm{BL}} - \Pi)/(q - \Pi)$ の中央値が、資料の値（元の計算 99.87%、直した計算 91.3%）を再現すること。
6. **最適化の収束**：Clarabel の状態が「最適」であること。目的関数の値を、別の解き方と比べること。元の SLSQP の停止の理由（成功の印、反復の回数）と、最適値からの差を記録すること。
7. **再現**：同じ DB と同じコードで、資料の数値（相関 0.89、順位相関 +0.05、実質銘柄数）を出し直せること。

計算の誤りが見つかった場合は、研究の仮説と混ぜず、まず計算の問題として記録して直す。

第 4 章

仮説の全体像

4.1　仮説の一覧

ID	テーマ	名称	費用の見込み
H01	D	現行の計算の再現と整合性の確認（計算の検証。研究の仮説ではない）	0
H02	F、A	LLM の数値予想は、入力の単純な変換と統計モデルを超える情報を持つか	0
H03	B	q と P：絶対ビュー、相対ビュー、順位ビュー	0
H04	C、D	Ω：回答の分散、較正、縮小、置換による対照	0
H05	A	市場とセクター：文章だけ・数字だけで聞く（実験 G の拡張）	約 0.2 ドル
H06	A、F	銘柄ごとの決算発表文から LLM が情報を取り出し、統計で数値化する	約 5 ドル
H07	E	フィードバックの LLM：何を渡すと何が変わるか	約 3 ドル

テーマの記号は、依頼文の A〜F（A：LLM に何を予測させるか、B：q と P、C：Ω、D：BLM と最適化、E：フィードバック、F：統計モデルとの比較）である。費用は gpt-4o-mini の単価（入力 100 万トークンあたり 0.15 ドル、出力 0.60 ドル）による見込みで、実績は結果のレポートに書く。総合報告書の実行 1（14,688 リクエスト、各 30 回答）が約 1.75 ドルだったことと、この単価は合っている。

4.2　実験の順番と、その理由

依頼文の暫定の順番（検証 → ビューの変換 → $q \cdot P \cdot \Omega$ → 較正 → フィードバック → 統計モデルとの比較）から、次のように変えた。

1. **H01（計算の検証）を最初に置く**。後の比較のすべてが、この計算に乗るためである。
2. **統計モデルとの比較（H02）を 2 番目に上げる**。依頼文では最後だったが、統計モデルの予想は H03 以降の「比べる相手」になる。先に作らないと、各仮説の対照群がそろわない。
3. **H03（q、P）と H04（Ω）は同じ評価の仕組みを使う**。H03 では Ω を、H04 では q を固定する。
4. **LLM を新しく呼ぶ実験（H05〜H07）は後に置く**。API を使う前に、評価の仕組みを H01〜H04 で確かめておくためである。H05 は小さく安いので先に行い、規模の大きい H06 の前の動作確認も兼ねる。

4.3　ブランチの作り方

対象	ブランチ
設計書（本書）	`research/llm-blm-hypotheses`
H01	`experiment/H01-verification`
H02	`experiment/H02-statistical-baseline`
H03	`experiment/H03-view-shape`
H04	`experiment/H04-omega-calibration`
H05	`experiment/H05-text-vs-numbers`
H06	`experiment/H06-earnings-text`
H07	`experiment/H07-feedback-llm`
結果の報告書	`research/llm-blm-results-report`

本書は `research/llm-blm-hypotheses`（`db-from-2015` から分岐）に置く。各仮説のブランチは、1 つ前の仮説のブランチから順に分岐する（H01 は本書のブランチから）。共通の評価の仕組みを H01 で作り、後の仮説で使い回すためである。最終の報告書は、最後の実験のブランチから `research/llm-blm-results-report` を分岐して作る。

第 5 章

共通の評価方法

5.1　期間と時点

- **評価の判断日**：2024-03-28〜2026-08-31 の 30 か月の、各月の最後の取引日（実行 1 と同じ）。予測の対象は、判断日の翌日から翌月の最後の取引日まで。
- **学習に使う期間**：統計モデルは 2015-02〜（判断日の前に結果が確定した月まで）。ウォークフォワード（判断日ごとに、その時点で結果が分かっている月だけで学習・較正する）で行う。判断日 d_i の時点では、判断日 d_{i-1} の予想の結果（d_i で終わる月のリターン）までが分かっている。
- **未来の情報を使わない決まり**：入力、較正、銘柄の選択に、判断日より後の情報を使わない。決算発表文は、提出日が判断日より**前**（同じ日は除く）のものだけを使う（同じ日の取引終了後の提出がありうるため）。
- **LLM のモデル**：銘柄や相場の予想に使うのは gpt-4o-mini（知識は 2023 年 10 月まで）だけにする。新しいモデル（gpt-5.x、Gemini 3.x）は評価期間の相場を学習で知っている可能性があるので、予想には使わない。新しいモデルは、コードのレビューにだけ使う。

5.2　対象の銘柄

判断日に S&P500 に在籍し、実行 1 の予想と時価総額があり、過去 252 日の半分以上に株価がある銘柄（`blm/inputs.py` と同じ。平均約 488 銘柄）。どの戦略も、同じ判断日には同じ銘柄を使う。

5.3　予想の当たり具合の指標

指標	定義
IC（順位相関）	判断日ごとに、予想の順位と翌月のリターンの順位のスピアマン相関。30 か月の平均と、t 値（平均 ÷ 標準偏差 $\times\sqrt{30}$）
相関（Pearson）	判断日ごとの予想と翌月のリターンの相関の平均
較正の傾き b	判断日ごとに平均を引いた予想と実際をまとめた回帰の傾き
MAE、RMSE	予想（平均日次リターン）と翌月の平均日次リターンの差
方向の正解率	判断日ごとの平均からの上下の向きが合った割合
水準の偏り	予想の平均 − 実際の平均
入力との相関	予想と、判断月の平均日次リターン（LLM が見た数字）の相関。なぞりの目安

翌月のリターンは、判断日の終値から翌月の最後の取引日までの配当込みのリターン（ビュー `portfolio_returns` と同じ作り方）を基本にする。資料の数値の再現（H01）では、資料と同じ「翌月の日次リターンの平均（15 日以上）」も使う。

5.4　BL の挙動の指標

採用率（銘柄ごとの $(\mu_{\mathrm{BL}} - \Pi)/(q - \Pi)$ の中央値。相対ビューでは、全体の水準を除いた差で測る）、均衡からの乖離 $\|\mu_{\mathrm{BL}} - \Pi\|$、$\tau\Sigma + \Omega$ の条件数、最適化の状態、能動的な比率のベータ $(w - w_{\mathrm{mkt}})^\top \beta$。

5.5　ポートフォリオの指標

指標	**定義**
累積・年率リターン	月次リターンの積から。年率は $(\prod(1 + r_t))^{12/T} - 1$
年率ボラティリティ	$\mathrm{sd}(r_t)\sqrt{12}$
シャープレシオ	3 か月物国債（`^IRX`）の利回りを月次に直して引いた超過リターンから
最大ドローダウン	月次の資産の最高値からの下落率の最大
TE、IR	時価総額加重との月次の差の標準偏差 $\times\sqrt{12}$、差の平均 $\times 12 \div$ TE
t 値	時価総額加重との月次の差の平均 $\div$ 標準誤差
売買回転率	前月の比率を実際の値動きで動かした比率と、新しい比率の差の絶対値の和の半分
コスト控除後	片道 0.1%（第 2 版の論文と同じ）× 売買の量（回転率の 2 倍）を月次リターンから引く。比べる相手の時価総額加重にも同じ計算で引く
実効保有銘柄数	$1/\sum_i w_i^2$ の平均
ベンチマークからの乖離	アクティブシェア $\frac{1}{2}\sum_i \lvert w_i - w_{\mathrm{mkt},i}\rvert$ の平均

5.6　ポートフォリオの作り方（H03 以降で共通）

結果を見る前に、次のとおり固定する。

- 共分散：過去 252 日の Ledoit–Wolf（現行のまま）。$\delta = 2.5$、$\tau = 0.025$（現行のまま）。
- 最適化：$\max_w w^\top \mu_{\mathrm{BL}} - \frac{\delta}{2} w^\top \Sigma w$、$\mathbf{1}^\top w = 1$、$w \geq 0$ に、**事前の TE を年率 3% 以内**（$(w - w_{\mathrm{mkt}})^\top \Sigma (w - w_{\mathrm{mkt}}) \leq 0.03^2/252$）を足す。3% は『ビューとリスクのコツ』の計算と同じ値で、比べられるようにした。
- 売買のコスト：片道 0.1%。
- 較正の傾き b_t：判断日より前に結果が分かっている月だけで計算し、$[0, 0.99]$ に収める。3 か月分の結果がそろうまでは 0 とする。$b_t = 0$ **の月は、ビューを使わず** $\mu_{\mathrm{BL}} = \Pi$ **とする**（$\Omega = \tau\Sigma(1/b_t - 1)$ は $b_t \to 0$ で無限大になり、ビューの重みが 0 になる極限と同じ）。$\Omega \propto \Sigma$ の場合は、割り算を避けて同じ値になる $\mu_{\mathrm{BL}} = \Pi + b_t\, \Sigma P^\top (P\Sigma P^\top)^{+}(q - P\Pi)$ で計算する。
- 売買の時点：基本は「判断日の終値で売買」（資料と同じ）。ただし LLM の入力には判断日のリターンまで入っているので、厳密にはその終値では売買できない。そこで、**判断日の翌取引日の終値で売買する場合**も、主なポートフォリオについて感度分析として併記する。

5.7　事前登録の範囲

H02〜H04 は、既存の実行 1 の回答を使う再分析である。実行 1 の当たり具合の全体の値（IC +0.05 など）は、この設計の前に資料で知っていた。したがって H02〜H04 は「何も知らない状態での事前登録」ではなく、「全体の値を知ったうえで、新しい分析の指標と判定の基準を、その分析を行う前に固定したもの」である。H05〜H07 の LLM の回答は、まだ存在しない（本書のあとに初めて集める）。

5.8　未来の情報が混ざらないことの確認

- 財務の指標（`stock_metrics`）は、判断日までに**提出された**四半期だけから作られている（テーブルの定義と資料の第 12 章。決算期末ではなく提出日で区切る）。150 日より古い決算は使わない。
- 時価総額は、その日以前に報告された発行済み株式数と、その日の終値から作る。
- 構成銘柄は、入れ替えの履歴から作った判断日時点の在籍期間で決める。データの取れない 28 銘柄の除外は、後の情報を使っている（資料の限界）。全戦略に共通なので比較は公平だが、成績の水準には偏りが残る。

5.9　統計的な判断の決まり

- 主な検定は、仮説ごとに 1 つの p 値（両側）に決めておく（各章の「支持・棄却の条件」）。H02〜H07 の 6 つの主な検定には、Holm の方法で多重比較の補正をかける（全体の有意水準 5%）。補正の前と後の両方を書く。
- 30 か月の月次データで、IC の月ごとの標準偏差が約 0.19（資料の値）なら、t 値 2 に届く IC の平均は約 0.07 である。**これより小さい IC は、本当にあっても検出できない。**
- **有意でないことは、効果がないことの証明ではない。**「LLM の情報はない」の向きの主張には、意味のある最小の効果を $\mathbf{IC} = 0.03$（年率に直すと小さくない大きさで、資料の LLM の IC 0.05 の 6 割）と決めておく。主な指標の 95% 信頼区間の上限が 0.03 未満なら「効果はない（あっても小さい）」、上限が 0.03 以上で有意でないなら「結論を出すには証拠が不足している」と書く。
- 順位を取るときの同じ値は、平均の順位にする。
- わずかな数値の差や、1 か月だけの大きな成績は、一般化しない。

第 6 章

H01：現行の計算の再現と整合性の確認

項目	内容
仮説 ID・名称	H01　現行の計算の再現と整合性の確認
解決したい問題	研究の結論は、計算が正しいことに乗っている。資料の数値が今の DB とコードで再現できるか、式・単位・次元・収束に問題がないかを先に確かめる
資料との関係	総合報告書の問題 1〜6、ビューとリスクのコツ第 19 章の表を再現の対象にする
根拠	依頼文の優先順位 1。DB は 2015 年まで延長した版（`blm_2015.sqlite`）に替わっており、資料を作った DB（`blm.sqlite`）と同じ結果になるかは確かめていない
変える要素	なし（確認だけ）。テストのコードと、一般の P・行列の Ω を受け取る関数、TE つきの最適化、評価の仕組みを足す
固定する要素	DB、実行 1 の回答、係数（$\tau = 0.025$、$\delta = 2.5$、252 日）
対照群	資料に書かれた数値
データと期間	判断日 2024-03-28〜2026-08-31 の 30 か月
評価指標	第 3 章の 7 項目
支持・棄却の条件	次をすべて満たせば「整合している」とする。(1) 式 (3.2) と式 (3.3) の差が相対誤差 10^{-8} 未満（ランダムな正定値行列と、実データ）。(2) ビューなしの比率と w_{mkt} の差の最大が 0.1% 未満。(3) Clarabel の状態がすべて最適。(4) 再現の値が資料の値と、相関・順位相関で ± 0.01、採用率で ± 1 ポイント以内。満たさないものは、原因を調べて記録する
実装と再現の手順	`tests/`（標準ライブラリの `unittest`）と `experiments/H01_verification/run.py`。`python -m unittest` と `python experiments/H01_verification/run.py` で再現する
想定される失敗	DB の作り直し（2015 年への延長）で、株価の調整後の値や銘柄の範囲が変わり、数値が少しずれる
API の費用	0

実験前の予想

式と単位は整合していて、資料の数値はほぼ再現できる。元の SLSQP は「成功」と報告しながら最適値の手前で止まっている。

第 7 章

H02：LLM の数値予想と統計モデル

仮説

LLM（実行 1）の翌月の予想が持つ情報は、LLM に渡した入力（判断月の平均日次リターンとその散らばり）の単純な関数で再現でき、それを統制すると、LLM に固有の予測力は残らない。また、LLM に渡していない数値（`stock_metrics` の 12 の指標）から、評価期間より前のデータで学習した統計モデルの予想と比べて、LLM の予想は IC で上回らない。

これは「LLM が統計モデルに対して追加の価値を生むか」を、最も素直な形で確かめるものである。帰無仮説を支持する方向の主張なので、結果が「支持されなかった」場合は、LLM が何かを足している証拠になる。

項目	内容
仮説 ID・名称	H02　LLM の数値予想は、入力の単純な変換と統計モデルを超える情報を持つか
解決したい問題	相関 0.89 で入力をなぞる予想に、なぞり以外の情報があるかは確かめられていない
資料との関係	総合報告書の「統計モデルとの比較（未着手）」、ビューとリスクのコツ第 13 章の指標の IC（2015〜）
根拠	予想が入力の写しなら、写しを作る計算（回帰）で同じ予想が作れる。LLM に固有の情報は、写しとの差にしか残らない
変える要素	予想の作り方：(a) LLM（実行 1）、(b) LLM の写し（判断月の平均・散らばり・日数で LLM の予想を回帰した当てはめ値。ウォークフォワード）、(c) 短期反転（− 直近 1 か月のリターン）、(d) モメンタム（12−1 か月）、(e) 統計モデル（12 の指標の断面 z スコアで、翌月のリターンの断面順位をリッジ回帰。2015-03〜の結果が確定した月で学習し、毎月学習し直す）
固定する要素	銘柄、期間、翌月のリターンの定義
対照群	(b)〜(e)。とくに (b) は「LLM を使わない同じ情報」の対照
データと期間	評価は 30 か月。統計モデルの学習は 2015-03〜判断日の前
評価指標	IC と t 値、相関、較正の傾き、MAE・RMSE、方向の正解率。写しの決定係数
支持・棄却の条件	**主な検定**：LLM の予想に固有の部分の IC。判断日ごとに、LLM の予想の順位を、判断月の平均日次リターンの順位と日次リターンの標準偏差の順位で回帰した残差（入力で説明できない部分）を作り、その残差と翌月のリターンの順位相関を取る。30 か月の平均の t 値から両側の p 値を出す。(i) $p < 0.05$ で正なら棄却（LLM に固有の予測力がある）。(ii) 有意でなく、95% 信頼区間の上限が 0.03 未満なら支持。(iii) 有意でなく、上限が 0.03 以上なら「証拠が不足」。（予想と入力の相関が 0.89 と高いので、両方を並べた回帰では標準誤差が大きくなる。そのため残差の IC を主な検定にし、並べた回帰は参考に示す。）**副次**：統計モデルと LLM の IC の差（月ごとの差の対応のある t 検定）
実装と再現の手順	`experiments/H02_statistical_baseline/run.py`。API は使わない
想定される失敗	統計モデルは、2015 年以降の指標の IC が小さい（資料）ので、統計モデルも当たらない可能性が高い。その場合「どちらも当たらない」という結果になり、比べる意味が弱くなる
API の費用	0

実験前の予想

写しの決定係数は 0.7 以上。残差の IC は有意にならない。ただし 30 か月では信頼区間の上限が 0.03 を下回らず、「証拠が不足」になる見込みが高い。統計モデルの IC も 0 と区別できない。

第 8 章

H03：ビューの形（q と P）

仮説

LLM の絶対ビュー（$P = I$）には、全体の水準の楽観・悲観の癖が入っている。Ω が対角のとき、この癖は能動的な比率のベータの傾きとして比率に入る。予想を判断日ごとの時価総額加重の平均からの差（相対ビュー）にすれば、この傾きは消える。さらに、予想を順位の点数に直す（順位ビュー）と、極端な予想（上場直後の銘柄など）に比率が集中することを防げる。

項目	内容
仮説 ID・名称	H03　q と P：絶対ビュー、相対ビュー、順位ビュー
解決したい問題	LLM の予想は 76% がプラスで、全体の水準の予想は翌月の実際と相関 -0.43（資料）。絶対ビューのままでは、当たらない水準の情報が比率に入る
資料との関係	ビューとリスクのコツ第 9 章（全体の水準が比率に効くのは Ω が対角のとき）。第 19 章では $\Omega \propto \Sigma$ のもとで相対ビューと絶対ビューが同じ結果になることを確かめている。本仮説は、Ω が対角の場合と、順位ビューを新しく比べる
根拠	対角の Ω では、一律の上乗せ $c\mathbf{1}$ が $c\tau\Sigma(\tau\Sigma + \Omega)^{-1}\mathbf{1}$ になり、市場との共分散の大きい銘柄ほど大きく上がる
変える要素	ビューの形 3 通り：(1) 絶対 $q = Q - r_f$、$P = I$。(2) 相対 $q_i = (Q_i - w_{\text{mkt}}^{\top} Q)$、均衡の側も同じく平均を引く。(3) 順位：$z_i = \Phi^{-1}((\text{rank}_i - 0.375)/(N + 0.25))$（同じ値は平均の順位）を、判断日ごとの予想の平均と標準偏差で日次の単位に戻した $q_i = \bar{Q} + \text{sd}(Q)\, z_i - r_f$。順位だけを残し、外れ値の大きさを捨てる。3 通りとも同じ BL の式（同じ Ω、同じ b_t）を通す。Ω は 2 通り：(a) 対角 $\tau\,\text{diag}(\Sigma)(1/b_t - 1)$、(b) Σ に比例 $\tau\Sigma(1/b_t - 1)$
固定する要素	予想（実行 1）、Σ、δ、τ、TE 3% の制約、コスト、銘柄、期間、b_t の計算
対照群	時価総額加重（ビューなし）。形の比較では (1) が対照
データと期間	30 か月
評価指標	能動的な比率のベータ、月ごとの予想の平均（楽観の度合い）と能動ベータの相関、最大の能動ウェイト、実効保有銘柄数、TE、IR、コスト控除後の超過リターン、回転率
支持・棄却の条件	**主な検定**：Ω が対角のとき、30 か月の「予想の時価総額加重の平均」と「能動的な比率のベータ」の相関の検定（相関 0 の t 検定、両側）。絶対ビューで正かつ $p < 0.05$ で、相対ビューの能動ベータの絶対値の平均が絶対ビューの半分以下なら支持。絶対ビューで有意でなければ「癖が比率に入る」こと自体が確かめられず、棄却。**副次**：順位ビューの最大の能動ウェイトが、絶対ビューより小さい（30 か月の平均）
実装と再現の手順	`experiments/H03_view_shape/run.py`。API は使わない
想定される失敗	TE 3% の制約がベータの傾きを抑えてしまい、形の違いが見えにくい。その場合に備え、TE の制約なしでも同じ計算をして併記する
API の費用	0

実験前の予想

対角の Ω では、絶対ビューの能動ベータは楽観の月に大きくなる（相関が正）。相対ビューではそれが消える。$\Omega \propto \Sigma$ では形による違いはほぼない。成績の差は偶然と区別できない。

第 9 章

H04：Ω の設計と信頼度の較正

仮説

(1) 回答のばらつきは、銘柄の値動きの大きさを統制すると、予想の外れの大きさを説明しない。(2) Ω を判断日より前の当たり具合で較正し、Σ に比例させ、推定の誤差に応じて縮めると、BL は設計どおりの採用率で「時価総額加重を少し動かす」形になる。(3) しかし、その比率の成績は、予想を銘柄の間でランダムに並べ替えたビュー（情報のない対照）と区別できない。

項目	内容
仮説 ID・名称	H04　Ω：回答の分散、較正、縮小、置換による対照
解決したい問題	回答の分散を Ω にすると、外れを 8 分の 1 に見積もり、予想を 91% 採用する（資料）。較正の方法は資料で試されているが、(a) 推定の誤差に応じた縮小、(b) コスト、(c) 情報のない対照との比較、(d) 回答のばらつきが外れの順番の手がかりになるか、は確かめられていない
資料との関係	ビューとリスクのコツ第 8、8b、19 章。そこでの 7 通りの比較を、コストつき・同じ TE の制約で再計算し、縮小と置換の対照を足す
根拠	傾きの推定値は少ない月では大きく揺れる（資料の図）。ランダムに並べ替えたビューで同じ成績が出るなら、成績はビューの情報ではなく、制約と銘柄の構成から来ている
変える要素	Ω の 5 通り：(1) 回答の分散（対角）、(2) He–Litterman $\tau\,\mathrm{diag}(\Sigma)$、(3) 傾きで較正（対角）、(4) 傾きで較正（Σ に比例）、(5) (4) の傾きを $\hat{b}\max\{0, 1-\mathrm{se}^2/\hat{b}^2\}$ で縮めたもの（se は月ごとの傾きの標準誤差）。$\hat{b}\le 0$ なら 0（ビューを使わない）。置換の対照：(5) と同じ b_t で、予想を判断日ごとに銘柄の間で並べ替えたもの（種 0〜199 の 200 通り）。さらに主な比率について、判断日の翌取引日の終値で売買する場合も計算する
固定する要素	ビューの形は相対ビュー、TE 3%、コスト、Σ、δ、τ、銘柄、期間
対照群	時価総額加重、置換のビュー
データと期間	30 か月
評価指標	採用率、実効保有銘柄数、アクティブシェア、事前と実績の TE、IR、コスト控除後の超過リターン、回転率、ビューの成績の置換分布の中での位置（片側の経験的 p 値）
支持・棄却の条件	**主な検定**は (3)：(5) のコスト控除後の年率超過リターンの、置換の 200 通りの中での片側の経験的 p 値（$(1+\#\{\text{置換} \ge \text{実際}\})/201$）。$p \ge 0.05$ なら「ビューの情報は検出されない」（支持）、$p < 0.05$ なら棄却。両側の Holm の補正には $2p$ を使う。(1) は、銘柄・月ごとに「回答の標準偏差」と「外れの絶対値」の順位相関を、過去 252 日のボラティリティで統制した偏順位相関で測り、30 か月の平均の $t < 2$ なら支持。(2) は、(5) の実現の採用率が設定（b_t）から ±1 ポイント以内、実効保有銘柄数が 30 以上、実績の TE が 6% 以下なら支持
実装と再現の手順	`experiments/H04_omega_calibration/run.py`。較正の関数は `blm/calibration.py`
想定される失敗	計算の時間が長くなる（1 回の最適化 × 30 か月 × 約 205 通り）。時間が足りなければ置換の回数を減らし、その事実と p 値の分解能を書く
API の費用	0

実験前の予想

(1) は支持（ばらつきは値動きの大きさで決まり、統制すると外れを説明しない）。(2) は支持。(3) も支持（LLM のビューの成績は置換と区別できない）。

第 10 章

H05：市場とセクターを、文章だけ・数字だけで聞く

仮説

実験 G で答えが市場の直近の値動きに沿ったのは、プロンプトに数字があったためである。運用会社の月次レポートの文章（要約と主なリスク）だけを渡すと、答えは市場の数字に沿わなくなる。ただし、その答えは翌月のセクターの成績を当てない。

項目	内容
仮説 ID・名称	H05　市場とセクター：文章だけ・数字だけで聞く（実験 G の拡張）
解決したい問題	「LLM を使う意味は文章を読む部分にある」という資料の結論の前提（文章から独自の判断が出るか）が、確かめられていない。資料が「次に行うべき実験」の 1 番目に挙げたもの
資料との関係	総合報告書の実験 G。G の 540 リクエスト（文章と数字の両方）の結果を、そのまま対照に使う
根拠	G の点数は S&P500 の直近 1 か月のリターンと順位相関 +0.77、VIX と −0.59。文章だけにすれば、なぞる数字がない
変える要素	渡す情報：(G) 文章＋数字（既存）、(T) 文章だけ（日付、レポートの公表日、要約、主なリスク）、(N) 数字だけ（G の市場の数字とセクターの指標。レポートなし）
固定する要素	問い（リスク 7 種類、セクター 11 個）、答えの形（1〜5 の数字 1 文字）、システムプロンプト、gpt-4o-mini、温度 0 で確率を読む（G と同じ）、30 か月
対照群	(G)、(N)
データと期間	30 か月。文章は G のプロンプトに入っていたもの（レポートの読み取りの結果は今の DB にないため、G の結果のファイルから取り出す）
評価指標	点数（確率で重み付けた平均）の月ごとの散らばり、点数と S&P500 の直近 1 か月のリターン・VIX の順位相関、セクターの点数と翌月のセクター ETF の超過リターンの月ごとの順位相関（IC）、リスクの種類の符号の的中率
支持・棄却の条件	**主な検定**：(T) のセクターの IC の 30 か月の平均の t 値（両側）。**なぞりの判定**：(T) の市場の点数と S&P500 の直近 1 か月のリターンの順位相関（30 か月）が、0 との差で有意でなく（$p \geq 0.05$）、かつ (G) の値（+0.77）より有意に小さい（Fisher の z、$p < 0.05$）なら「なぞりは消えた」。なぞりが消え、IC が正で $p < 0.05$ なら「文章から当たる判断が出る」を支持。なぞりが消えて IC が有意でなければ「なぞりは消えるが、当たることは確かめられない」
実装と再現の手順	`experiments/H05_text_vs_numbers/run.py`。回答は JSONL で保存
想定される失敗	月次レポートは世界全体の見通しで、米国のセクターにほとんど触れない（資料：読み取れたのは最も多い情報技術で 39 本中 10 本）。(T) のセクターの答えが、ほぼ毎月同じになる可能性がある
API の費用	見込み：2 条件 × 540 リクエスト、入力約 700 トークン、出力 1 トークン（確率つき）。約 0.1〜0.2 ドル

実験前の予想

(T) では市場の点数が直近のリターンに沿わなくなる。しかし月ごとの変化は小さく、セクターの IC は 0 と区別できない。

第 11 章

H06：決算発表文から LLM が取り出す情報

仮説

LLM に銘柄の数字（リターン、指標）を渡さず、各社の決算発表文（8-K の Item 2.02 に付く EX-99.1）だけを読ませて、業績の見通し・ガイダンスの変更・経営陣の語調を −2〜+2 の点数で取り出させる。この点数を、あらかじめ決めた等しい重みで足した合成点数は、翌月のリターンと正の順位相関を持ち、同じ時点で手に入る数値（売上と利益の前年比、直近 1 か月のリターン、12–1 か月のモメンタム）を統制しても、その相関が残る。

これは依頼文のテーマ A の「LLM による情報抽出と、統計モデルによる数値化の分業」を、そのまま形にしたものである。LLM には数字を予想させず、文章からの判断だけをさせる。点数を期待リターンに直すのは、統計（Grinold の式とウォークフォワードの IC）である。

項目	内容
仮説 ID・名称	H06　銘柄ごとの決算発表文から LLM が情報を取り出し、統計で数値化する
解決したい問題	月次レポートは全銘柄で同じ文章なので、銘柄の差を作れない（資料）。銘柄ごとの文章が必要
資料との関係	総合報告書の次に行うこと 5（銘柄ごとの文章の情報源）、先行研究（Lopez-Lira と Tang、Kim ほか 2024、Anic ほか 2025）。実験 D〜F は数字を渡したので、文章だけを渡すのは新しい
根拠	決算発表後の値動きは、発表の内容に沿って続く傾向（PEAD）が知られている。数字の驚きは数値でも測れるが、ガイダンスや語調は文章にしかない
変える要素	ビューの元：(L) 決算発表文の合成点数。対照：(S) 同じ時点の数値の指標（売上と利益の前年比、モメンタム、直近 1 か月）、(N) 実行 1 の数値予想、(0) ビューなし
固定する要素	gpt-4o-mini、温度 0、出力の形（JSON の構造化出力）、読む長さ（HTML のタグと表の罫線を取り除いた本文の先頭の約 15,000 文字）、点数の合成の重み（等しい重み、学習しない）、ポートフォリオの作り方（第 5 章）
対照群	(S)、(N)、(0)
データと期間	決算発表文：SEC EDGAR から、提出日が 2023-11-01〜2026-08-30 のもの。判断日ごとに、提出日が判断日より前で 120 日以内の最新の 1 本を使う。gpt-4o-mini の知識の期限（2023 年 10 月）より後の文章だけである
評価指標	IC と t 値（全銘柄、発表から 35 日以内の銘柄）、Fama–MacBeth の係数、点数と直近リターンの相関（なぞりの確認）、ポートフォリオの指標
支持・棄却の条件	**主な検定**：判断日ごとに、翌月のリターンの順位を、合成点数の順位と、売上の前年比・利益の前年比・直近 1 か月のリターン・12–1 か月のモメンタムの順位で回帰し（Fama–MacBeth）、合成点数の係数の平均の t 値（両側）。正で $p < 0.05$ なら支持、有意でなければ「支持されなかった」（信頼区間も示す）。副次：合成点数の IC の t、発表から 35 日以内の銘柄だけでの IC
実装と再現の手順	`experiments/H06_earnings_text/`。取得（`fetch.py`）、読み取り（`score.py`）、評価（`evaluate.py`）の 3 段。取得した文章は `data/` の下（Git の外）に置き、点数と条件は実験のフォルダに保存する。SEC へのリクエストは毎秒 10 回以下に抑え、連絡先は実行時の環境変数で渡す

項目	内容
想定される失敗	発表文が EX-99.1 でない会社がある（ファイル名で見つける規則が合わない）。文章が長く、先頭だけでは見通しの部分が切れる。点数がほとんどの会社で同じ（例：語調は毎回「やや前向き」）になり、銘柄の差が出ない。30 か月では小さな IC を検出できない
API の費用	見込み：約 5,500 本 × 入力約 4,500 トークン ≈ 2,500 万トークンで約 3.7 ドル、出力約 0.5 ドル。合計約 4〜5 ドル。最初に 30 本で動作を確かめる

実験前の予想

点数は直近のリターンとはあまり相関しない（なぞりは起きにくい）。IC は小さな正（0.01〜0.03）で、30 か月では $t < 2$ にとどまる可能性が高い。発表から日が浅い銘柄だけでは IC が大きくなる。

第 12 章

H07：フィードバックの LLM

仮説

LLM に自分の過去の予想の外れを渡すと、予想の水準の偏り（楽観）は小さくなる。しかし、銘柄の順位の当たり具合（IC）は上がらない。銘柄ごとの前月の外れを渡すと、外れを追いかけて予想を大きく動かす（過剰な反応）。予想する役とフィードバックを受けて直す役を分けると、予想は小さく縮むが、順位は変わらない。

既存のコードには、フィードバックの LLM がない。そこで、何を渡すと何が改善するはずかを先に決め、小さな規模で比べる。

条件	渡すもの	改善するはずのもの（理由）
F0 フィードバックなし	実行 1 と同じプロンプト（実行 1 の回答をそのまま使う）。雑音の目安として、同じプロンプトでもう 1 回聞く（F0′）	—
F1 外れのみ	F0 ＋「先月のあなたの予想は x、実際は y」（その銘柄）	銘柄ごとの癖が直るはず。ただし 1 か月の外れは雑音が大きい
F2 較正の情報	F0 ＋判断日までの全銘柄の成績の要約（予想の平均と実際の平均、順位相関、入力との相関）	水準の偏りと、なぞりの自覚
F3 役の分離	別の呼び出しで「見直す役」に、F0 の予想の平均、入力、F2 と同じ要約を渡し、直した予想を答えさせる	予想する役の癖を、別の役が割り引く

「BL を適用した後の比率やリスクを渡す」条件は、この規模では行わない。理由は、相対ビューと $\Omega \propto \Sigma$ のもとでは水準の偏りが比率に効かない（H03、H04 で確かめる）ので、比率の情報で予想の何が良くなるべきかを、事前に決められないためである。結果の報告書で、この判断を見直す。

項目	**内容**
仮説 ID・名称	H07　フィードバックの LLM：何を渡すと何が変わるか
解決したい問題	フィードバックの LLM は未実装。フィードバックを足すことで、過学習、自己強化、不要な予想の変更が起きないかも見る
資料との関係	総合報告書の段階 2（未着手）。実験 F（会話にすると方針が固まり、なぞりが強まった）
根拠	予想の外れの情報は判断日の時点で手に入る（判断日 d_{i-1} の予想の結果は d_i で確定する）ので、未来の情報を使わずに渡せる
変える要素	F0〜F3 の 4 条件（上の表）
固定する要素	gpt-4o-mini、温度 1.0、1 リクエストで 30 回答、F0 と同じ入力（判断月の日次リターンの列と会社情報）、銘柄、期間
対照群	F0（実行 1）。雑音の目安として F0′
データと期間	最初の判断日（2024-03-28）に実行 1 の予想がある銘柄から、種 0 で 100 銘柄を選ぶ（その後の在籍を条件にすると未来の情報を使うので、条件にしない）。指数から外れた銘柄は、その月から除き、補わない。30 か月（フィードバックは 2 か月目から）
評価指標	IC、較正の傾き、水準の偏り、入力との相関、F0 からの予想の変化の大きさ（F0′ と F0 の差に対する倍率）、回答の標準偏差

項目	内容
支持・棄却の条件	**主な検定**：F2 と F0 の月ごとの IC の差の対応のある t 検定（両側）。正で $p < 0.05$ なら棄却（フィードバックで IC が上がる）。有意でなく、差の 95% 信頼区間の上限が 0.03 未満なら支持、上限が 0.03 以上なら「証拠が不足」。副次：水準の偏りの絶対値が F0 の半分以下になるか（F2、F3）、F1 の予想の変化が雑音の目安の 2 倍を超えるか
実装と再現の手順	`experiments/H07_feedback_llm/run.py`。判断日の順に 1 か月ずつ実行する。全回答、プロンプト、トークン数を JSONL で保存
想定される失敗	100 銘柄 × 29 か月では IC の推定の誤差が大きい（月ごとの IC の標準偏差は、銘柄数が少ないぶん大きくなる）
API の費用	見込み：4 条件（F0′、F1、F2、F3）× 約 2,900 リクエスト、入力約 350 トークン、出力 30 回答 × 約 8 トークン。約 2〜3 ドル

実験前の予想

F2 と F3 は水準の偏りを小さくする。IC は F0 と区別できない。F1 は予想を雑音の目安より大きく動かすが、IC は上がらない。

第 13 章

リスクと限界

リスク・限界	内容と対処
評価の期間が短い	30 か月では、IC が 0.07 未満の効果は検出できない。「支持されなかった」と「効果がない」を区別して書く
多重比較	仮説が 7 つ、各仮説に複数の変種がある。主な検定を仮説ごとに 1 つに決め、Holm の補正をかける。副次の結果は参考として扱う
相場の局面の偏り	評価期間は上昇相場が中心で、下落相場の挙動は分からない
生存者バイアス	データの取れない 28 銘柄の除外（資料）は全戦略に共通。成績の水準には偏りが残る
LLM の乱数	温度 1.0 の実験は、同じ条件でも回答が変わる。全回答と条件を保存し、「保存した回答から同じ結果を計算し直せる」ことを再現性とする（資料の決まりと同じ）
LLM の知識の期限	gpt-4o-mini（2023 年 10 月まで）だけを予想に使う。決算発表文には社名が入るが、評価期間の出来事はモデルが知らない
決算発表文の取得	SEC の利用の決まり（毎秒 10 回以下、連絡先の明記）を守る。取得した文章は Git に入れない
コードのレビュー	新しいモデル（gpt-5.x など）にコードを読ませるのは、レビューの補助だけにする。その指摘も、自分で確かめてから使う
費用	見込みの合計は 10 ドル前後（総合報告書の予算の上限 5 万円の範囲）。各実験の前に 30 件程度で動作を確かめる

結果の報告で守ること

- 仮説ごとの結論は「支持された」「支持されなかった」「結論を出すには証拠が不足している」「実験未実施」のどれかで書く。
- 成績が改善しなかった場合も、そのまま記録する。対照群との差を数字で書く。
- 実行できなかった部分は、実行した部分と分けて書き、推測で埋めない。