情報工学工房　プロジェクト総合報告書 2

LLM の数値予想から、決算発表文の読み取りへ

仮説の検証、方針の見直し、文献調査、
新しいアーキテクチャと事前登録した実験の記録

電気通信大学　情報理工学域 III 類

小嶋一輝

2026 年 10 月 18 日版

総合報告書 1（2026 年 10 月 13 日版）の続き。対象の期間は 2026 年 10 月 14 日から 18 日。

概要

本書は、総合報告書 1（2026 年 10 月 13 日版）の後、10 月 14 日から 18 日までに行った作業をまとめたものである。総合報告書 1 は、元論文（Lee ほか、arXiv:2504.14345）の計算を再現し、問題点を確かめ、「gpt-4o-mini の答えは、渡した数字の中の直近の値動きに沿う」ことを 7 つの実験で示した。本書の作業は 4 つに分かれる。

1. **仮説の検証（H01〜H07）**：総合報告書 1 の課題を 7 つの仮説に分け、事前に決めた指標と判定の基準で検証した。結果は、別の 2 つのモデル（Codex と Gemini）にも読ませて確かめた。
2. **方針の見直しと文献調査**：次に何をするかの方針を、Claude・GPT・Gemini の 3 者に独立に書かせて比べた。先行研究は、Gemini Deep Research を加えた 4 者で調べ、挙がった文献をすべて機械的に照合した。
3. **新しいアーキテクチャ**：LLM の役割を「決算発表文から判断を読み取ること」に絞り、決算発表 1 本を単位にする評価の仕組み（DB の表、時刻の規則、5 つの点数の付け方）を設計して実装した。2015〜2026 年の決算発表 28,447 本を取得し、先読みのない ChronoGPT の環境も作った。
4. **事前登録した実験（実験 2）**：評価の手順と判定の基準を、株価の反応を計算する前に文書とコードで固定し、1 回だけ実行した。

本書の主な結論

- **LLM に数値のリターンを予想させる構成には、価値がない**。予想の 81% は渡した月の値動きの写しで、写しを除いた固有の IC は -0.004 だった。BLM の計算は、当たり具合で Ω を較正すれば設計どおりに動くが、成績は予想を並べ替えたビューと区別できなかった（H02、H04）。
- **LLM が決算発表文から読み取った点数は、発表への株価の反応をはっきり説明する（実験 2、事前登録した検定で支持）**。点数が 1 標準偏差高いと、発表をはさむ 2 取引日の超過リターンは $+1.20\%$ 高い（t 9.4、置換の対照で $p = 0.001$）。辞書・FinBERT・TF-IDF・数値の驚きを統制しても変わらず、効果は FinBERT や TF-IDF の約 3 倍だった。
- **ただし、取引にも BLM のビューにも使えない**。反応は発表の 2 日のうちに出尽くし、その後のドリフトは有意でない。点数が手に入るときには、株価はすでに動いている。
- **先読みのない小さなモデル（ChronoGPT）は、質問に答えさせる使い方ではほとんど読み取れない**（同じ標本で $+0.04\%$）。
- 方法の面では、(1) 3 者の方針の比較、(2) 文献の機械的な照合（どのモデルの文献にも誤りがあった）、(3) 事前登録、の 3 つが、結論の確かさを支えた。

本書の数値は、とくに断りがなければ、リポジトリのブランチ `feature/earnings-events`（実験 2）と `research/llm-blm-results-report`（H01〜H07）の結果のファイルから取った。詳しい報告は『LLM-BLM 実験結果レポート』（H01〜H07）と『LLM-BLM 実験 2』にある。

目次

概要 1

第 I 部　背景 5

第 1 章　総合報告書 1 の後に残っていた問い 6
1.1　作業の流れ 6
1.2　本書の読み方 6

第 II 部　仮説の検証（H01〜H07） 7

第 2 章　仮説と方法 8

第 3 章　結果 9
3.1　H01：計算の再現 9
3.2　H02：LLM の数値予想は、入力の写し 9
3.3　H03：相対ビューでも、ベータへの傾きは消えない 10
3.4　H04：較正した BLM は設計どおりに動くが、成績は偶然と区別できない 10
3.5　H05：文章だけを渡すと、なぞりが消える 11
3.6　H06：決算発表文の点数は、月次の検定では有意にならない 11
3.7　H07：フィードバックで予想は良くならず、強気に寄る 12
3.8　判定のまとめ 13

第 4 章　別のモデルによる確認 14

第 III 部　方針の見直しと文献調査 15

第 5 章　3 者の方針の比較 16
5.1　方法 16
5.2　3 者が一致したこと 16
5.3　意見が分かれたこと 16

第 6 章　文献調査 17
6.1　方法：4 者で調べ、機械的に照合する 17
6.2　方針を変えた発見 17
6.3　4 者が一致した判断 18

第 7 章　統合した方針 19

第 IV 部　新しいアーキテクチャ 20

第 8 章　設計 21
8.1　ディレクトリ 21
8.2　DB の表 22
8.3　時刻の規則 22

第 9 章　データと点数 24
9.1　決算発表の取得 24
9.2　5 つの点数の付け方 24
9.3　ChronoGPT の環境 24

第 V 部　実験 2：事前登録したイベントの評価 26

第 10 章　事前登録 27

第 11 章　結果 28

第 12 章　考察 30
12.1　LLM は読めるが、儲けには使えない 30
12.2　BLM にとっての意味 30
12.3　限界 30

第 VI 部　関連の検討 31

第 13 章　共分散のノイズ除去（X01） 32

第 14 章　道具と計算環境 34
14.1　外部のモデルと連携する道具 34
14.2　計算の時間と外注の検討 34

第 VII 部　まとめ 35

第 15 章　課題と今後の計画 36
15.1　今の課題 36
15.2　次の段階の問い 36
15.3　前向きの再現は、12 月上旬に結果が出る 37
15.4　次の実験 37
15.5　スケジュール 38
15.6　やらないこと 39
15.7　リスクと未解決の問い 39

第 16 章　結論 40

第 VIII 部　付録 41

付録 A　ブランチとコミット 42

付録 B　資料の一覧 43

参考文献 44

第Ⅰ部

背景

第 1 章

総合報告書 1 の後に残っていた問い

総合報告書 1 の結論は、次の 3 つだった。

- 元論文の計算では、BLM が LLM の予想を中央値で 99.9% 採用し、市場の均衡がほとんど使われていない。最適化（SLSQP）も途中で止まっている。
- gpt-4o-mini の予想は、渡した月の平均リターンとの相関が 0.89 で、翌月の実際のリターンとの順位相関は +0.05 にとどまる。
- 入力や質問の形を変えた 7 つの実験でも、LLM は渡した数字の中の直近の値動きをなぞった。数字の処理は統計モデルに任せ、LLM には文章の解釈だけをさせる構成を、次に確かめるべきである。

残っていた問いは、(a) LLM の予想に「なぞり」以外の情報が少しでもあるか、(b) BLM の設計（q、P、Ω）をどう直せばよいか、(c) 文章を読ませれば違うか、(d) フィードバックで良くなるか、の 4 つである。

1.1　作業の流れ

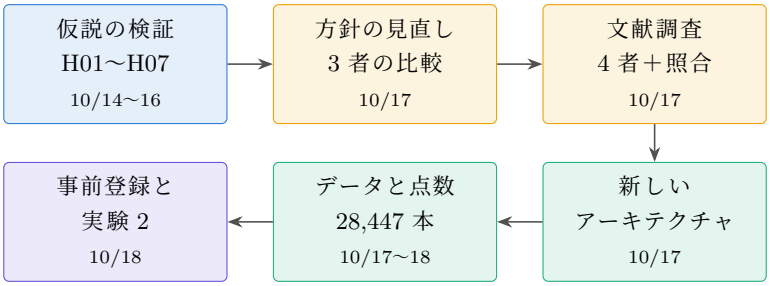


図1.1: 本書の作業の流れ。

1.2　本書の読み方

- 第 II 部は、『実験結果レポート』の要約である。数値と判定はそのレポートと同じで、詳細はそちらにある。
- 第 III 部は、方針と文献調査の記録である。元の文書は、リポジトリの外の `工房/LLM-BLM 考察用/` にある。
- 第 IV・V 部は、新しいアーキテクチャと実験 2 である。『実験 2』のレポートより、設計と実装の説明を詳しくした。

第 II 部

仮説の検証（H01〜H07）

第 2 章

仮説と方法

総合報告書 1 の課題を、7 つの仮説に分けた（『LLM-BLM 実験仮説』）。仮説ごとに Git のブランチを分け、指標・判定の基準・使うデータを、実行の前に決めた。

表2.1: 7 つの仮説。

ID	内容	API
H01	現行の計算の再現と整合性	なし
H02	LLM の数値予想は、入力の写しと統計モデルを超える情報を持つか	なし
H03	ビューの形（絶対・相対・順位）で、ベータへの傾きが消えるか	なし
H04	Ω：回答の分散、過去の当たり具合による較正、縮小、置換による対照	なし
H05	市場とセクターを、文章だけ・数字だけで聞く	1,080 回
H06	決算発表文から LLM が判断を取り出し、統計で数値化する	5,429 回
H07	過去の成績をフィードバックする LLM	約 11,600 回

共通の条件は次のとおりである。

- 評価期間は 2024 年 3 月末〜2026 年 8 月末の判断日 30 か月。gpt-4o-mini の知識の期限（2023 年 10 月）より後。
- 対象は各時点の S&P500 の構成銘柄（月平均 489 銘柄）。
- 比率の計算は、TE の上限つきの平均分散最適化（Clarabel）。売買のコストは片道 0.1%。
- API の費用は合計 6.72 ドル（18,237 リクエスト）。

第 3 章

結果

3.1　H01：計算の再現

資料の数値はほぼすべて再現できた。ただし、元論文の最適化（SciPy の SLSQP）は、入力のごく小さな違いで止まる位置が変わり、比率を再現できなかった（図 3.1）。

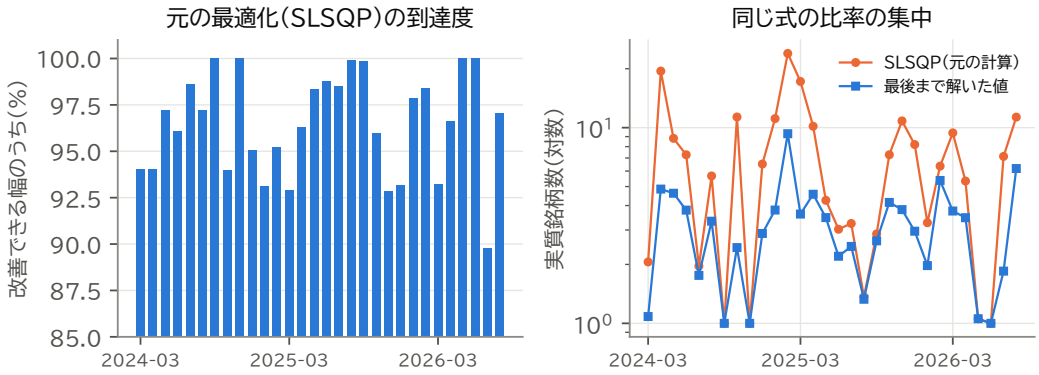


図3.1: 左：元の最適化が、改善できる幅の何% まで進んで止まったか。右：同じ目的関数の比率の集中（SLSQP の結果と、最後まで解いた結果）。

3.2　H02：LLM の数値予想は、入力の写し

LLM の予想の 81% は、渡した月の平均と散らばりの直線の関数で説明できた。写しを除いた LLM に固有の部分の IC は −0.004（95% 区間 −0.036〜+0.027）。LLM と同じ当たり具合（IC +0.05）は、「先月の平均リターン」をそのまま使っても得られる（図 3.2）。**支持された**（固有の予測力は、あっても IC 0.03 未満）。

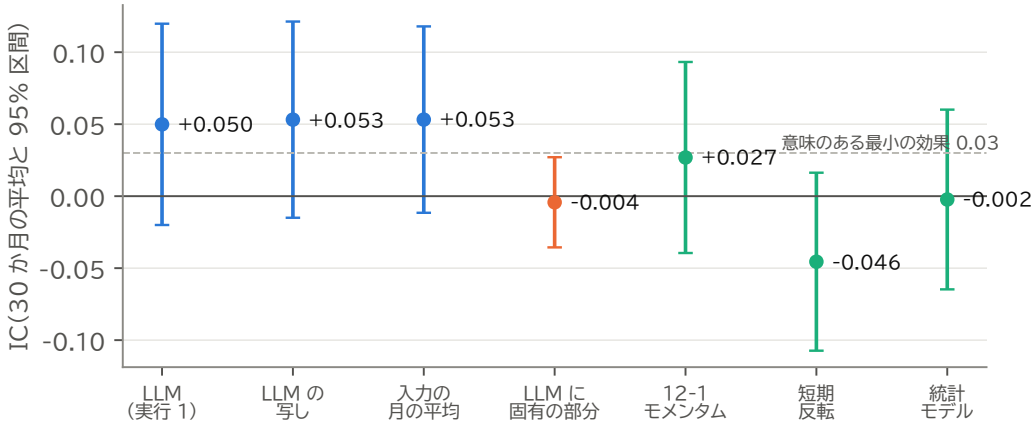


図3.2: 予想ごとの IC（30 か月の平均と 95% 区間）。

3.3 H03：相対ビューでも、ベータへの傾きは消えない

市場が上がった月には高ベータの銘柄が上がり、LLM がそれをなぞるので、銘柄の間の予想の差そのものがベータに傾く。相対ビューにしても、能動ベータは 0.94 倍にしか減らなかった（図 3.3）。**支持されなかった**。

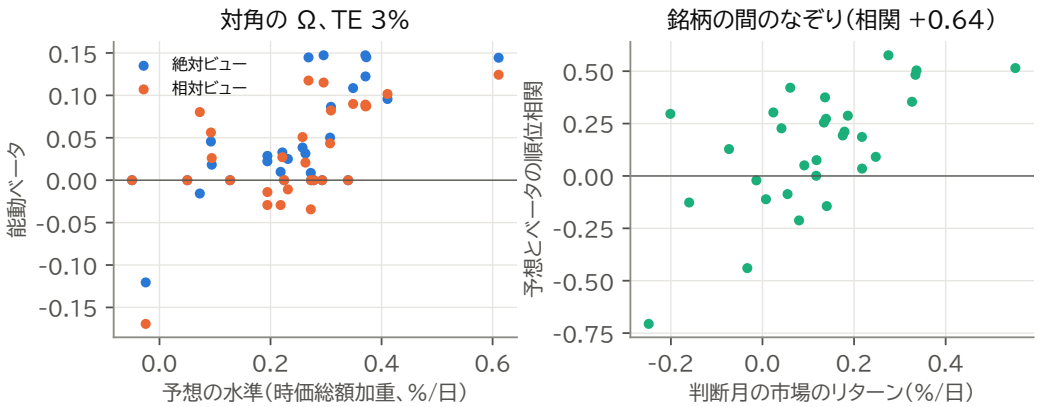


図3.3: 左：予想の水準と能動ベータ（30 か月）。右：判断日ごとの「LLM の予想と銘柄のベータの順位相関」と、判断月の市場のリターン。

3.4 H04：較正した BLM は設計どおりに動くが、成績は偶然と区別できない

$\Omega \propto \Sigma$ とし、採用率を判断日より前の較正の傾き（推定の誤差で縮めたもの）にすると、BLM は設計どおりに動いた。採用率は設定どおり、比率は時価総額加重を少し動かす形（実質 47 銘柄、実績の TE 4.2%）になった。しかし成績（コスト控除後年率 +0.53%）は、予想を銘柄の間で並べ替えたビュー 200 回と区別できない（片側 $p = 0.104$。セクターの中だけで並べ替える厳しい対照では 0.38）（図 3.4）。回答のばらつきは、誤差の大きさとしては確信が強すぎて使えない（外れの 2 乗の約 8 分の 1）が、外れやすさの順番の手がかりにはなった（偏順位相関 +0.17）。

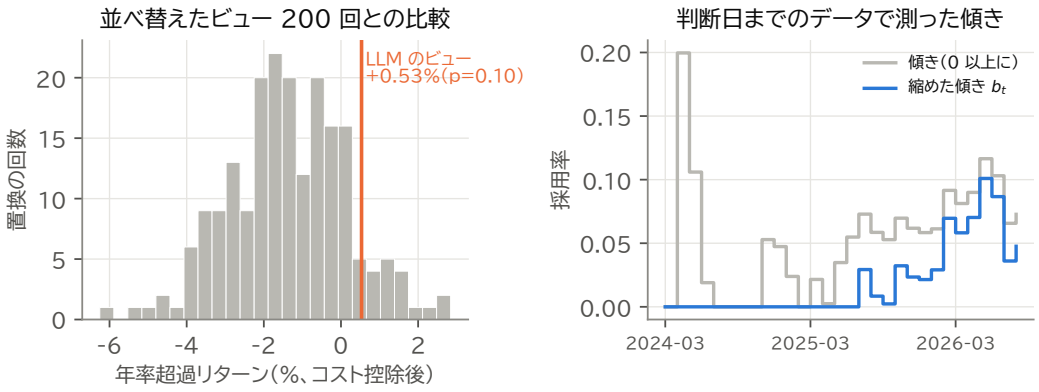


図3.4: 左：並べ替えたビュー 200 回の超過リターンの分布と、実際の LLM のビュー。右：判断日までのデータで測った較正の傾き（灰）と、推定の誤差で縮めた値（青）。

3.5　H05：文章だけを渡すと、なぞりが消える

月次レポートの文章だけを渡すと、市場の点数と直近 1 か月のリターンの順位相関が +0.77 から +0.05 に下がった（図 3.5）。ただし、セクターの判断が当たるかは、30 か月では確かめられなかった（IC +0.06、t 0.72）。

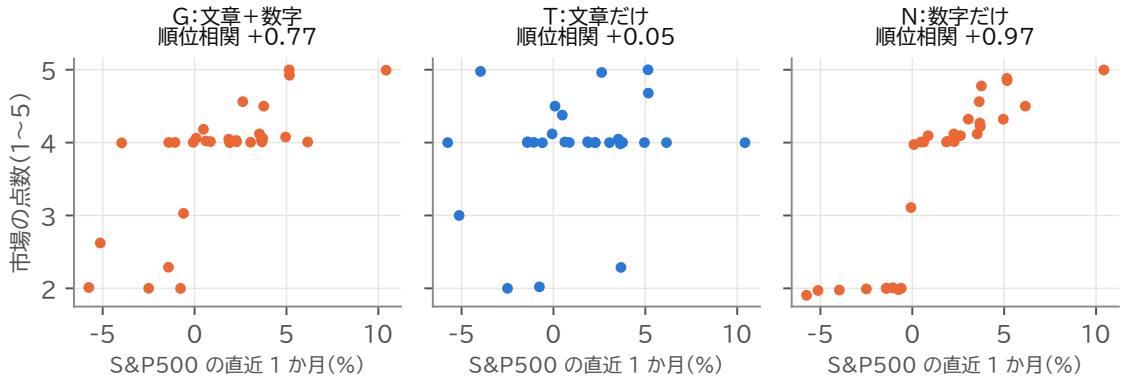


図3.5: 市場の点数と、S&P500 の直近 1 か月のリターン（30 か月）。左から、数字と文章（G）、文章だけ（T）、数字だけ（N）。

3.6　H06：決算発表文の点数は、月次の検定では有意にならない

決算発表文 5,429 本を gpt-4o-mini に読ませた点数は、直近の値動きをなぞらず（相関 +0.08）、業績の伸びに沿った（売上の前年比と +0.41）。しかし、翌月のリターンに対する事前に決めた検定（数値を統制した Fama–MacBeth の係数）は t 0.97 で、**支持されなかった**。月ごとの IC の自己相関を考慮した Newey–West の t では、IC +0.033 が t 2.32 になり、探索的には有意だった（図 3.6）。

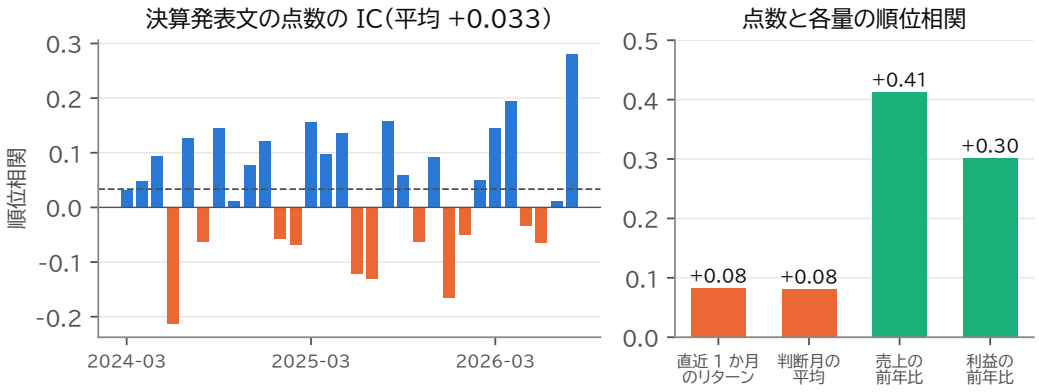


図3.6: 左：合成点数の月ごとの IC。右：合成点数と各量の順位相関（30 か月の平均）。

3.7　H07：フィードバックで予想は良くならず、強気に寄る

自分の過去の成績の要約を渡しても IC は上がらず（差 +0.011、t 0.76）、楽観の偏りはかえって日次 +0.12% から +0.29% に強まった。どの月も一律に約 +0.17%/日上振れしており、要約を見せること自体が強気の目安として働いたと考えられる（図 3.7）。**証拠不足**。

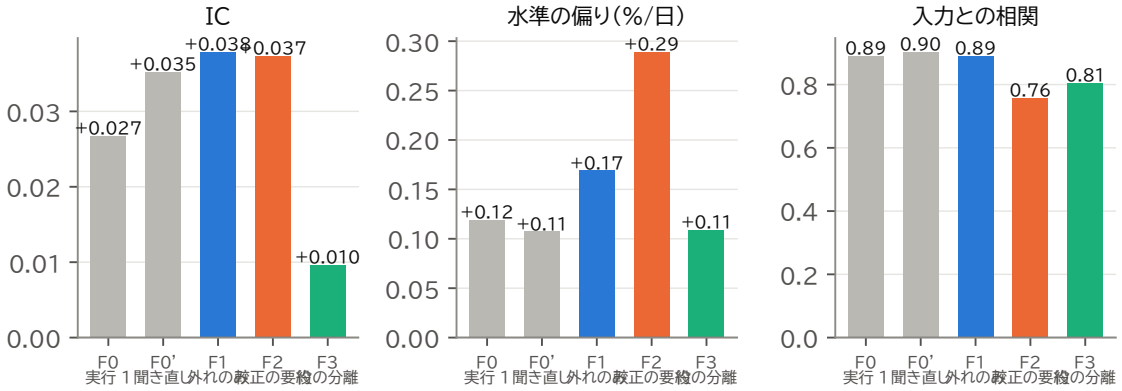


図3.7: 条件ごとの IC、水準の偏り、入力との相関。

3.8　判定のまとめ

表3.1: 仮説ごとの判定（『実験結果レポート』の表と同じ）。

ID	判定	主な結果
H01	整合	式は一致。元の SLSQP は再現できない
H02	支持	LLM に固有の IC -0.004
H03	支持されず	相対ビューでも能動ベータは 0.94 倍
H04	支持（(1) は棄却）	置換の中で片側 $p = 0.104$。ばらつきは大きさに使えない
H05	前半は支持	なぞり $+0.77 \to +0.05$。当たるかは証拠不足
H06	支持されず	数値を統制した係数 t 0.97（Newey–West の IC は t 2.32、探索的）
H07	証拠不足	IC の差 $+0.011$。楽観の偏りは 2.4 倍

Holm の補正の後に 5% で有意なのは H03 だけだった。**「LLM のビューに予測力がある」という向きの主張は、どの仮説でも有意にならなかった。**

第 4 章

別のモデルによる確認

判定のメモを gpt-5.3-codex と gemini-3.1-pro-preview に読ませ、別の説明、言い過ぎ、見落としを挙げさせた。指摘は自分で確かめ、計算で確かめられるものは追加の確認を行った（結果を見た後の探索なので、判定は変えない）。

- **取り入れた**：月ごとの値の自己相関（Newey–West）、セクターの中だけで並べ替える厳しい置換の対照、H05 の温度の影響の言い過ぎの修正、H07 の楽観の原因の比較。
- **取り入れた考察**：BLM の較正は「LLM の価値を引き出す道具」ではなく「価値のないビューを無害にする安全装置」として働いた。決算発表文を、月次ではなく発表ごとのイベントとして評価すべきである（Codex の提案。これが実験 2 になった）。
- **採らなかった**：「Fama–MacBeth は銘柄の間の相関を統制しない」（誤り）、「H03 の傾きは有名企業を好む固定的な偏り」（傾きは月ごとに市場と +0.64 で動くので当たらない）など。

第 III 部

方針の見直しと文献調査

第 5 章

3 者の方針の比較

5.1　方法

同じ依頼文（前提、データの一覧、主な結果、見出しの指定）と同じ資料を、Claude・GPT（gpt-5.6、推論 high）・Gemini（gemini-3.1-pro-preview、思考 high）に渡し、互いの答えを見ずに「次に何をするか」の方針を書かせた。Claude は、ほかの 2 者の答えを読む前に書き終えた。

5.2　3 者が一致したこと

1. LLM に数値のリターンを予想させる構成は打ち切る。回答のばらつきを Ω にすることも、フィードバックもやめる。
2. LLM の役割は、決算発表文から決まった形の点数を取り出すことに絞る。
3. 評価の単位を、月次の断面から決算発表ごとのイベントに移す。
4. BLM は情報を作らない。検証を通った信号を安全に比率へ変える部分として扱う。
5. LLM を使わない文章の分析を対照に置く。

5.3　意見が分かれたこと

表5.1: 3 者の方針の違い。

論点	Claude	GPT	Gemini
期限より前の文章（2015〜2023）	匿名化し、関門つきで探索に使う	確認用にはしない	匿名化して研究の中心にする
前向きの検証	今すぐ記録を始める	主な検定にする	2 月に仕組みを作るだけ
意味のある最小の効果	IC 0.03	追加の IC 0.01	決めていない
BLM	残す	順位の戦略に勝てなければ外す	残す

GPT 案は検証の手続きが最も厳密で、イベントの時刻の監査を最初に置いた。Gemini 案は匿名化の関門が具体的だったが、「先読みを完全に排除できる」とする言い過ぎがあった。

第 6 章

文献調査

6.1　方法：4 者で調べ、機械的に照合する

8 つのテーマ（数値の予想と外挿、先読みと記憶、決算発表文と株価、イベントスタディの設計、不確実性の表現、BLM とビュー、評価の確かさ、フィードバックと偏り）について、Claude・GPT・Gemini（どちらもウェブ検索つき）と Gemini Deep Research の 4 者に独立に調べさせた。挙がった文献は、arXiv・OpenAlex・Crossref で機械的に照合した（`工房/LLM/refcheck.py`）。arXiv の番号は、題名と著者まで突き合わせた。

表6.1: 4 者の文献調査と、照合で見つかった誤り。

	文献	照合で見つかった誤り
Claude	36	H04 の結果の読み違い（照合の段階で修正）
GPT	38	著者の取り違え 2 件。方針を変えた発見の多くはここから
Gemini	15	別の論文の番号、自分で「推定」とした DOI、見つからない文献、著者が Anonymous のもの
Deep Research	17	著者の取り違え 4 件、主張の出どころの誤り、要旨にない数値、学術でない根拠

依頼の文書の誤り

4 者に渡した依頼の文書で、H04 の結果を逆に書いていた（正しくは「ばらつきは大きさには使えないが、順番の手がかりにはなった」）。GPT は添付のレポートから正しく読んだが、Gemini と Deep Research は誤った文を前提に書いた。依頼の文書に訂正を注記し、以後は依頼に書く結果を元の報告から写して確かめることにした。

6.2　方針を変えた発見

1. **決算発表文の内容は、翌朝の寄り付きで株価に完全に反映される**（Wu ほか 2025、13.8 万本）。→ 主な目的変数を「発表への反応」にし、その後のドリフトを副次にした。
2. **LLM に下流の目的（「株価の予測に使う」）を教えると、語調などの点数が目的に沿って偏る**。その改善は知識の期限より前にだけ現れる（Cao・Jiang・Xu、NBER WP 35142）。→ プロンプトに目的を書かない。今回の評価は期限より後なので、H06 のプロンプトはそのまま使った。
3. **年ごとに学習を区切った LLM が、重みつきで公開されている**（ChronoGPT-Instruct、1999〜2024 年の年ごと、1.55B、He ほか 2025）。→ 2015〜2023 年の文章は、匿名化ではなくこれで読む。

4. **総合報告書 1 が成功例として引いた Kim・Muhn・Nikolaev（2024）は、2025 年 2 月に arXiv で取り下げられていた**（データの不整合のため）。

6.3　4 者が一致した判断

- 知識の期限より前の文章は、匿名化しても確認には使えない（伏せても社名や日付が復元される。Lopez-Lira・Tang・Zhu 2025）。前回の方針で匿名化を中心にした Gemini も、文献を調べた後は「確認用にはしない」に変わった。
- LLM を使わない対照は、辞書（Loughran–McDonald）・TF-IDF の正則化回帰・FinBERT の 3 つにする。
- イベントの時刻の監査は必須である（同じ日の発表どうしの相関で検定が過大に棄却する。Kolari・Pynnönen 2010）。

第 7 章

統合した方針

3 者の方針と文献から、次の方針にまとめた。

研究の主な問い

LLM（gpt-4o-mini）が決算発表文から取り出した判断は、数値の驚きと、LLM を使わない文章の分析を超えて、発表への株価の反応を説明するか。

- **標本**：主は 2023 年 11 月以降（gpt-4o-mini が株価を知らない期間）、副は 2016〜2023 年（ChronoGPT で読む）。
- **前向きの検証はやめた**。当初は 2026 年 10 月以降の発表を記録して 2027 年 2 月に開ける案だったが、待つ期間が長すぎる。発表への反応なら過去のデータだけで評価でき、手順を先に固定（事前登録）すれば、結果を見てから方法を選ぶ余地もなくせる。（実験 2 の後に、短い期間の前向きの再現として計画に戻した。第 15 章）
- **やらないこと**：数値予想のプロンプトの工夫、新しいモデル（gpt-5.x、gemini-3.x）での予想、予想役へのフィードバック、成績を見て τ・TE・Ω を選ぶこと。

第 IV 部

新しいアーキテクチャ

第 8 章

設計

設計は、実装の前にリポジトリの 設計.md に書いた。

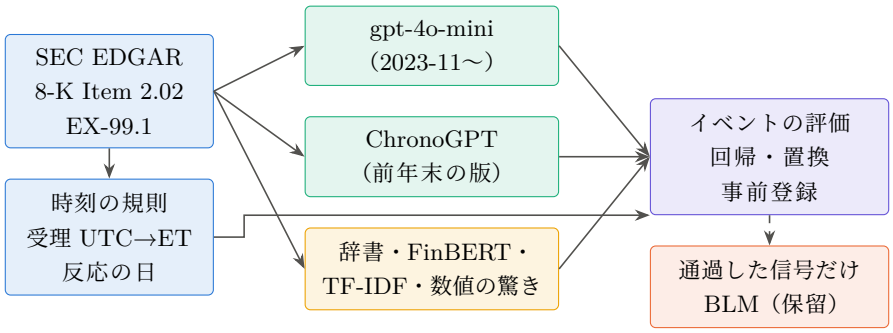


図8.1: 新しいアーキテクチャ。LLM は文章の点数を取り出す役だけを担い、価値の判定はイベントの評価で行う。

8.1 ディレクトリ

既存の reports/（月次レポート）と同じ形で、events/ と run_events.py を足した。DB の読み書きは、これまでどおり marketdb/db/ に置いた。

場所	内容
run_events.py	入口（取得、時刻、数値の驚き、点数、状態の表示）
events/edgar.py	8-K の一覧、EX-99.1 の選択、HTML から文章へ
events/timing.py	受理時刻をニューヨーク時間に直し、時間帯と反応の日を決める
events/surprise.py	SUE と売上の驚き
events/returns.py	反応の超過リターン（株価から毎回計算し、保存しない）
events/evaluate.py	発表日でまとめた標準誤差の回帰、置換の対照、Holm（numpy だけで書き、手計算と照合）
events/scorers/	点数の付け方 5 つ（第 9 章）
marketdb/db/events.py	新しい表の読み書き
experiments/E2_event_reaction/	事前登録の文書、評価のコード、結果

`tests/`	時刻、数値の驚き、DB、統計、評価のテスト（全体で 44 件）

8.2 DB の表

表8.2: 追加した表と view。

表	中身
`earnings_releases`	決算発表 1 本で 1 行。書類番号、銘柄、提出日、受理時刻（UTC と ET）、時間帯、反応の日、本文の場所とハッシュ
`release_score_runs`	点数の付け方 1 通りで 1 行。方法、モデル、設定（JSON）とそのハッシュ、結果を学習に使うか
`release_scores`	点数（付け方 × 発表 × 項目で 1 行）
`release_score_calls`	モデルを呼んだ記録（版、答え、トークン、費用、時間）
`release_surprises`	数値の驚き（SUE、売上の驚き）
`trading_days`（view）	取引日と通し番号

点数の表は、月次レポートの表（`report_runs` と `report_values`）と同じ「回 × 対象 × 項目」の形にした。設定のハッシュで付け方を区別するので、同じ設定の点数付けを途中から再開でき、設定を変えると別の付け方として記録される。本文は DB に入れない（H06 の記録には 1 行ごとに本文が入っていて 91MB になった）。

8.3 時刻の規則

- EDGAR の受理時刻（UTC）をニューヨーク時間に直す。
- 時間帯：寄り前（9:30 より前）、場中（9:30〜16:00）、引け後（16:00〜17:30）、17:30 以後。
- 反応の日：寄り前と場中はその日（取引日でなければ次の取引日）、16:00 以後は次の取引日。

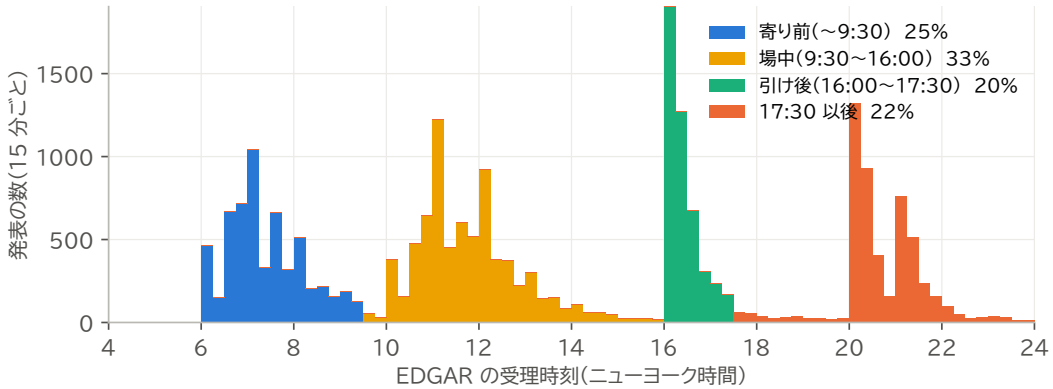


図8.2: 受理時刻の分布（23,056 本）。4 つの山が約 4 時間ずれて対になっている。

受理時刻の分布（図 8.2）には 4 つの山があり、寄り前（6〜8 時）と場中（10〜13 時）、引け後（16 時台）と 17:30 以後（20〜21 時）が、それぞれ約 4 時間ずれて対になっていた。多くの会社が、プレスリリースを配

信してから数時間後に 8-K を提出するためである。主な窓（反応の日の前日の終値から翌日の終値まで）は、どちらの場合も配信の後の値動きを含む。

第 9 章

データと点数

9.1　決算発表の取得

SEC EDGAR から、S&P500 の構成銘柄（期間中に一度でも入った 668 社）の 8-K のうち Item 2.02 を含むものを取得した。SEC の求めに従い、User-Agent に連絡先を入れ（実行時の環境変数で渡し、保存しない）、毎秒 8 回以下に抑えた。H06 の 6,209 本と点数 5,429 本は新しい表に移し、件数と費用（3.31 ドル）が記録と一致することを確かめた。

表9.1: 決算発表のデータ。

取得した 8-K（2015 年 1 月〜2026 年 8 月）	28,447
本文が取れたもの	28,108
数値の驚き（SUE）が計算できたもの	24,598
取得にかかった時間（2015〜2023 年の 22,295 本）	約 2.5 時間

9.2　5 つの点数の付け方

表9.2: 点数の付け方。時間はこの PC（GPU は RTX 5050 Laptop 8GB）での合計。

方法	中身	費用・時間
gpt-4o-mini	H06 と同じ質問。ガイダンスの変更・見通し・語調（−2〜+2）とリスクの種類	3.31 ドル（H06 で計算済み）
ChronoGPT	発表の前の年末の版。選択肢の確率を、中身のない文章での確率で割って較正	0 円（8.3 時間）
辞書	Loughran–McDonald。発表の年より後に加わった語は使わない	0 円（6 分）
FinBERT	先頭の 200 文の、肯定 − 否定の確率の平均	0 円（4.2 時間）
TF-IDF ＋リッジ	四半期ごとに、それより前に窓が閉じた発表の反応で学び直す（事前登録の後）	0 円（14 分）

9.3　ChronoGPT の環境

ChronoGPT-Instruct の 2014〜2024 年末の 11 の版を取得した（`工房/LLM/chrono/`）。

- 元の重み（fp32、7.4GB）は 8GB の GPU に載らないので、bf16（3.7GB）に変換して保存した。元のファイルのハッシュは公開値と一致した。
- 2022 年末の版でも、今の米国大統領を「Bill Clinton」と答える。指示の学習のデータが 2000 年より前の内容に限られているためで、知識を問う使い方には向かない。
- 較正しないと、良い発表にも悪い発表にもガイダンスを 9 割以上「引き下げ」と答える癖がある。中身のない文章で測った癖で割る「文脈による較正」を標準にした。
- 点数付けを速くする工夫を 2 つ入れた。選択肢の前の文章を 1 回だけ計算する、頭が同じ選択肢をまとめる。1 本 3.2 秒が 1.1 秒になり、結果は公式の計算と 10^{-7} 以下で一致した。
- 版を切り替えるとき、前の版を GPU に残したまま次を読み込むと、メモリが溢れて 4 倍遅くなった。前の版を外してから読むように直した。

第 V 部

実験 2：事前登録したイベントの評価

第 10 章

事前登録

標本 A は、H06 で翌月のリターンについて一度見た期間である。結果を見てから手順を選ぶ余地をなくすため、株価の反応を一度も計算しないうちに、次のものを 1 つのコミット（`2df746e`）に固定して GitHub にプッシュし、その後に 1 回だけ実行した。

- 事前登録の文書（`preregistration.md`）：標本、変数、検定、判定の基準、副次の分析 S1〜S4、頑健性の確認 R1〜R7、実装の細部
- 評価のコード（`run.py`）：作ったデータでだけテストしたもの
- 使う点数の番号と、その設定のハッシュ

表10.1: 主な検定の設計。

目的変数	反応の日の前日の終値から翌日の終値まで（2 取引日）の超過リターン（セクター ETF との差）。上下 1% で丸める
主な説明変数	gpt-4o-mini の合成点数（語調＋見通し＋ガイダンス、標準化）
統制	SUE、売上の驚き、辞書・FinBERT・TF-IDF の点数、発表前 21 日の超過リターン、時価総額の対数、セクターと年・四半期の固定効果
標準誤差	反応の日ごとにまとめる
置換の対照	同じ反応の日の中で点数を入れ替えて 1,000 回
判定	t 検定と置換の両方で片側 $p < 0.05$ なら「支持」

丸めとコロナの時期の影響を見るため、丸めなし・幅を変えた丸め・順位の版・コロナの月を除いた版を、頑健性の確認（判定には使わない）として事前登録に入れた。

第 11 章

結果

判定

支持。標本 A（2023 年 11 月〜2026 年 8 月、5,374 本、527 の発表日）で、gpt-4o-mini の合成点数の係数は 1 標準偏差あたり +120bp（95% 区間 +95〜+145bp、$t = 9.41$）。置換の対照の片側 $p = 0.001$（1,000 回で実際を超えたのは 0 回）。

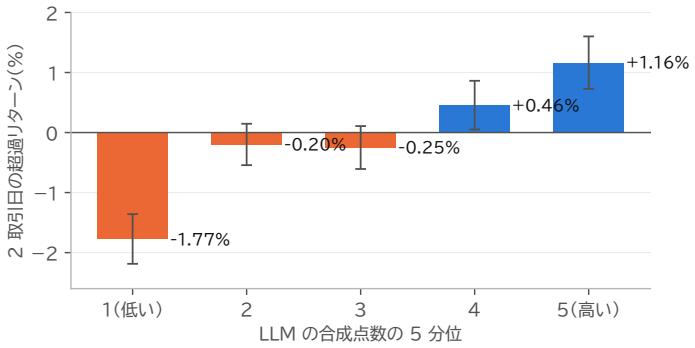


図11.1: 合成点数の 5 分位ごとの、2 取引日の超過リターン（探索の図）。

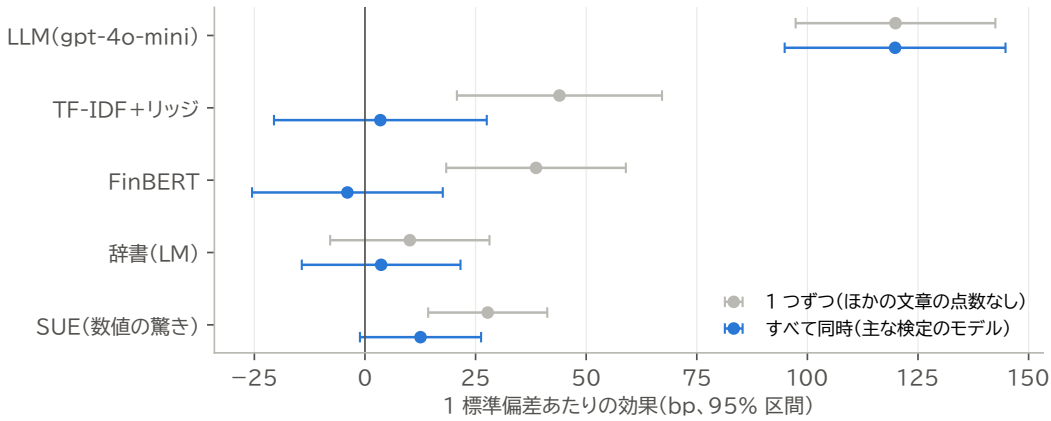


図11.2: 点数ごとの効果。灰はほかの文章の点数を入れずに 1 つずつ、青はすべて同時（探索の図）。

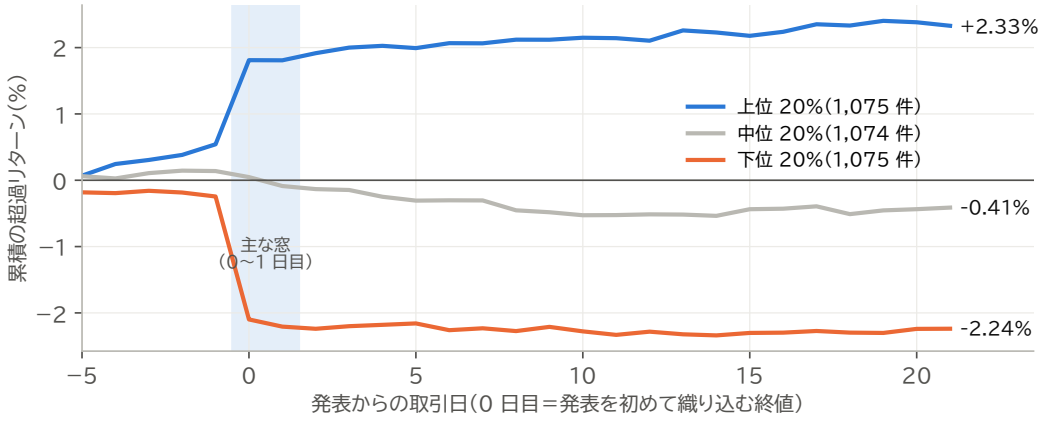


図11.3: 合成点数の上位・中位・下位 20% の累積の超過リターン（探索の図）。

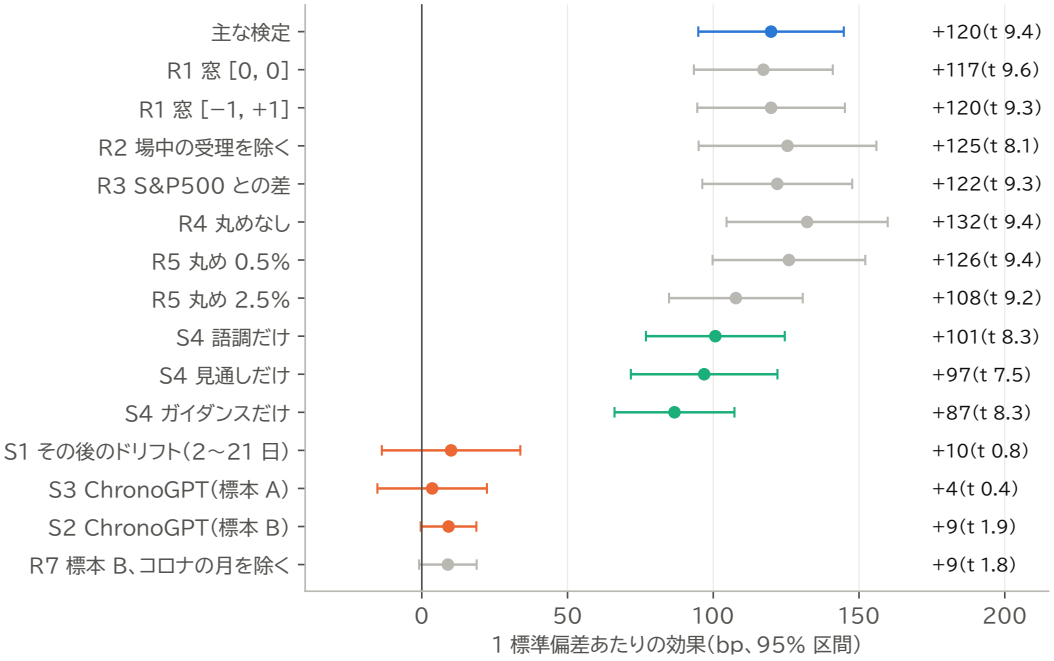


図11.4: 主な検定（青）、頑健性（灰）、語調・見通し・ガイダンスの 1 つずつ（緑）、ドリフトと ChronoGPT（橙）。

- **点数の順に反応が並ぶ**：5 分位の平均は −1.77%、−0.20%、−0.25%、+0.46%、+1.16%。
- **LLM を使わない方法の情報をほぼ含む**（図 11.2）：1 つずつなら TF-IDF（+44bp）、FinBERT（+39bp）、SUE（+28bp）も効くが、LLM と同時に入れると文章の 3 つの方法はほぼ 0 になる。LLM は 1 つずつでも同時でも +120bp。
- **反応は 2 日で出尽くす**（図 11.3）：その後の 2〜21 日目のドリフトは有意でない（S1、+10bp、t 0.8）。
- **語調・見通し・ガイダンスは、どれも単独で強く効く**（S4、+87〜+101bp）。
- **頑健**：窓、場中の受理、比べる指数、丸めの有無と幅、順位の版のどれでも、t は 7.5〜9.6（図 11.4）。
- **ChronoGPT は弱い**：標本 A で +4bp（t 0.4）、標本 B（2016〜2023 年、14,204 本）で +9bp（Holm の補正の後 $p = 0.089$）。

第 12 章

考察

12.1　LLM は読めるが、儲けには使えない

gpt-4o-mini は、決算発表文から「市場がどう受け取るか」を、辞書や FinBERT より正確に読み取れた。Siano（2025）の「LLM の測度は、辞書や LLM でない機械学習の 3 倍、発表の短い期間のリターンを説明する」と合う。一方、反応は 2 日のうちに出尽くし、点数が手に入るときには株価はすでに動いている（Wu ほか 2025 と合う）。H06 で翌月のリターンを説明できなかったことと矛盾しない。

12.2　BLM にとっての意味

BLM のビューは「これから先のリターンの見込み」なので、発表への反応を説明する点数をそのままビューにしても、価値は生まれない。総合報告書 1 からの問い「LLM のビューは BLM に追加の価値を生むか」への答えは、今の時点では「数値予想では生まない。文章の読み取りは正確だが、それが効くのは発表の瞬間だけで、月次のビューには生かせない」である。

12.3　限界

- 数値の驚きの統制が弱い（アナリストの予想がなく、前年同期との差で測った）。LLM が本文の「予想を上回った」を読んでいるなら、効果の一部は「文章から数値の驚きを読む力」である。
- 主な標本は約 3 年（527 の発表日）。
- 受理時刻は配信時刻ではない。場中の受理を除いても、窓を広げても結果は変わらなかった。
- ChronoGPT の弱さは、モデルの弱さか、質問の形の弱さか区別できない。

第 VI 部

関連の検討

第 13 章

共分散のノイズ除去（X01）

BLM の共分散 Σ は、約 460 銘柄を 252 日で推定している。銘柄の数が日数より多いので、標本共分散は逆行列がとれず、ノイズが大きい（図 13.1）。今の BLM は Ledoit–Wolf の縮小推定を使っている。『ファイナンス機械学習』（López de Prado）の Marcenko–Pastur のノイズ除去と比べた（LLM は使わない、2016〜2026 年の 127 か月）。

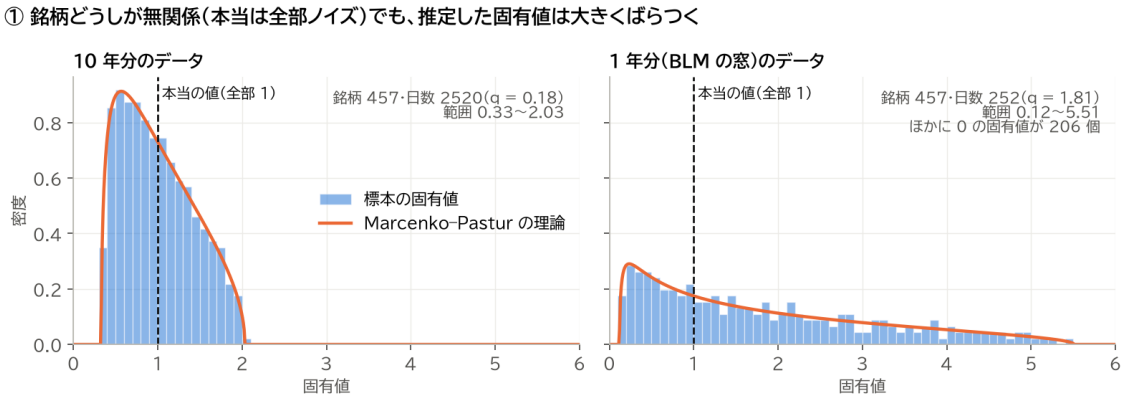


図13.1: 銘柄どうしが無関係な作ったデータでも、推定した固有値は大きくばらつく（1 年分では 0.12〜5.5 に広がり、206 個が 0）。

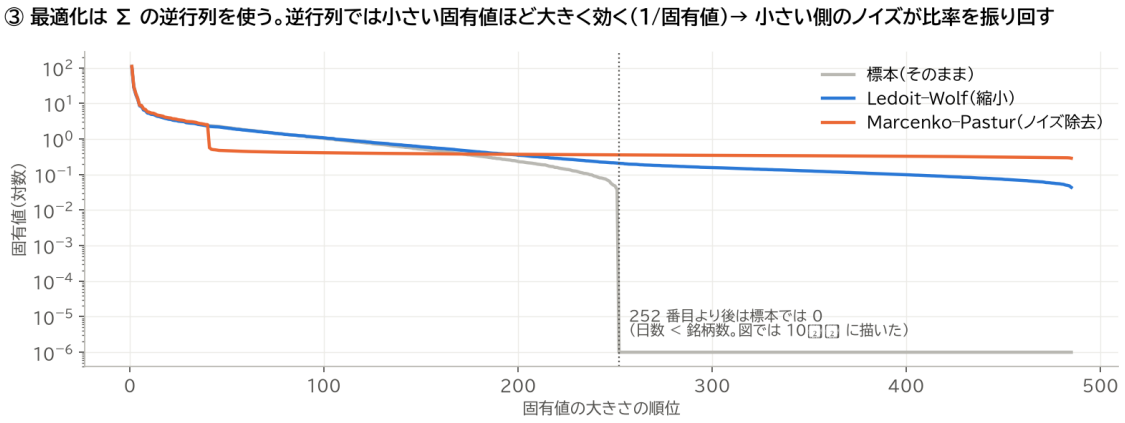


図13.2: 推定ごとの固有値。最適化は逆行列を使うので、小さい側のノイズが比率を振り回す。

表13.1: 翌月の実際のリスク（年率）。

	標本	Ledoit–Wolf（今の BLM）	Marcenko–Pastur
制約のない最小分散	14.4%	11.3%	**10.4%**
空売りなしの最小分散	10.5%	**10.5%**	10.6%
BLM の最適化（TE の上限 3%）：実際の TE	4.8%	**4.5%**	4.7%

- 制約のない最適化では、ノイズ除去がはっきり効く。
- 空売りの禁止や TE の上限があると、制約そのものがノイズによる賭けを抑えるので、差はほぼ消える。**BLM の共分散は今の Ledoit–Wolf のままでよい。**
- どの推定でも、実際の TE は上限 3% の約 1.5 倍になった。H04 の実績の TE 4.2% と合う。BLM の結果は、上限ではなく実際の TE で報告する。
- 実際の株価では、Marcenko–Pastur が信号として残す固有値が平均 42 個と多い。銘柄ごとにノイズの大きさが違い、理論の前提が成り立たないためである。

第 14 章

道具と計算環境

14.1　外部のモデルと連携する道具

同じ依頼を複数のモデルに出して比べる作業が増えたので、工房の道具を整えた。

- `LLM/ask.py`：OpenAI・Codex・Gemini・Gemini Deep Research・ローカルの LLM に質問する。ウェブ検索、PDF の添付、長い推論の裏での実行、モデルごとの答えと実行記録の保存に対応した。
- `LLM/refcheck.py`：文献の実在、題名、著者を arXiv・OpenAlex・Crossref で照合する。今回の 4 者の調査の誤りは、すべてこれで見つかった。
- スキル `llm-panel`：同じ依頼を 3 者に出して比べる手順をまとめた。

14.2　計算の時間と外注の検討

表14.1: 今回の計算（この PC）。

決算発表の取得（22,295 本）	約 2.5 時間
ChronoGPT の点数（28,108 本）	8.3 時間
FinBERT の点数（28,108 本）	4.2 時間
実験 2 の評価（TF-IDF の学習を含む）	14 分
API の費用（今回の追加分）	0 ドル（gpt-4o-mini の点数は H06 のもの）

ChronoGPT の点数付けのような GPU の作業は、RunPod や Vast.ai で GPU を時間単位で借りれば、数ドルで数倍〜10 倍速くできる見込みである。大学の RTX 3080 ×4 を SSH で使う案もある。どちらも、点数を付ける発表の一覧を書き出し、結果を DB に取り込む機能を足せば使える（やること.md の D1）。

第 VII 部

まとめ

第 15 章

課題と今後の計画

この章は、本書を GPT（gpt-5.6）と Gemini（gemini-3.1-pro-preview）に読ませ、同じ依頼で独立に立案させた計画と、Claude の下書きを比べてまとめた（`工房/LLM-BLM 考察用/今後の計画/`）。2 者が挙げた文献は、すべて実在と著者を照合した。

15.1　今の課題

1. **実験 2 を、結果を見ていない発表で再現していない**（GPT）。主な標本は約 3 年（527 の発表日）で、しかも H06 で一度見た期間である。同じ標本を統制やプロンプトを変えて分析し直しても、新しい確認にはならない。
2. **数値の驚きの統制が弱い**（3 者）。アナリストの予想がないので、LLM が文章の中の「予想を上回った」「見通しを引き上げた」という数値の情報を読んでいるだけかもしれない。
3. **発表の時刻と標本の重複が監査されていない**（3 者）。受理は配信より遅れることがあり、8-K の訂正（8-K/A）や同じ日の複数の提出も確かめていない。
4. **先読みのない比べる相手が弱い**（3 者）。ChronoGPT の弱さが、モデルの限界か、ゼロショットの使い方の限界か区別できない。
5. **発表への反応と、投資の価値がつながっていない**（3 者）。ドリフトは有意でなく、BLM のビューにする根拠がない。
6. **試す設定が増えるほど、偶然の当たりを拾う**（GPT）。主な検定、頑健性、探索を分け、試した設定をすべて記録する必要がある。

15.2　次の段階の問い

主な問い

gpt-4o-mini の点数が示した説明力（1 標準偏差あたり +120bp）は、結果を見ていない新しい発表でも再現するか。

副次の問いは、(1) ガイダンスの数値などで統制を強めても残るか、(2) 株価に触れない中立のプロンプトでも同じ点数になるか、(3) 先読みのない ChronoGPT の埋め込みは、ゼロショットや TF-IDF を超えるか、(4) 発表の後に、売買の費用を上回るドリフトが残るか、の 4 つである。

15.3　前向きの再現は、12 月上旬に結果が出る

前向きの検証は、2027 年 2 月まで待つ必要があるとして一度やめた（第 7 章）。しかし実験 2 で強い結果が出た今は、同じ標本の分析を重ねるより、新しい発表での再現のほうが価値が高い（GPT の指摘）。しかも、待つ期間は短くて済む。件数だけから見積もると（株価の反応は見ていない）、今の決算シーズン（2026 年 10 月 15 日〜11 月 30 日）だけで約 450 本・発表日 29 日がある。実験 2 の標準誤差から、120bp の効果なら片側 5% で検出できる確率は約 86%（80bp なら約 57%）で、**結果は株価がそろう 12 月上旬に出る**。

表15.1: 前向きの標本の大きさと検出力の見込み（2025 年の同じ時期の件数と、実験 2 の標準誤差から計算）。

期間	発表	発表日	標準誤差	120bp	80bp
10 月 15 日〜11 月 30 日（1 シーズン）	約 450	約 29	約 44bp	86%	57%
＋1 月 15 日〜2 月 28 日（2 シーズン）	約 950	約 75	約 30bp	99%	84%

15.4　次の実験

実験	内容
1. 前向きの再現（最優先、GPT）	**方法**：10 月下旬に、手順（実験 2 と同じ回帰・統制・判定）、対象（2026-10-15〜11-30 の受理）、開ける日を事前登録する。主な点数は H06 と同じプロンプト。 **基準**：t 検定と置換の両方で片側 $p < 0.05$ なら「再現した」。検出力が足りずに有意でないときは、「失敗」ではなく「判定不能」とする。 **費用・時間**：API 1〜3 ドル。作業 2〜3 日と、シーズンの終わりまでの待ち。 **次の判断**：再現すれば、統制の強化と仕組みの分解に進む。しなければ、実験 2 は期間に依存した結果として報告する。1〜2 月のシーズンを足すかは、今の時点で別に事前登録するかを決める（結果を見てから足すと、見ながら標本を増やすことになる）。
2. 監査と数値の統制（3 者）	**方法**：重複（8-K/A、同じ日の複数の提出）を一覧にする。受理と配信のずれを、時間帯ごとに選んだ発表で手作業で照合する。発表文からガイダンスの数値（売上・EPS の見通し）を規則で抽出し、前回の見通しとの差を統制に加える。抽出は 100 本程度を人手で確かめる。 **基準**（GPT の案）：反応の日の誤りが 5% 以下、数値の抽出の精度が 90% 以上。統制を強めても、前向きの標本で LLM の係数が残るか。既存の標本 A での分析は「探索」とする。 **費用・時間**：2〜4 週間、API は使っても 5 ドル以内。 **次の判断**：係数が大きく縮めば「文章から数値の驚きを読んだ効果」、残れば「数値以外も読んでいる」。

3. 中立のプロンプト（GPT）	**方法**：株価や予測に触れない質問を事前に固定し、前向きの標本と標本 A に付ける。 **基準**（GPT の案）：元の点数との順位相関が 0.8 以上で、前向きの標本でも係数が正で有意なら、測り方は安定とする。 **費用・時間**：API 3〜6 ドル、1 週間。
4. ChronoGPT の埋め込み＋回帰（3 者）	**方法**：最後の層（1,536 次元）を取り出し、各時点より前に窓が閉じた発表だけでリッジ回帰を学習する（He ほか 2025）。2016〜2023 年で、事前登録してから評価する。 **基準**：同じ統制の下で、TF-IDF を入れても係数が正で、二つの検定で $p < 0.05$。 **費用・時間**：GPU で約 9 時間（大学の GPU か、時間単位の借用で 10 ドル以内）。実装 1〜2 週間。 **次の判断**：成功すれば「先読みのない LLM の表現にも価値がある」。失敗しても gpt-4o-mini の結果は否定せず、小さなモデルの限界として分けて報告する。
5. ドリフトの関門（GPT）	**方法**：実際の発表日の構造で、2〜21 日目のドリフトの検出できる最小の効果を計算する。前向きの標本と合わせて評価する。 **基準**：ドリフトが二つの検定で有意で、95% 区間の下限が売買の費用を上回るときだけ、順位の戦略・等リスク・BLM を同じ実際の TE と費用で比べる。それ以外では BLM を実行しない。 **補足**：時価総額や文章の長さで分けてドリフトを探す案（Gemini）は、分けるほど偶然の当たりを拾うので、関門の外の「探索」として報告するだけにする。

15.5 スケジュール

表15.3: 残りの期間の計画。

時期	作業	判断点
10 月下旬	前向きの再現の事前登録、重複の確認、株価の更新の仕組み、片づけ（取り下げ論文の引用、古い資料）	手順を固定できたか
11 月	監査とガイダンスの数値の抽出、中立のプロンプト、ChronoGPT の埋め込みの実装、検出力の計算	抽出の精度が基準を満たすか
12 月上旬	10〜11 月の発表を取得・点数化し、株価を更新して、前向きの再現を 1 回だけ実行	再現したか（支持／支持されず／判定不能）
12 月中旬〜1 月	ChronoGPT の埋め込みの検定、統制を強めた分析、ドリフトの関門	先読みのないモデルでも読めるか。BLM に進むか
2〜3 月	関門を通れば BLM の比較。最終報告	結論を確定

費用は、API が 5〜10 ドル、GPU の借用は必要なときだけ 10 ドル以内の見込みで、これまでの約 10 ドルと合わせても予算（約 300 ドル）を大きく下回る。共分散の窓の比較（X02）は、主な分析を遅らせない範囲で行う。

15.6　やらないこと

- LLM に翌月のリターンを数値で予想させること（H02 で固有の IC が −0.004）。
- 新しいモデル（gpt-5.x、gemini-3.x）での点数付け（評価期間の株価を知っている恐れがある）。
- 同じ標本で多くのプロンプト・窓・統制を試し、最も良いものを主な結果にすること。
- 今の点数を、そのまま月次の BLM のビューにすること。
- 有料のアナリスト予想や分足の株価を前提にすること。

15.7　リスクと未解決の問い

- 知識の期限は、個々の文章や企業を覚えていないことの保証ではない。
- 無料のデータだけでは市場の予想を再現できず、「数値以外を読んだ」という主張には限界が残る。
- 前向きの標本は 1 シーズンでは小さく、効果が半分なら検出できない可能性が高い。
- API のモデルの中身が変わると、点数が再現できなくなる恐れがある。モデルの版、答え、設定、ハッシュを保存して対処する。
- 「**LLM が従来の 3 倍正確に読めるのに、なぜドリフトがないのか**」（Gemini）。市場がすでに同じ水準の読み取りを瞬時に行っているのか、別の理由なのかは未解決である。

第 16 章

結論

総合報告書 1 からの問い「LLM のビューは、Black-Litterman モデルや単純な統計に追加の価値を生むか」に、本書の作業は次のように答えた。

1. **LLM に数値のリターンを予想させても、価値はない**。予想は入力の写しで、固有の予測力は検出できず、BLM に入れても偶然と区別できない。プロンプトを工夫しても、フィードバックしても変わらなかった。
2. **LLM は、決算発表文を読む力では、従来の方法をはっきり上回る**。事前登録した検定で、発表への株価の反応を、辞書・FinBERT・TF-IDF・数値の驚きを超えて説明した（1 標準偏差あたり +1.2%、t 9.4）。
3. **しかし、その読む力は、取引や月次の BLM のビューには結びつかない**。反応は発表の 2 日で出尽くす。

LLM の価値を BLM に生かすには、「発表の後もしばらく株価に織り込まれない情報」を LLM が取り出せることを示す必要がある。今の結果は、その情報が少なくとも gpt-4o-mini の発表文の点数には見られないことを示している。

次の一歩は、実験 2 の結果を、結果を見ていない 2026 年 10〜11 月の決算発表で再現することである（12 月上旬に結果が出る）。

第 VIII 部

付録

付録 A

ブランチとコミット

表A.1: 本書の作業のブランチ（すべて GitHub にプッシュ済み。強制プッシュはしていない）。

ブランチ	内容
`research/llm-blm-hypotheses`	仮説の設計書
`experiment/H01-verification`〜`H07-feedback-llm`	仮説ごとの実験（前のブランチから順に分けた）
`research/llm-blm-results-report`	実験結果レポートと、別のモデルによる確認
`feature/earnings-events`	設計、実装、データ、X01、事前登録（`2df746e`）、実験 2 の結果と報告書

付録 B

資料の一覧

資料	中身
資料集/LLM-BLM_ 実験仮説	7 つの仮説の設計書（26 ページ）
資料集/LLM-BLM_ 実験結果レポート	H01〜H07 の結果（30 ページ）
資料集/LLM-BLM_ 実験 2/	実験 2 の報告書（18 ページ）と図
設計.md	新しいアーキテクチャの設計
やること.md	次にやることの一覧
experiments/E2_event_reaction/	事前登録、評価のコード、結果
experiments/X01_covariance_denoise/	共分散の比較と、ノイズ除去の解説
工房/LLM-BLM 考察用/設計方針/	3 者の方針と比較
工房/LLM-BLM 考察用/文献調査/	4 者の文献調査、照合の結果、比較
工房/LLM-BLM 考察用/まとめ/	文献調査と設計方針の PDF・PPTX（10 月 17 日朝の時点のもの。前向きの検証などは本書の方針で置き換えた）

参考文献

- Cao, S., Jiang, W., Xu, H. (2026). Seeing the Goal, Missing the Truth: Human Accountability for AI Bias. NBER WP 35142; arXiv:2602.09504.
- Chen, S., Green, T. C., Gulen, H., Zhou, D. (2024). What Does ChatGPT Make of Historical Stock Returns? arXiv:2409.11540.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Chronologically Consistent Large Language Models. arXiv:2502.21206.
- He, S., Lv, L., Manela, A., Wu, J. (2025). Instruction Tuning Chronologically Consistent Language Models. arXiv:2510.11677.
- Huang, A. H., Wang, H., Yang, Y. (2023). FinBERT: A Large Language Model for Extracting Information from Financial Text. Contemporary Accounting Research 40(2).
- Jagannathan, R., Ma, T. (2003). Risk Reduction in Large Portfolios: Why Imposing the Wrong Constraints Helps. Journal of Finance 58(4).
- Kim, A. G., Muhn, M., Nikolaev, V. V. (2024). Financial Statement Analysis with Large Language Models. arXiv:2407.17866（2025 年 2 月に取り下げ）.
- Kolari, J. W., Pynnönen, S. (2010). Event Study Testing with Cross-Sectional Correlation of Abnormal Returns. Review of Financial Studies 23(11).
- Lee, Y., Kim, Y., Kim, S., Lee, Y. (2025). LLM-Enhanced Black-Litterman Portfolio Optimization. arXiv:2504.14345.
- Lopez-Lira, A., Tang, Y., Zhu, M. (2025). The Memorization Problem: Can We Trust LLMs' Economic Forecasts? arXiv:2504.14765.
- López de Prado, M. (2020). Machine Learning for Asset Managers. Cambridge University Press.
- Loughran, T., McDonald, B. (2011). When Is a Liability Not a Liability? Journal of Finance 66(1).
- Siano, F. (2025). The News in Earnings Announcement Disclosures: Capturing Word Context Using LLM Methods. Management Science 71(11).
- Wu, Y., Akin, E. M., Martineau, C., Grégoire, V., Veneris, A. (2025). Extracting the Structure of Press Releases for Predicting Earnings Announcement Returns. arXiv:2509.24254.